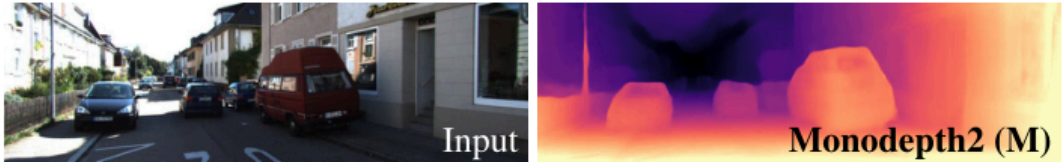
Apprentissage auto-supervisé pour la perception robotique

INF8422 : Perception robotique et intelligence spatiale

Prof. Pierre-Yves Lajoie · Polytechnique Montréal

POLYTECHNIQUE MONTRÉAL

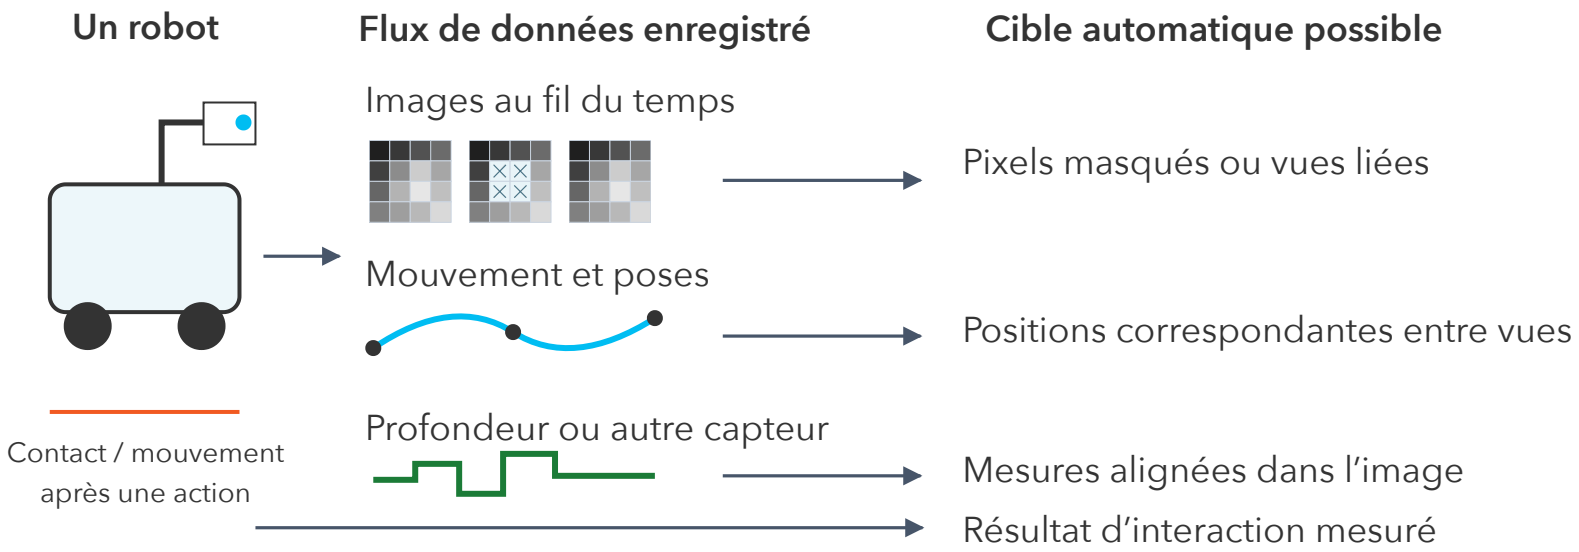


Observation caméra et profondeur estimée
Godard et al., Monodepth2, ICCV 2019, Fig. 1 (ligne supérieure)

SECTION 01

Mécanismes d’apprentissage auto-supervisé

Signaux de supervision disponibles pour un robot

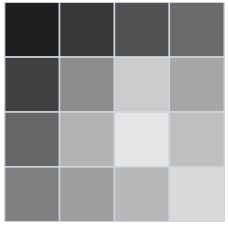


Une règle doit définir la cible

Les données enregistrées peuvent fournir un signal d'apprentissage si l'on définit une relation valide entre les observations.

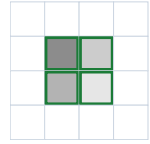
Définition de l'apprentissage auto-supervisé

L'apprentissage auto-supervisé entraîne un modèle à partir de signaux de supervision dérivés automatiquement des données elles-mêmes, sans nécessiter d'étiquettes annotées manuellement pour cette étape d'apprentissage.



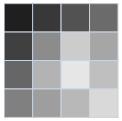
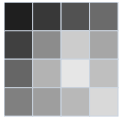
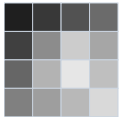
Même observation

→ Prédire une étiquette d'objet ← **« objet »** Annotation humaine

→ Prédire les pixels masqués ←  Copiée de l'observation

L'origine de la cible d'apprentissage détermine le régime de supervision.

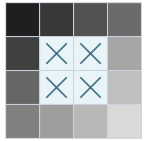
Apprentissages supervisé, auto-supervisé et semi-supervisé

Supervisé		Exemples annotés manuellement	→ Perte sur annotations
Auto-supervisé		Cibles construites automatiquement	→ Perte issue des données
Semi-supervisé		Exemples étiquetés + non étiquetés	→ Termes supervisés + non étiquetés

La fonction de perte (coût) ne suffit pas à identifier le régime

L'erreur quadratique et l'entropie croisée peuvent autant comparer des prédictions à des cibles manuelles ou automatiques.

Tâches prétextes et cibles automatiques



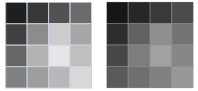
Prédiction de pixels masqués

Entrée : information visible

→

Pixels observés retirés

Cible : sélection de l'image originale



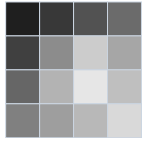
Appariement de vues liées

Entrée : deux images donc on connaît la relation

→

Une association connue

Cible : relation connue (ex: rotation, translation, chevauchement)



Prédiction directe du résultat

Entrée : observation avant l'action

→

Coût de traversée mesuré : 0.4

Cible : mesures après l'action

Une tâche prétexte construit une représentation par prédiction ou appariement.

Préentraînement et fine tuning facultatif



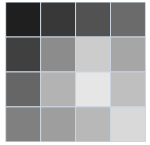
Encodeur fθ

Apprendre une représentation

Prédiction prétexte

Cible issue des données

Réutiliser l'encodeur appris



Encodeur fθ

Gelé ou adapté

Tête de tâche hβ

Catégorie d'objet, par exemple

Les étiquettes manuelles peuvent servir à l'adaptation ou à l'évaluation.

Deux choix d'adaptation

Geler l'encodeur et entraîner une tête de tâche, ou ajuster l'encodeur avec la tête.

Apprentissage direct à partir de résultats mesurés

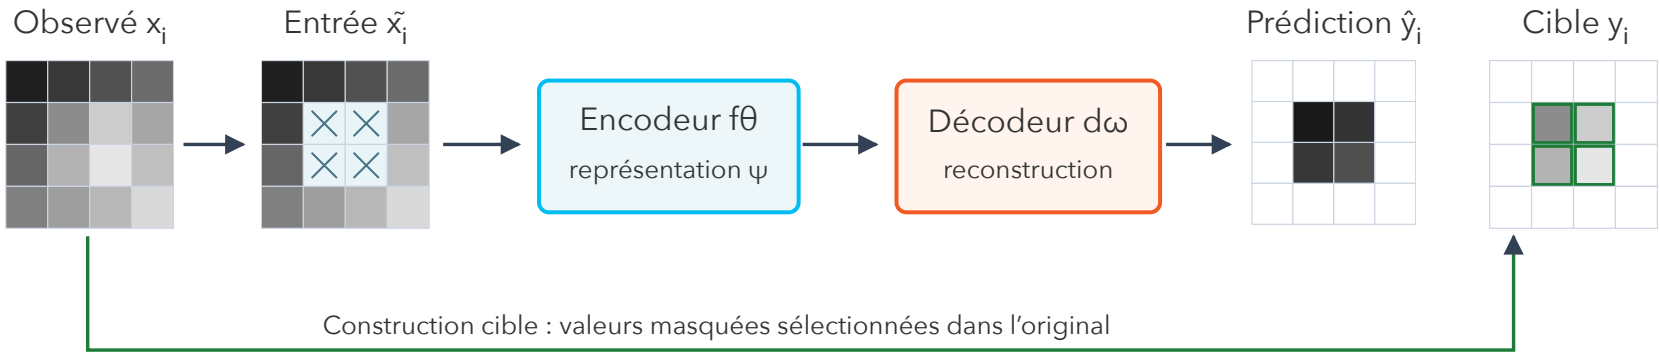
Observer le terrain **Exécuter un mouvement fixe connu** **Mesurer le résultat**



Cible automatique Coût illustratif = 1 − mesuré / commandé = **0.4**

Image caméra antérieure → **Encodeur + tête de tâche** → Coût de traversée prédit

Masquage: Entrée, prédiction et cible

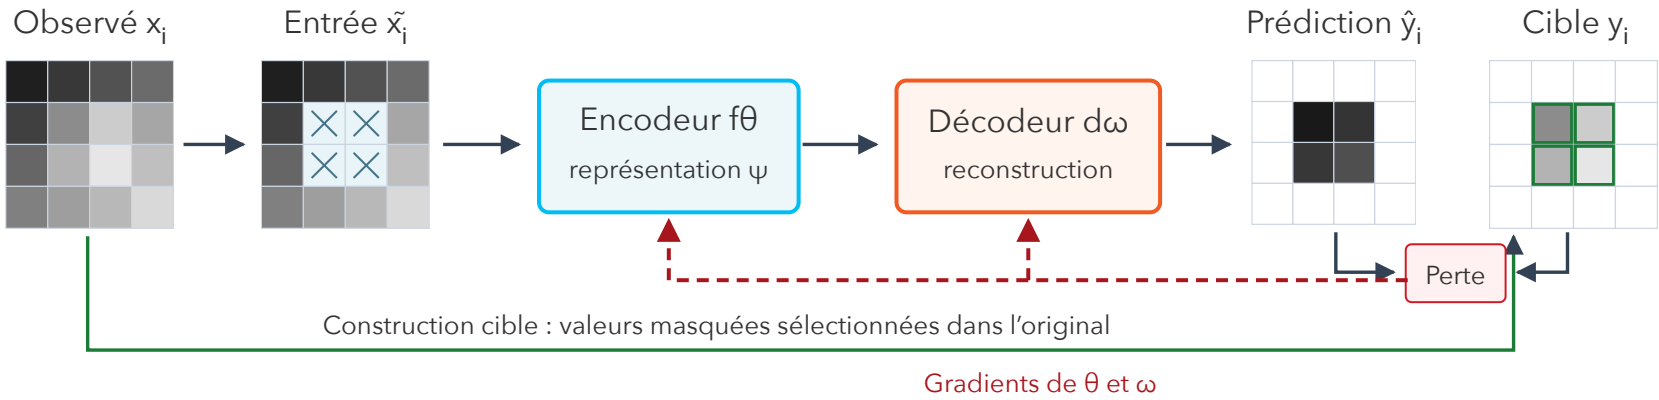


$$y_i = (x_{i,k})_{k \in \mathcal{M}}$$

Copier les valeurs observées masquées dans la branche cible.

i identifie une observation · Θ regroupe les paramètres de l'encodeur et du décodeur · M sélectionne les positions masquées

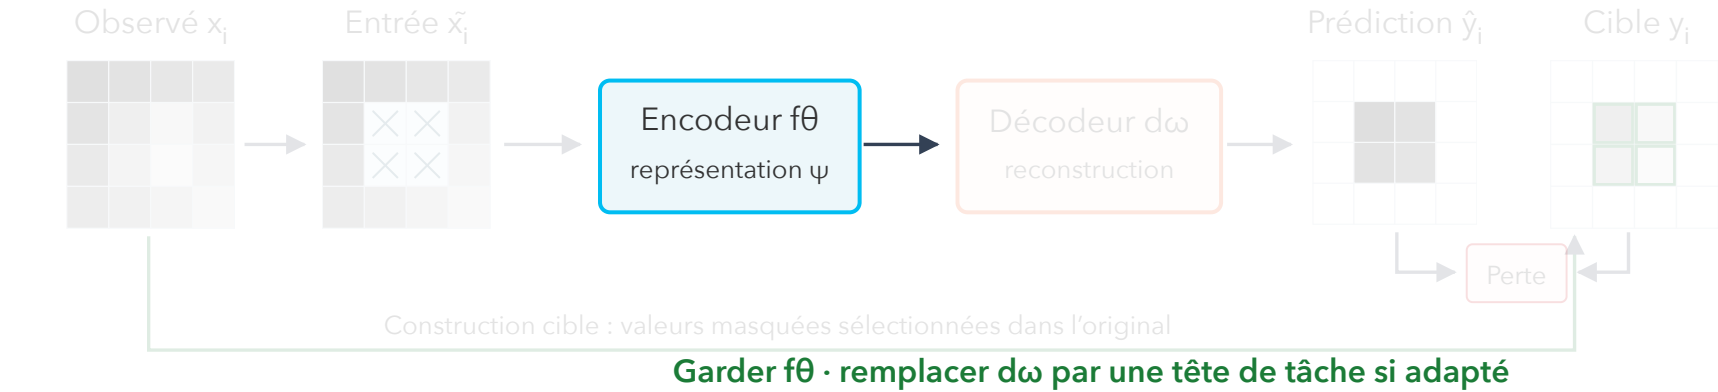
Masquage: Perte et mise à jour des paramètres



$$\Theta_{n+1} = \Theta_n - \eta \nabla_\Theta \mathcal{L}$$

n compte les pas d'optimisation. η règle l'amplitude de chaque mise à jour.

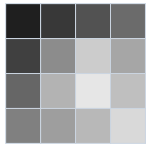
Masquage: Ce qui reste après l'apprentissage



Garder fθ · remplacer dω par une tête de tâche si adapté

$$\boldsymbol{\psi} = f_\theta(x) \qquad \hat{y}^{\text{task}} = h_\beta(\boldsymbol{\psi})$$

Encoder une nouvelle observation. La tâche détermine la tête de sortie.

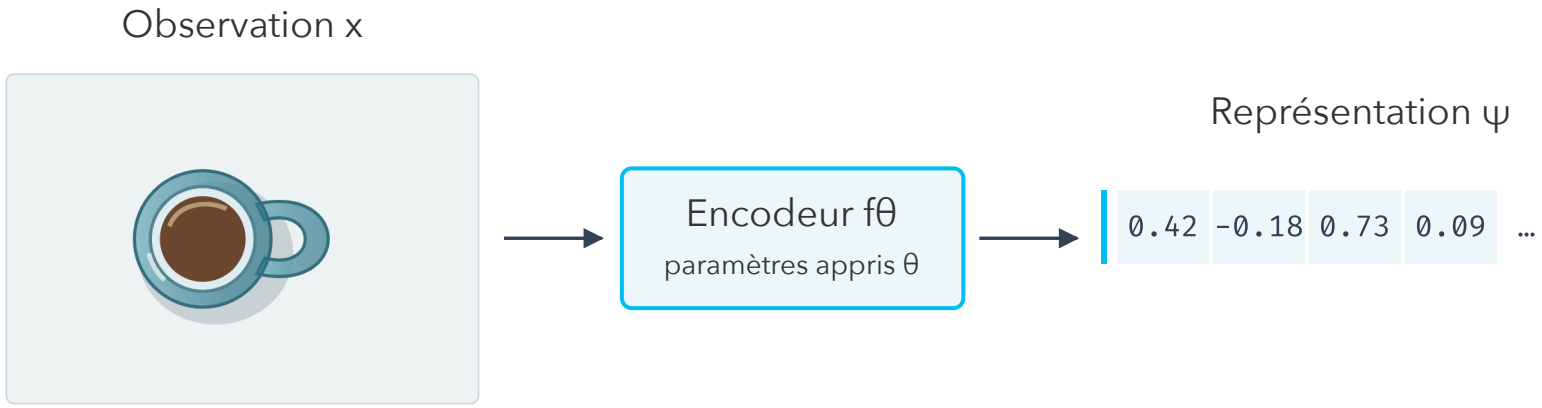
 → **Encodeur fθ** → **Tête de tâche hβ** → Sortie de tâche

Évaluer la représentation conservée sur la tâche de perception visée.

SECTION 02

Représentations pour la perception

Représentations de l'encodeur



Description interne réutilisable pour une tâche

$$\psi = f_\theta(x)$$

Une description réutilisable

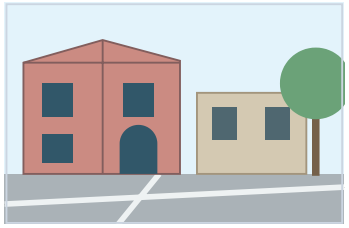
La qualité d'une représentation dépend de l'information disponible pour la tâche visée.

Caractéristiques globales et denses

Caractéristiques globales : 1 vecteur par image

Reconnaître un lieu déjà visité

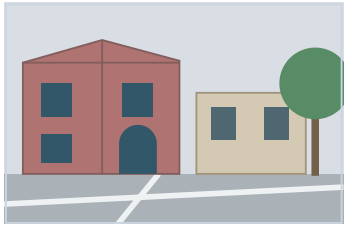
Image requête



Encodeur fθ ↓

`0.42` `-0.18` `0.73`

Image stockée



Encodeur fθ ↓

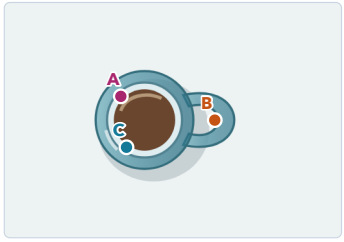
`0.40` `-0.20` `0.71`

Comparer les descripteurs globaux

Caractéristiques denses : vecteurs par position

Trouver le point d'anse correspondant

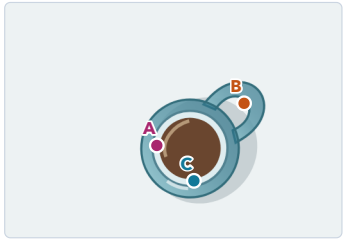
Image de référence



Encodeur fθ ↓



Nouvelle image



Encodeur fθ ↓



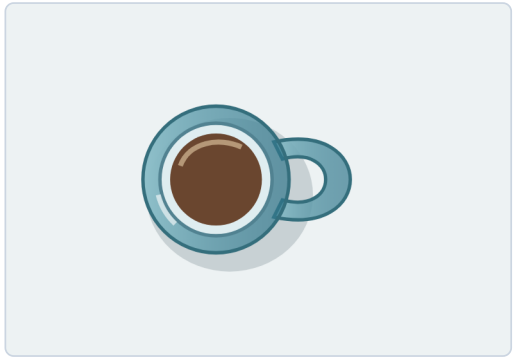
`-0.24` `0.81` `0.46`

Invariance aux changements non pertinents

Pour **reconnaître cette tasse**, l'éclairage et l'arrière-plan peuvent être des variables parasites.

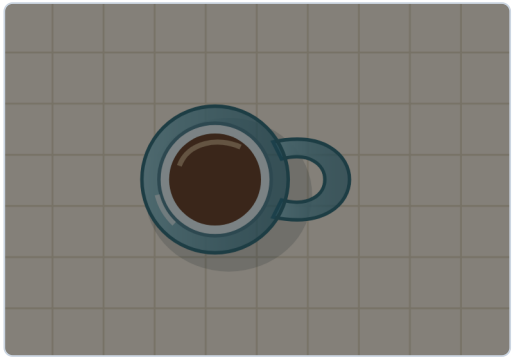
On procède donc à des **augmentations** lors de l'entraînement.

Observation de référence



changer l'apparence

Observation modifiée



Identité désirée

même tasse

Éclairage : 0.55×

Arrière-plan : motif

Les pixels changent; la décision de reconnaissance reste stable.

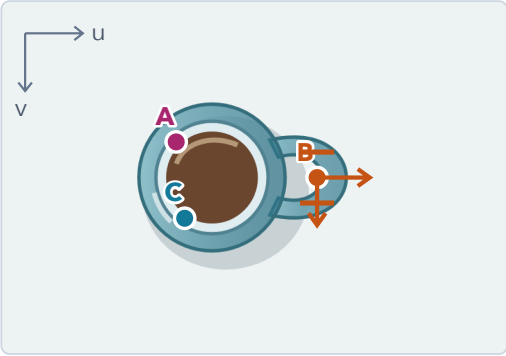
> Conserver l'information qui identifie l'objet malgré les changements choisis.

Information spatiale nécessaire à l'action

Pour **saisir l'anse**, sa position et son orientation doivent rester accessibles.

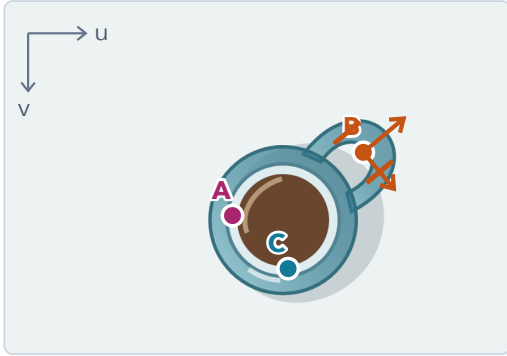
On procède donc à des **augmentations** lors de l'entraînement.

Observation de référence



déplacer la tasse

Observation modifiée



Prise en coordonnées image

(212.5, 90.1)

α = -40° · positif horaire

B : même descripteur illustratif

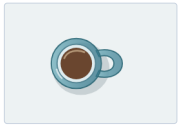
```
-0.24  0.81  0.46
```

Le descripteur d'anse reste associé à B; position et orientation changent.

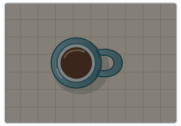
> Les caractéristiques correspondantes peuvent rester cohérentes alors que leurs positions changent.

Objectifs d'appariement et de prédiction

Apparier les observations liées



vue 1 → fθ → ψ1



vue 2 → fθ → ψ2

ψ1 et ψ2 → Comparer les caractéristiques

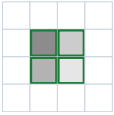
Relation connue : même observation

θ partagé

Prédire l'information masquée



entrée $\tilde{x}$ → fθ → ψ → dω → $\hat{y}$ → Perte ← Cible y



Deux mécanismes à suivre

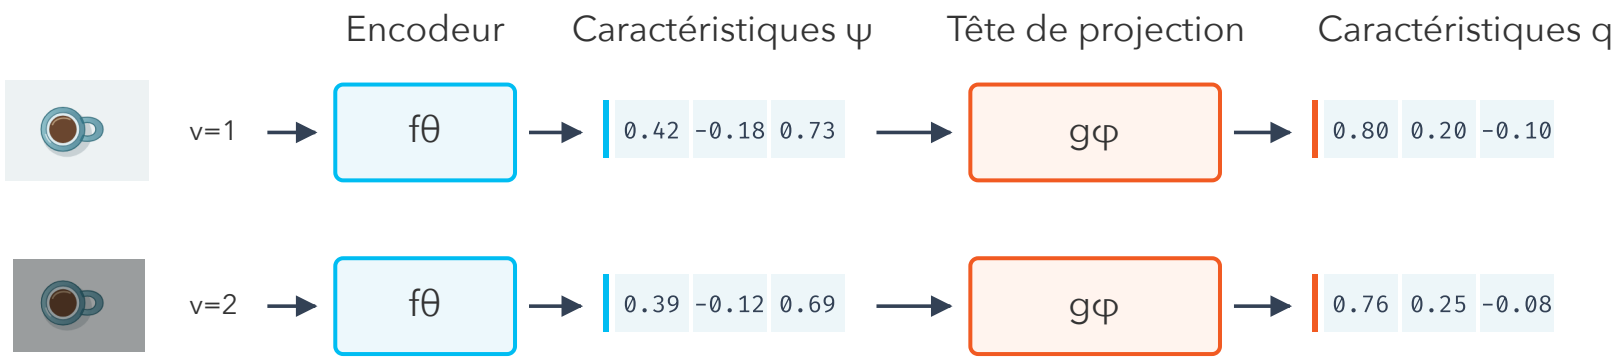
L'appariement utilise une relation connue entre observations.

Alors que le masquage utilise une information observée retirée de l'entrée.

SECTION 03

Appariement, effondrement et auto-distillation

Encodeur et tête de projection



Réutiliser la représentation de l'encodeur

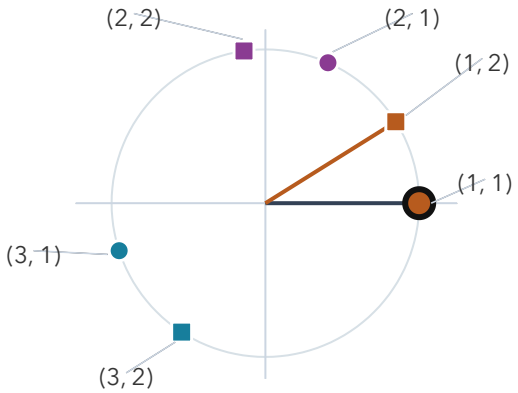
Comparer les projections

$$\boldsymbol{\psi}_i^{(v)} = f_\theta(\tilde{\boldsymbol{x}}_i^{(v)}) \qquad \mathbf{q}_i^{(v)} = g_\phi(\boldsymbol{\psi}_i^{(v)})$$

L'objectif compare q. Plusieurs tâches différentes en aval (downstream) peuvent réutiliser ψ de l'encodeur.

Similarité et température

Ancre (1, 1) · Positif (1, 2)



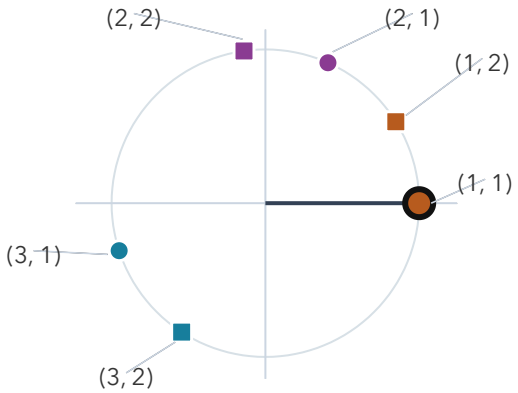
Candidat (i, v)	cosinus	Probabilité normalisée
(1, 2) · positif	0.848	60.9%
(2, 1) · négatif	0.407	25.2%
(2, 2) · négatif	-0.139	8.5%
(3, 1) · négatif	-0.951	1.7%
(3, 2) · négatif	-0.545	3.8%

τ = 0.50 · probabilité positive = 60.9% · ℓ = 0.496

$$\mathrm{sim}(\mathbf{q}_a, \mathbf{q}_b) = \frac{\mathbf{q}_a^\top \mathbf{q}_b}{\|\mathbf{q}_a\|_2 \|\mathbf{q}_b\|_2}$$

Perte contrastive

Ancre (1, 1) · Positif (1, 2)



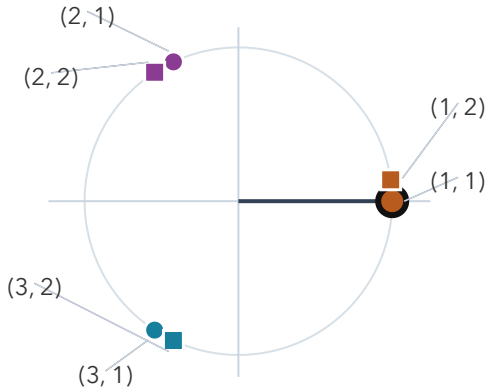
Candidat (i, v)	cosinus	Probabilité normalisée
(1, 2) · positif	0.848	60.9%
(2, 1) · négatif	0.407	25.2%
(2, 2) · négatif	-0.139	8.5%
(3, 1) · négatif	-0.951	1.7%
(3, 2) · négatif	-0.545	3.8%

τ = 0.50 · probabilité positive = 60.9% · ℓ = 0.496

$$\ell_i^{(1)} = -\log \frac{\exp(\mathrm{sim}(\mathbf{q}_i^{(1)}, \mathbf{q}_i^{(2)})/\tau)}{\sum_{(j,v)\neq(i,1)} \exp(\mathrm{sim}(\mathbf{q}_i^{(1)}, \mathbf{q}_j^{(v)})/\tau)}$$

Effet de l'objectif sur les représentations

Vue transformée → **fθ** → ψ → **gφ** → q

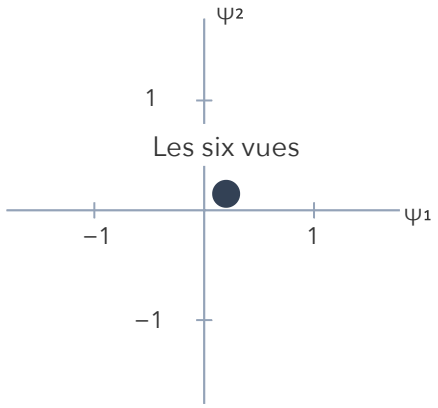


Candidat (i, v)	cosinus	Probabilité normalisée
(1, 2) · positif	0.990	82.6%
(2, 1) · négatif	-0.423	4.9%
(2, 2) · négatif	-0.545	3.8%
(3, 1) · négatif	-0.545	3.8%
(3, 2) · négatif	-0.423	4.9%

τ = 0.50 · probabilité positive = 82.6% · ℓ = 0.192 · moyenne des six ancres = 0.189

Augmenter l'accord avec le positif relativement aux vues concurrentes.

Représentation constante: Effondrement



Trois paires distinctes

Perte moyenne d'accord des paires : **0.0000**

Dispersion : (0.000, 0.000)

Un vecteur constant efface les distinctions entre observations.

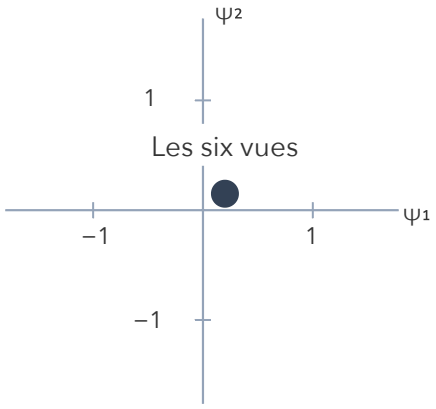
c = (0.20, 0.15)

$$f_\theta(x) = \mathbf{c} \text{ pour tout } x \quad \Longrightarrow \quad \ell_{\text{agree},i} = 0$$

Il faut éviter qu'une solution optimale possible de l'apprentissage soit l'effondrement (collapse) de la représentation.

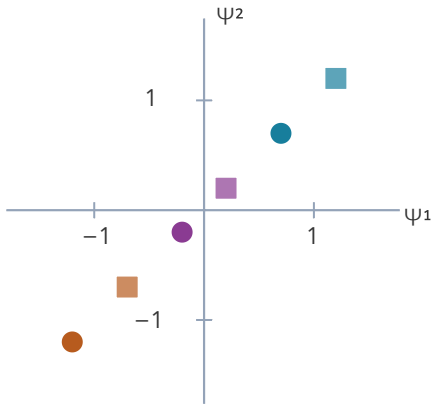
Perte de dimensions de représentation

Point : effondrement complet



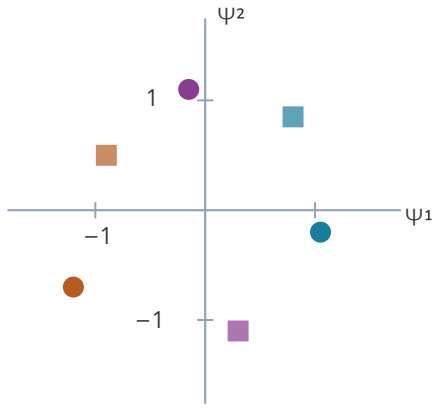
Écart-type : (0.00, 0.00)

Ligne : une direction variable



Écart-type : (0.89, 0.89)

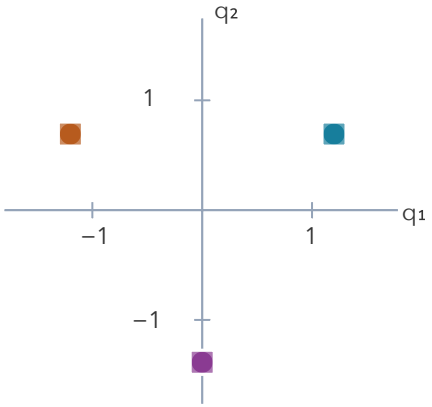
Deux directions variables



Écart-type : (0.91, 0.88)

Régularisation: Variance-Invariance-Covariance (VICReg)

Vue → fθ → ψ → **gφ (expanseur)** → q · régulariser q des deux branches



Invariance · 0.0000

Distance entre vues correspondantes

Variance · 0.0000

Plancher d'écart-type par dimension

Covariance · 0.0000

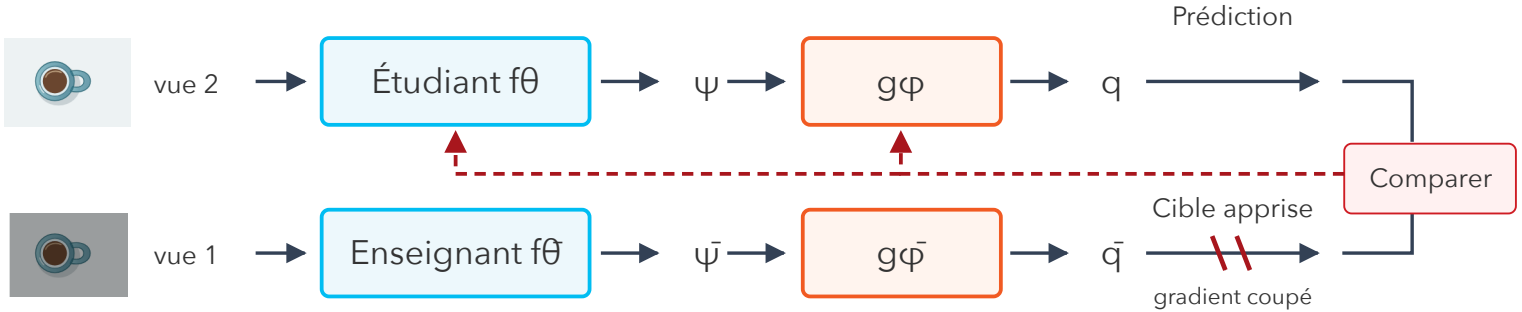
Covariance hors diagonale au carré

$$\mathcal{L}_{\text{VICReg}} = \lambda_{\text{inv}}\mathcal{L}_{\text{inv}} + \lambda_{\text{var}}\mathcal{L}_{\text{var}} + \lambda_{\text{cov}}\mathcal{L}_{\text{cov}}$$

La covariance décourage les directions redondantes.

Bardes et al. · VICReg · ICLR 2022

Auto-Distillation: Apprendre des cibles fournies par un enseignant

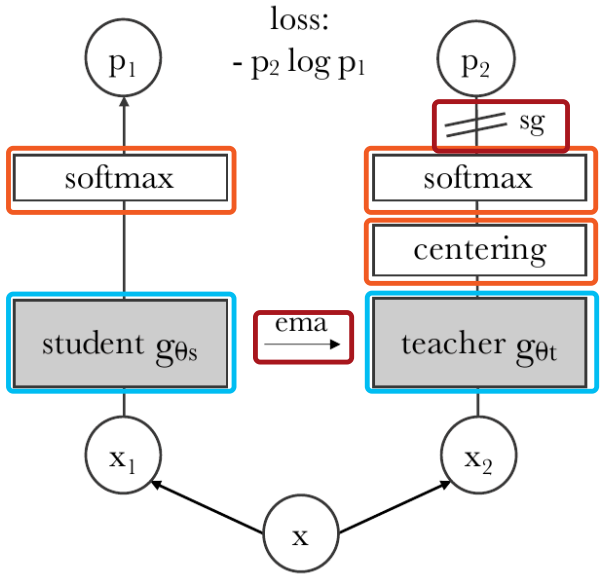


Tirets : gradients de θ et φ · aucun gradient enseignant

Une cible qui évolue pendant l'apprentissage

L'étudiant prédit une sortie enseignante à partir d'une autre vue de l'observation.

Architecture de DINO



Étudiant et enseignant : encodeur + tête

$$g_{\theta_s} \leftrightarrow g_\phi \circ f_\theta$$

$$g_{\theta_t} \leftrightarrow g_{\bar{\phi}} \circ f_{\bar{\theta}}$$

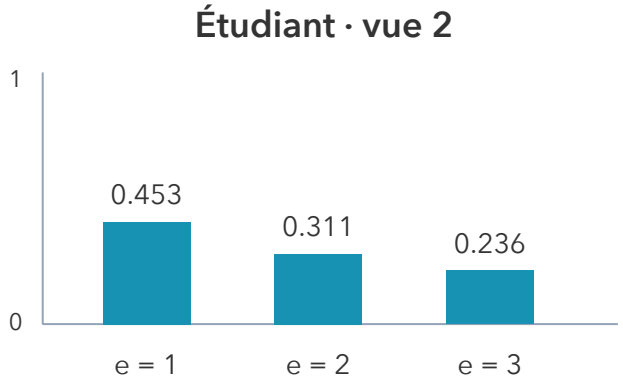
Centrer les sorties enseignantes, puis appliquer des températures softmax distinctes.

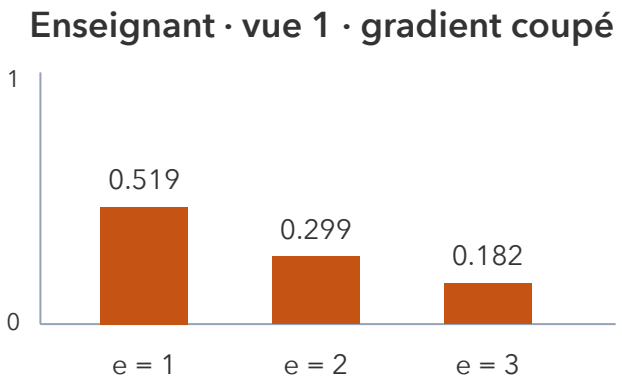
Couper le gradient enseignant; modifier ses paramètres par moyenne mobile.

Caron et al. · DINO · ICCV 2021 · Fig. 2 principale

Apparier les distributions; mettre à jour étudiant et enseignant selon des règles distinctes.

Appariement de distributions dans DINO

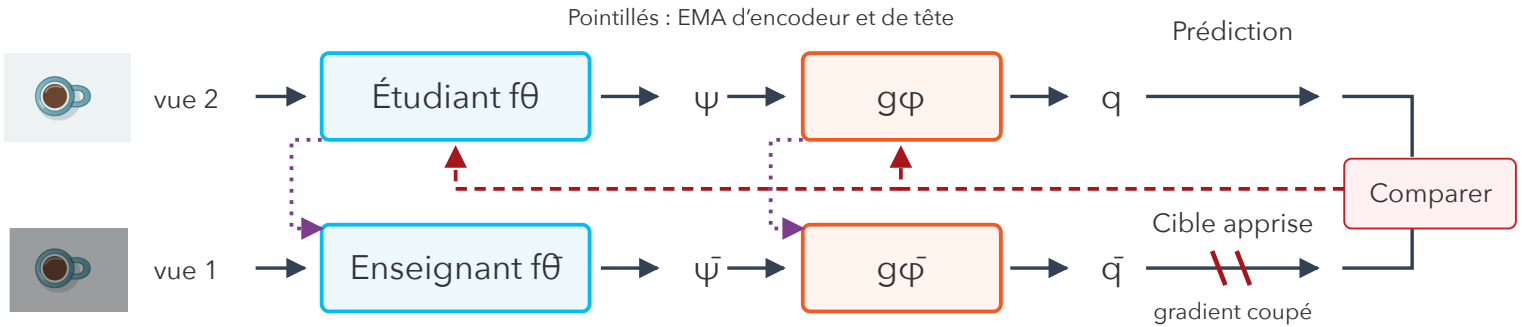




$$\ell_{\text{DINO}} = -\sum_{e} \rho_{\text{teach},e} \log \rho_{\text{stu},e}$$

Entropie croisée calculée pour une paire : **1.0230**

Mises à jour par gradient et moyennes mobiles



Tirets : gradients de θ et φ · aucun gradient enseignant

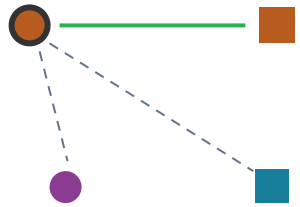
$$\bar{\theta}_{n+1} = \mu\bar{\theta}_n + (1-\mu)\theta_{n+1}$$

Encodeur : θ = 0.488 · θ̄ = 0.578 Tête : φ = 0.830 · φ̄ = 0.966

Après un lot (batch): mettre à jour la tête enseignante φ̄ avec une moyenne mobile.

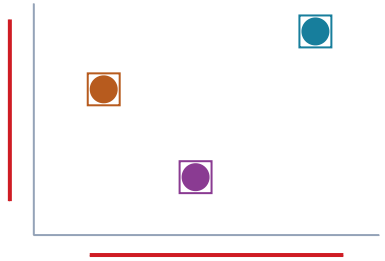
Résumé de l'apprentissage de représentation

SimCLR



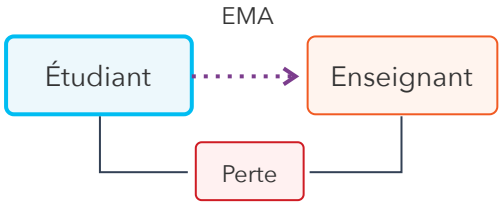
Vues concurrentes

VICReg



Dispersion + décorrélation

DINO



Cible centrée et accentuée

Distribution enseignante

Observation → encodeur → caractéristiques → relation ou cible → perte → mise à jour

L'objectif d'une bonne représentation

Conserver l'information utile à la tâche visée.

Ignorer le reste.

SECTION 04

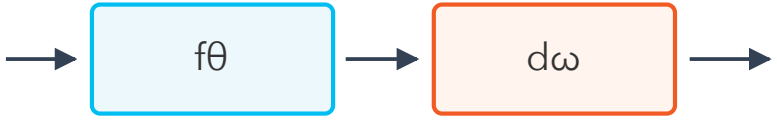
Reconstruction et prédiction de caractéristiques

La reconstruction comme signal d'apprentissage

Entrée partiellement observée







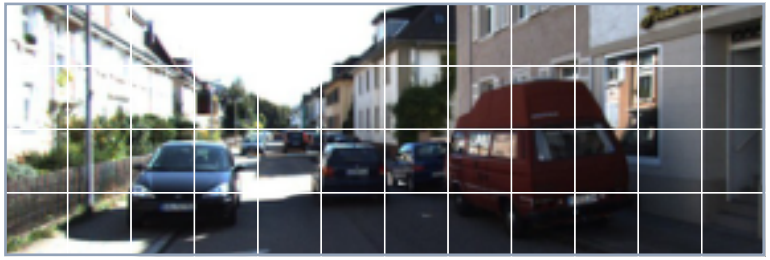
Les pixels originaux observés fournissent la cible.

Retirer l'information de l'entrée de prédiction, en la conservant pour la cible.

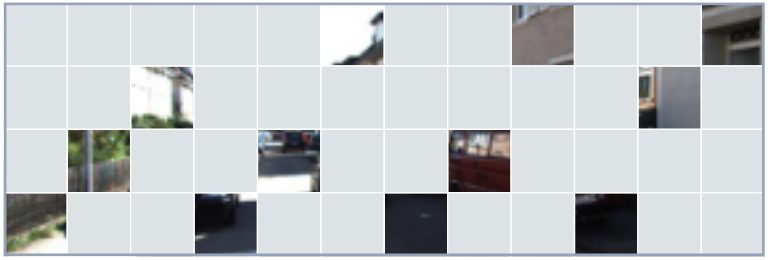
> L'observation originale fournit une cible sans annotation humaine.

Blocs visibles et masqués

Observation originale x



Blocs visibles V · masqués M

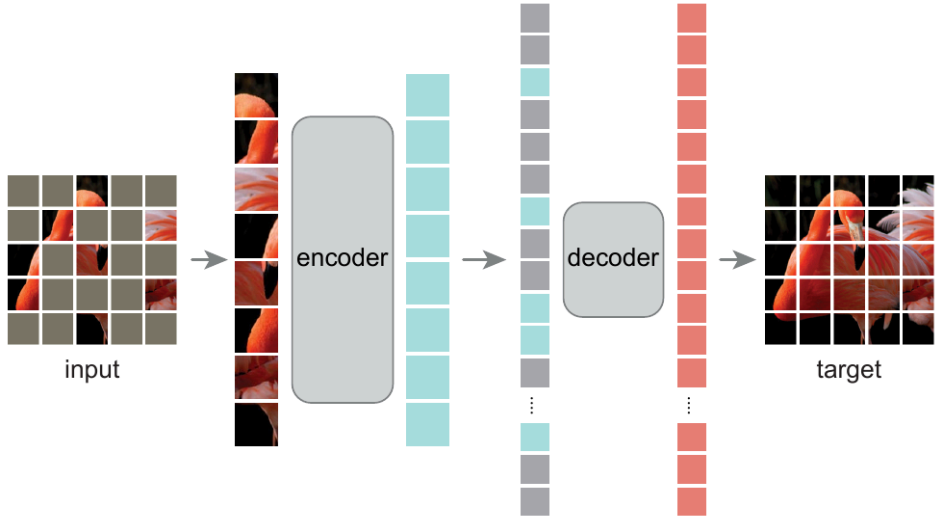




Jetons visibles + positions

L'encodeur MAE (masked auto-encoder) reçoit les jetons visibles et leurs positions originales.

Architecture de MAE

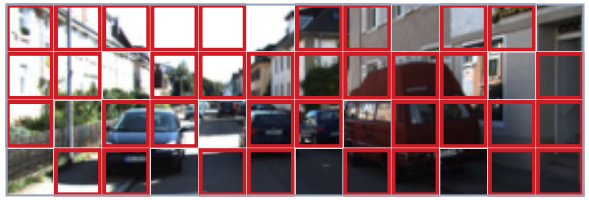


Les jetons de masque entrent dans le décodeur après encodage du visible.

He et al., MAE, CVPR 2022 · Fig. 1 · arXiv v3

Perte de reconstruction aux positions masquées

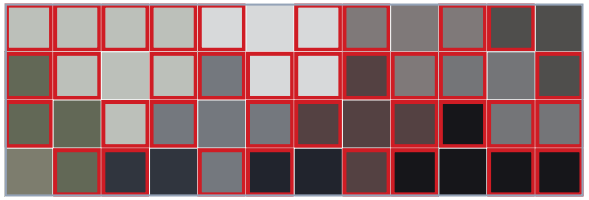
Pixels cibles originaux



Entrée encodeur visible



Prédiction de pixels



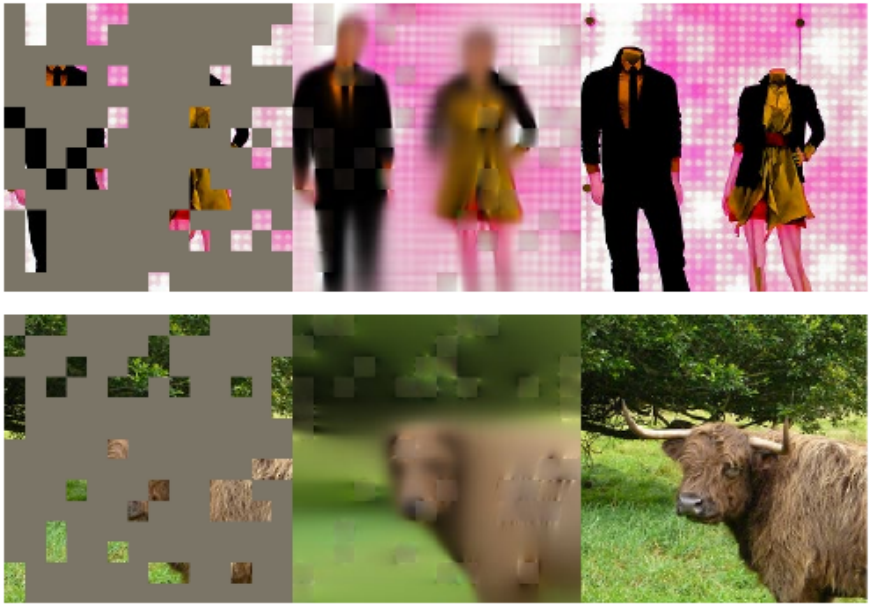
$$\mathcal{L}_{\text{pixel}} = \frac{1}{|\mathcal{M}|} \sum_{k \in \mathcal{M}} \|\widehat{x}_k - x_k\|_2^2$$

> Moyenner sur 36 blocs masqués : Lpixel = 148.32

La perte de base agit sur les blocs masqués.

Reconstruction plausible et ambiguïté

Entrée masquée Reconstruction MAE Image originale



Plusieurs complétions possibles

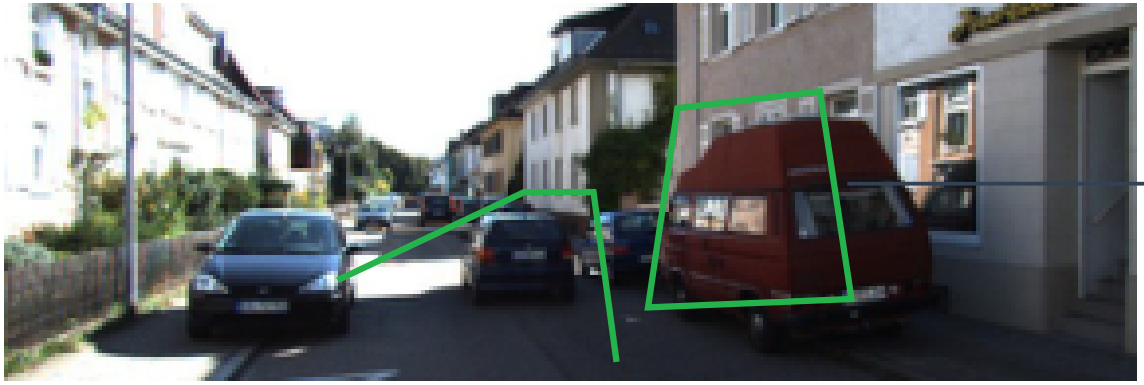
Le contexte visible ne détermine pas chaque détail masqué.

Les sorties diffèrent des originaux, avec une structure de scène plausible.

La plausibilité visuelle ne prouve ni compréhension sémantique ni précision robotique.

He et al., MAE, CVPR 2022 · Fig. 3, deux exemples les plus à droite · arXiv v3 · Images de validation COCO; modèle préentraîné sur ImageNet

Que demande de conserver une cible de prédiction ?



Structure de véhicule

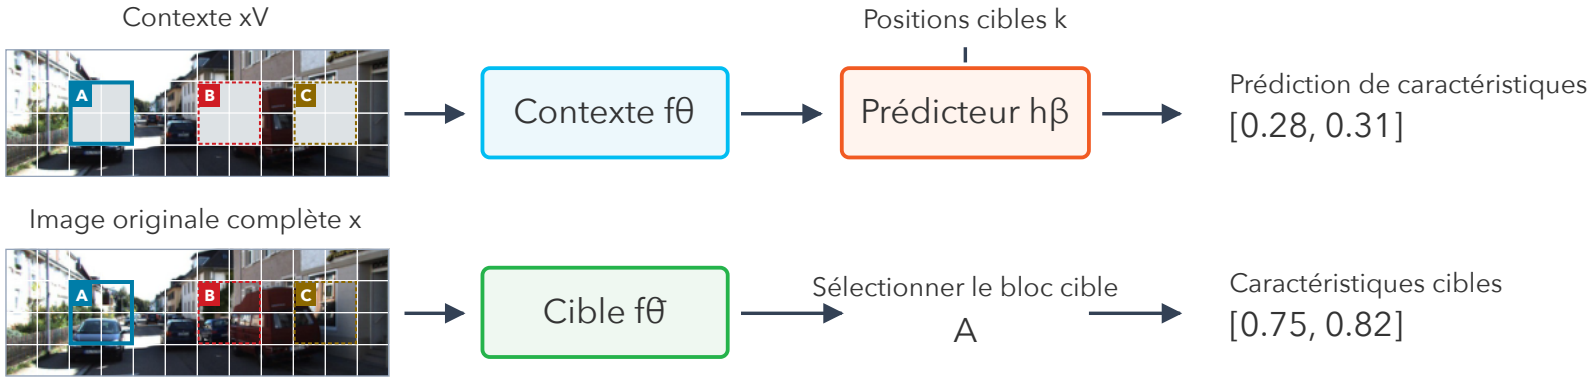
Indices utiles à la tâche

La tâche peut privilégier la structure des objets et de la route.

La cible définit les erreurs de prédiction à réduire.

> Les caractéristiques utiles à apprendre dépendent de la tâche.

JEPA: Prédire dans l'espace des caractéristiques

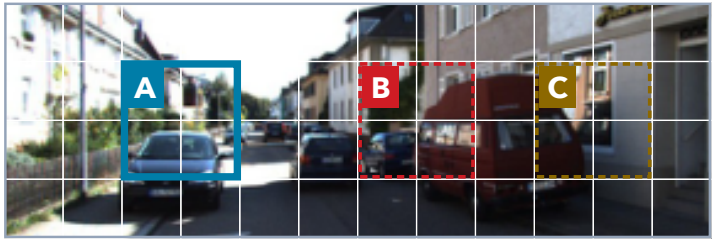


$$\psi_k^{\text{target}} = f_{\bar{\theta}}(x)_k$$

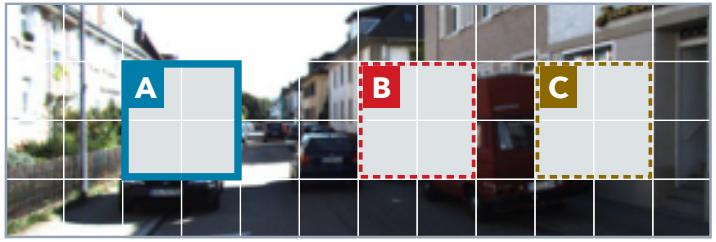
Changer le calcul de cible pour qu'elle soit dans l'espace intermédiaire des caractéristiques. Sans avoir à décoder dans l'espace de prédiction (ex: image). Permet d'apprendre des concepts plus abstraits. Entraînement à grande échelle plus efficace.

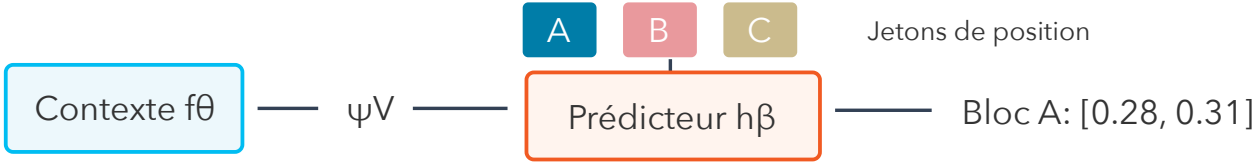
JEPA: Contexte et positions cibles

Original · blocs spatiaux A, B, C



Contexte V · toutes les cibles retirées

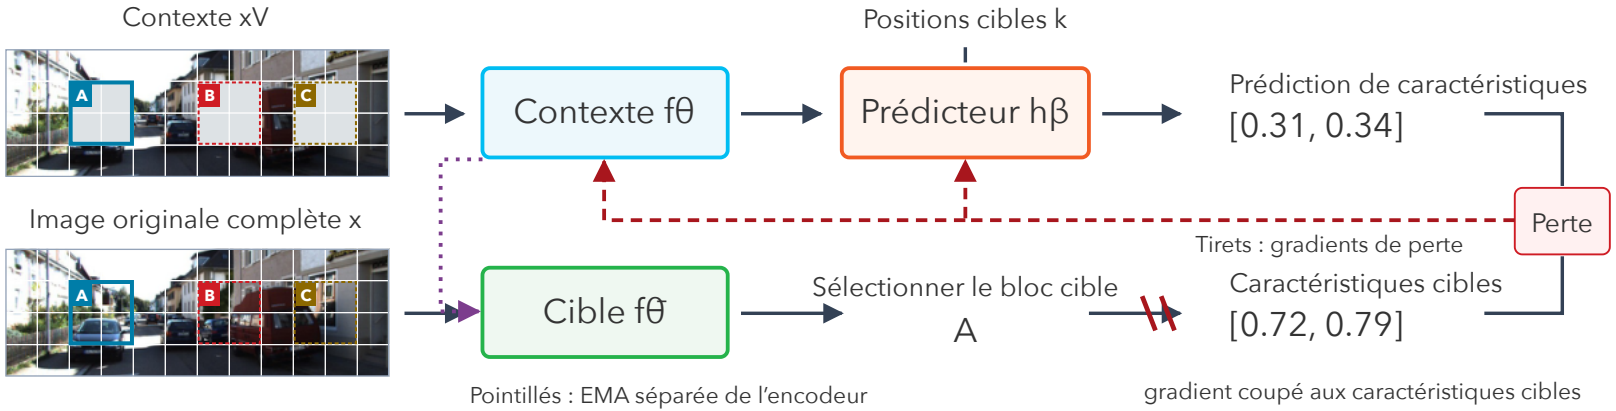




Le jeton indique où prédire, sans contenir de pixels masqués.

$$\widehat{\psi}_k = h_\beta(f_\theta(x_\mathcal{V}), k)$$

JEPA: Perte de caractéristiques et mises à jour des cibles



$$\bar{\theta}_{n+1} = \mu\bar{\theta}_n + (1-\mu)\theta_{n+1}$$

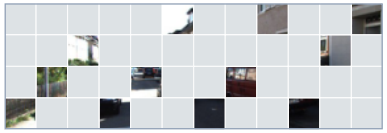
Lfeature = 0.1515

θ = 0.833 · β = 0.738 · θ̄ = 0.967

L'EMA transfère les paramètres du contexte.

Cibles de pixels et cibles de caractéristiques

MAE · cible de pixels



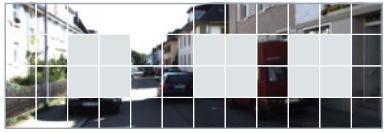
fθ — dω — $\hat{x}_k$ ↔



Masques + jetons de position

Pixels observés x_k

I-JEPA · cible de caractéristiques



fθ — hβ — $\hat{\psi}_k$ ↔ $sg(f_{\bar{\theta}}(x)_k)$

Jetons de position cible

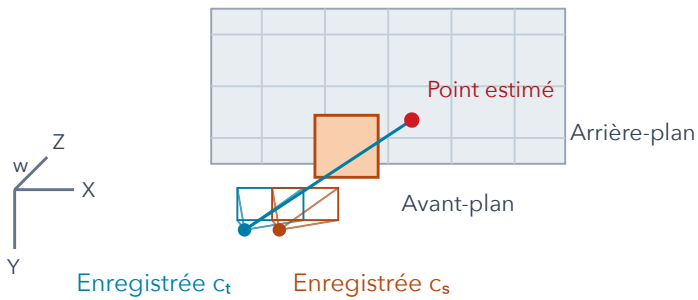
Cibles sur toutes les features de l'image

SECTION 05

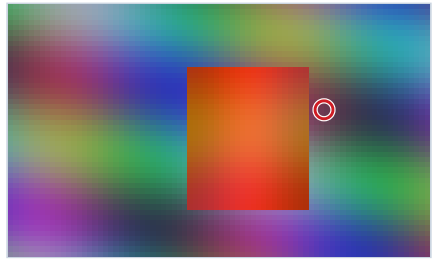
Supervision géométrique

Apprendre la profondeur à partir de plusieurs observations

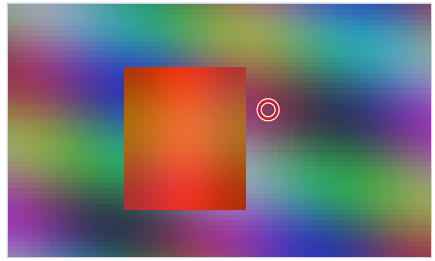
Scène 3D synthétique · vue fixe



Cible enregistrée I_t · u→, v↓



Source enregistrée I_s



Le marqueur source suit la projection calculée.

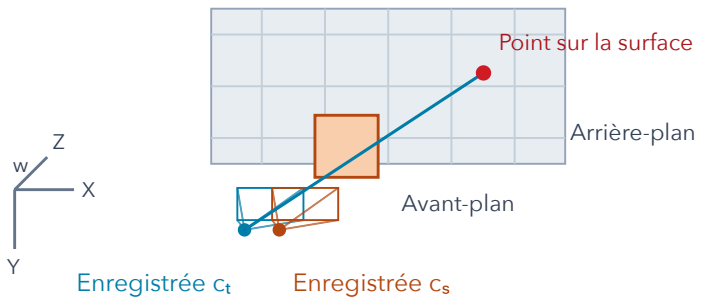
$\hat{D} = 3.50 \cdot \hat{p}$ dans c_t : [1.06, -0.18, 3.50] · u_s = [49.31, 20.00]

L'image enregistrée fournit la cible; profondeur et pose sont prédites.

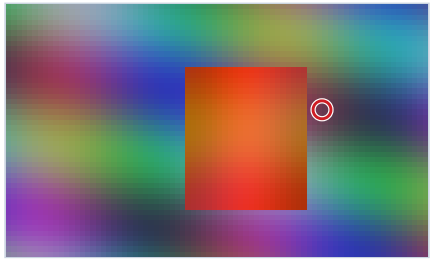
La structure de scène et le mouvement caméra peuvent fournir un signal d'apprentissage.

Projection caméra et paramètres intrinsèques

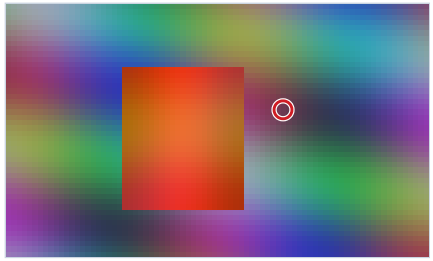
Scène 3D synthétique · vue fixe



Cible enregistrée I_t · u→, v↓



Source enregistrée I_s



Le marqueur source suit la projection calculée.

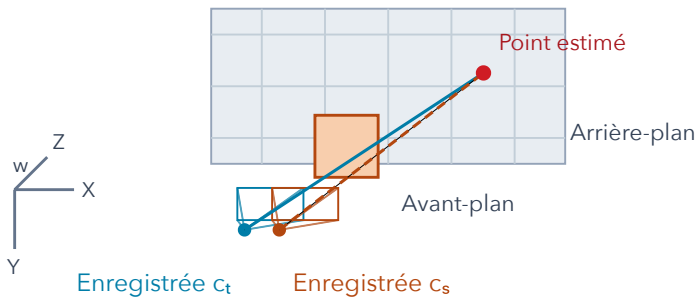
$$K_t = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

fx = fy = 68 · cx = 39.5 · cy = 23.5 · X droite, Y bas, Z avant

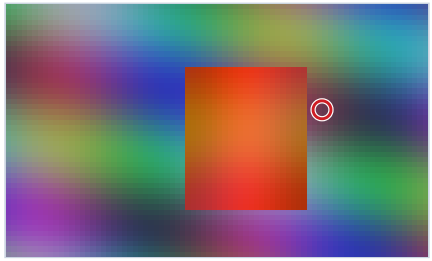
La profondeur est Z optique, distinct de la distance sur un rayon unitaire.

Rétroprojeter un pixel cible

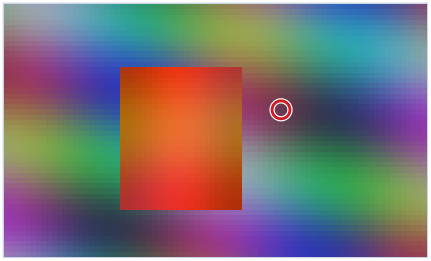
Scène 3D synthétique · vue fixe



Cible enregistrée I_t · u→, v↓



Source enregistrée I_s



Le marqueur source suit la projection calculée.

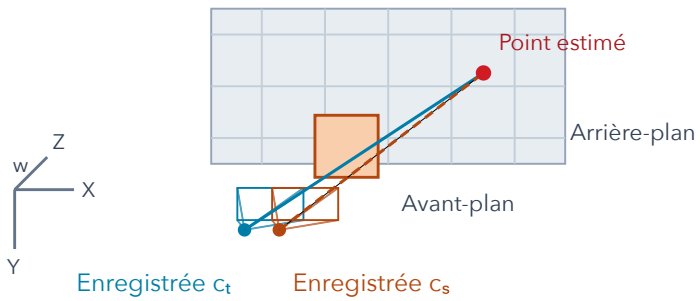
$$\hat{p}^{c_t} = \widehat{D}_t(\mathbf{u}) K_t^{-1} \tilde{\mathbf{u}}$$

$\hat{D}$ = 5.00 · $\hat{p}$ dans c_t : [1.51, -0.26, 5.00] · u_s = [52.52, 20.00]

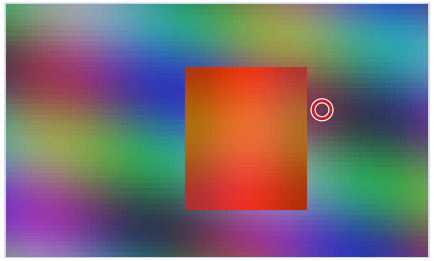
L'estimation de profondeur déplace le point sur un rayon cible fixe.

Effet de la pose de la caméra

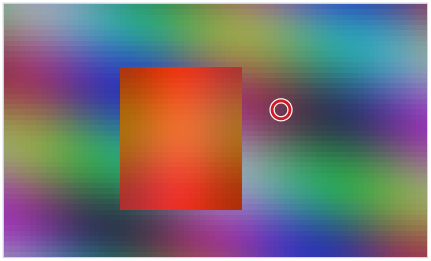
Scène 3D synthétique · vue fixe



Cible enregistrée I_t · u→, v↓



Source enregistrée I_s



Le marqueur source suit la projection calculée.

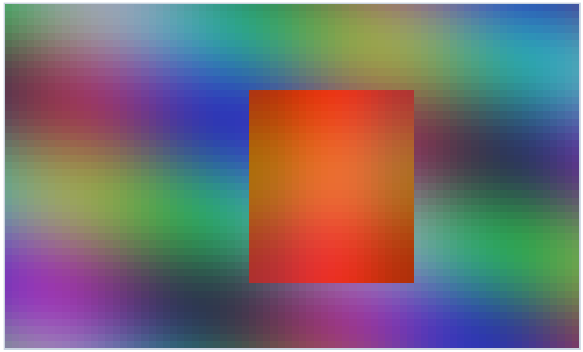
$$\hat{p}^{c_s} = \hat{R}^{c_s}_{c_t}\hat{p}^{c_t} + \hat{t}^{c_s}_{c_t}$$

$\hat{p}$ dans c_t : [1.51, -0.26, 5.00] · $\hat{p}$ dans c_s : [0.96, -0.26, 5.00]

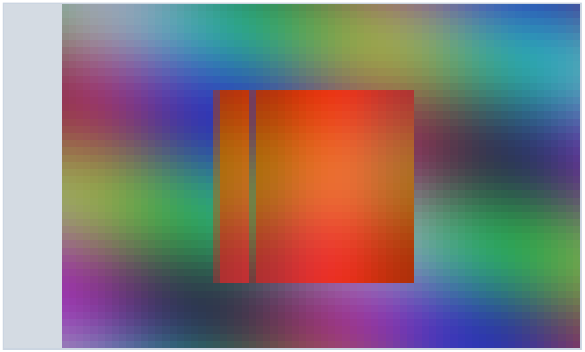
La pose estimée modifie les coordonnées et l'échantillonnage; les observations restent fixes.

Perte de reconstruction photométrique

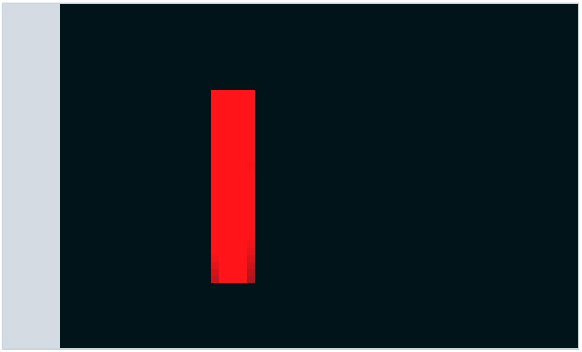
Cible enregistrée I_t



Cible reconstruite $\hat{I}_t$



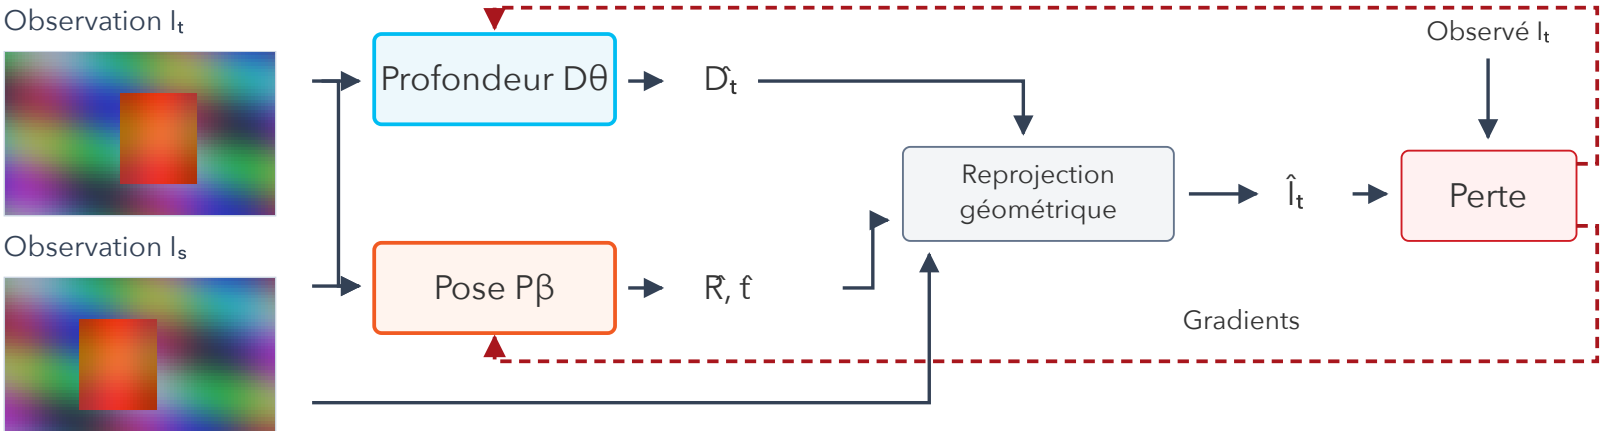
Erreur RVB L1 · clair = élevé



$$\mathcal{L}_{\text{photo}} = \frac{1}{|\Omega|} \sum_{\mathbf{u} \in \Omega} \| I_t(\mathbf{u}) - \hat{I}_t(\mathbf{u}) \|_1$$

Moyenne RVB L1 = 0.0448 · 3456 / 3840 pixels dans Ω

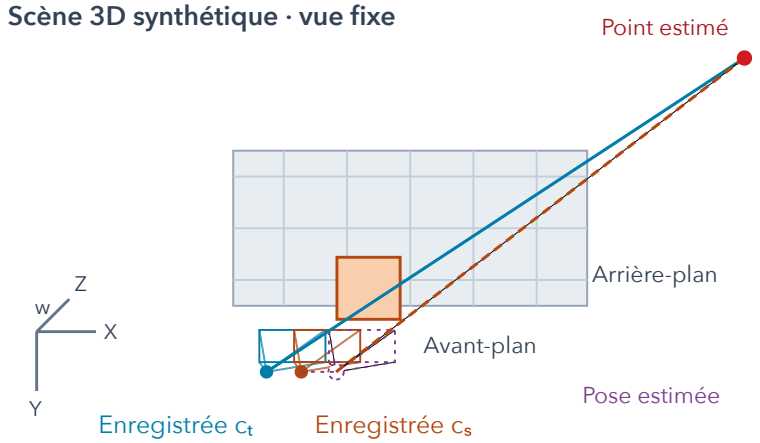
Mettre à jour les réseaux de profondeur et de pose

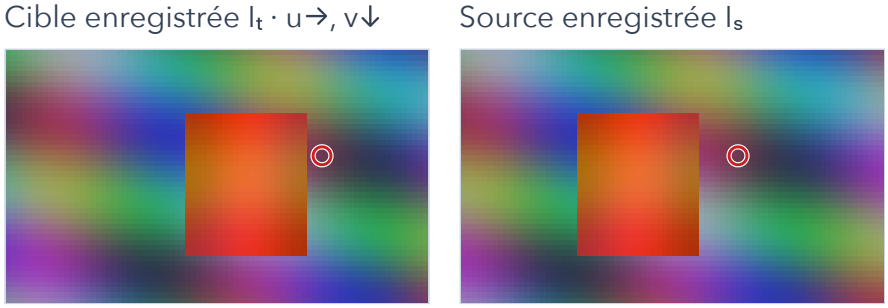


$$\Theta_{n+1} = \Theta_n - \eta \nabla_\Theta \mathcal{L}_{\text{photo}}, \qquad \Theta = (\theta, \beta)$$

Mise à jour scalaire calculée : moins d'erreur ne fixe pas l'échelle métrique.

Ambiguïté d'échelle monoculaire





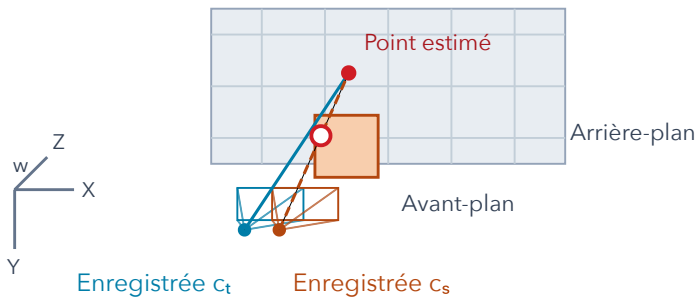
$$\pi(K_s\,\kappa\hat{p}^{c_s}) = \pi(K_s\hat{p}^{c_s}), \qquad \kappa > 0$$

$\hat{D}$ = 10.00 · $\hat{p}$ dans c_t : [3.01, -0.51, 10.00] · u_s = [52.52, 20.00]

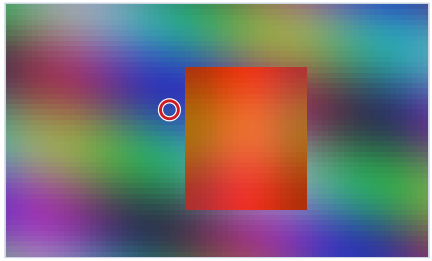
Mettre profondeur et translation relative à l'échelle ensemble; les pixels restent fixes.

Limites liées aux occultations

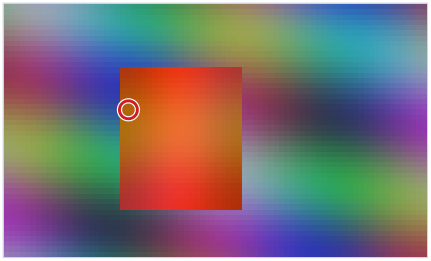
Scène 3D synthétique · vue fixe



Cible enregistrée I_t · u→, v↓



Source enregistrée I_s



Cible Échantillonné **RVB L1 = 1.2332**

Le marqueur source suit la projection calculée.

$Z_s = 5.00 > 0$ · $u_s = [23.52, 20.00]$ · le rayon source atteint d'abord l'avant-plan

Une projection positive dans l'image peut encore être occultée.

Limites liées à la texture et à la réflectance



Godard et al., Monodepth2, ICCV 2019 · Fig. 8 · arXiv v4

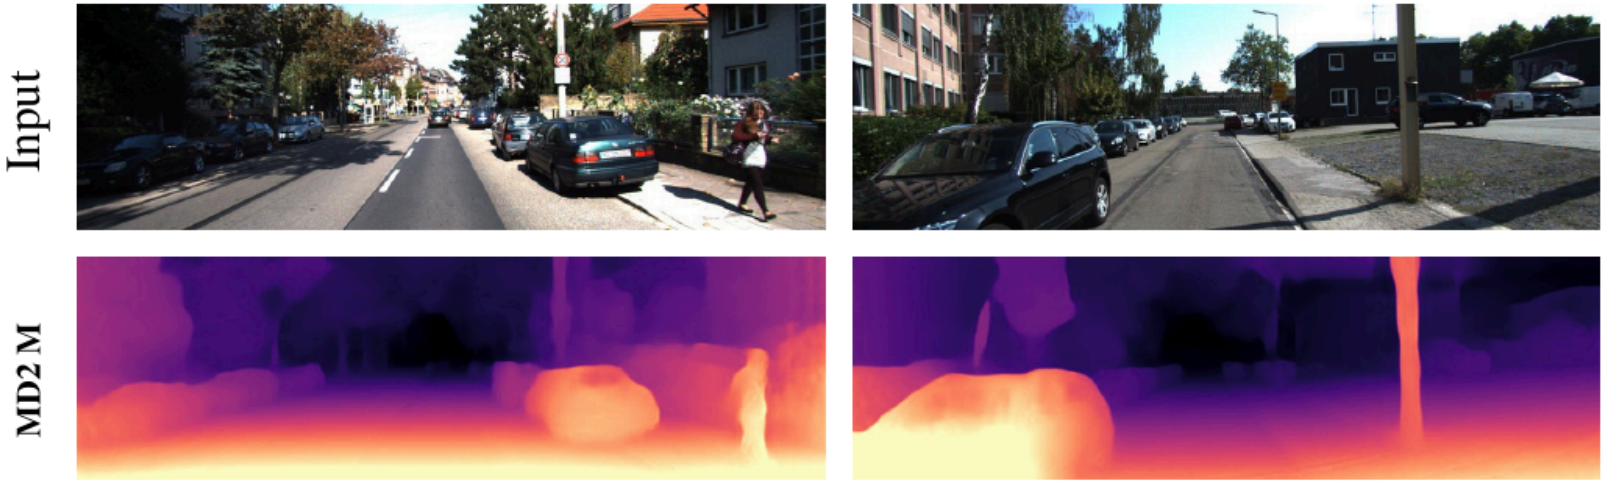
La cohérence d'apparence peut échouer

En haut : zones déformées, réfléchissantes et saturées en couleur.

En bas : frontières ambiguës et formes complexes peuvent aussi poser problème.

Exemples de l'article, avec étiquettes de méthodes et régions soulignées originales.

Profondeur apprise sur des images réelles



Images caméra enregistrées en haut; profondeurs monoculaires Monodepth2 prédites en bas.

> Pour une profondeur métrique, il faut ajouter un fine-tuning par supervision contre des données 3D (ex: LiDAR).

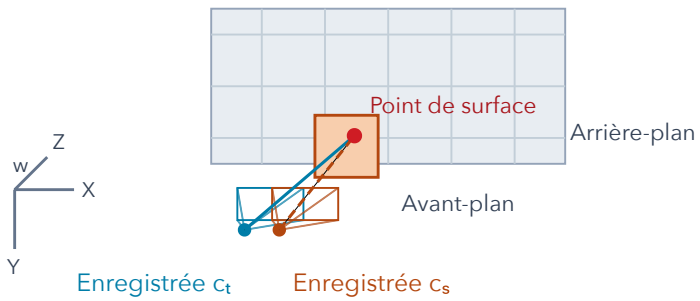
Godard et al., Monodepth2, ICCV 2019 · Fig. 7, deux premiers exemples, lignes Input et MD2 M · Partition Eigen de KITTI · arXiv v4

SECTION 06

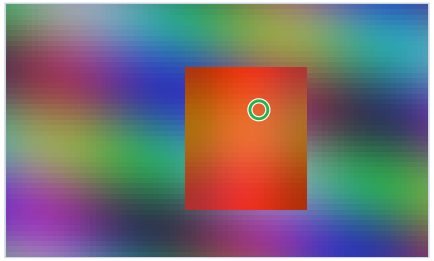
Correspondances denses

Correspondances de pixels construites par géométrie

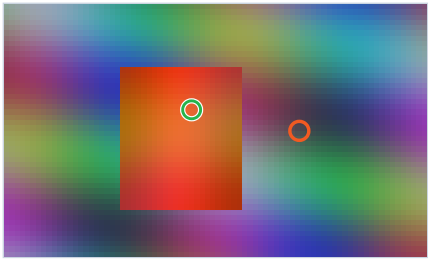
Scène 3D synthétique · vue fixe



Cible I_t



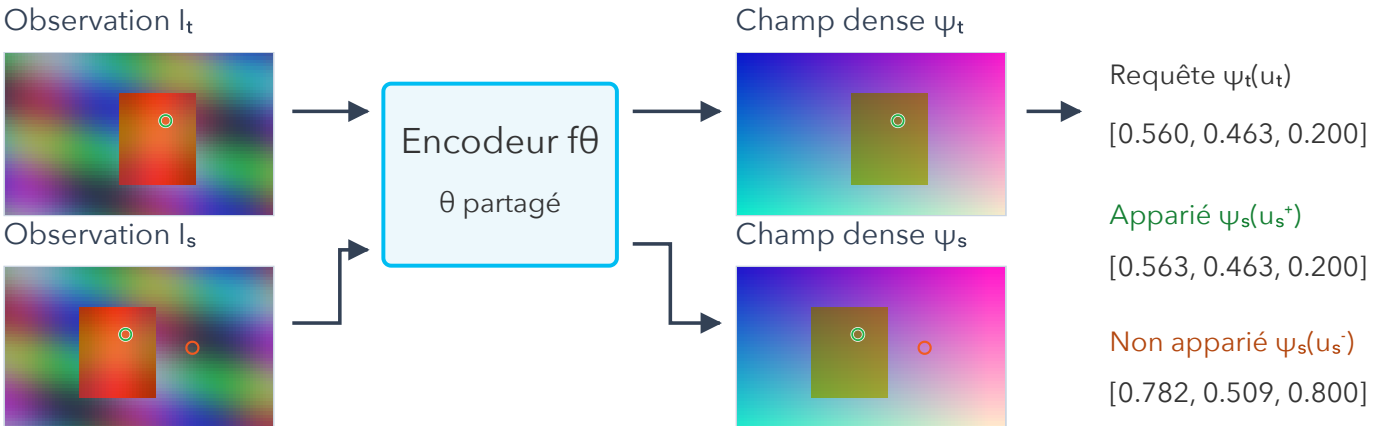
Source I_s



Vert : même point de surface · orange : autre point de surface

$$p^{c_t} = D_t(\mathbf{u}_t) K_t^{-1} \tilde{\mathbf{u}}_t, \qquad \mathbf{u}_s = \pi(K_s(R_{c_t}^{c_s} p^{c_t} + t_{c_t}^{c_s}))$$

Apprendre des descripteurs denses



$$d_+ = \|\boldsymbol{\psi}_t(\mathbf{u}_t) - \boldsymbol{\psi}_s(\mathbf{u}_s^+)\|_2, \quad d_- = \|\boldsymbol{\psi}_t(\mathbf{u}_t) - \boldsymbol{\psi}_s(\mathbf{u}_s^-)\|_2$$

Distance correspondante $d_+ = 0.0033$ | Distance non correspondante $d_- = 0.6414$

Les non-correspondances imposent une séparation.

Appariement de descripteur (recherche de matches)

Image requête I_t

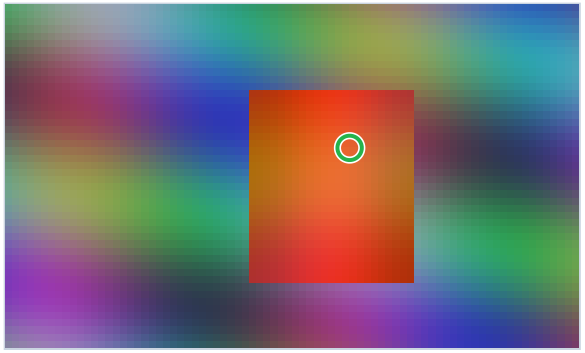
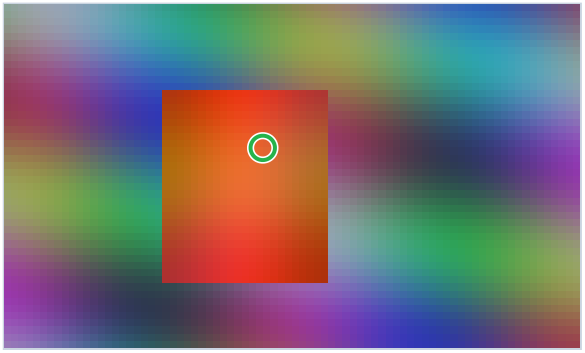
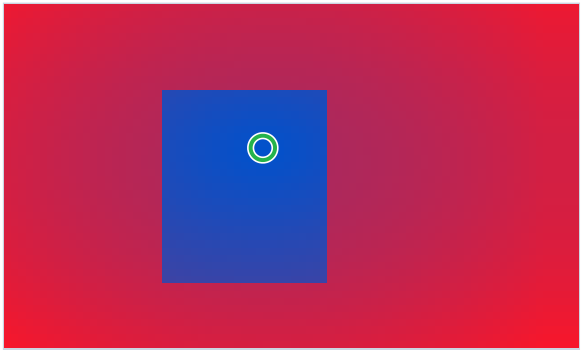


Image de recherche I_s



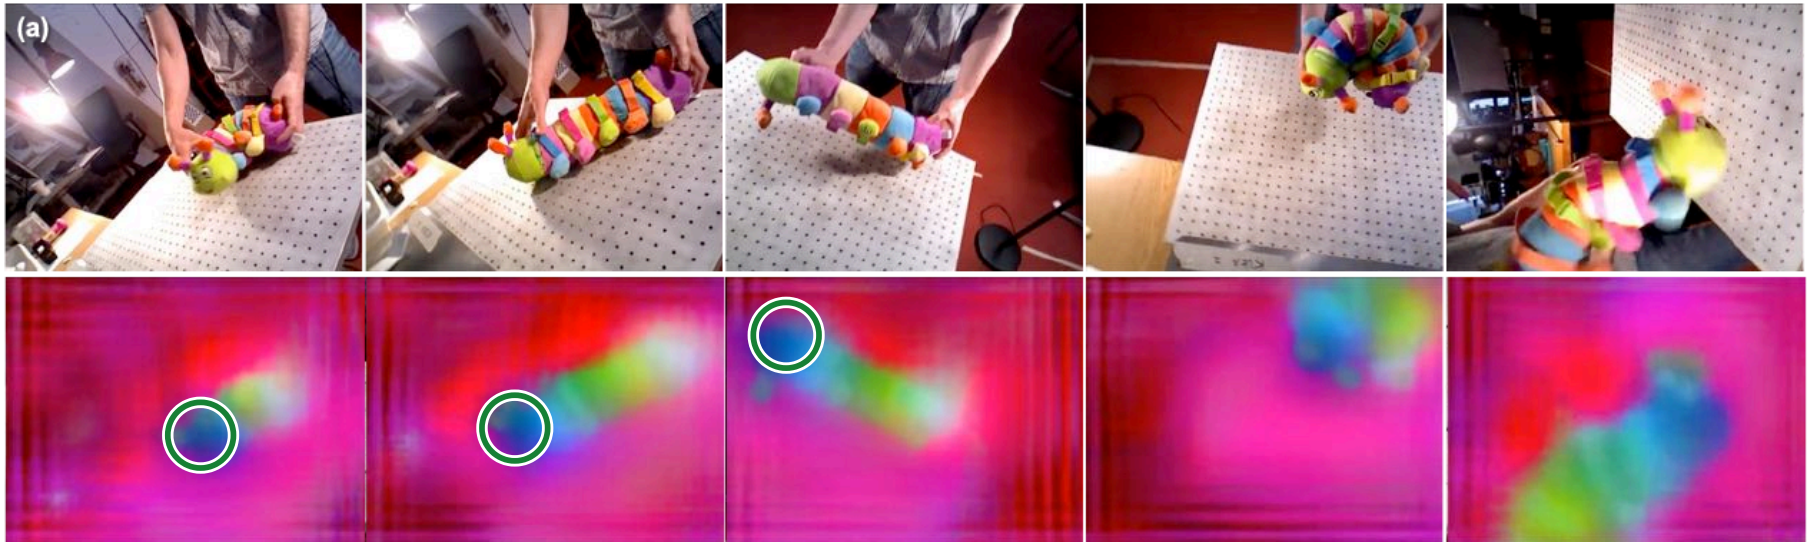
Distance · bleu : proche



$$\mathbf{u}_s^* = \arg\min_{\mathbf{u}_s} \|\boldsymbol{\psi}_t(\mathbf{u}_t) - \boldsymbol{\psi}_s(\mathbf{u}_s)\|_2$$

Cohérence des descripteurs entre configurations

Observations RVB en haut · couleurs des descripteurs denses en bas

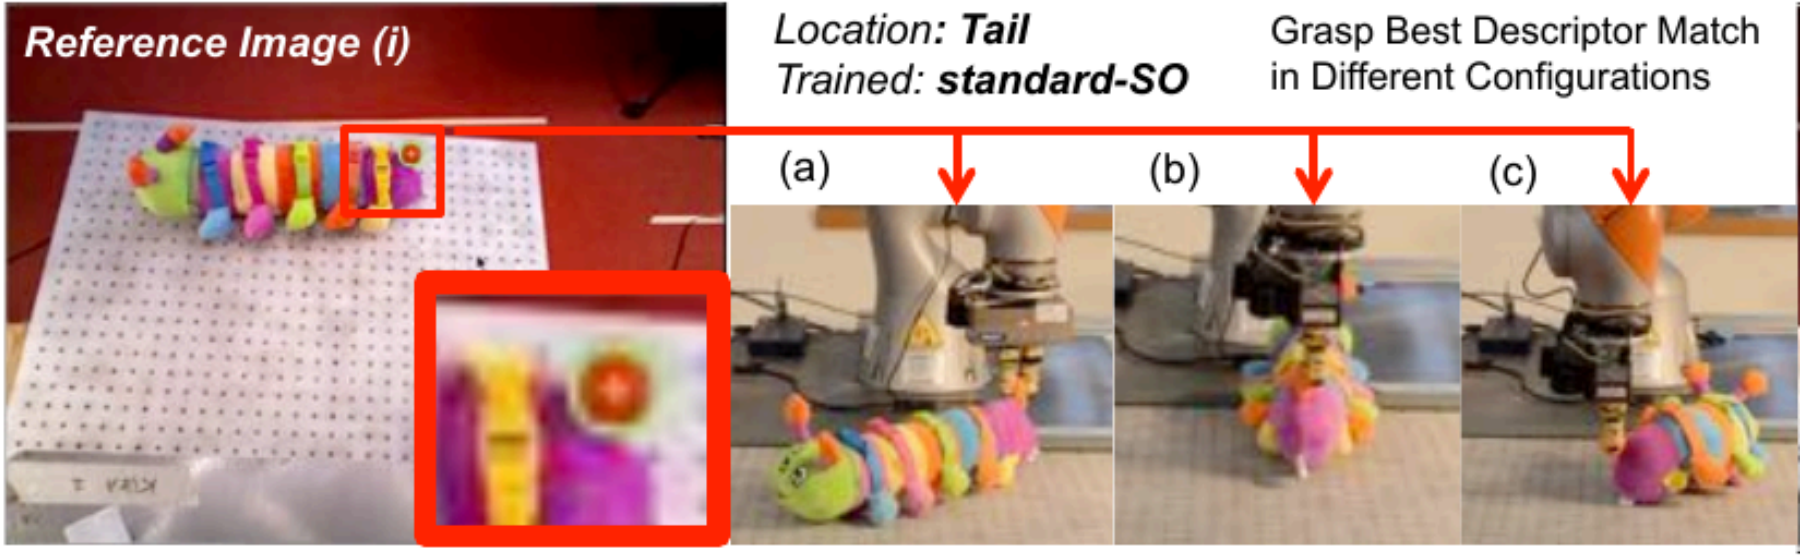


L'objet change de configuration; les régions correspondantes gardent des couleurs similaires.

> Les couleurs codent des descripteurs, sans étiquettes manuelles de parties sémantiques.

Florence et al., Dense Object Nets, CoRL 2018 · Fig. 2(a), les cinq configurations · arXiv v2

Trouver un point de prise

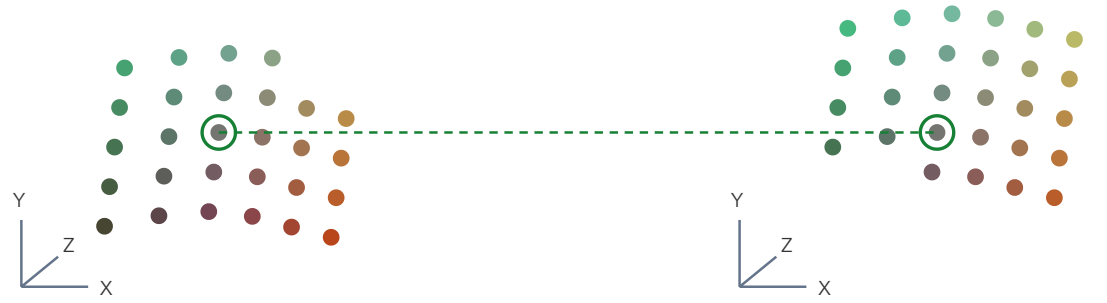


Florence et al., Dense Object Nets, CoRL 2018 · Fig. 6(i), queue, standard-so · arXiv v2

Extension aux correspondances 3D

Nuage A · repère a

Nuage B exprimé dans a



28 points

28 points · 20 points communs

$$p^a = R_b^a p^b + t_b^a$$

Requête p^a = [-0.18, -0.15, 0.49] · apparié p^b = [0.54, -0.48, 0.79]

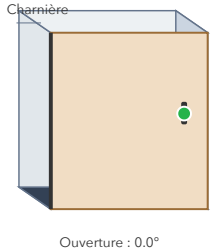
Des correspondances fiables et bien réparties peuvent contraindre un recalage rigide.

SECTION 07

Apprendre les possibilités d’action par l’expérience

Observation, action, résultat, cible

Observation antérieure x_t



t = 0 · avant l'action

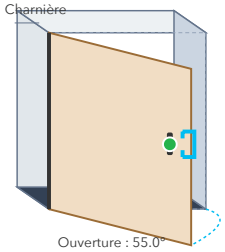
Action commandée a_t



Saisir l'anse, tirer vers l'extérieur

Ouverture désirée : ≥ 30°

Mesures capteurs ultérieures o



Contact détecté · ouverture 55°

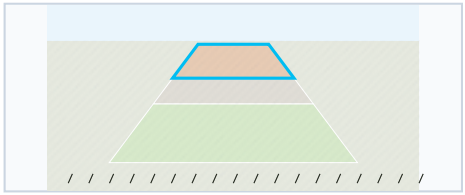
$$y_t = \Gamma(x_t, a_t, o_{t:t+\Delta})$$



Les gradients modifient θ et β; la cible mesurée reste fixe.

Prédiction illustrative 0.881 · cible mesurée 1 · perte binaire 0.1269

La traversabilité dépend du robot



Zone sélectionnée : boue · même commande 1.00 m/s



Roues étroites / contrôleur A

Mesuré 0.25 m/s

Perte : 0.75



Chenilles larges / contrôleur B

Mesuré 0.65 m/s

Perte : 0.35

La traversabilité dépend de plateforme, contrôle, action et règle de résultat.

Mesurer les résultats de traversée

Sol parcouru · vue du dessus

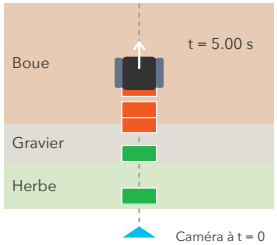


Image antérieure I_0 · t = 0

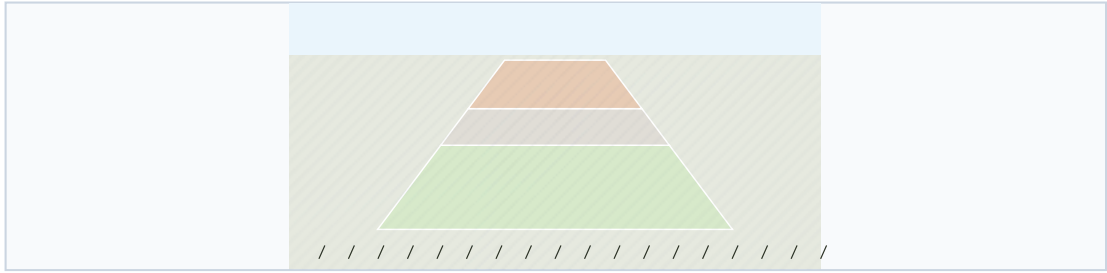


Image enregistrée → Résultat disponible

$$y = \Gamma(o) = \mathrm{clip}_{[0,1]}(1 - v_{\mathrm{meas}}/v_{\mathrm{cmd}})$$

Commande 1.00 m/s · mesure 0.60 m/s · perte y = 0.40

Le parcours mesure le mouvement; l'indicateur choisi le transforme en coût.

Supervision différée

Sol parcouru · vue du dessus

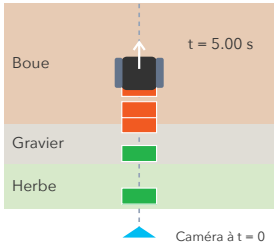


Image antérieure I_0 · $t = 0$

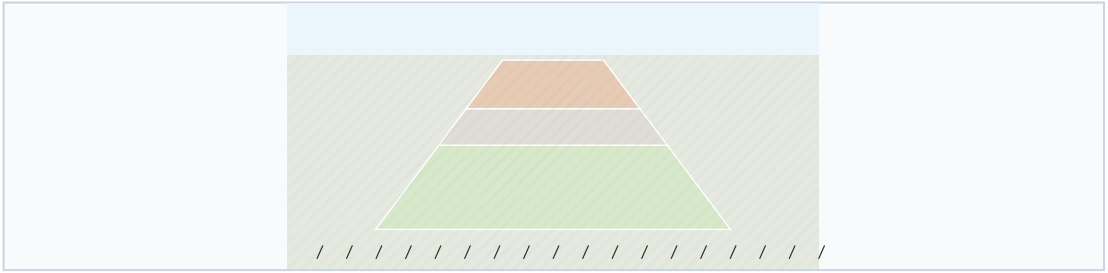


Image enregistrée → Résultat disponible

> Commande 1.00 m/s · mesure 0.60 m/s · perte y = 0.40

L'image antérieure est fixe. La cible n'arrive qu'après traversée réelle.

Reprojeter l'expérience

Sol parcouru · vue du dessus

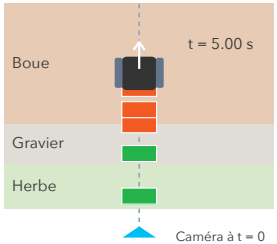
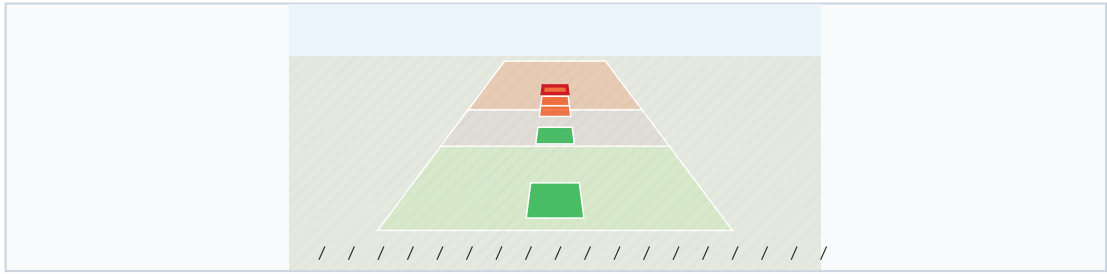


Image antérieure I_0 · $t = 0$



Coût faible observé · Coût élevé observé · Non visité

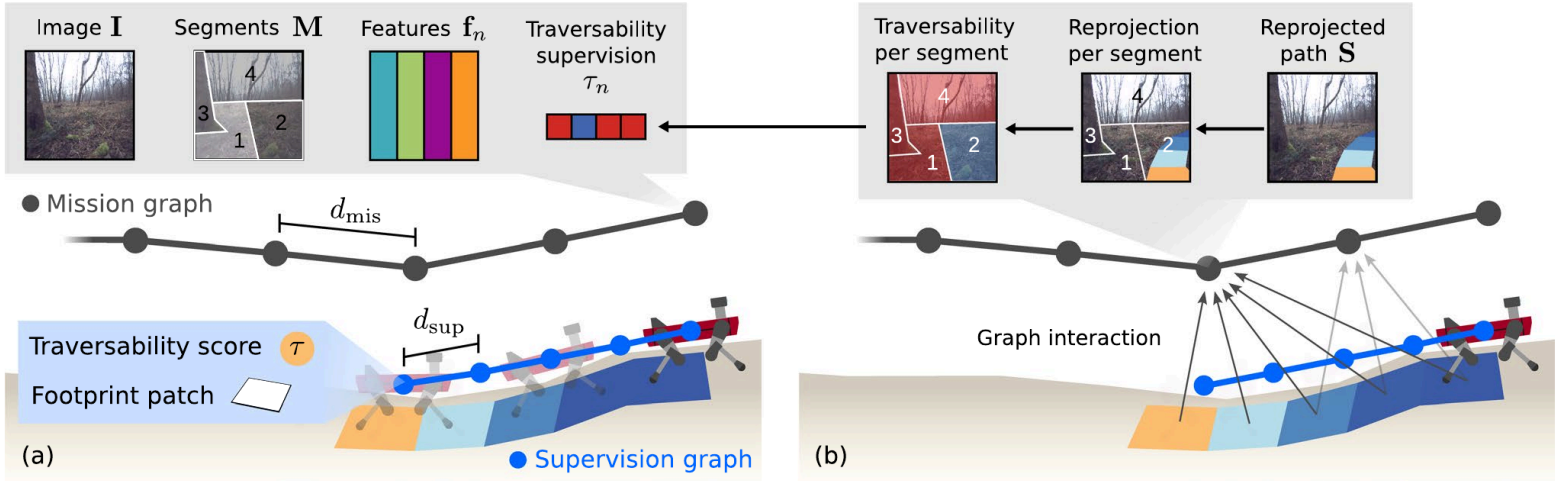
$$\mathbf{u}_0 = \pi\left(K_0\left(R_r^{c_0} p^r + t_r^{c_0}\right)\right)$$

Commande 1.00 m/s · mesure 0.60 m/s · perte y = 0.40 · 5 cibles projetées · décalage temporel de pose 0.0 s

Estimation locale jouet : 0.500 → cible mesurée 0.40 · erreur quadratique moyenne 0.0690

Restaurer la synchronisation avant d'utiliser ces cibles mesurées.

Wild Visual Navigation



Entrée visuelle

Images RVB et caractéristiques visuelles préentraînées

Signal mesuré

Vitesse plane commandée et estimée

Supervision accumulée

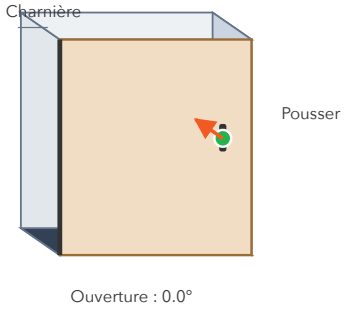
Scores d'empreintes reprojetés dans les images stockées

Le mouvement expérimenté fournit des cibles d'estimation visuelle de traversabilité.

Mattamala et al., WVN, Autonomous Robots 2025 · Fig. 5(a,b), page 6 du PDF du journal

Possibilités d’action en manipulation

Observation initiale fixe x_t



Tirer vers l’extérieur

Direction initiale d’ouverture

Le long de la porte fermée

Faible moment d’ouverture

Pousser vers l’intérieur

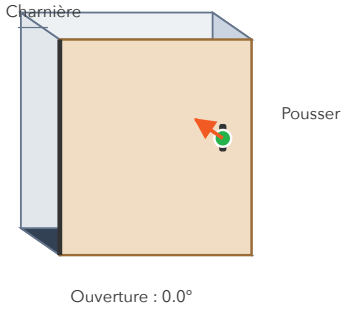
La butée bloque le mouvement

Rayon de contact 0.85 m · direction F = [0.00, 1.00, 0.00] · orientation de prise fixe

La même poignée produit des résultats différents selon la direction d’action.

Prédire le résultat d'une action

Observation initiale fixe x_t



Tirer vers l'extérieur

Direction initiale d'ouverture

Le long de la porte fermée

Faible moment d'ouverture

Pousser vers l'intérieur

La butée bloque le mouvement

Rayon de contact 0.85 m · direction F = [0.00, 1.00, 0.00] · orientation de prise fixe

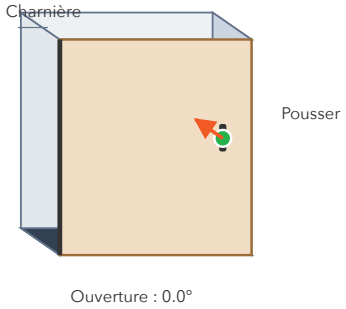
$$\hat{y}_t = h_\beta(f_\theta(x_t), a_t)$$

Succès d'ouverture prédit : 0.018

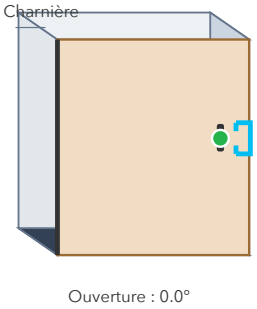
Prédire à partir de l'observation et de l'action proposée, avant de voir le résultat.

Construire automatiquement une cible d'action

Observation initiale fixe x_t



Observation après action · action terminée



Rayon de contact 0.85 m · direction F = [0.00, 1.00, 0.00] · orientation de prise fixe

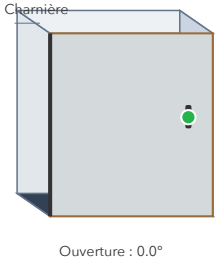
$$y_t = \Gamma(o) = \mathbf{1}[\text{ouverture mesurée} \geq 30^\circ]$$

Succès d'ouverture prédit : 0.018 · Ouverture mesurée 0.0° → cible automatique y = 0

Objectif : ouvrir d'au moins 30°.

ActAIM : apprendre à partir d'interactions

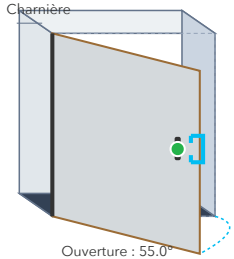
Profondeur initiale D_0



Exécuter l'action en simulation

- Point de contact p
- Orientation de pince R
- Direction de mouvement F

Profondeur ultérieure D_1



Encoder les profondeurs avant / après → Seuil de changement de plongement → **Étiquette automatique d'interaction**

Apprendre des modes d'interaction
Modèle latent + géométrie locale

→

Proposer des actions
Où et comment interagir

L'article apprend une distribution d'interactions produisant un changement visuel.

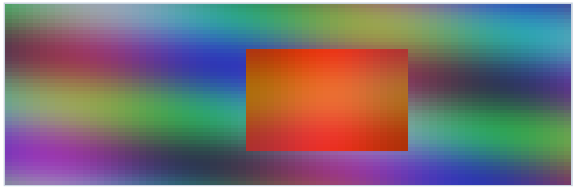
Un changement ne spécifie pas à lui seul « ouvrir cette porte de 30° ».

Wang et al., ActAIM, ICRA 2023 · Sections III, IV-A/B, V-A · arXiv v1

En résumé: Le principe d'apprentissage

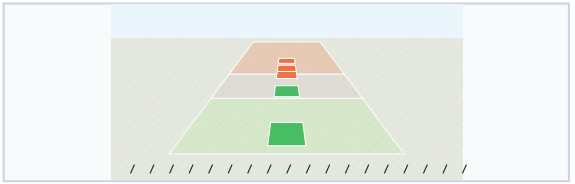
Association géométrique

Vue caméra enregistrée



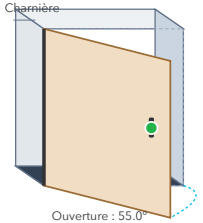
Profondeur + poses + visibilité
→ pixels correspondants

Expérience de traversée



Commande + mouvement mesuré
→ cibles de coût local

Interaction avec le meuble



Résultat de tâche mesuré
→ cible de succès

$$\hat{y}_t = h_\beta(f_\theta(x_t), a_t), \qquad y_t = \Gamma(x_t, a_t, o_{t:t+\Delta})$$



Les gradients modifient θ et β; la cible mesurée reste fixe.

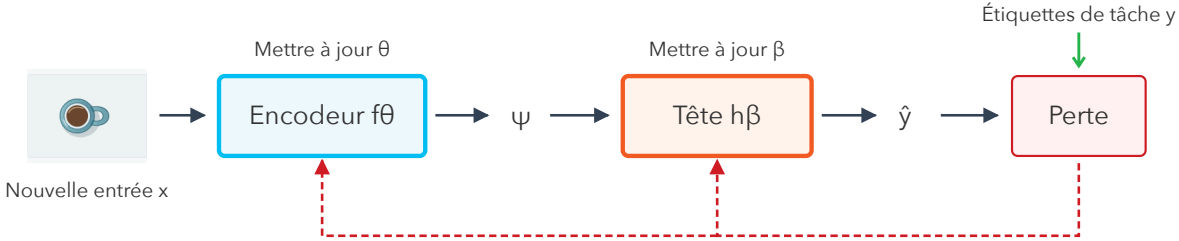
> Identifier la source et le domaine de la cible, et ce que le modèle doit prédire.

SECTION 08

Considérations importantes à retenir

Adaptation

Ajuster l'encodeur et la tête



$$\Theta = (\theta, \beta), \quad \text{modifier encodeur et tête}$$

Caractéristiques gelées

Évaluer l'information accessible à la tête choisie.

fine tuning

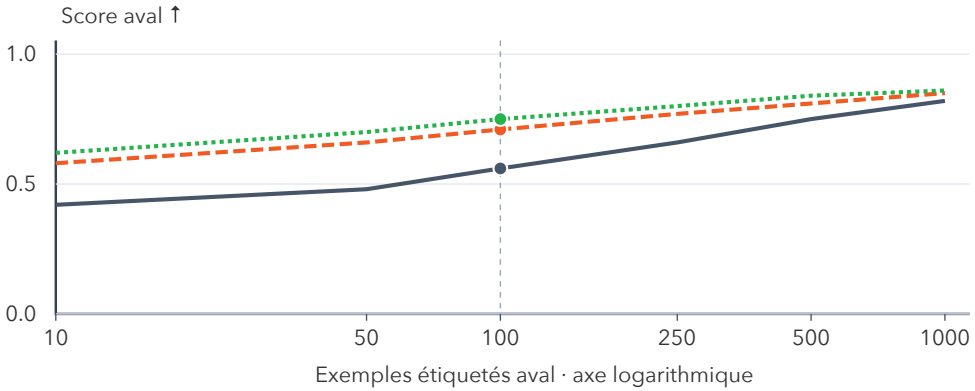
Adapter les caractéristiques et la tête à la tâche cible.

Une sonde linéaire exige hβ linéaire. Un encodeur gelé peut aussi alimenter une tête non linéaire.

Chen et al., SimCLR, ICML 2020 · Annexe B.8

Efficacité des étiquettes (label efficiency)

Courbes illustratives



Initialisation aléatoire **0.56** Préentraînement supervisé **0.71** Préentraînement auto-supervisé **0.75**

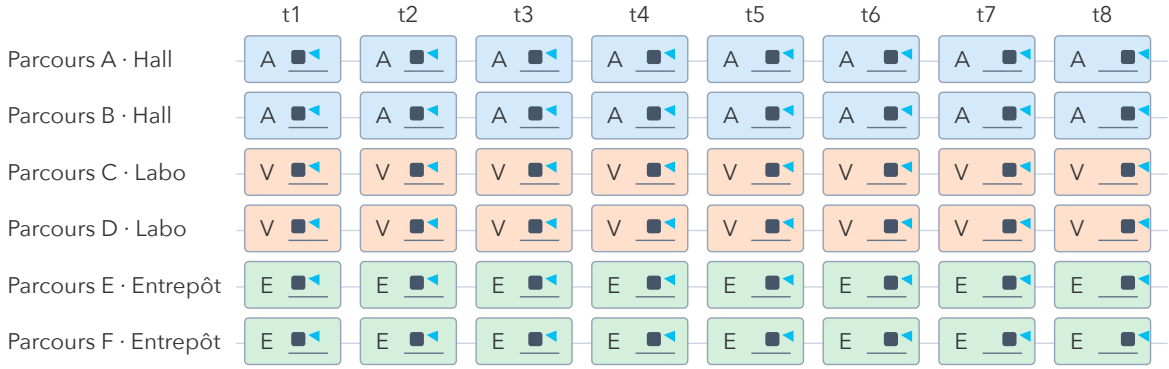
Même partition aval et tête · règles de réglage cohérentes
Rapporter séparément données, annotations et calcul du préentraînement.

Comparer le besoin d'étiquettes à un score et un protocole spécifiés.

Partitionner correctement les données robotiques

A · Apprentissage V · Validation E · Test / évaluation

Le temps avance →



Audit apprentissage/test · paires voisines : **0** · trajectoires communes : **0** · environnements communs : **0**

Environnements séparés dans ces métadonnées; vérifier aussi les enregistrements.

Choisir la partition selon la généralisation : parcours, session, objet ou environnement.

scikit-learn · évaluation groupée; regroupement robotique illustratif

Évaluer la tâche de perception visée

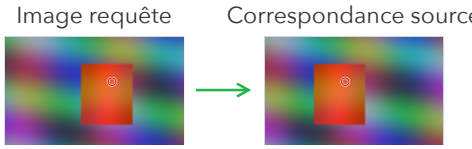
Profondeur

AbsRel = mean(|D̂ − D| / D)

Référence D	2 m	4 m	6 m
Prédiction D̂	2.0 m	4.0 m	6.0 m

AbsRel : **0.000** · aligné par médiane

Correspondance



Erreur pixel / rappel sur paires visibles réservées

Traversabilité



Erreur de coût sur zones réservées parcourues

Possibilité d'action en manipulation



Traction à l'anse
Ouverture prédite
succès : **0.881**

Classification ou perte probabiliste sur résultats réservés

L'alignement utilise la profondeur de référence à l'évaluation, sans retrouver l'échelle métrique à l'inférence.

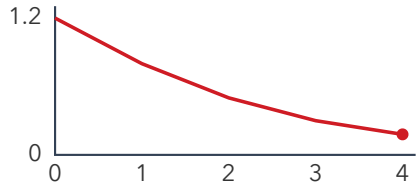
Erreur prédictive et succès en boucle fermée répondent à des questions différentes.

Évaluateur officiel Monodepth2 · AbsRel et échelle médiane monoculaire

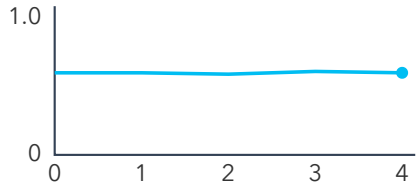
Perte prétexte et utilité aval

Exemple construit · ces courbes ne sont pas des résultats expérimentaux

Perte prétexte d'apprentissage ↓



Score aval sur données réservées ↑



Axes horizontaux : étape d'optimisation n

Étape d'optimisation n = 4 · perte prétexte 0.18 · score aval 0.60



→



Caractéristiques du fond seul

Vues en accord, mais position d'anse perdue.

Une perte prétexte plus faible ne prouve pas un progrès sur la tâche du robot.

Synthèse du cours

Vues liées

$\tilde{x}_1 \leftrightarrow \tilde{x}_2$

Transformation / temps

Observations masquées

$x_k \rightarrow$ cible x_k

Pixels retirés

Self-Distillation

$$\mathrm{sg}(f_{\bar{\theta}}(x))$$

Caractéristiques cibles

Géométrie

Profondeur + poses

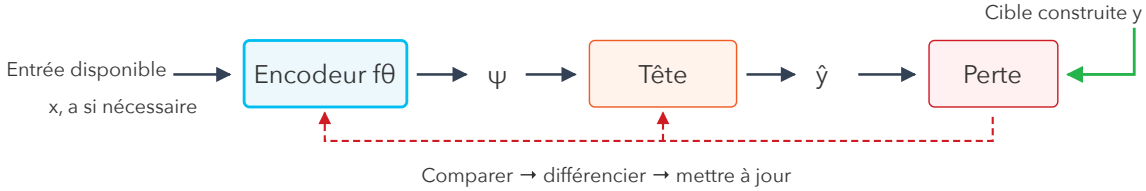
Profondeur / paires visibles

Mesures ultérieures

o → Γ → y

Traversée / interaction

Sources de cibles alternatives, chacune avec sa règle et ses observations valides.



Hypothèses du signal Relations entre vues · représentation · visibilité · synchronisation · support de mesure

À retenir: Une même représentation peut être réutilisée pour plusieurs tâches.

SOURCES DU COURS

Références

Références : apprentissage de représentations

SimCLR A Simple Framework for Contrastive Learning of Visual Representations
T. Chen, S. Kornblith, M. Norouzi, G. Hinton. **ICML 2020.**

DINO Emerging Properties in Self-Supervised Vision Transformers
M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, A. Joulin. **ICCV 2021.**

VICReg VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning
A. Bardes, J. Ponce, Y. LeCun. **ICLR 2022.**

MAE Masked Autoencoders Are Scalable Vision Learners
K. He, X. Chen, S. Xie, Y. Li, P. Dollár, R. Girshick. **CVPR 2022.**

I-JEPA Self-Supervised Learning From Images With a Joint-Embedding Predictive Architecture
M. Assran, Q. Duval, I. Misra, P. Bojanowski, P. Vincent, M. Rabbat, Y. LeCun, N. Ballas. **CVPR 2023.**
Code officiel d'apprentissage: src/train.py

Autres sources citées dans le cours

FixMatch FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence
K. Sohn, D. Berthelot, C.-L. Li, Z. Zhang, N. Carlini, E. D. Cubuk, A. Kurakin, H. Zhang, C. Raffel. **NeurIPS 2020.**

NetVLAD NetVLAD: CNN Architecture for Weakly Supervised Place Recognition
R. Arandjelović, P. Gronat, A. Torii, T. Pajdla, J. Sivic. **CVPR 2016.**

Références : géométrie et correspondances

Monodepth2

Digging Into Self-Supervised Monocular Depth Estimation

C. Godard, O. Mac Aodha, M. Firman, G. Brostow. **ICCV 2019.**

Évaluateur officiel de profondeur: evaluate_depth.py · commit b017a81

TCN

Time-Contrastive Networks: Self-Supervised Learning from Video

P. Sermanet, C. Lynch, Y. Chebotar, J. Hsu, E. Jang, S. Schaal, S. Levine. **ICRA 2018.**

Dense Object Nets

Dense Object Nets: Learning Dense Visual Object Descriptors By and For Robotic Manipulation

P. R. Florence, L. Manuelli, R. Tedrake. **CoRL 2018.**

Références : interaction et évaluation

WVN

Wild visual navigation: fast traversability learning via pre-trained models and online self-supervision

M. Mattamala, J. Frey, P. Libera, N. Chebrolu, G. Martius, C. Cadena, M. Hutter, M. Fallon.
Autonomous Robots 49, article 19, 2025.

ActAIM

Self-Supervised Learning of Action Affordances as Interaction Modes

L. Wang, N. Dvornik, R. Dubeau, M. Mittal, A. Garg. **ICRA 2023.**

Source d'évaluation

Évaluation

Cross-validation: evaluating estimator performance — grouped-data iterators

scikit-learn developers. **Documentation officielle · consultée le 7 octobre 2026.**