

Apprentissage auto-supervisé pour la perception robotique

INF8422 : Perception robotique et intelligence spatiale

Prof. Pierre-Yves Lajoie · Polytechnique Montréal

**POLYTECHNIQUE
MONTREAL**



Observation caméra et profondeur estimée


Godard et al., Monodepth2, ICCV 2019, Fig. 1 (ligne supérieure)

SECTION 01

Mécanismes d'apprentissage auto-supervisé



Signaux de supervision disponibles pour un robot




Une règle doit définir la cible

Les données enregistrées peuvent fournir un signal d'apprentissage si l'on définit une relation valide entre les observations.

Définition de l'apprentissage auto-supervisé


L'apprentissage auto-supervisé entraîne un modèle à partir de signaux de supervision dérivés automatiquement des données elles-mêmes, sans nécessiter d'étiquettes annotées manuellement pour cette étape d'apprentissage.



L'origine de la cible d'apprentissage détermine le régime de supervision.

Apprentissages supervisé, auto-supervisé et semi-supervisé


Supervisé



Exemples annotés manuellement

→ Perte sur annotations


Auto-supervisé



Cibles construites automatiquement

→ Perte issue des données

Semi-supervisé



Exemples étiquetés + non étiquetés

→ Termes supervisés + non étiquetés

La fonction de perte (coût) ne suffit pas à identifier le régime

L'erreur quadratique et l'entropie croisée peuvent autant comparer des prédictions à des cibles manuelles ou automatiques.

Tâches prétextes et cibles automatiques




Prédiction de pixels masqués

Entrée : information visible



Pixels observés retirés

Cible : sélection de l'image originale



Appariement de vues liées

Entrée : deux images donc on connaît la relation



Une association connue

Cible : relation connue (ex: rotation, translation, chevauchement)



Prédiction directe du résultat

Entrée : observation avant l'action




Coût de traversée mesuré : 0.4

Cible : mesures après l'action

Une tâche prétexte construit une représentation par prédiction ou appariement.

Préentraînement et ajustement fin facultatif



Encodeur f_{θ}

Apprendre une représentation




Prédiction prétexte

Cible issue des données



Réutiliser l'encodeur appris



Encodeur f_{θ}

Gelé ou adapté



Tête de tâche h_{β}

Catégorie d'objet, par exemple

Les étiquettes manuelles peuvent servir à l'adaptation ou à l'évaluation.

Deux choix d'adaptation


Geler l'encodeur et entraîner une tête de tâche, ou ajuster l'encodeur avec la tête.

Apprentissage direct à partir de résultats mesurés

Observer le terrain

Exécuter un mouvement fixe connu

Mesurer le résultat



Vitesse commandée : 1.0 m/s

Vitesse mesurée : 0.6 m/s

Cible automatique Coût illustratif = $1 - \text{mesuré} / \text{commandé} = 0.4$

Image caméra antérieure




Encodeur + tête de tâche



Coût de traversée prédit

Masquage: Entrée, prédiction et cible




$$y_i = (x_{i,k})_{k \in \mathcal{M}}$$

Copier les valeurs observées masquées dans la branche cible.

i identifie une observation · Θ regroupe les paramètres de l'encodeur et du décodeur · $\mathcal{M}$ sélectionne les positions masquées


Masquage: Perte et mise à jour des paramètres



$$\Theta_{n+1} = \Theta_n - \eta \nabla_{\Theta} \mathcal{L}$$

n compte les pas d'optimisation. η règle l'amplitude de chaque mise à jour.

Masquage: Ce qui reste après l'apprentissage



Garder f_θ · remplacer d_ω par une tête de tâche si adapté

$$\psi = f_\theta(x) \quad \hat{y}^{\text{task}} = h_\beta(\psi)$$

Encoder une nouvelle observation. La tâche détermine la tête de sortie.




Évaluer la représentation conservée sur la tâche de perception visée.

SECTION 02

Représentations pour la perception



Représentations de l'encodeur



$$\psi = f_{\theta}(x)$$

Une description réutilisable


La qualité d'une représentation dépend de l'information disponible pour la tâche visée.

Caractéristiques globales et denses

Caractéristiques globales : 1 vecteur par image

Reconnaître un lieu déjà visité


Image requête



Encodeur $f\theta \downarrow$

0.42 -0.18 0.73

Image stockée



Encodeur $f\theta \downarrow$


0.40 -0.20 0.71

Comparer les descripteurs globaux

Caractéristiques denses : vecteurs par position

Trouver le point d'anse correspondant


Image de référence




Encodeur $f\theta \downarrow$



Nouvelle image



Encodeur $f\theta \downarrow$




-0.24 0.81 0.46

Invariance aux changements non pertinents

Pour **reconnaître cette tasse**, l'éclairage et l'arrière-plan peuvent être des variables parasites.

On procède donc à des **augmentations** lors de l'entraînement.

Observation de référence



→
changer
l'apparence

Observation modifiée



Identité désirée

même tasse

Éclairage : 0.55×

Arrière-plan : motif

Les pixels changent; la décision de reconnaissance reste stable.


Conserver l'information qui identifie l'objet malgré les changements choisis.

Information spatiale nécessaire à l'action

Pour **saisir l'anse**, sa position et son orientation doivent rester accessibles.


On procède donc à des **augmentations** lors de l'entraînement.

Observation de référence



→
déplacer la
tasse

Observation modifiée



Prise en coordonnées image

(212.5, 90.1)

$\alpha = -40^\circ$ · positif horaire

B : même descripteur illustratif


-0.24	0.81	0.46
-------	------	------

Le descripteur d'anse reste associé à B; position et orientation changent.


Les caractéristiques correspondantes peuvent rester cohérentes alors que leurs positions changent.

Objectifs d'appariement et de prédiction

Apparier les observations liées



Prédire l'information masquée



Deux mécanismes à suivre

L'appariement utilise une relation connue entre observations.


Alors que le masquage utilise une information observée retirée de l'entrée.

SECTION 03

Appariement, effondrement et auto-distillation



Encodeur et tête de projection



Réutiliser la représentation de l'encodeur


Comparer les projections

$$\psi_i^{(v)} = f_\theta(\tilde{x}_i^{(v)}) \quad \mathbf{q}_i^{(v)} = g_\phi(\psi_i^{(v)})$$

L'objectif compare q . Plusieurs tâches différentes en aval (downstream) peuvent réutiliser ψ de l'encodeur.

Similarité et température

Ancre (1, 1) · Positif (1, 2)




Candidat (i, v)

(1, 2) · positif
(2, 1) · négatif
(2, 2) · négatif
(3, 1) · négatif
(3, 2) · négatif

cosinus

0.848
0.407
-0.139
-0.951
-0.545


Probabilité normalisée



$\tau = 0.50 \cdot \text{probabilité positive} = 60.9\% \cdot \ell = 0.496$

$$\text{sim}(\mathbf{q}_a, \mathbf{q}_b) = \frac{\mathbf{q}_a^T \mathbf{q}_b}{\|\mathbf{q}_a\|_2 \|\mathbf{q}_b\|_2}$$

Perte contrastive



Architecture publiée de SimCLR

Article $h \rightarrow$ cours ψ

Article $z \rightarrow$ cours q


Après préentraînement : garder $f\theta$.

Évaluer les caractéristiques de l'encodeur.

Chen et al. · ICML 2020 · Fig. 2

Effet de l'objectif sur les représentations

Vue transformée $\rightarrow f\theta \rightarrow \psi \rightarrow g\varphi \rightarrow q$




Candidat (i, v)	cosinus	Probabilité normalisée	
(1, 2) · positif	0.990		82.6%
(2, 1) · négatif	-0.423		4.9%
(2, 2) · négatif	-0.545		3.8%
(3, 1) · négatif	-0.545		3.8%
(3, 2) · négatif	-0.423		4.9%

$$\tau = 0.50 \cdot \text{probabilité positive} = 82.6\% \cdot \ell = 0.192 \cdot \text{moyenne des six ancres} = 0.189$$

Augmenter l'accord avec le positif relativement aux vues concurrentes.

Représentation constante: Effondrement



Trois originaux · deux vues chacun

Perte moyenne d'accord des paires : **0.0000**

Dispersion : (0.000, 0.000)

Un vecteur constant efface les distinctions entre observations.


$\mathbf{c} = (0.20, 0.15)$

$$f_{\theta}(x) = \mathbf{c} \text{ pour tout } x \implies \ell_{\text{agree},i} = 0$$

Il faut éviter qu'une solution optimale possible de l'apprentissage soit l'effondrement (collapse) de la représentation.


Perte de dimensions de représentation

Point : effondrement complet




Écart-type : (0.00, 0.00)

Ligne : une direction variable



Écart-type : (0.89, 0.89)


Deux directions variables



Écart-type : (0.91, 0.88)

Régularisation: Variance-Invariance-Covariance (VICReg)

Vue $\rightarrow f\theta \rightarrow \psi \rightarrow \mathbf{g}\phi$ (expandeur) $\rightarrow \mathbf{q}$ · régulariser $\mathbf{q}$ des deux branches



Invariance · 0.0000

Distance entre vues correspondantes

Variance · 0.0000

Plancher d'écart-type par dimension

Covariance · 0.0000


Covariance hors diagonale au carré

$$\mathcal{L}_{\text{VICReg}} = \lambda_{\text{inv}} \mathcal{L}_{\text{inv}} + \lambda_{\text{var}} \mathcal{L}_{\text{var}} + \lambda_{\text{cov}} \mathcal{L}_{\text{cov}}$$

La covariance décourage les directions redondantes.

Bardes et al. · VICReg · ICLR 2022


Auto-Distillation: Apprendre des cibles fournies par un enseignant



Une cible qui évolue pendant l'apprentissage

L'étudiant prédit une sortie enseignante à partir d'une autre vue de l'observation.

Architecture de DINO



Étudiant et enseignant : encodeur + tête

$$g_{\theta_s} \leftrightarrow g_{\phi} \circ f_{\theta}$$

$$g_{\theta_t} \leftrightarrow g_{\bar{\phi}} \circ f_{\bar{\theta}}$$

Centrer les sorties enseignantes, puis appliquer des températures softmax distinctes.


Couper le gradient enseignant; modifier ses paramètres par moyenne mobile.

Caron et al. · DINO · ICCV 2021 · Fig. 2 principale


Apparier les distributions; mettre à jour étudiant et enseignant selon des règles distinctes.

Appariement de distributions dans DINO

Étudiant · vue 2




Enseignant · vue 1 · gradient coupé



$$\ell_{\text{DINO}} = - \sum_e \rho_{\text{teach},e} \log \rho_{\text{stu},e}$$

Entropie croisée calculée pour une paire : **1.0230**

Mises à jour par gradient et moyennes mobiles




$$\bar{\theta}_{n+1} = \mu \bar{\theta}_n + (1 - \mu) \theta_{n+1}$$

Encodeur : $\theta = 0.488 \cdot \bar{\theta} = 0.578$ Tête : $\phi = 0.830 \cdot \bar{\phi} = 0.966$

Après un lot (batch): mettre à jour la tête enseignante $\bar{\phi}$ avec une moyenne mobile.


Résumé de l'apprentissage de représentation

SimCLR




Vues concurrentes

VICReg



Dispersion + décorrélation

DINO



Cible centrée et accentuée

Distribution enseignante

Observation → encodeur → caractéristiques → relation ou cible → perte → mise à jour

L'objectif d'une bonne représentation

Conserver l'information utile à la tâche visée.

Ignorer le reste.


SECTION 04

Reconstruction et prédiction de caractéristiques



La reconstruction comme signal d'apprentissage

Entrée partiellement observée




Les pixels originaux observés fournissent la cible.

Retirer l'information de l'entrée de prédiction, en la conservant pour la cible.


L'observation originale fournit une cible sans annotation humaine.

Blocs visibles et masqués

Observation originale x




Blocs visibles V · masqués M



Jetons visibles + positions

L'encodeur MAE reçoit les jetons visibles et leurs positions originales.

Architecture de MAE




Les jetons de masque entrent dans le décodeur après encodage du visible.


He et al., MAE, CVPR 2022 · Fig. 1 · arXiv v3

Perte de reconstruction aux positions masquées


Pixels cibles originaux



Entrée encodeur visible



Prédiction de pixels illustrative




$$\mathcal{L}_{\text{pixel}} = \frac{1}{|\mathcal{M}|} \sum_{k \in \mathcal{M}} \|\hat{x}_k - x_k\|_2^2$$

Moyenner sur 36 blocs masqués : $\mathcal{L}_{\text{pixel}} = 148.32$

Erreurs visibles exclues; la perte de base agit sur $\mathcal{M}$.

Reconstruction plausible et ambiguïté



Plusieurs complétions possibles


Le contexte visible ne détermine pas chaque détail masqué.

Les sorties diffèrent des originaux, avec une structure de scène plausible.

La plausibilité visuelle ne prouve ni compréhension sémantique ni précision robotique.

He et al., MAE, CVPR 2022 · Fig. 3, deux exemples les plus à droite · arXiv v3 · Images de validation COCO; modèle préentraîné sur ImageNet

Que demande de conserver une cible de prédiction ?




Structure de véhicule
Indices utiles à la tâche

La tâche peut privilégier la structure des objets et de la route.

La cible définit les erreurs de prédiction à réduire.

Les caractéristiques utiles à apprendre dépendent de la tâche.

JEPA: Prédire dans l'espace des caractéristiques




$$\psi_k^{\text{target}} = f_{\bar{\theta}}(x)_k$$



Changer le calcul de cible pour qu'elle soit dans l'espace intermédiaire des caractéristiques. Sans avoir à décoder dans l'espace de prédiction (ex: image). Permet d'apprendre des concepts plus abstraits. Entraînement à grande échelle plus efficace.

JEPA: Contexte et positions cibles

Original · blocs spatiaux A, B, C




Contexte V · toutes les cibles retirées



Le jeton indique où prédire, sans contenir de pixels masqués.

$$\widehat{\psi}_k = h_\beta(f_\theta(x_V), k)$$

JEPA: Perte de caractéristiques et mises à jour des cibles




$$\bar{\theta}_{n+1} = \mu \bar{\theta}_n + (1 - \mu) \theta_{n+1}$$

Lfeature = 0.1515

$\theta = 0.833 \cdot \beta = 0.738 \cdot \bar{\theta} = 0.967$

L'EMA transfère les paramètres du contexte; le prédicteur n'a pas de copie EMA.

Architecture d'I-JEPA



Assran et al., I-JEPA, CVPR 2023 · Fig. 3 · arXiv v3

Cibles de pixels et cibles de caractéristiques

MAE · cible de pixels



I-JEPA · cible de caractéristiques




SECTION 05

Supervision géométrique




Apprendre la profondeur à partir de plusieurs observations


Scène 3D synthétique · vue fixe



Cible enregistrée $I_t \cdot u \rightarrow, v \downarrow$



Source enregistrée I_s




Le marqueur source suit la projection calculée.

$$D = 3.50 \cdot \hat{p} \text{ dans } c_t : [1.06, -0.18, 3.50] \cdot u_s = [49.31, 20.00]$$

L'image enregistrée fournit la cible; profondeur et pose sont prédites.

La structure de scène et le mouvement caméra peuvent fournir un signal d'apprentissage.

Notation des poses dans le cours



Coordonnées dans le robot

$$p^r = [1.00, 0.60, 0.00]$$

Coordonnées dans le monde


$$p^w = [2.57, 1.42, 0.00]$$

Translation : origine de r exprimée dans w.


$$p^w = R_r^w p^r + t_r^w$$

Projection caméra et paramètres intrinsèques


Scène 3D synthétique · vue fixe



Cible enregistrée $I_t \cdot u \rightarrow, v \downarrow$



Source enregistrée I_s



Le marqueur source suit la projection calculée.


$$K_t = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

$f_x = f_y = 68 \cdot c_x = 39.5 \cdot c_y = 23.5 \cdot X$ droite, Y bas, Z avant


La profondeur est Z optique, distinct de la distance sur un rayon unitaire.

Rétroprojeter un pixel cible


Scène 3D synthétique · vue fixe



Cible enregistrée $I_t \cdot u \rightarrow, v \downarrow$



Source enregistrée I_s



Le marqueur source suit la projection calculée.


$$\hat{p}^{c_t} = \widehat{D}_t(\mathbf{u}) K_t^{-1} \tilde{\mathbf{u}}$$

$\tilde{D} = 5.00 \cdot \hat{p}$ dans c_t : $[1.51, -0.26, 5.00] \cdot u_s = [52.52, 20.00]$


L'estimation de profondeur déplace le point sur un rayon cible fixe.

Changer de repère caméra


Scène 3D synthétique · vue fixe



Cible enregistrée I_t · u →, v ↓



Source enregistrée I_s



Le marqueur source suit la projection calculée.


$$\hat{p}^{c_s} = \widehat{R}_{c_t}^{c_s} \hat{p}^{c_t} + \hat{t}_{c_t}^{c_s}$$

$\hat{p}$ dans c_t : [1.51, -0.26, 5.00] · $\hat{p}$ dans c_s : [0.96, -0.26, 5.00]


La pose estimée modifie les coordonnées et l'échantillonnage; les observations restent fixes.

Projection source et échantillonnage


Scène 3D synthétique · vue fixe



Cible enregistrée $I_t \cdot u \rightarrow, v \downarrow$



Source enregistrée I_s



■ Cible ■ Échantillonné **RVB L1 = 0.1420**

Voisins bilinéaires · poids

■ 0.69 ■ 0.31 ■ 0.00 ■ 0.00


$$\hat{Z}_s > 0 \quad 0 \leq u_s \leq 79 \quad 0 \leq v_s \leq 47$$

$$D = 3.50 \cdot \hat{p} \text{ dans } c_t : [1.06, -0.18, 3.50] \cdot u_s = [49.31, 20.00]$$


L'interpolation bilinéaire combine les pixels sources voisins enregistrés.

Perte de reconstruction photométrique

Cible enregistrée I_t



Cible reconstruite $\hat{I}_t$



Erreur RVB L1 · clair = élevé




$$\mathcal{L}_{\text{photo}} = \frac{1}{|\Omega|} \sum_{\mathbf{u} \in \Omega} \|I_t(\mathbf{u}) - \hat{I}_t(\mathbf{u})\|_1$$

Moyenne RVB L1 = $0.0448 \cdot 3456 / 3840$ pixels dans Ω

Ω exclut projections derrière caméra et hors image; les occultations restent incluses.

Mettre à jour les réseaux de profondeur et de pose



$$\Theta_{n+1} = \Theta_n - \eta \nabla_{\Theta} \mathcal{L}_{\text{photo}}, \quad \Theta = (\theta, \beta)$$


$$\theta = \hat{D} = 3.504 \cdot \beta = \text{base estimée} = 0.524$$

$$\text{RVB L1 d'un pixel} = 0.1181$$


Mise à jour scalaire calculée : moins d'erreur ne fixe pas l'échelle métrique.

Ambiguïté d'échelle monoculaire


Scène 3D synthétique · vue fixe



Cible enregistrée $I_t \cdot u \rightarrow, v \downarrow$



Source enregistrée I_s



■ Cible ■ Échantillonné **RVB L1 = 0.0004**

Le marqueur source suit la projection calculée.


$$\pi(K_s \kappa \hat{p}^{c_s}) = \pi(K_s \hat{p}^{c_s}), \quad \kappa > 0$$

$D = 10.00 \cdot \hat{p}$ dans $c_t : [3.01, -0.51, 10.00] \cdot u_s = [52.52, 20.00]$


Mettre profondeur et translation relative à l'échelle ensemble; les pixels restent fixes.

Objets en mouvement indépendant


Scène 3D synthétique · vue fixe



Cible enregistrée $I_t \cdot u \rightarrow, v \downarrow$



Source enregistrée $I_s \cdot$ objet mobile



■ Cible ■ Échantillonné **RVB L1 = 1.0106**


Rouge : rigide · vert : point mobile réel

Reprojection rigide $u_s = [35.53, 20.00]$ · point mobile $u_s = [53.67, 20.00]$


L'objet mobile viole la scène statique; sa reprojection rigide est incohérente.

Occultation et désoccultation


Scène 3D synthétique · vue fixe



Cible enregistrée $I_t \cdot u \rightarrow, v \downarrow$



Source enregistrée I_s



■ Cible ■ Échantillonné **RVB L1 = 1.2332**

Le marqueur source suit la projection calculée.

$Z_s = 5.00 > 0 \cdot u_s = [23.52, 20.00]$ · le rayon source atteint d'abord l'avant-plan

Une projection positive dans l'image peut encore être occultée.

Limites liées à la texture et à la réflectance



La cohérence d'apparence peut échouer

En haut : zones déformées, réfléchissantes et saturées en couleur.


En bas : frontières ambiguës et formes complexes peuvent aussi poser problème.

Exemples de l'article, avec étiquettes de méthodes et régions soulignées originales.


Godard et al., Monodepth2, ICCV 2019 · Fig. 8 · arXiv v4

Choix de reconstruction de Monodepth2

Cible enregistrée I_t




Source enregistrée A



RVB L1 reprojeté : 0.0000

Source enregistrée B




RVB L1 reprojeté : 0.0000

$$m(\mathbf{u}) = \left[\min_s e_s^{\text{warp}}(\mathbf{u}) < \min_s e_s^{\text{identity}}(\mathbf{u}) \right]$$

Minimum reprojeté 0.0000 · minimum non reprojeté 0.0000 · $m = 0$

Vues identiques : aucun gain de reprojection, donc rejet par l'inégalité stricte.

Profondeur apprise sur des images réelles



Images caméra enregistrées en haut; profondeurs monoculaires Monodepth2 prédites en bas.

L'apprentissage relie les observations; l'inférence prédit la profondeur d'une seule image.

Godard et al., Monodepth2, ICCV 2019 · Fig. 7, deux premiers exemples, lignes Input et MD2 M · Partition Eigen de KITTI · arXiv v4


SECTION 06

Correspondances dans l'espace et le temps




Le temps comme source d'observations liées

Caméra A




Caméra B



Deux instants voisins peuvent différer en inclinaison, débit et remplissage.

Time-Contrastive Networks



Sermanet et al., Time-Contrastive Networks, ICRA 2018 · Fig. 1 · arXiv v3

Ancre et positif

Vues différentes au même instant.

Négatif temporel


Un autre instant de la même séquence.

Le curseur vert relie les vues simultanées. Bleu et rouge conservent les rôles de l'article.


Les relations vidéo supervisent cet objectif.
L'encodeur expérimental part des poids ImageNet.

Correspondances de pixels construites par géométrie


Scène 3D synthétique · vue fixe



Cible I_t



Source I_s




Vert : même point de surface · orange : autre point de surface

$$p^{c_t} = D_t(\mathbf{u}_t) K_t^{-1} \tilde{\mathbf{u}}_t, \quad \mathbf{u}_s = \pi(K_s(R_{c_t}^{c_s} p^{c_t} + t_{c_t}^{c_s}))$$

$\mathbf{u}_t = [48.00, 20.00]$ · projeté $\mathbf{u}_s = [35.53, 20.00]$ · correspondance visible disponible

Une non-correspondance est un autre point visible, pas une autre vue du même point.

Apprendre des descripteurs denses



$$d_+ = \|\psi_t(\mathbf{u}_t) - \psi_s(\mathbf{u}_s^+)\|_2, \quad d_- = \|\psi_t(\mathbf{u}_t) - \psi_s(\mathbf{u}_s^-)\|_2$$

Distance correspondante $d_+ = 0.0033$

Distance non correspondante $d_- = 0.6414$

Les non-correspondances imposent une séparation; la géométrie fournit les rôles.

Apparier avec des descripteurs appris

Image requête I_t






Image de recherche I_s



Distance · bleu : proche




$$\mathbf{u}_s^* = \arg \min_{\mathbf{u}_s} \|\psi_t(\mathbf{u}_t) - \psi_s(\mathbf{u}_s)\|_2$$

Comparés 3840 / 3840 descripteurs · meilleur candidat [36.00, 20.00] · distance 0.0033

Le plus proche descripteur fournit un candidat, sans garantir visibilité ni prise valide.

Cohérence des descripteurs entre configurations

Observations RVB en haut · couleurs des descripteurs denses en bas




L'objet change de configuration; les régions correspondantes gardent des couleurs similaires.

Les couleurs codent des descripteurs, sans étiquettes manuelles de parties sémantiques.

Florence et al., Dense Object Nets, CoRL 2018 · Fig. 2(a), les cinq configurations · arXiv v2

Transférer un point de prise




La personne spécifie un pixel de tâche → Appariement dans une nouvelle image → Profondeur + géométrie de prise

Le point image apparié alimente la planification de prise.


Florence et al., Dense Object Nets, CoRL 2018 · Fig. 6(i), queue, standard-so · arXiv v2

Extension aux correspondances 3D

Nuage A · repère a



Nuage B exprimé dans a



$$p^a = R_b^a p^b + t_b^a$$

Requête $p^a = [-0.18, -0.15, 0.49]$ · apparié $p^b = [0.54, -0.48, 0.79]$

Des correspondances fiables et bien réparties peuvent contraindre un recalage rigide.


SECTION 07

Apprendre les possibilités d'action par l'expérience



Observation, action, résultat, cible

Observation antérieure x_t



Ouverture : 0.0°

$t = 0$ · avant l'action


Action commandée a_t



Saisir l'anse, tirer vers l'extérieur

Ouverture désirée : $\geq 30^\circ$


Mesures capteurs ultérieures o



Ouverture : 55.0°


Contact détecté · ouverture 55°

$$y_t = \Gamma(x_t, a_t, o_{t:t+\Delta})$$



Prédiction illustrative 0.881 · cible mesurée 1 · perte binaire 0.1269

La traversabilité dépend du robot



Zone sélectionnée : boue · même commande 1.00 m/s



Roues étroites / contrôleur A

Mesuré 0.25 m/s

Coût automatique : 0.75



Chenilles larges / contrôleur B

Mesuré 0.65 m/s

Coût automatique : 0.35

La traversabilité dépend de plateforme, contrôle, action et règle de résultat.

Mesurer les résultats de traversée

Sol parcouru · vue du dessus




Image antérieure $l_0 \cdot t = 0$




Image enregistrée → Résultat disponible

$$y = \Gamma(o) = \text{clip}_{[0,1]}(1 - v_{\text{meas}}/v_{\text{cmd}})$$

Commande 1.00 m/s · mesure 0.60 m/s · coût automatique $y = 0.40$

Le parcours mesure le mouvement; l'indicateur choisi le transforme en coût.

Supervision différée

Sol parcouru · vue du dessus




Image antérieure $l_0 \cdot t = 0$




Image enregistrée → Résultat disponible

Commande 1.00 m/s · mesure 0.60 m/s · coût automatique $y = 0.40$

L'image antérieure est fixe. La cible n'arrive qu'après traversée réelle.

Projeter l'expérience dans une image antérieure

Sol parcouru · vue du dessus





Image antérieure $l_0 \cdot t = 0$



■ Coût faible observé ■ Coût élevé observé ▨ Non visité


$$\mathbf{u}_0 = \pi(K_0(R_r^{c_0} p^r + t_r^{c_0}))$$

Commande 1.00 m/s · mesure 0.60 m/s · coût automatique $y = 0.40 \cdot 5$ cibles projetées · décalage temporel de pose 0.0 s

Estimation locale jouet : 0.500 → cible mesurée 0.40 · erreur quadratique moyenne 0.0690

Restaurer la synchronisation avant d'utiliser ces cibles mesurées.

Wild Visual Navigation



Entrée visuelle

Images RVB et caractéristiques visuelles
préentraînées

Signal mesuré

Vitesse plane commandée et estimée

Supervision accumulée

Scores d'empreintes reprojétés dans les
images stockées

Le mouvement expérimenté fournit des cibles d'estimation visuelle de traversabilité.

Mattamala et al., WVN, Autonomous Robots 2025 · Fig. 5(a,b), page 6 du PDF du journal

Résultats mesurés et terrain non visité

Sol parcouru · vue du dessus





Image antérieure $l_0 \cdot t = 0$



Commande 1.00 m/s · mesure 0.60 m/s · coût automatique $y = 0.40$


Le chemin sélectionne les données; les régions non visitées restent non mesurées.

Le score WVN nul des segments non visités est un choix conservateur, sans échec observé.

Mattamala et al., WVN, 2025 · Sections 3.4.3 et 3.5.2

Possibilités d'action en manipulation

Observation initiale fixe x_t



Tirer vers l'extérieur

Direction initiale d'ouverture

Le long de la porte fermée

Faible moment d'ouverture

Pousser vers l'intérieur


La butée bloque le mouvement

Rayon de contact 0.85 m · direction $F = [0.00, 1.00, 0.00]$ · orientation de prise fixe

La même anse produit des résultats différents selon la direction d'action.

Prédire le résultat d'une action

Observation initiale fixe x_t



Tirer vers l'extérieur

Direction initiale d'ouverture

Le long de la porte fermée

Faible moment d'ouverture

Pousser vers l'intérieur

La butée bloque le mouvement

Rayon de contact 0.85 m · direction $F = [0.00, 1.00, 0.00]$ · orientation de prise fixe


$$\hat{y}_t = h_\beta(f_\theta(x_t), a_t)$$

Succès d'ouverture prédit : 0.018


Prédire à partir de l'observation et de l'action proposée, avant de voir le résultat.

Construire automatiquement une cible d'action

Observation initiale fixe x_t



Observation après action · action terminée




Rayon de contact 0.85 m · direction $F = [0.00, 1.00, 0.00]$ · orientation de prise fixe

$$y_t = \Gamma(o) = \mathbf{1}[\text{ouverture mesurée} \geq 30^\circ]$$

Succès d'ouverture prédit : 0.018 · Ouverture mesurée 0.0° → cible automatique $y = 0$

Objectif : ouvrir d'au moins 30°; un petit mouvement ne suffit pas.

Pertes pour les cibles issues d'interactions



Résultat binaire de tâche

Règle Γ : ouverture mesurée $\geq 30^\circ$

Cible automatique $y = 1$

Tête de tâche $h\beta$

Probabilité $\hat{y} = 0.800$

Perte

Cible y


$$\hat{y} = \text{sigmoid}(b), \quad \ell = -y \log \hat{y} - (1 - y) \log (1 - \hat{y})$$

Entropie croisée binaire calculée : 0.2231

Choisir une perte compatible; l'auto-supervision vient de la provenance de y .

ActAIM : apprendre à partir d'interactions


Profondeur initiale D_0



Exécuter l'action en simulation

- Point de contact p
- Orientation de pince R
- Direction de mouvement F

Profondeur ultérieure D_1



Encoder les profondeurs avant / après → Seuil de changement de plongement → **Étiquette automatique d'interaction**

Apprendre des modes d'interaction

Modèle latent + géométrie locale

→

Proposer des actions

Où et comment interagir


L'article apprend une distribution d'interactions produisant un changement visuel.

Un changement ne spécifie pas à lui seul « ouvrir cette porte de 30° ».

Wang et al., ActAIM, ICRA 2023 · Sections III, IV-A/B, V-A · arXiv v1


Cibles imparfaites et expérience sélectionnée

Traversée : erreur d'association



Erreur temporelle → mauvaise zone image
→ cible de la mauvaise observation

Meuble : erreur de mesure



Ouverture réelle 0° · capteur : 35°
→ cible $y = 1$ pour une porte non ouverte

Une cible automatique peut être fausse.

Historique des actions tentées

Anse / traction : $y = 1$

Anse / poussée : $y = 0$


Autre contact / direction : non tenté

L'expérience sélectionnée laisse des lacunes dans les données.

Le principe d'apprentissage commun


Association géométrique

Vue caméra enregistrée




Profondeur + poses + visibilité
→ pixels correspondants

Expérience de traversée




Commande + mouvement mesuré
→ cibles de coût local

Interaction avec le meuble



Résultat de tâche mesuré
→ cible de succès

$$\hat{y}_t = h_{\beta}(f_{\theta}(x_t), a_t), \quad y_t = \Gamma(x_t, a_t, o_{t:t+\Delta})$$



Identifier la source et le domaine de la cible, et ce que le modèle doit prédire.


SECTION 08

Introduction à l'adaptation et à l'évaluation



Encodeur gelé et ajustement fin

Ajuster l'encodeur et la tête



$\Theta = (\theta, \beta)$, modifier encodeur et tête

Caractéristiques gelées

Évaluer l'information accessible à la tête choisie.

Ajustement fin


Adapter les caractéristiques et la tête à la tâche cible.

Une sonde linéaire exige h_β linéaire. Un encodeur gelé peut aussi alimenter une tête non linéaire.

Chen et al., SimCLR, ICML 2020 · Annexe B.8

Références de comparaison et efficacité des étiquettes

Courbes illustratives · aucun résultat mesuré ni classement universel



■ Initialisation aléatoire **0.56**

■ Préentraînement supervisé **0.71**

■ Préentraînement auto-supervisé **0.75**

Même partition aval et tête · règles de réglage cohérentes

Rapporter séparément données, annotations et calcul du préentraînement.

Comparer le besoin d'étiquettes à un score et un protocole spécifiés.


Partitionner correctement les données robotiques

A · Apprentissage

V · Validation

E · Test / évaluation

Le temps avance →



Audit apprentissage/test · paires voisines : 0 · trajectoires communes : 0 · environnements communs : 0

Environnements séparés dans ces métadonnées; vérifier aussi les enregistrements.

Choisir la partition selon la généralisation : parcours, session, objet ou environnement.

[scikit-learn · évaluation groupée; regroupement robotique illustratif](#)

Évaluer la tâche de perception visée

Profondeur

$$\text{AbsRel} = \text{mean}(|\hat{D} - D| / D)$$

Référence D

2 m

4 m

6 m

Prédiction $\hat{D}$

2.0 m

4.0 m

6.0 m

AbsRel : **0.000** · aligné par médiane

Traversabilité




Erreur de coût sur zones réservées parcourues

L'alignement utilise la profondeur de référence à l'évaluation, sans retrouver l'échelle métrique à l'inférence.

Erreur prédictive et succès en boucle fermée répondent à des questions différentes.

Évaluateur officiel Monodepth2 · AbsRel et échelle médiane monoculaire

Correspondance



Erreur pixel / rappel sur paires visibles réservées

Possibilité d'action en manipulation



Traction à l'anse

Ouverture prédite


succès : **0.881**

Classification ou perte probabiliste sur résultats réservés


Perte prétexte et utilité aval

Exemple construit · ces courbes ne sont pas des résultats expérimentaux

Perte prétexte d'apprentissage ↓




Score aval sur données réservées ↑



Axes horizontaux : étape d'optimisation n

Étape d'optimisation $n = 4$ · perte prétexte 0.18 · score aval 0.60



Caractéristiques du fond seul

Vues en accord, mais position d'anse perdue.

Une perte prétexte plus faible ne prouve pas un progrès sur la tâche du robot.

Synthèse du cours

Vues liées

$\tilde{x}_1 \leftrightarrow \tilde{x}_2$

Transformation / temps

Observations masquées

$x_k \rightarrow$ cible x_k

Pixels retirés

Sorties enseignantes

$sg(f_{\theta}(x))$

Caractéristiques cibles

Géométrie

Profondeur +
poses


Profondeur / paires visibles

Mesures ultérieures

$o \rightarrow \Gamma \rightarrow y$

Traversée / interaction

Sources de cibles alternatives, chacune avec sa règle et ses observations valides.



Hypothèses du signal Relations entre vues · représentation · visibilité · synchronisation · support de mesure

Réutiliser la représentation ou le prédicteur de tâche direct.
Évaluer la sortie sur la tâche robotique réservée.

SOURCES DU COURS

Références



Références : apprentissage de représentations

SimCLR	A Simple Framework for Contrastive Learning of Visual Representations T. Chen, S. Kornblith, M. Norouzi, G. Hinton. ICML 2020 .
DINO	Emerging Properties in Self-Supervised Vision Transformers M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, A. Joulin. ICCV 2021 .
VICReg	VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning A. Bardes, J. Ponce, Y. LeCun. ICLR 2022 .
MAE	Masked Autoencoders Are Scalable Vision Learners K. He, X. Chen, S. Xie, Y. Li, P. Dollár, R. Girshick. CVPR 2022 .
I-JEPA	Self-Supervised Learning From Images With a Joint-Embedding Predictive Architecture M. Assran, Q. Duval, I. Misra, P. Bojanowski, P. Vincent, M. Rabbat, Y. LeCun, N. Ballas. CVPR 2023 . Code officiel d'apprentissage: src/train.py

Autres sources citées dans le cours

FixMatch	FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence K. Sohn, D. Berthelot, C.-L. Li, Z. Zhang, N. Carlini, E. D. Cubuk, A. Kurakin, H. Zhang, C. Raffel. NeurIPS 2020 .
NetVLAD	NetVLAD: CNN Architecture for Weakly Supervised Place Recognition R. Arandjelović, P. Gronat, A. Torii, T. Pajdla, J. Sivic. CVPR 2016 .

Références : géométrie et correspondances

Monodepth2

Digging Into Self-Supervised Monocular Depth Estimation

C. Godard, O. Mac Aodha, M. Firman, G. Brostow. **ICCV 2019.**

Évaluateur officiel de profondeur: [evaluate_depth.py](#) · commit b017a81

TCN

Time-Contrastive Networks: Self-Supervised Learning from Video

P. Sermanet, C. Lynch, Y. Chebotar, J. Hsu, E. Jang, S. Schaal, S. Levine. **ICRA 2018.**

Dense Object Nets

Dense Object Nets: Learning Dense Visual Object Descriptors By and For Robotic Manipulation

P. R. Florence, L. Manuelli, R. Tedrake. **CoRL 2018.**

Références : interaction et évaluation

WVN

Wild visual navigation: fast traversability learning via pre-trained models and online self-supervision

M. Mattamala, J. Frey, P. Libera, N. Chebrolu, G. Martius, C. Cadena, M. Hutter, M. Fallon.

Autonomous Robots 49, article 19, 2025.

ActAIM

Self-Supervised Learning of Action Affordances as Interaction Modes

L. Wang, N. Dvornik, R. Dubeau, M. Mittal, A. Garg. **ICRA 2023.**

Source d'évaluation

Évaluation

Cross-validation: evaluating estimator performance – grouped-data iterators

scikit-learn developers. **Documentation officielle · consultée le 7 octobre 2026.**