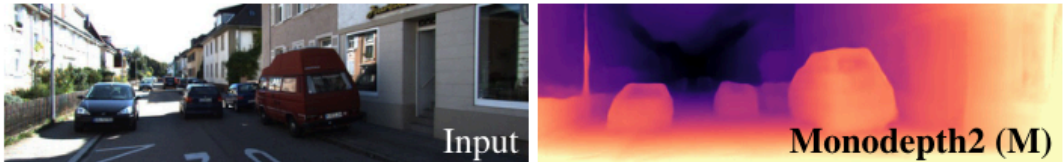
# Apprentissage auto-supervisé pour la perception robotique

**INF8422 : Perception robotique et intelligence spatiale**

Prof. Pierre-Yves Lajoie · Polytechnique Montréal

POLYTECHNIQUE MONTRÉAL

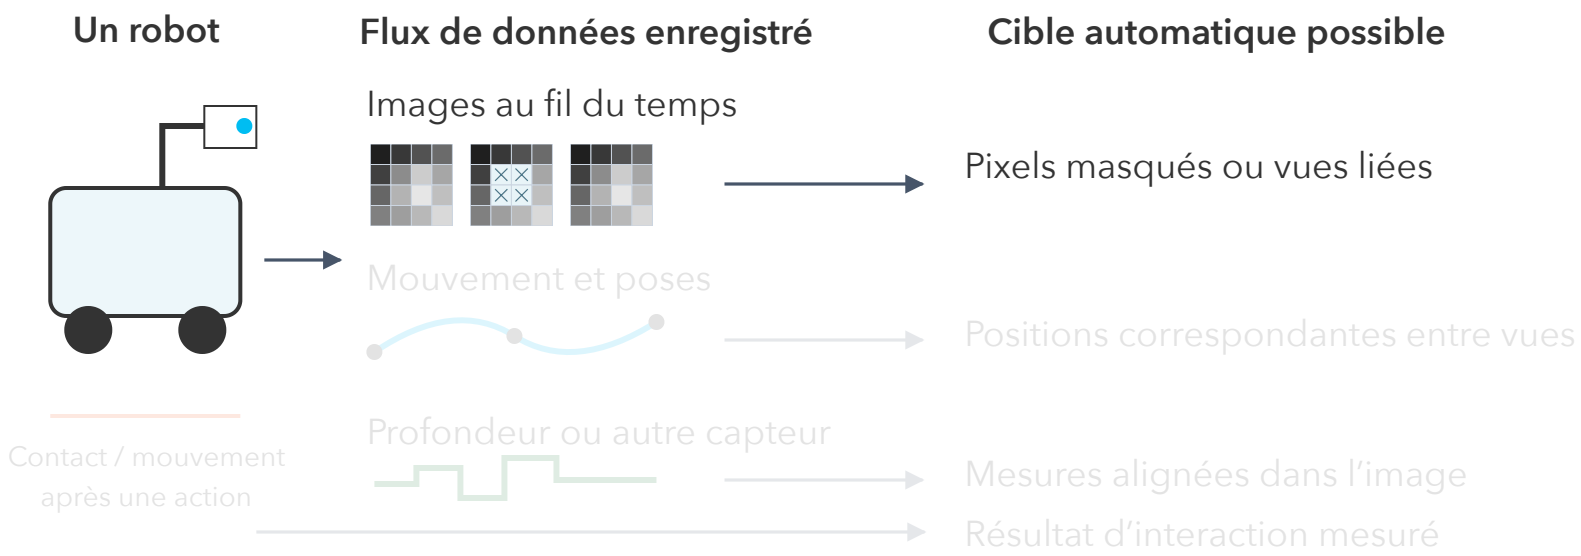



Observation caméra et profondeur estimée
Godard et al., Monodepth2, ICCV 2019, Fig. 1 (ligne supérieure)

SECTION 01

# Mécanismes d’apprentissage auto-supervisé

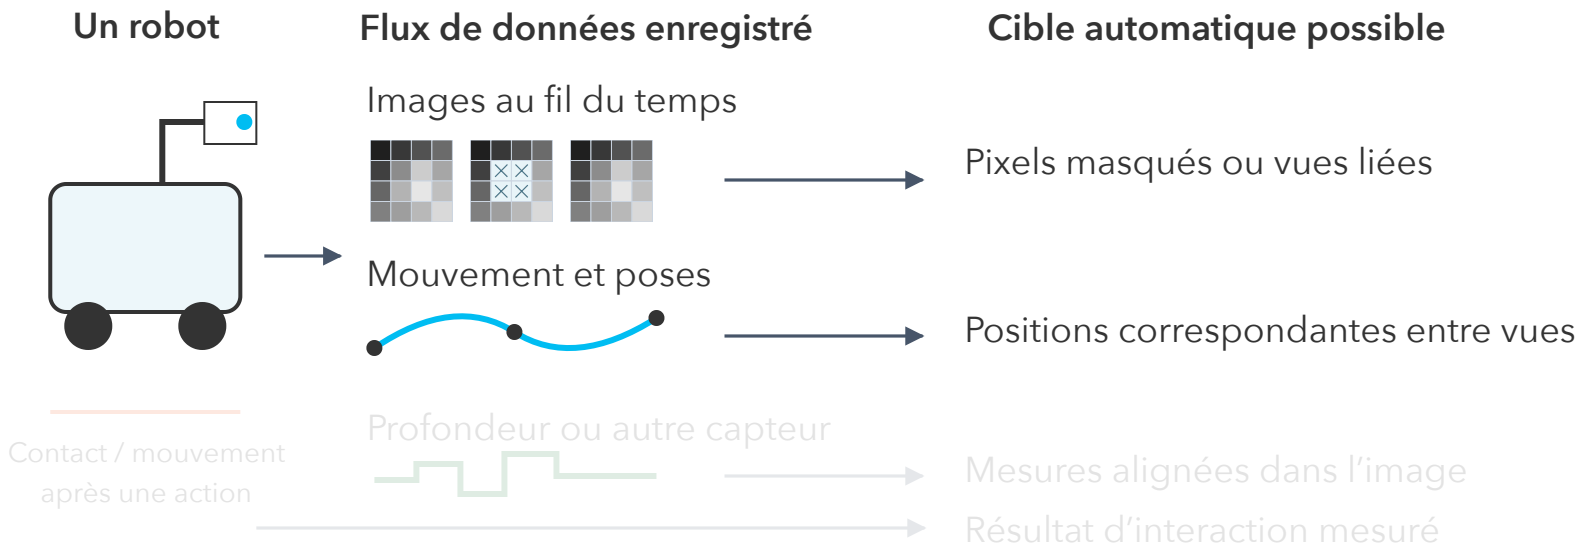
# Signaux de supervision disponibles pour un robot




**Une règle doit définir la cible**

Les données enregistrées peuvent fournir un signal d'apprentissage si l'on définit une relation valide entre les observations.

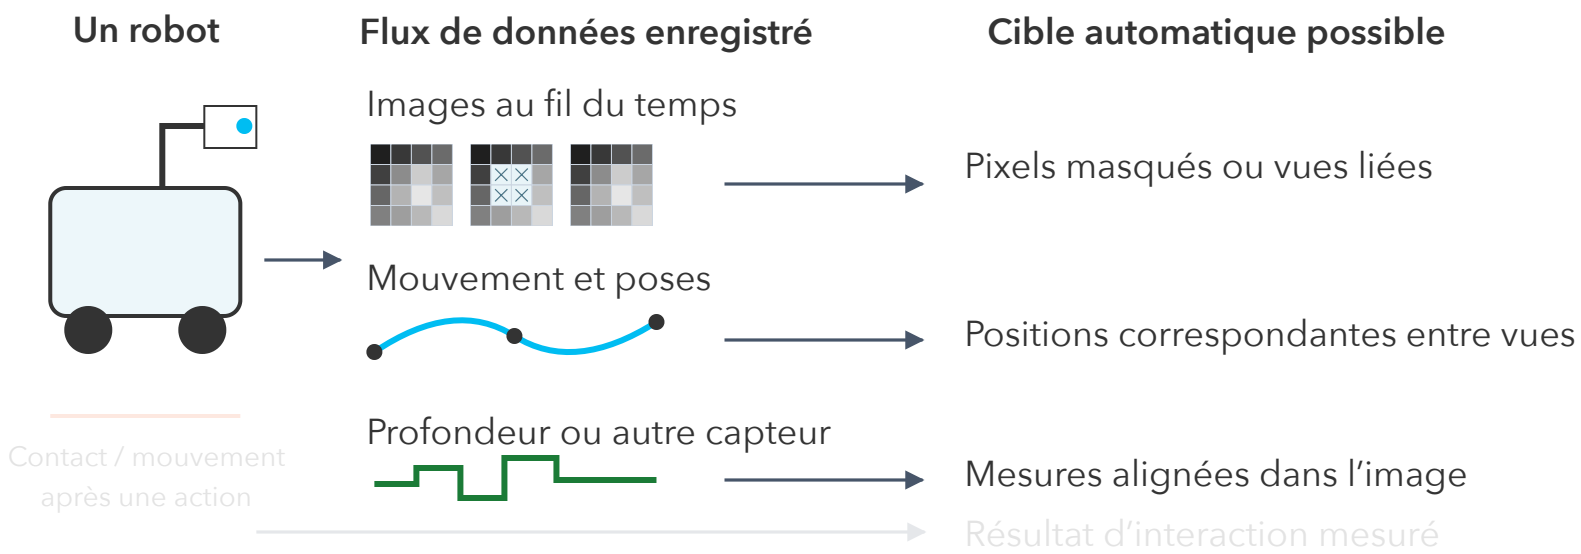
# Signaux de supervision disponibles pour un robot




**Une règle doit définir la cible**

Les données enregistrées peuvent fournir un signal d'apprentissage si l'on définit une relation valide entre les observations.

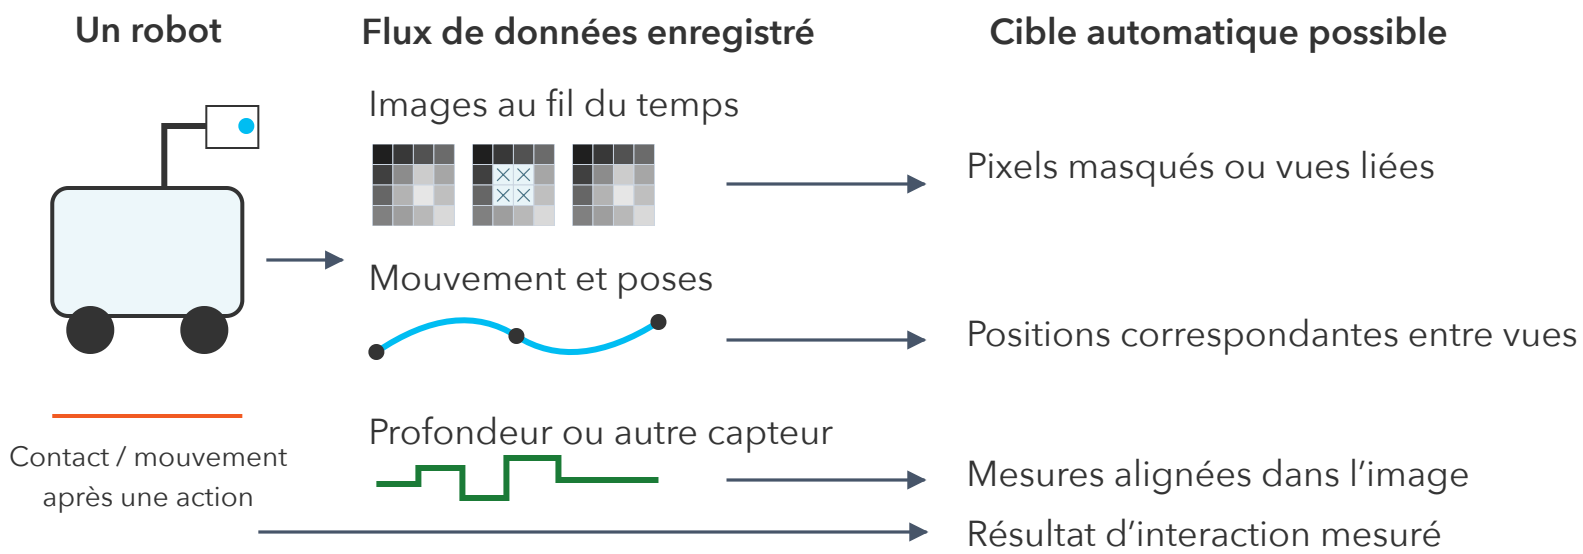
# Signaux de supervision disponibles pour un robot




**Une règle doit définir la cible**

Les données enregistrées peuvent fournir un signal d'apprentissage si l'on définit une relation valide entre les observations.

# Signaux de supervision disponibles pour un robot

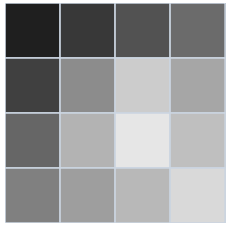



**Une règle doit définir la cible**

Les données enregistrées peuvent fournir un signal d'apprentissage si l'on définit une relation valide entre les observations.

# Définition de l’apprentissage auto-supervisé

L’apprentissage auto-supervisé entraîne un modèle à partir de signaux de supervision dérivés automatiquement des données elles-mêmes, sans nécessiter d’étiquettes annotées manuellement pour cette étape d’apprentissage.



Même observation

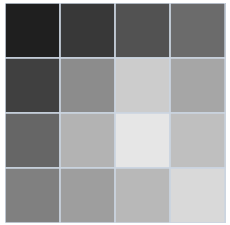
→ Prédire une étiquette d’objet ← **« objet »** Annotation humaine

→ Prédire les pixels masqués ← Copiée de l’observation

> L’origine de la cible d’apprentissage détermine le régime de supervision.

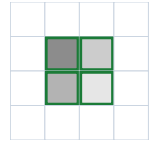
# Définition de l’apprentissage auto-supervisé

L’apprentissage auto-supervisé entraîne un modèle à partir de signaux de supervision dérivés automatiquement des données elles-mêmes, sans nécessiter d’étiquettes annotées manuellement pour cette étape d’apprentissage.



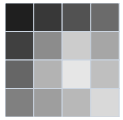
Même observation

→ Prédire une étiquette d’objet ← **« objet »** Annotation humaine

→ Prédire les pixels masqués ←  Copiée de l’observation

L’origine de la cible d’apprentissage détermine le régime de supervision.

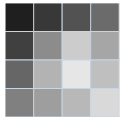
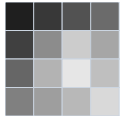
# Apprentissages supervisé, auto-supervisé et semi-supervisé

| | | | |
|---|---|---|---|
| **Supervisé** |  | Exemples annotés manuellement | → Perte sur annotations |
| **Auto-supervisé** |  | Cibles construites automatiquement | → Perte issue des données |
| **Semi-supervisé** |  | Exemples étiquetés + non étiquetés | → Termes supervisés + non étiquetés |

**La fonction de perte (coût) ne suffit pas à identifier le régime**

L'erreur quadratique et l'entropie croisée peuvent autant comparer des prédictions à des cibles manuelles ou automatiques.

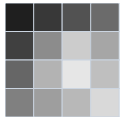
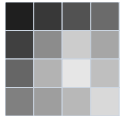
# Apprentissages supervisé, auto-supervisé et semi-supervisé

| | | | |
|---|---|---|---|
| **Supervisé** |  | Exemples annotés manuellement | → Perte sur annotations |
| **Auto-supervisé** |  | Cibles construites automatiquement | → Perte issue des données |
| **Semi-supervisé** |  | Exemples étiquetés + non étiquetés | → Termes supervisés + non étiquetés |

**La fonction de perte (coût) ne suffit pas à identifier le régime**

L'erreur quadratique et l'entropie croisée peuvent autant comparer des prédictions à des cibles manuelles ou automatiques.

# Apprentissages supervisé, auto-supervisé et semi-supervisé

| | | | |
|---|---|---|---|
| **Supervisé** |  | Exemples annotés manuellement | → Perte sur annotations |
| **Auto-supervisé** |  | Cibles construites automatiquement | → Perte issue des données |
| **Semi-supervisé** |  | Exemples étiquetés + non étiquetés | → Termes supervisés + non étiquetés |

**La fonction de perte (coût) ne suffit pas à identifier le régime**

L'erreur quadratique et l'entropie croisée peuvent autant comparer des prédictions à des cibles manuelles ou automatiques.

# Tâches prétextes et cibles automatiques



**Prédiction de pixels masqués**

Entrée : information visible

→

**Pixels observés retirés**

Cible : sélection de l'image originale



**Appariement de vues liées**

Entrée : deux images donc on connaît la relation

→

**Une association connue**

Cible : relation connue (ex: rotation, translation, chevauchement)



**Prédiction directe du résultat**

Entrée : observation avant l'action

→

**Coût de traversée mesuré : 0.4**

Cible : mesures après l'action

Une tâche prétexte construit une représentation par prédiction ou appariement.

# Tâches prétextes et cibles automatiques



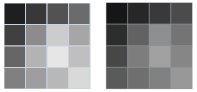
**Prédiction de pixels masqués**

Entrée : information visible

→

**Pixels observés retirés**

Cible : sélection de l'image originale



**Appariement de vues liées**

Entrée : deux images donc on connaît la relation

→

**Une association connue**

Cible : relation connue (ex: rotation, translation, chevauchement)



**Prédiction directe du résultat**

Entrée : observation avant l'action

→

**Coût de traversée mesuré : 0.4**

Cible : mesures après l'action

Une tâche prétexte construit une représentation par prédiction ou appariement.

# Tâches prétextes et cibles automatiques



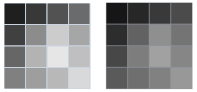
**Prédiction de pixels masqués**

Entrée : information visible

→

**Pixels observés retirés**

Cible : sélection de l'image originale



**Appariement de vues liées**

Entrée : deux images donc on connaît la relation

→

**Une association connue**

Cible : relation connue (ex: rotation, translation, chevauchement)



**Prédiction directe du résultat**

Entrée : observation avant l'action

→

**Coût de traversée mesuré : 0.4**

Cible : mesures après l'action

Une tâche prétexte construit une représentation par prédiction ou appariement.

# Préentraînement et fine tuning facultatif



**Encodeur fθ**

Apprendre une représentation

**Prédiction prétexte**

Cible issue des données

Réutiliser l'encodeur appris



**Encodeur fθ**

Gelé ou adapté

**Tête de tâche hβ**

Catégorie d'objet, par exemple

Les étiquettes manuelles peuvent servir à l'adaptation ou à l'évaluation.

**Deux choix d'adaptation**

Geler l'encodeur et entraîner une tête de tâche, ou ajuster l'encodeur avec la tête.

# Préentraînement et fine tuning facultatif



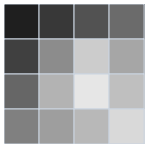
**Encodeur fθ**

Apprendre une représentation

**Prédiction prétexte**

Cible issue des données

Réutiliser l'encodeur appris



**Encodeur fθ**

Gelé ou adapté

**Tête de tâche hβ**

Catégorie d'objet, par exemple

Les étiquettes manuelles peuvent servir à l'adaptation ou à l'évaluation.

**Deux choix d'adaptation**

Geler l'encodeur et entraîner une tête de tâche, ou ajuster l'encodeur avec la tête.

# Apprentissage direct à partir de résultats mesurés

**Observer le terrain** **Exécuter un mouvement fixe connu** **Mesurer le résultat**

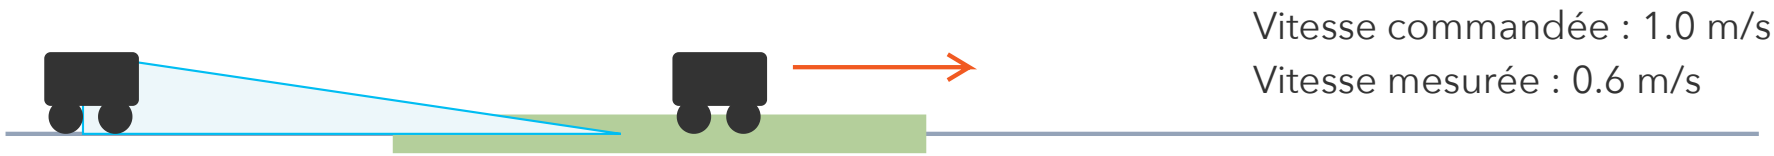



**Cible automatique** Coût illustratif = 1 − mesuré / commandé = **0.4**

Image caméra antérieure → **Encodeur + tête de tâche** → Coût de traversée prédit

# Apprentissage direct à partir de résultats mesurés

**Observer le terrain** **Exécuter un mouvement fixe connu** **Mesurer le résultat**

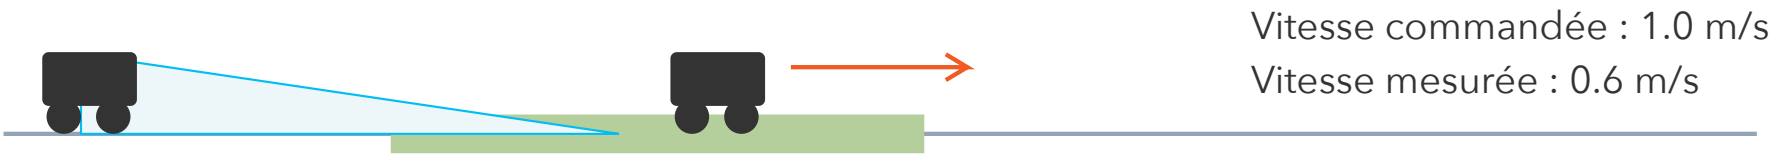



**Cible automatique** Coût illustratif = 1 − mesuré / commandé = **0.4**

Image caméra antérieure → **Encodeur + tête de tâche** → Coût de traversée prédit

# Apprentissage direct à partir de résultats mesurés

**Observer le terrain** **Exécuter un mouvement fixe connu** **Mesurer le résultat**

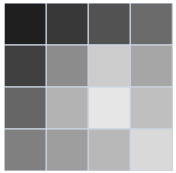



**Cible automatique** Coût illustratif = 1 − mesuré / commandé = **0.4**

Image caméra antérieure → **Encodeur + tête de tâche** → Coût de traversée prédit

# Masquage: Entrée, prédiction et cible

Observé $x_i$

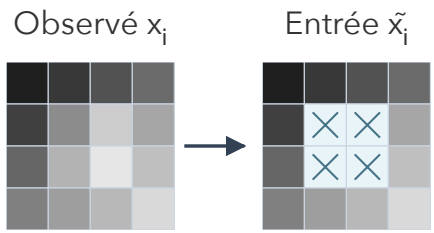


$$x_i \text{ est une image observée}$$

L'observation complète reste accessible à la procédure d'apprentissage.

i identifie une observation · Θ regroupe les paramètres de l'encodeur et du décodeur · M sélectionne les positions masquées

# Masquage: Entrée, prédiction et cible

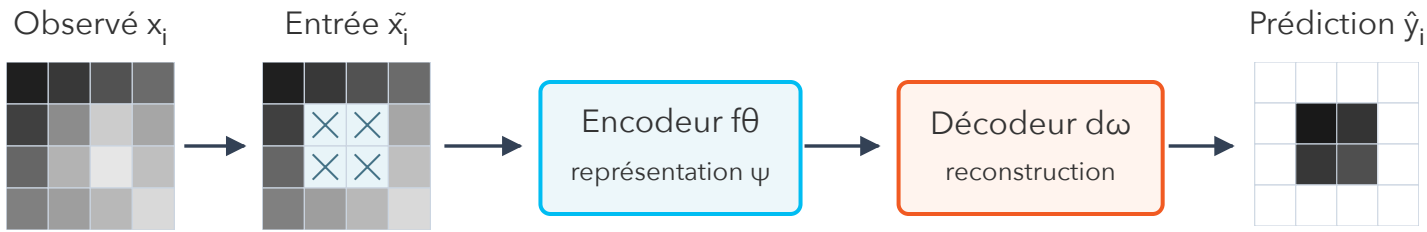



$$\tilde{x}_i = \mathbf{mask}(x_i)$$

Le modèle reçoit seulement le visible. L'original reste séparé.

i identifie une observation · Θ regroupe les paramètres de l'encodeur et du décodeur · M sélectionne les positions masquées

# Masquage: Entrée, prédiction et cible

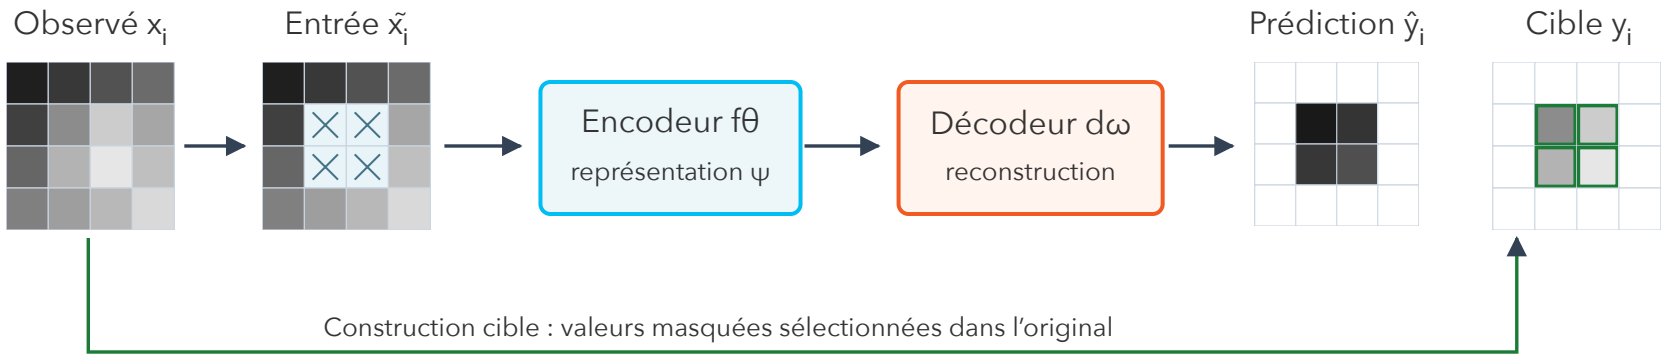



$$\hat{y}_i = P_\Theta(\tilde{x}_i)$$

Encodeur et décodeur prédisent les valeurs retirées.

i identifie une observation · Θ regroupe les paramètres de l'encodeur et du décodeur · M sélectionne les positions masquées

# Masquage: Entrée, prédiction et cible

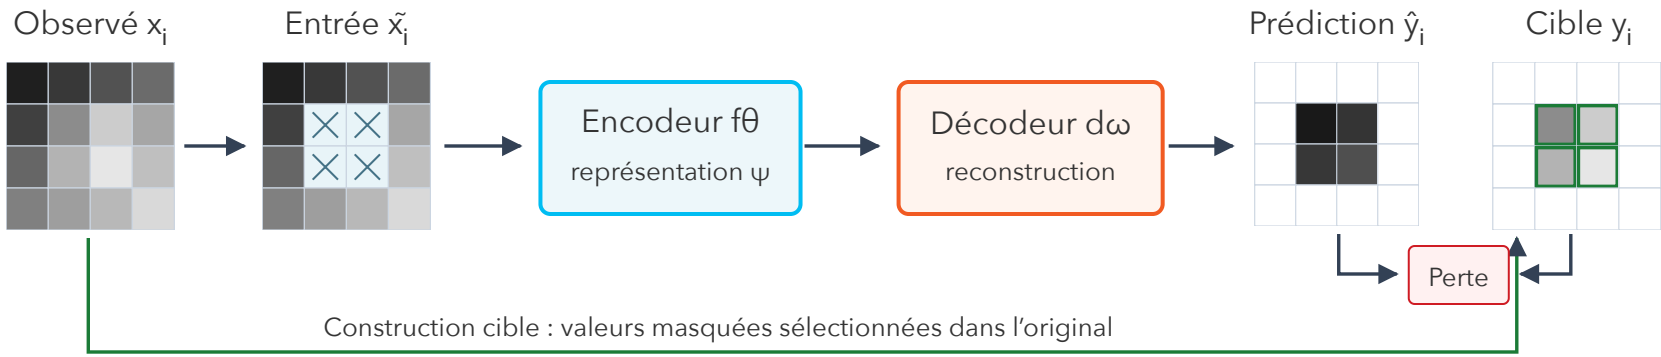



$$y_i = (x_{i,k})_{k \in \mathcal{M}}$$

Copier les valeurs observées masquées dans la branche cible.

i identifie une observation · Θ regroupe les paramètres de l'encodeur et du décodeur · M sélectionne les positions masquées

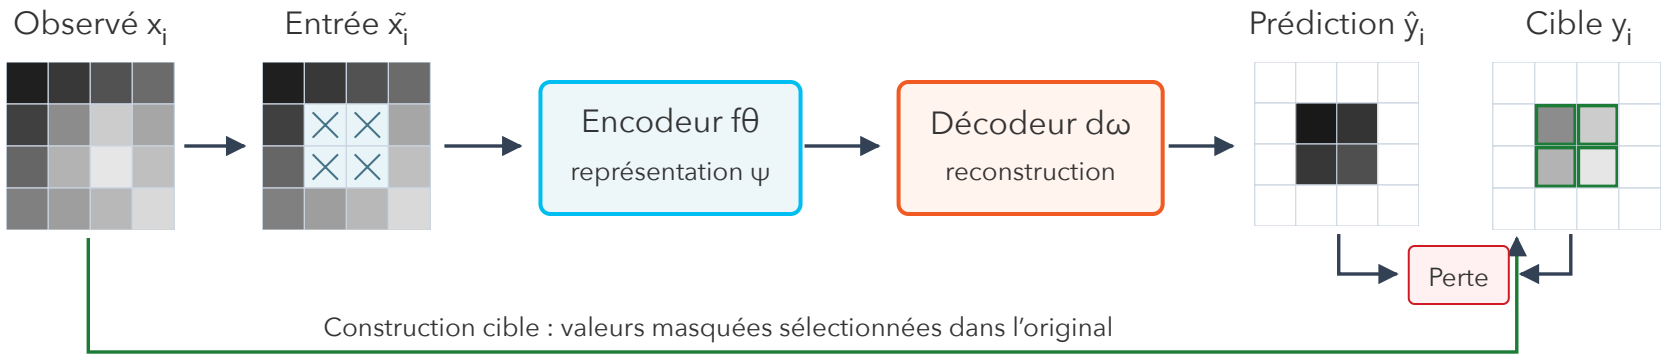
# Masquage: Perte et mise à jour des paramètres




$$\ell(\hat{y}_i, y_i) = \frac{1}{|\mathcal{M}|} \sum_{k \in \mathcal{M}} (\hat{y}_{i,k} - y_{i,k})^2$$

Évaluer l'erreur aux seules positions masquées choisies.

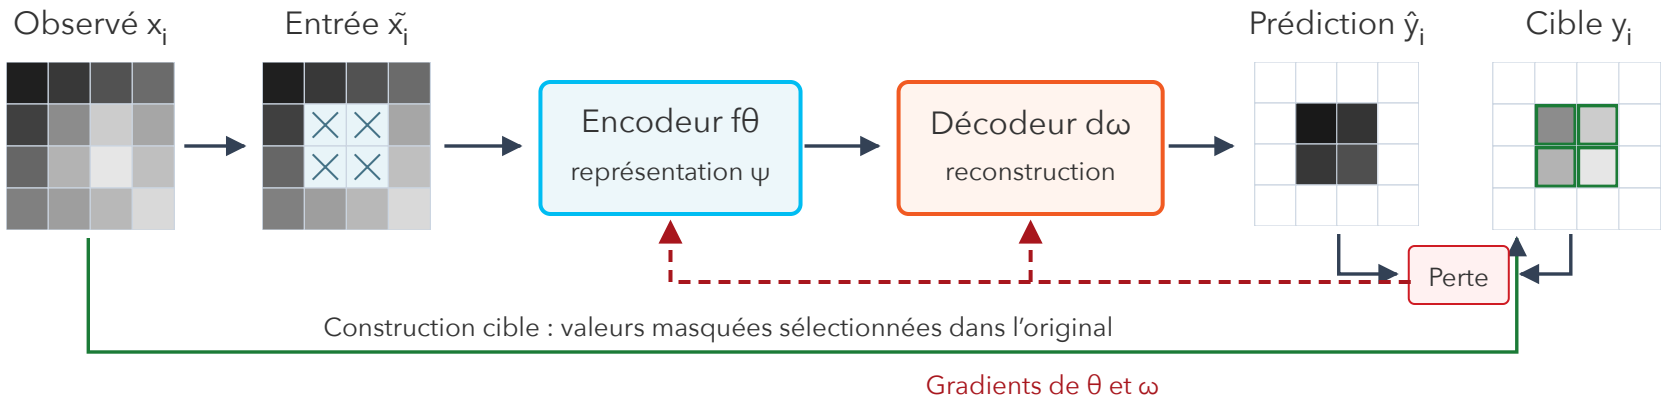
# Masquage: Perte et mise à jour des paramètres




$$\mathcal{L} = \frac{1}{B} \sum_{i=1}^{B} \ell(\hat{y}_i, y_i)$$

B compte les observations. La moyenne spatiale se fait dans chaque perte.

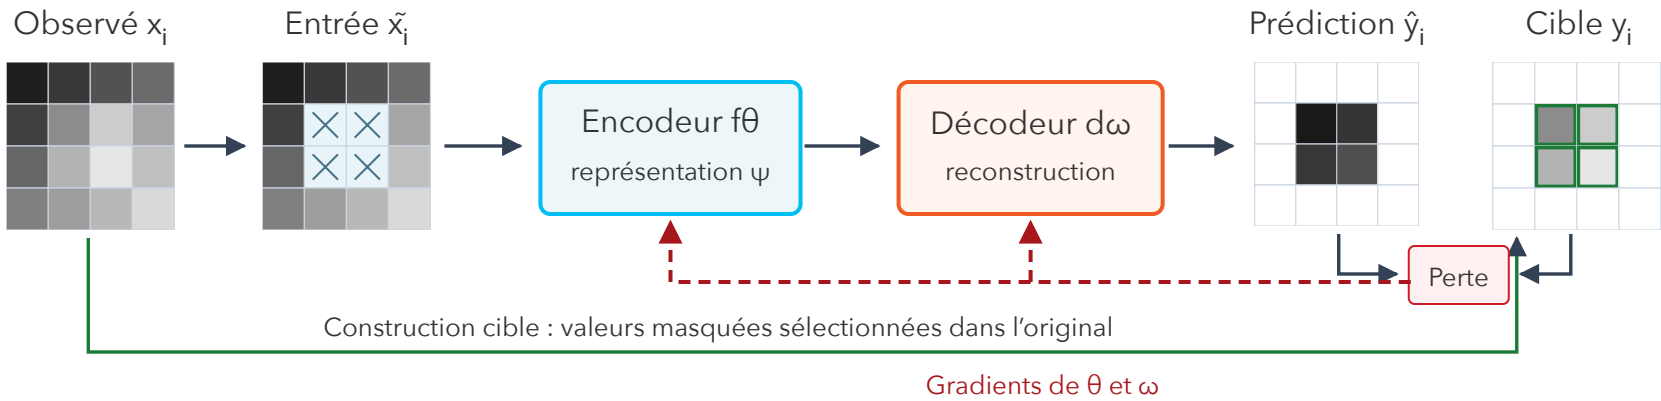
# Masquage: Perte et mise à jour des paramètres




$$\nabla_{\Theta}\mathcal{L} \qquad \Theta = (\theta, \omega)$$

Rétropropagation vers encodeur et décodeur.

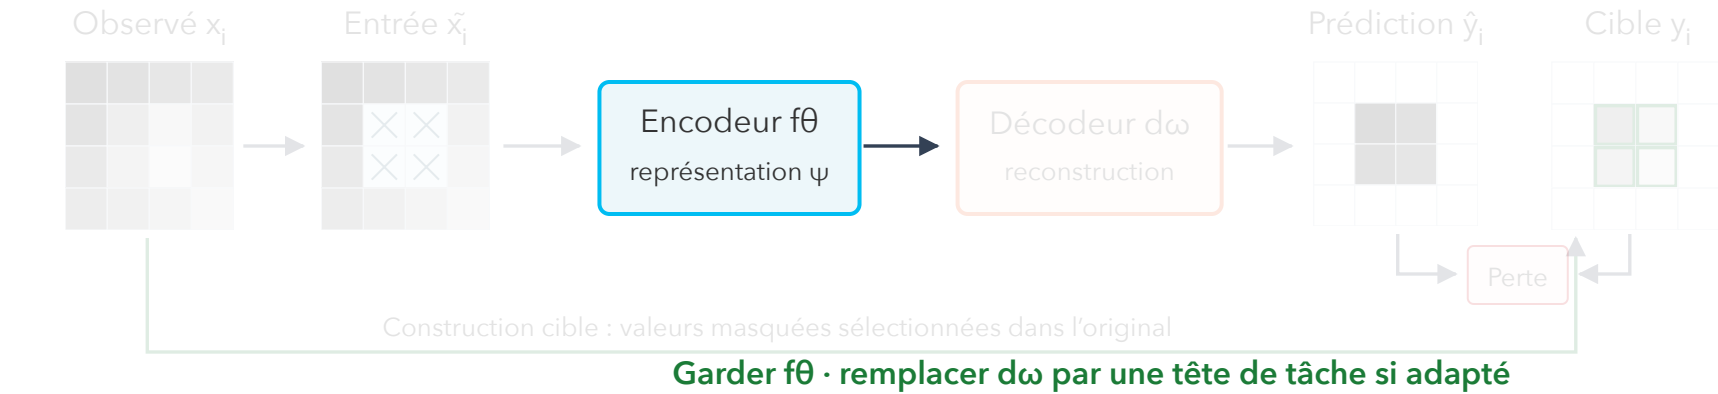
# Masquage: Perte et mise à jour des paramètres




$$\Theta_{n+1} = \Theta_n - \eta \nabla_\Theta \mathcal{L}$$

n compte les pas d'optimisation. η règle l'amplitude de chaque mise à jour.

# Masquage: Ce qui reste après l'apprentissage




**Garder fθ · remplacer dω par une tête de tâche si adapté**

$$\boldsymbol{\psi} = f_\theta(x) \qquad \hat{y}^{\text{task}} = h_\beta(\boldsymbol{\psi})$$

Encoder une nouvelle observation. La tâche détermine la tête de sortie.

 → **Encodeur fθ** → **Tête de tâche hβ** → Sortie de tâche

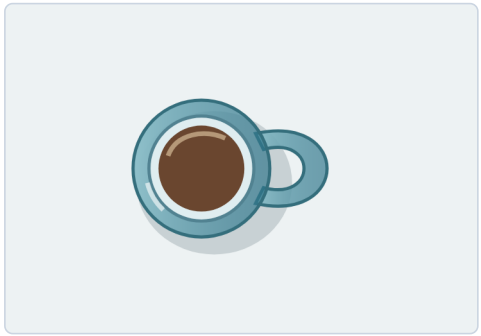
Évaluer la représentation conservée sur la tâche de perception visée.

SECTION 02

# Représentations pour la perception

# Représentations de l'encodeur

Observation x



Encodeur fθ

paramètres appris θ

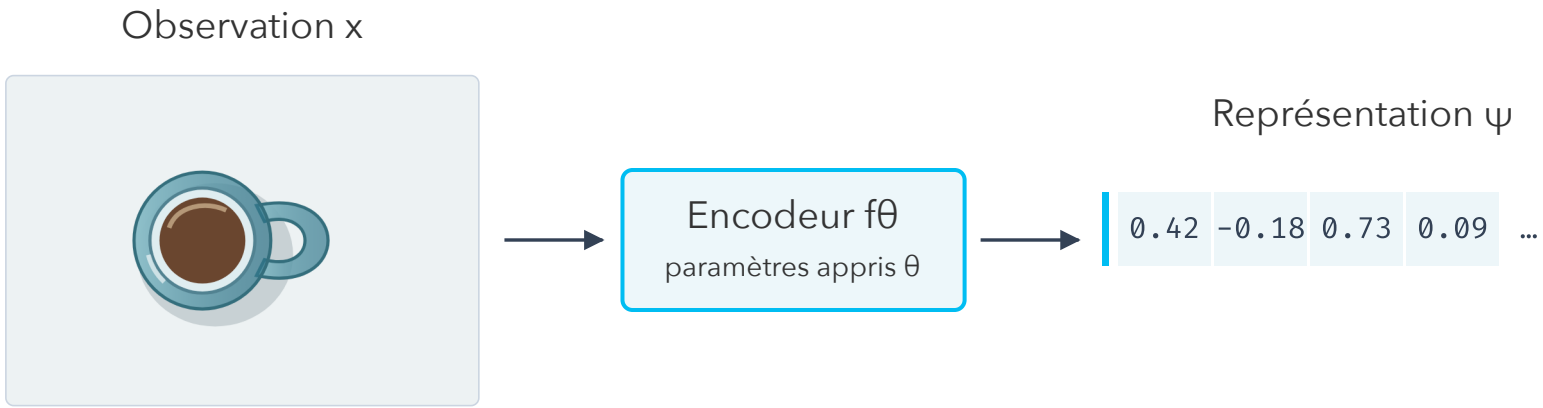
Description interne réutilisable pour une tâche

$$\psi = f_\theta(x)$$

**Une description réutilisable**

La qualité d'une représentation dépend de l'information disponible pour la tâche visée.

# Représentations de l'encodeur




Description interne réutilisable pour une tâche

$$\psi = f_\theta(x)$$

**Une description réutilisable**

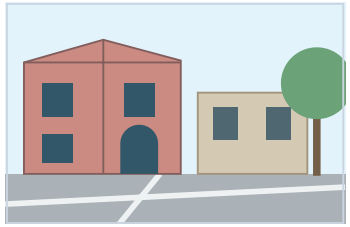
La qualité d'une représentation dépend de l'information disponible pour la tâche visée.

# Caractéristiques globales et denses

## Caractéristiques globales : 1 vecteur par image

Reconnaître un lieu déjà visité

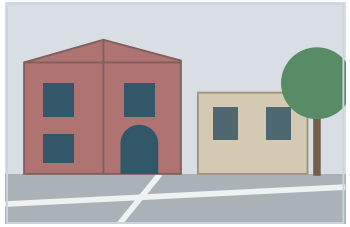
Image requête



Encodeur fθ ↓

`0.42 -0.18 0.73`

Image stockée



Encodeur fθ ↓

`0.40 -0.20 0.71`

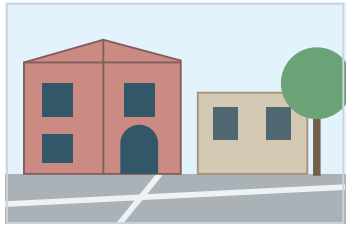
**Comparer les descripteurs globaux**

# Caractéristiques globales et denses

## Caractéristiques globales : 1 vecteur par image

Reconnaître un lieu déjà visité

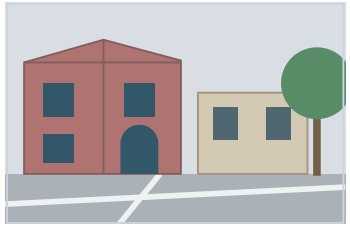
Image requête



Encodeur fθ ↓

`0.42` `-0.18` `0.73`

Image stockée



Encodeur fθ ↓

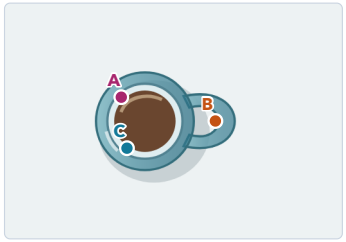
`0.40` `-0.20` `0.71`

**Comparer les descripteurs globaux**

## Caractéristiques denses : vecteurs par position

Trouver le point d'anse correspondant

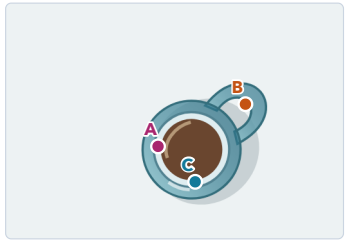
Image de référence




Encodeur fθ ↓



Nouvelle image




Encodeur fθ ↓



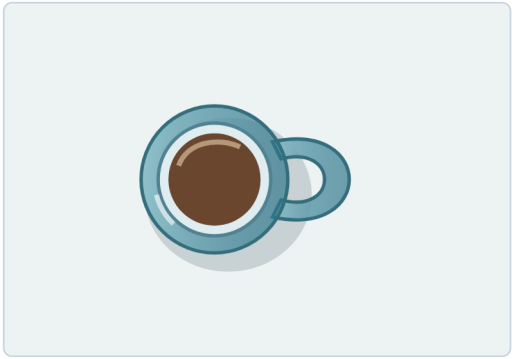
`-0.24` `0.81` `0.46`

# Invariance aux changements non pertinents

Pour **reconnaître cette tasse**, l'éclairage et l'arrière-plan peuvent être des variables parasites.

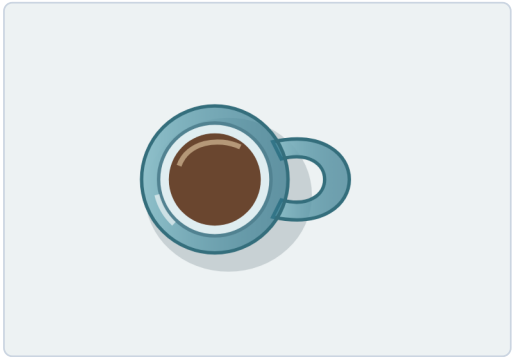
On procède donc à des **augmentations** lors de l'entraînement.

**Observation de référence**



changer l'apparence

**Observation modifiée**



**Identité désirée**

**même tasse**

Éclairage : 1.00×

Arrière-plan : uni

Les pixels changent; la décision de reconnaissance reste stable.

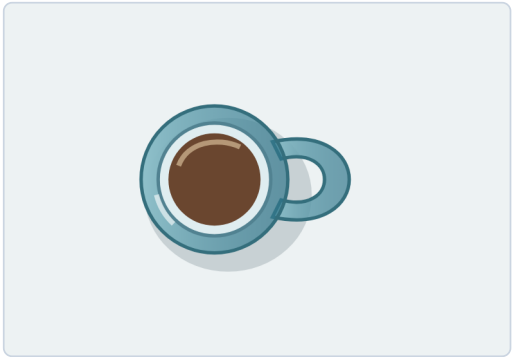
> Conserver l'information qui identifie l'objet malgré les changements choisis.

# Invariance aux changements non pertinents

Pour **reconnaître cette tasse**, l'éclairage et l'arrière-plan peuvent être des variables parasites.

On procède donc à des **augmentations** lors de l'entraînement.

**Observation de référence**



changer l'apparence

**Observation modifiée**



**Identité désirée**

**même tasse**

Éclairage : 0.55×

Arrière-plan : uni

Les pixels changent; la décision de reconnaissance reste stable.

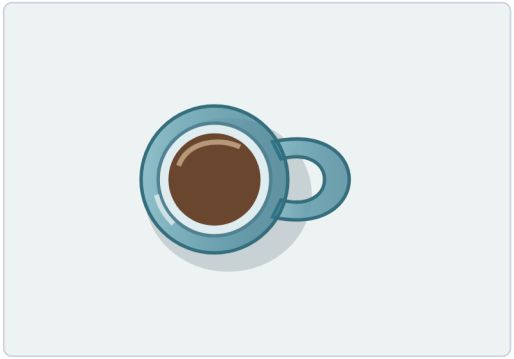
> Conserver l'information qui identifie l'objet malgré les changements choisis.

# Invariance aux changements non pertinents

Pour **reconnaître cette tasse**, l'éclairage et l'arrière-plan peuvent être des variables parasites.

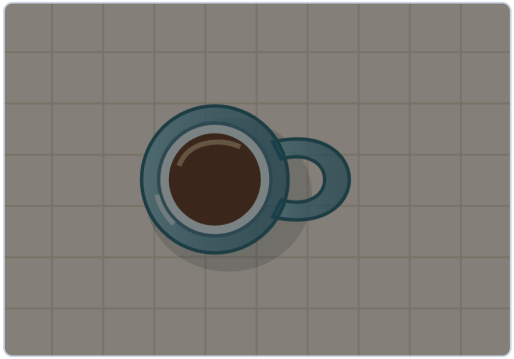
On procède donc à des **augmentations** lors de l'entraînement.

**Observation de référence**



changer l'apparence

**Observation modifiée**



**Identité désirée**

**même tasse**

Éclairage : 0.55×

Arrière-plan : motif

Les pixels changent; la décision de reconnaissance reste stable.

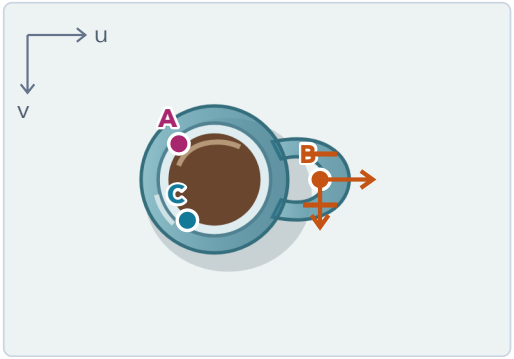
> Conserver l'information qui identifie l'objet malgré les changements choisis.

# Information spatiale nécessaire à l'action

Pour **saisir l'anse**, sa position et son orientation doivent rester accessibles.

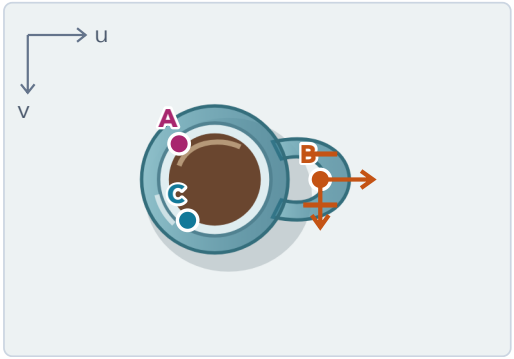
On procède donc à des **augmentations** lors de l'entraînement.

**Observation de référence**




déplacer la tasse

**Observation modifiée**




**Prise en coordonnées image**

**(187.0, 105.0)**

α = 0° · positif horaire

B : même descripteur illustratif

```
-0.24  0.81  0.46
```

Le descripteur d'anse reste associé à B; position et orientation changent.

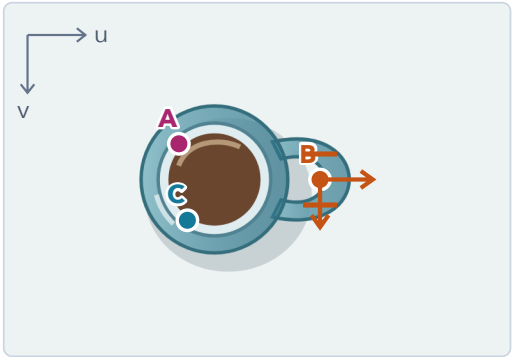
> Les caractéristiques correspondantes peuvent rester cohérentes alors que leurs positions changent.

# Information spatiale nécessaire à l'action

Pour **saisir l'anse**, sa position et son orientation doivent rester accessibles.

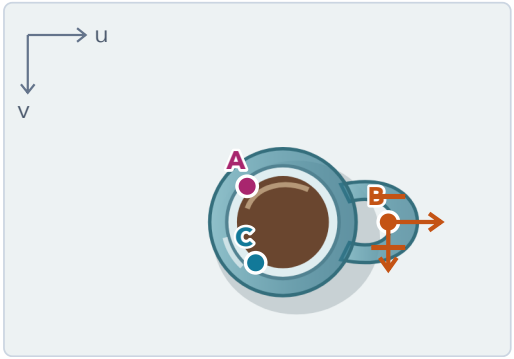
On procède donc à des **augmentations** lors de l'entraînement.

**Observation de référence**




déplacer la tasse

**Observation modifiée**




**Prise en coordonnées image**

**(227.0, 130.0)**

α = 0° · positif horaire

B : même descripteur illustratif

```
-0.24  0.81  0.46
```

Le descripteur d'anse reste associé à B; position et orientation changent.

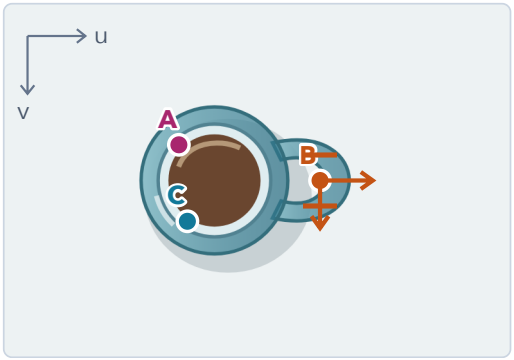
> Les caractéristiques correspondantes peuvent rester cohérentes alors que leurs positions changent.

# Information spatiale nécessaire à l'action

Pour **saisir l'anse**, sa position et son orientation doivent rester accessibles.

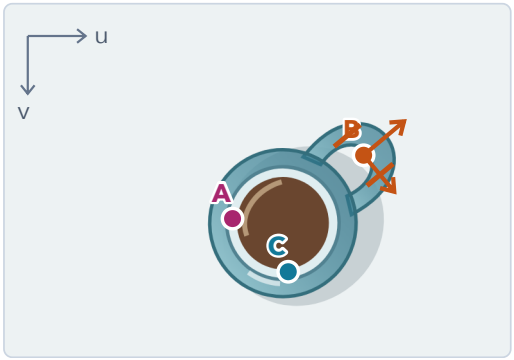
On procède donc à des **augmentations** lors de l'entraînement.

**Observation de référence**




déplacer la tasse

**Observation modifiée**




**Prise en coordonnées image**

**(212.5, 90.1)**

α = -40° · positif horaire

B : même descripteur illustratif

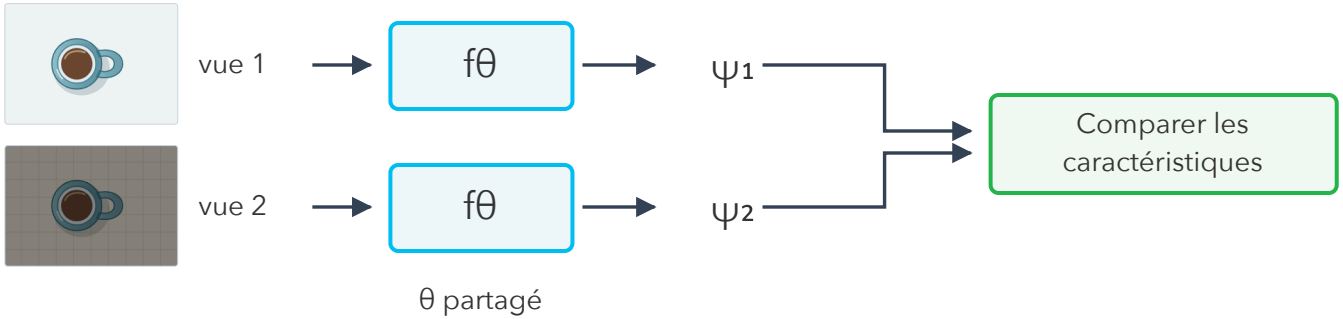
```
-0.24  0.81  0.46
```

Le descripteur d'anse reste associé à B; position et orientation changent.

> Les caractéristiques correspondantes peuvent rester cohérentes alors que leurs positions changent.

# Objectifs d'appariement et de prédiction

## Apparier les observations liées



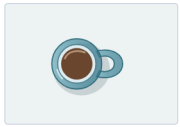

**Deux mécanismes à suivre**

L'appariement utilise une relation connue entre observations.

Alors que le masquage utilise une information observée retirée de l'entrée.

# Objectifs d'appariement et de prédiction

## Apparier les observations liées



vue 1 → fθ → ψ1



vue 2 → fθ → ψ2

ψ1 et ψ2 → Comparer les caractéristiques

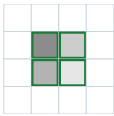
Relation connue : même observation

θ partagé

## Prédire l'information masquée



entrée $\tilde{x}$ → fθ → ψ → dω → $\hat{y}$ → Perte ← Cible y



**Deux mécanismes à suivre**

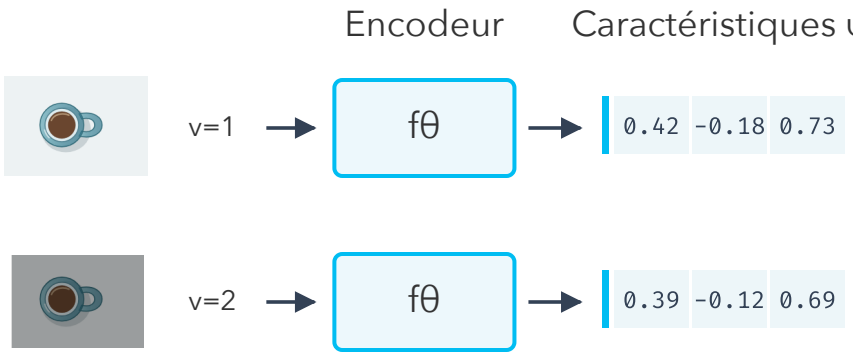
L'appariement utilise une relation connue entre observations.

Alors que le masquage utilise une information observée retirée de l'entrée.

SECTION 03

# Appariement, effondrement et auto-distillation

# Encodeur et tête de projection

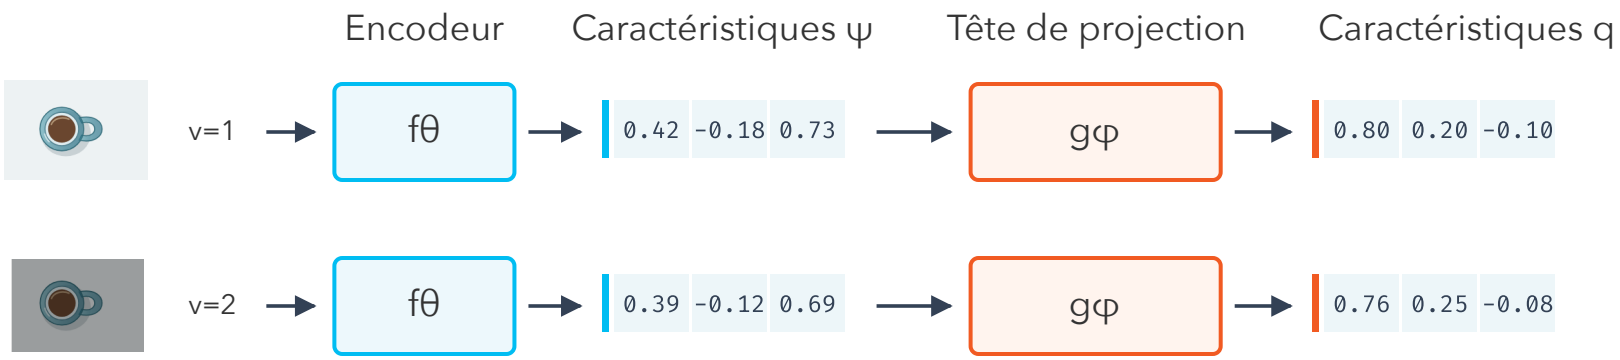



Réutiliser la représentation de l'encodeur

$$\boldsymbol{\psi}_i^{(v)} = f_\theta(\tilde{\boldsymbol{x}}_i^{(v)})$$

L'objectif compare q. Plusieurs tâches différentes en aval (downstream) peuvent réutiliser ψ de l'encodeur.

# Encodeur et tête de projection




Réutiliser la représentation de l'encodeur

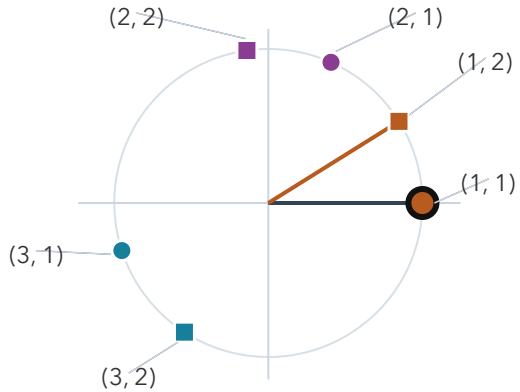
Comparer les projections

$$\boldsymbol{\psi}_i^{(v)} = f_\theta(\tilde{\boldsymbol{x}}_i^{(v)}) \qquad \mathbf{q}_i^{(v)} = g_\phi(\boldsymbol{\psi}_i^{(v)})$$

L'objectif compare q. Plusieurs tâches différentes en aval (downstream) peuvent réutiliser ψ de l'encodeur.

# Similarité et température

Ancre (1, 1) · Positif (1, 2)

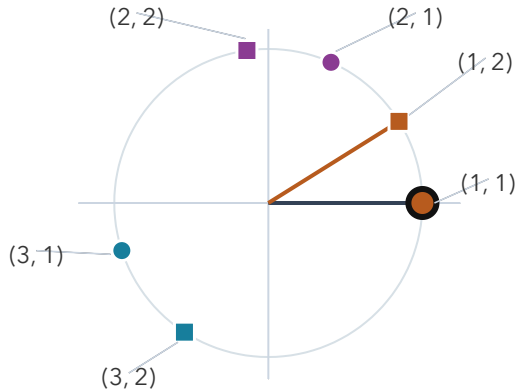



| **Candidat (i, v)** | cosinus | Probabilité normalisée |
|---|---|---|
| (1, 2) · positif | 0.848 | 60.9% |
| (2, 1) · négatif | 0.407 | 25.2% |
| (2, 2) · négatif | -0.139 | 8.5% |
| (3, 1) · négatif | -0.951 | 1.7% |
| (3, 2) · négatif | -0.545 | 3.8% |

$\tau = 0.50$ · probabilité positive = 60.9% · $\ell = 0.496$

# Similarité et température

Ancre (1, 1) · Positif (1, 2)



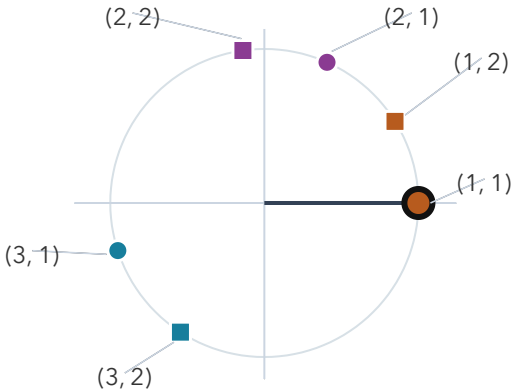

| Candidat (i, v) | cosinus | Probabilité normalisée |
|---|---|---|
| (1, 2) · positif | 0.848 | 60.9% |
| (2, 1) · négatif | 0.407 | 25.2% |
| (2, 2) · négatif | -0.139 | 8.5% |
| (3, 1) · négatif | -0.951 | 1.7% |
| (3, 2) · négatif | -0.545 | 3.8% |

τ = 0.50 · probabilité positive = 60.9% · ℓ = 0.496

$$\mathrm{sim}(\mathbf{q}_a, \mathbf{q}_b) = \frac{\mathbf{q}_a^\top \mathbf{q}_b}{\|\mathbf{q}_a\|_2 \|\mathbf{q}_b\|_2}$$

# Perte contrastive

Ancre (1, 1) · Positif (1, 2)



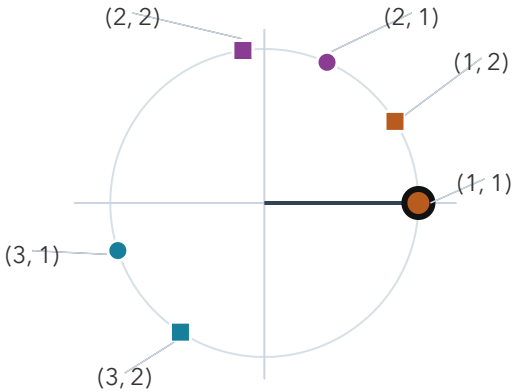

| Candidat (i, v) | cosinus | Probabilité normalisée |
|---|---|---|
| (1, 2) · positif | 0.848 | 60.9% |
| (2, 1) · négatif | 0.407 | 25.2% |
| (2, 2) · négatif | -0.139 | 8.5% |
| (3, 1) · négatif | -0.951 | 1.7% |
| (3, 2) · négatif | -0.545 | 3.8% |

τ = 0.50 · probabilité positive = 60.9% · ℓ = 0.496

$$w_+ = \exp(\mathrm{sim}(\mathbf{q}_i^{(1)}, \mathbf{q}_i^{(2)})/\tau)$$

# Perte contrastive

Ancre (1, 1) · Positif (1, 2)



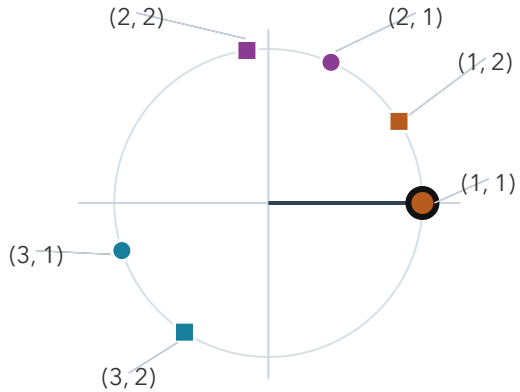

| **Candidat (i, v)** | cosinus | Probabilité normalisée |
|---|---|---|
| (1, 2) · positif | 0.848 | 60.9% |
| (2, 1) · négatif | 0.407 | 25.2% |
| (2, 2) · négatif | -0.139 | 8.5% |
| (3, 1) · négatif | -0.951 | 1.7% |
| (3, 2) · négatif | -0.545 | 3.8% |

τ = 0.50 · probabilité positive = 60.9% · $\ell$ = 0.496

$$L = \sum_{(j,v)\neq(i,1)} \exp(\mathrm{sim}(\mathbf{q}_i^{(1)}, \mathbf{q}_j^{(v)})/\tau)$$

# Perte contrastive

Ancre (1, 1) · Positif (1, 2)



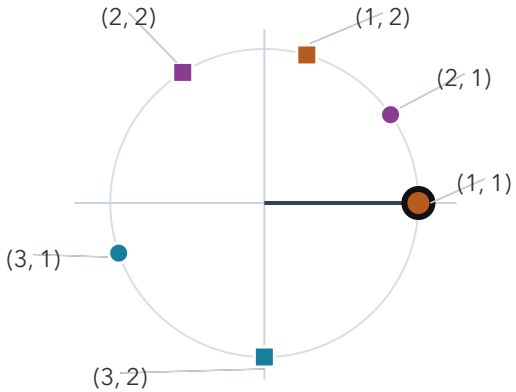

| **Candidat (i, v)** | cosinus | Probabilité normalisée |
|---|---|---|
| (1, 2) · positif | 0.848 | 60.9% |
| (2, 1) · négatif | 0.407 | 25.2% |
| (2, 2) · négatif | -0.139 | 8.5% |
| (3, 1) · négatif | -0.951 | 1.7% |
| (3, 2) · négatif | -0.545 | 3.8% |

τ = 0.50 · probabilité positive = 60.9% · ℓ = 0.496

$$\ell_i^{(1)} = -\log \frac{\exp(\mathrm{sim}(\mathbf{q}_i^{(1)}, \mathbf{q}_i^{(2)})/\tau)}{\sum_{(j,v)\neq(i,1)} \exp(\mathrm{sim}(\mathbf{q}_i^{(1)}, \mathbf{q}_j^{(v)})/\tau)}$$

# Effet de l'objectif sur les représentations

Vue transformée → **fθ** → ψ → **gφ** → q



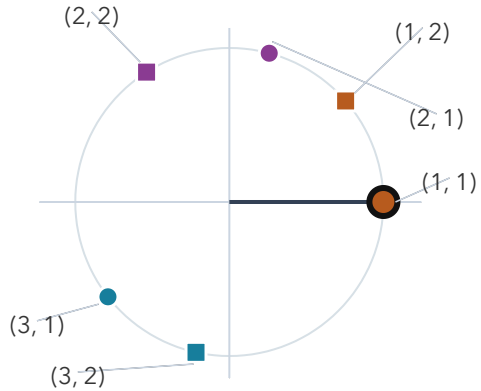

| **Candidat (i, v)** | cosinus | Probabilité normalisée |
|---|---|---|
| (1, 2) · positif | 0.276 | 20.7% |
| (2, 1) · négatif | 0.819 | 61.4% |
| (2, 2) · négatif | -0.530 | 4.1% |
| (3, 1) · négatif | -0.946 | 1.8% |
| (3, 2) · négatif | -0.000 | 11.9% |

τ = 0.50 · probabilité positive = 20.7% · ℓ = 1.574 · moyenne des six ancres = 1.493

Augmenter l'accord avec le positif relativement aux vues concurrentes.

# Effet de l'objectif sur les représentations

Vue transformée → **fθ** → ψ → **gφ** → q



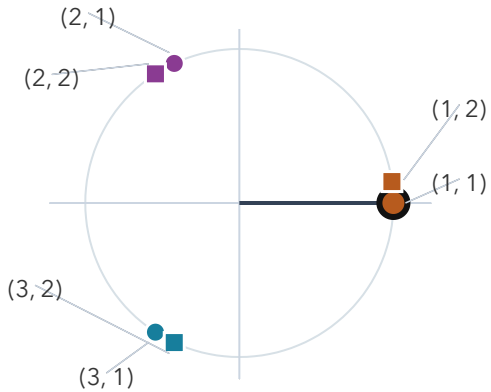

| **Candidat (i, v)** | cosinus | Probabilité normalisée |
|---|---|---|
| (1, 2) · positif | 0.755 | 61.1% |
| (2, 1) · négatif | 0.259 | 22.7% |
| (2, 2) · négatif | -0.537 | 4.6% |
| (3, 1) · négatif | -0.788 | 2.8% |
| (3, 2) · négatif | -0.216 | 8.8% |

τ = 0.50 · probabilité positive = 61.1% · ℓ = 0.492 · moyenne des six ancres = 0.585

Augmenter l'accord avec le positif relativement aux vues concurrentes.

# Effet de l'objectif sur les représentations

Vue transformée → **fθ** → ψ → **gφ** → q

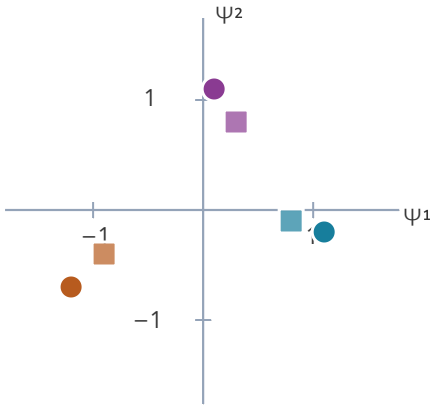



| **Candidat (i, v)** | cosinus | Probabilité normalisée |
|---|---|---|
| (1, 2) · positif | 0.990 | 82.6% |
| (2, 1) · négatif | -0.423 | 4.9% |
| (2, 2) · négatif | -0.545 | 3.8% |
| (3, 1) · négatif | -0.545 | 3.8% |
| (3, 2) · négatif | -0.423 | 4.9% |

τ = 0.50 · probabilité positive = 82.6% · ℓ = 0.192 · moyenne des six ancres = 0.189

Augmenter l'accord avec le positif relativement aux vues concurrentes.

# Représentation constante: Effondrement




**Trois paires distinctes**

Perte moyenne d'accord des paires : **0.1367**

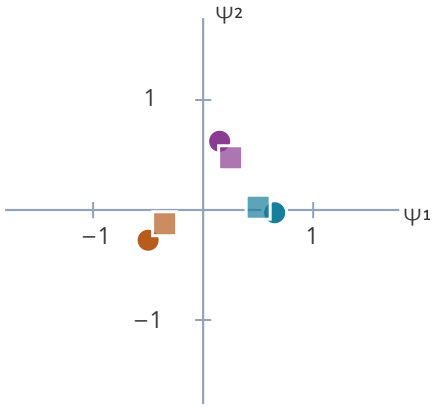
Dispersion : (0.916, 0.708)

Rapprocher les vues d'une même paire n'exige pas nécessairement de garder les différences entre les pairs.

$$\ell_{\text{agree},i} = \|\boldsymbol{\psi}_i^{(1)} - \boldsymbol{\psi}_i^{(2)}\|_2^2$$

Il faut éviter qu'une solution optimale possible de l'apprentissage soit l'effondrement (collapse) de la représentation.

# Représentation constante: Effondrement




**Trois paires distinctes**

Perte moyenne d'accord des paires : **0.0342**

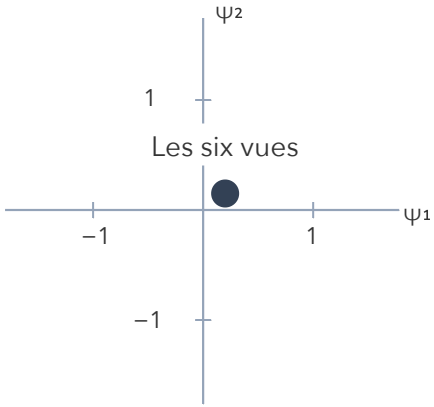
Dispersion : (0.458, 0.354)

Rapprocher les vues d'une même paire n'exige pas nécessairement de garder les différences entre les pairs.

$$\ell_{\text{agree},i} = \|\boldsymbol{\psi}_i^{(1)} - \boldsymbol{\psi}_i^{(2)}\|_2^2$$

Il faut éviter qu'une solution optimale possible de l'apprentissage soit l'effondrement (collapse) de la représentation.

# Représentation constante: Effondrement




**Trois paires distinctes**

Perte moyenne d'accord des paires : **0.0000**

Dispersion : (0.000, 0.000)

Un vecteur constant efface les distinctions entre observations.

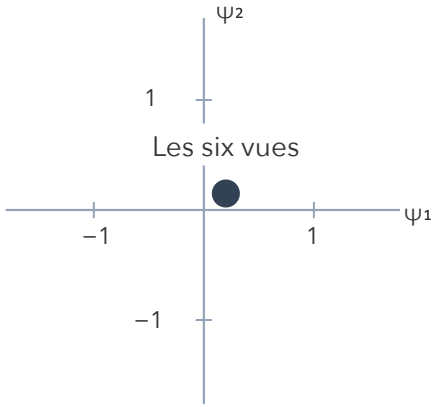
c = (0.20, 0.15)

$$f_\theta(x) = \mathbf{c} \text{ pour tout } x \quad \Longrightarrow \quad \ell_{\text{agree},i} = 0$$

Il faut éviter qu'une solution optimale possible de l'apprentissage soit l'effondrement (collapse) de la représentation.

# Perte de dimensions de représentation

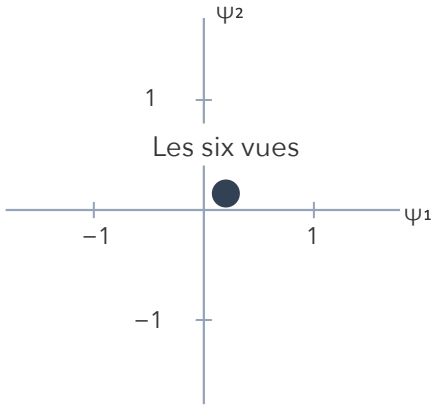
**Point : effondrement complet**




Écart-type : (0.00, 0.00)

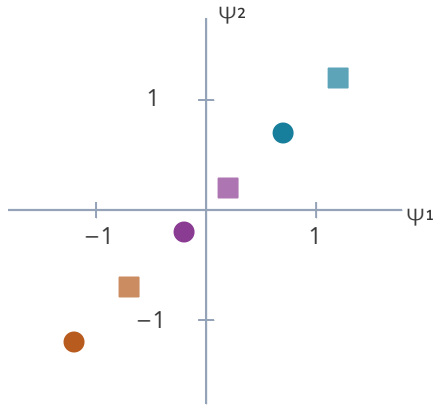
# Perte de dimensions de représentation

**Point : effondrement complet**




Écart-type : (0.00, 0.00)

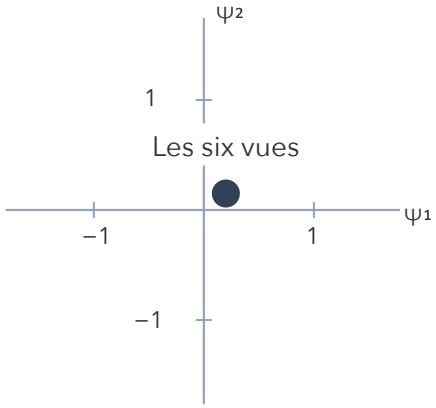
**Ligne : une direction variable**




Écart-type : (0.89, 0.89)

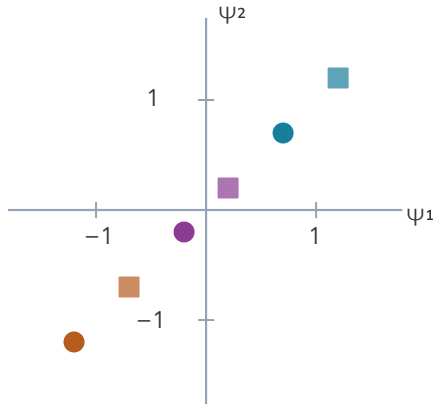
# Perte de dimensions de représentation

**Point : effondrement complet**



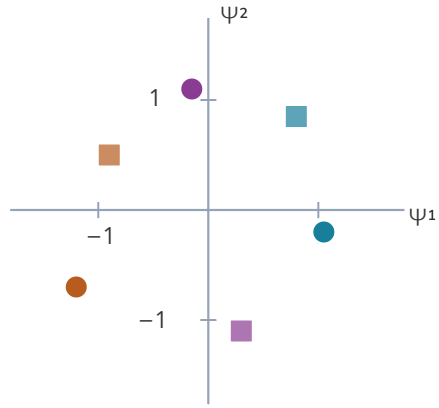

Écart-type : (0.00, 0.00)

**Ligne : une direction variable**




Écart-type : (0.89, 0.89)

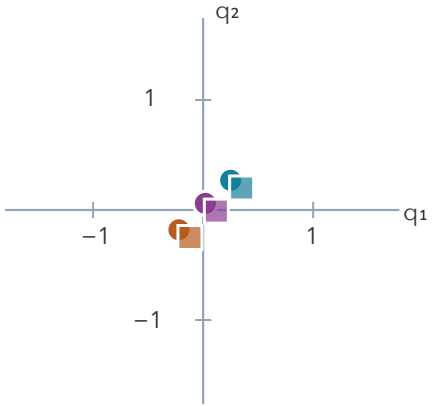
**Deux directions variables**




Écart-type : (0.91, 0.88)

# Régularisation: Variance-Invariance-Covariance (VICReg)

Vue → fθ → ψ → **gφ (expanseur)** → q · régulariser q des deux branches




**Invariance** · 0.0149

Distance entre vues correspondantes

**Variance** · 1.5394

Plancher d'écart-type par dimension

**Covariance** · 0.0056

Covariance hors diagonale au carré

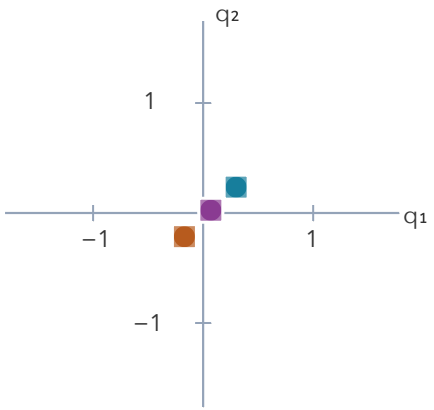
$$\mathcal{L}_{\text{VICReg}} = \lambda_{\text{inv}}\mathcal{L}_{\text{inv}} + \lambda_{\text{var}}\mathcal{L}_{\text{var}} + \lambda_{\text{cov}}\mathcal{L}_{\text{cov}}$$

Partir de vues décalées, presque effondrées.

Bardes et al. · VICReg · ICLR 2022

# Régularisation: Variance-Invariance-Covariance (VICReg)

Vue → fθ → ψ → **gφ (expanseur)** → q · régulariser q des deux branches




**Invariance** · 0.0000

Distance entre vues correspondantes

**Variance** · 1.5394

Plancher d'écart-type par dimension

**Covariance** · 0.0056

Covariance hors diagonale au carré

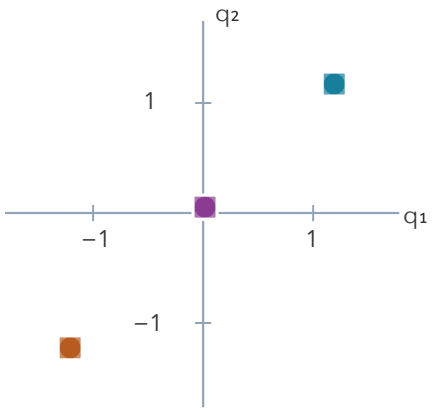
$$\mathcal{L}_{\text{VICReg}} = \lambda_{\text{inv}}\mathcal{L}_{\text{inv}} + \lambda_{\text{var}}\mathcal{L}_{\text{var}} + \lambda_{\text{cov}}\mathcal{L}_{\text{cov}}$$

L'invariance rapproche les vues correspondantes.

Bardes et al. · VICReg · ICLR 2022

# Régularisation: Variance-Invariance-Covariance (VICReg)

Vue → fθ → ψ → **gφ (expanseur)** → q · régulariser q des deux branches




**Invariance** · 0.0000

Distance entre vues correspondantes

**Variance** · 0.0000

Plancher d'écart-type par dimension

**Covariance** · 4.1444

Covariance hors diagonale au carré

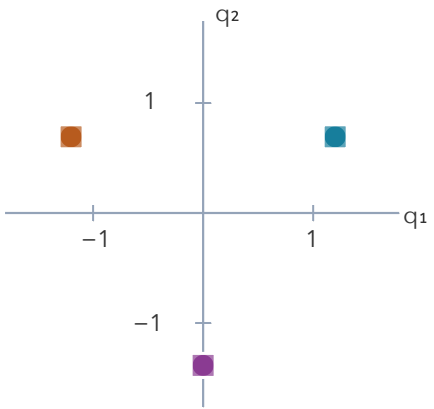
$$\mathcal{L}_{\text{VICReg}} = \lambda_{\text{inv}}\mathcal{L}_{\text{inv}} + \lambda_{\text{var}}\mathcal{L}_{\text{var}} + \lambda_{\text{cov}}\mathcal{L}_{\text{cov}}$$

La variance impose une dispersion minimale par dimension.

Bardes et al. · VICReg · ICLR 2022

# Régularisation: Variance-Invariance-Covariance (VICReg)

Vue → fθ → ψ → **gφ (expanseur)** → q · régulariser q des deux branches




**Invariance** · 0.0000

Distance entre vues correspondantes

**Variance** · 0.0000

Plancher d'écart-type par dimension

**Covariance** · 0.0000

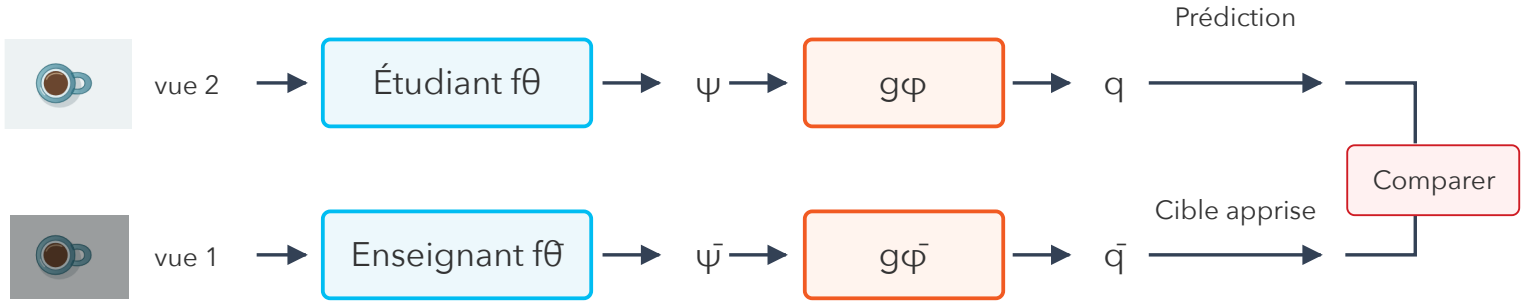
Covariance hors diagonale au carré

$$\mathcal{L}_{\text{VICReg}} = \lambda_{\text{inv}}\mathcal{L}_{\text{inv}} + \lambda_{\text{var}}\mathcal{L}_{\text{var}} + \lambda_{\text{cov}}\mathcal{L}_{\text{cov}}$$

La covariance décourage les directions redondantes.

Bardes et al. · VICReg · ICLR 2022

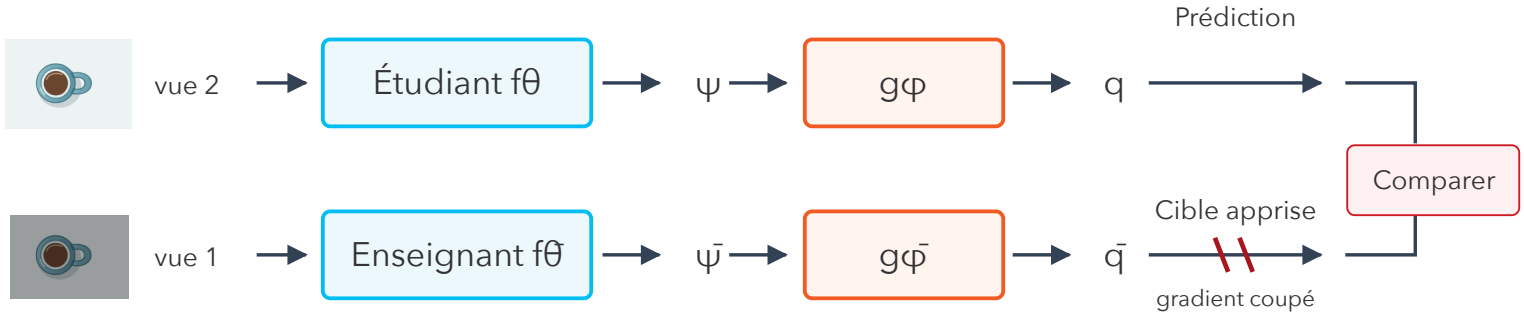
# Auto-Distillation: Apprendre des cibles fournies par un enseignant




**Une cible qui évolue pendant l'apprentissage**

L'étudiant prédit une sortie enseignante à partir d'une autre vue de l'observation.

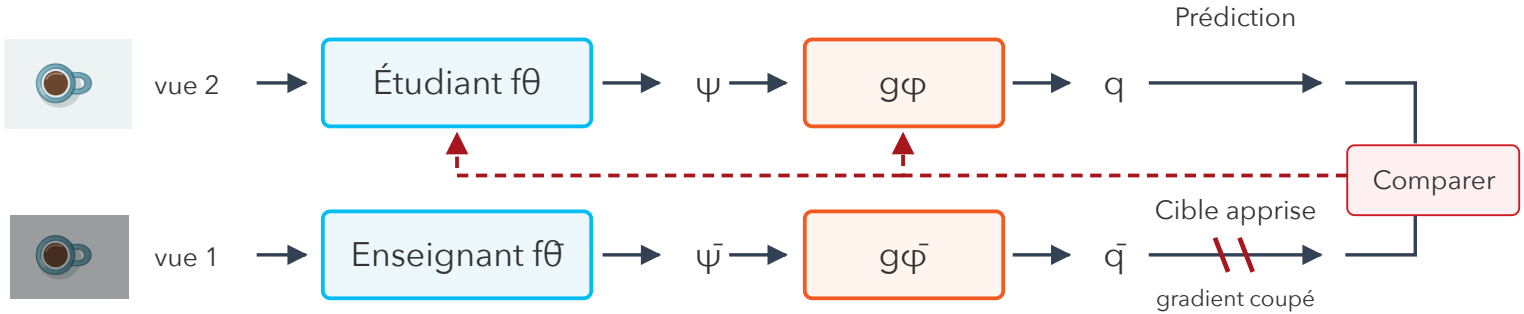
# Auto-Distillation: Apprendre des cibles fournies par un enseignant




**Une cible qui évolue pendant l'apprentissage**

L'étudiant prédit une sortie enseignante à partir d'une autre vue de l'observation.

# Auto-Distillation: Apprendre des cibles fournies par un enseignant

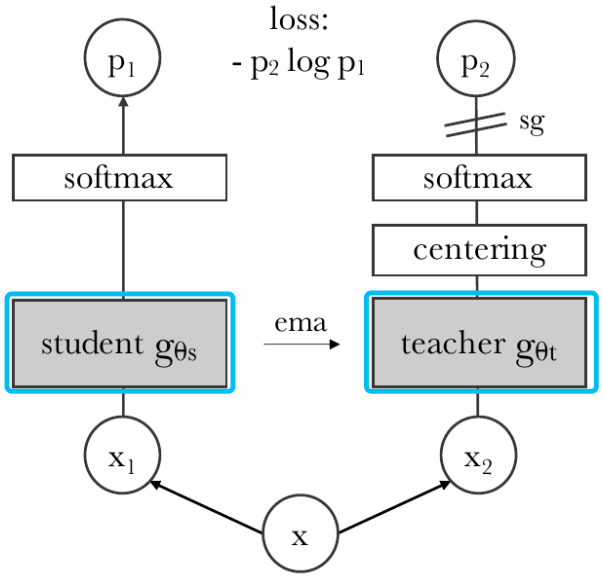



Tirets : gradients de θ et φ · aucun gradient enseignant

**Une cible qui évolue pendant l'apprentissage**

L'étudiant prédit une sortie enseignante à partir d'une autre vue de l'observation.

# Architecture de DINO




Caron et al. · DINO · ICCV 2021 · Fig. 2 principale

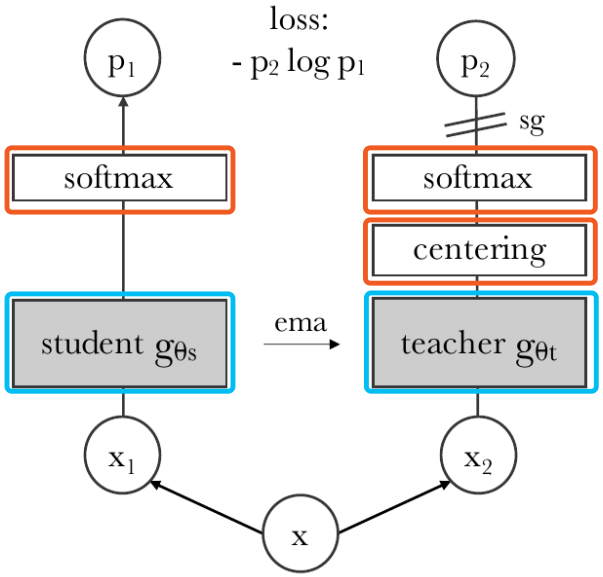
**Étudiant et enseignant : encodeur + tête**

$$g_{\theta_s} \leftrightarrow g_\phi \circ f_\theta$$

$$g_{\theta_t} \leftrightarrow g_{\bar{\phi}} \circ f_{\bar{\theta}}$$

Apparier les distributions; mettre à jour étudiant et enseignant selon des règles distinctes.

# Architecture de DINO




Caron et al. · DINO · ICCV 2021 · Fig. 2 principale

**Étudiant et enseignant : encodeur + tête**

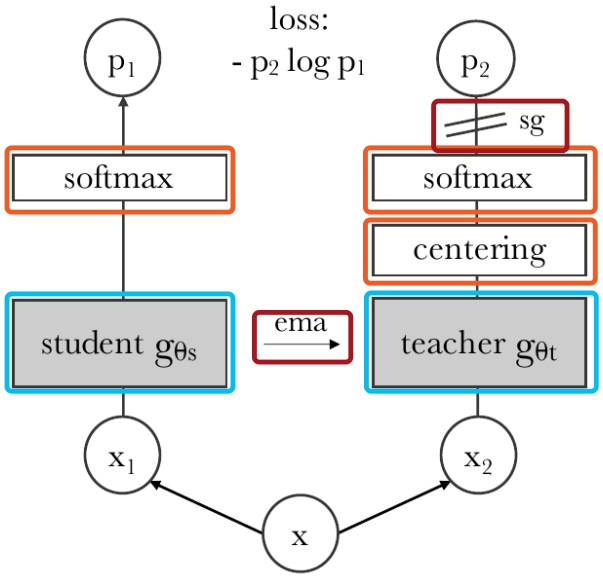
$$g_{\theta_s} \leftrightarrow g_\phi \circ f_\theta$$

$$g_{\theta_t} \leftrightarrow g_{\bar{\phi}} \circ f_{\bar{\theta}}$$

Centrer les sorties enseignantes, puis appliquer des températures softmax distinctes.

Apparier les distributions; mettre à jour étudiant et enseignant selon des règles distinctes.

# Architecture de DINO




Caron et al. · DINO · ICCV 2021 · Fig. 2 principale

**Étudiant et enseignant : encodeur + tête**

$$g_{\theta_s} \leftrightarrow g_\phi \circ f_\theta$$

$$g_{\theta_t} \leftrightarrow g_{\bar{\phi}} \circ f_{\bar{\theta}}$$

Centrer les sorties enseignantes, puis appliquer des températures softmax distinctes.

Couper le gradient enseignant; modifier ses paramètres par moyenne mobile.

Apparier les distributions; mettre à jour étudiant et enseignant selon des règles distinctes.

# Appariement de distributions dans DINO

**Étudiant · vue 2**

Sorties de tête (exemple)

```
0.18  0.03  -0.08
```

**Enseignant · vue 1 · gradient coupé**

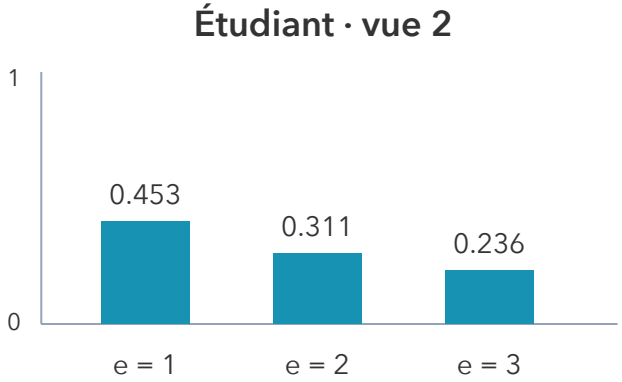
Sorties de tête (exemple)

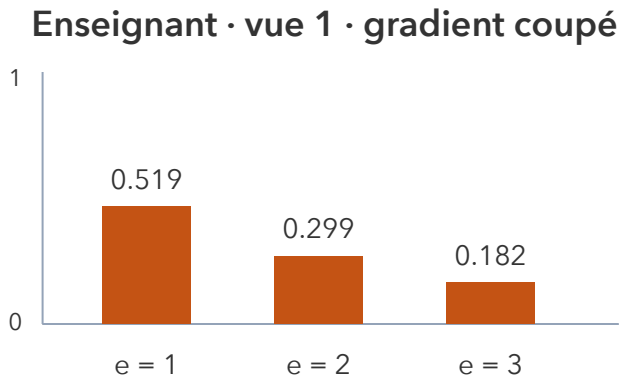
```
0.25  0.11  -0.02
```

Centre m = (0.05, 0.02, −0.01)

$$\mathbf{q}_i^{(2)} = g_\phi(f_\theta(\widetilde{x}_i^{(2)})) \qquad \bar{\mathbf{q}}_i^{(1)} = g_{\bar{\phi}}(f_{\bar{\theta}}(\widetilde{x}_i^{(1)}))$$

# Appariement de distributions dans DINO

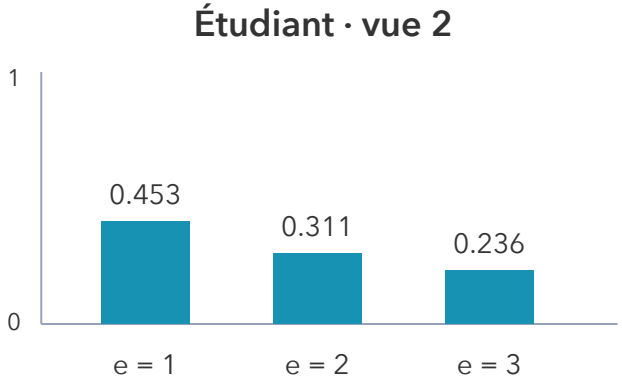


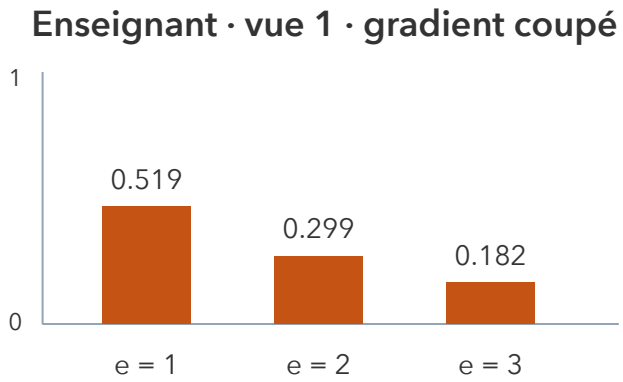




$$\boldsymbol{\rho}_{\text{stu}} = \text{softmax}(\mathbf{q}_i^{(2)} / \tau_{\text{stu}})$$

$$\boldsymbol{\rho}_{\text{teach}} = \text{sg}\Big(\text{softmax}((\bar{\mathbf{q}}_i^{(1)} - \mathbf{m}) / \tau_{\text{teach}})\Big)$$

# Appariement de distributions dans DINO

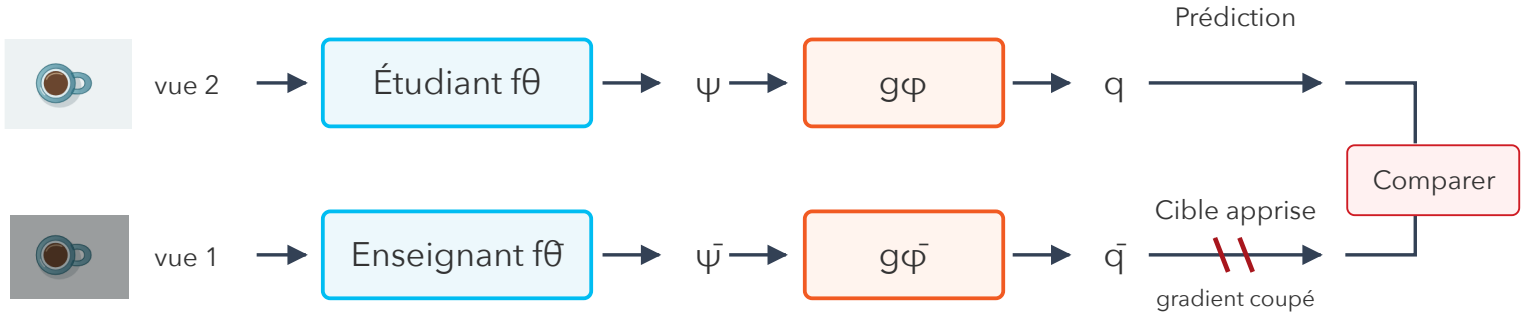



$$\ell_{\text{DINO}} = -\sum_{e} \rho_{\text{teach},e} \log \rho_{\text{stu},e}$$

Entropie croisée calculée pour une paire : **1.0230**

# Mises à jour par gradient et moyennes mobiles

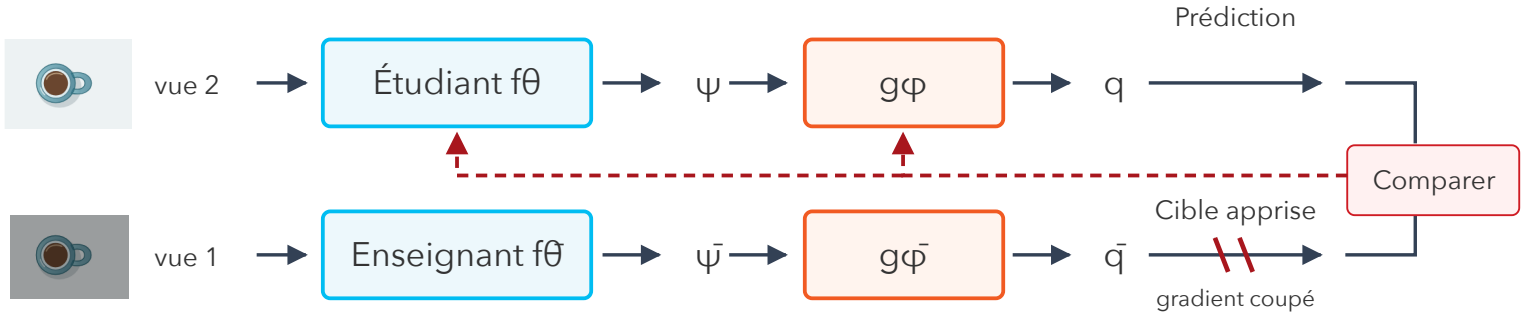



$$\Theta = (\theta, \phi) \qquad \bar{\Theta} = (\bar{\theta}, \bar{\phi})$$

Encodeur : $\theta = 0.450 \cdot \bar{\theta} = 0.600$ Tête : $\varphi = 0.800 \cdot \bar{\varphi} = 1.000$

Au départ, les paramètres enseignants sont les mêmes que ceux de l'étudiant.

# Mises à jour par gradient et moyennes mobiles



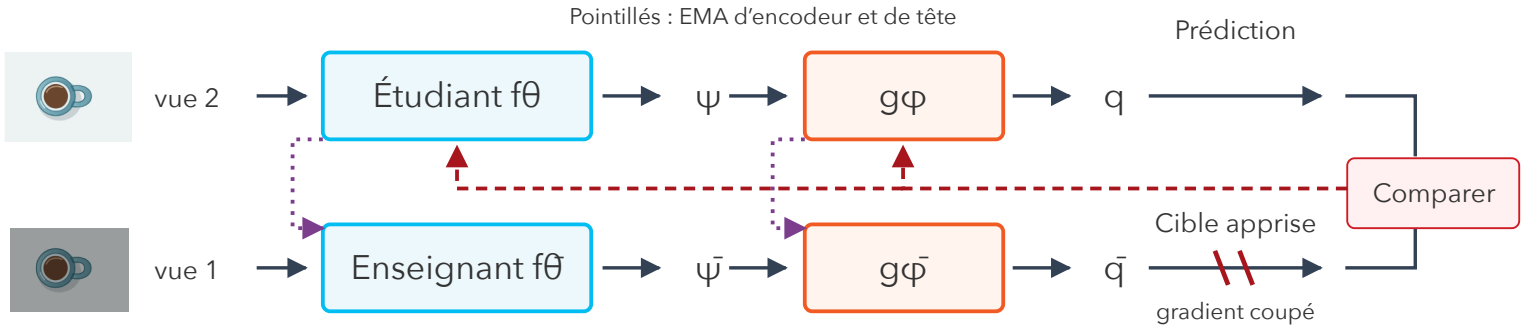

Tirets : gradients de θ et φ · aucun gradient enseignant

$$\Theta_{n+1} = \Theta_n - \eta \nabla_\Theta \mathcal{L}$$

Encodeur : θ = 0.488 · θ̄ = 0.600  Tête : φ = 0.830 · φ̄ = 1.000

Pas étudiant calculé : entropie croisée à cible fixe 0.7281 → 0.6997.

# Mises à jour par gradient et moyennes mobiles




Tirets : gradients de θ et φ · aucun gradient enseignant

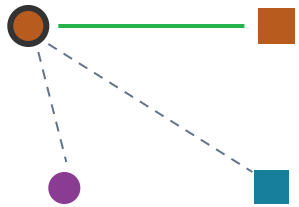
$$\bar{\theta}_{n+1} = \mu\bar{\theta}_n + (1-\mu)\theta_{n+1}$$

Encodeur : θ = 0.488 · θ̄ = 0.578  Tête : φ = 0.830 · φ̄ = 0.966

Après un lot (batch): mettre à jour la tête enseignante φ̄ avec une moyenne mobile.

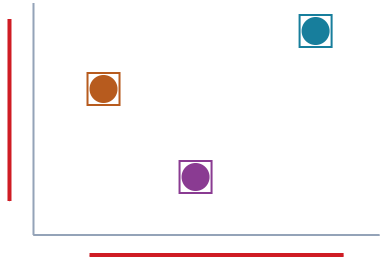
# Résumé de l'apprentissage de représentation

**SimCLR**



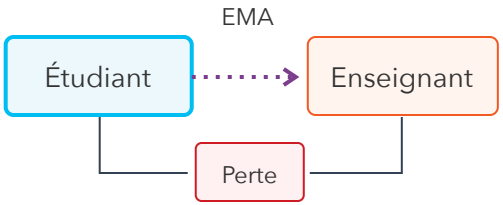
Vues concurrentes

**VICReg**



Dispersion + décorrélation

**DINO**




Cible centrée et accentuée

Distribution enseignante

Observation → encodeur → caractéristiques → relation ou cible → perte → mise à jour

**L'objectif d'une bonne représentation**

Conserver l'information utile à la tâche visée.

Ignorer le reste.

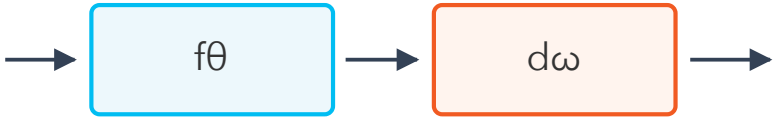
SECTION 04

# Reconstruction et prédiction de caractéristiques

# La reconstruction comme signal d'apprentissage

Image observée x






Pixels prédits



Les pixels originaux observés fournissent la cible.

Copier l'entrée peut reconstruire sans apprendre de caractéristiques utiles.

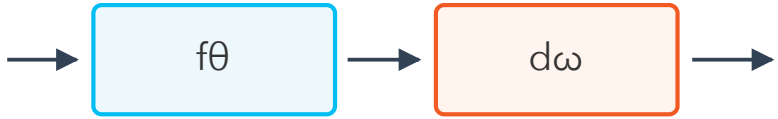
> L'observation originale fournit une cible sans annotation humaine.

# La reconstruction comme signal d'apprentissage

Entrée partiellement observée








Pixels prédits

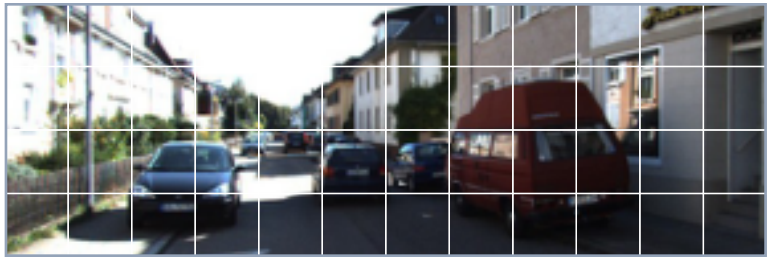
Les pixels originaux observés fournissent la cible.

Retirer l'information de l'entrée de prédiction, en la conservant pour la cible.

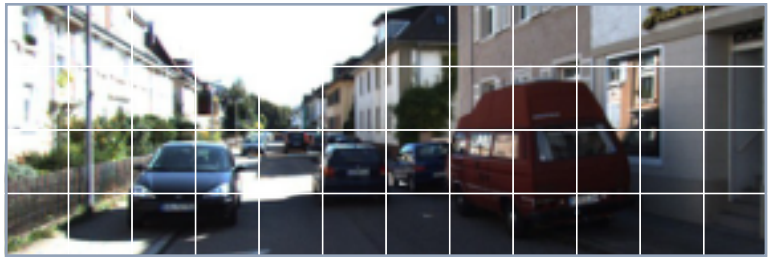
> L'observation originale fournit une cible sans annotation humaine.

# Blocs visibles et masqués

Observation originale x



Découpage : 48 blocs carrés

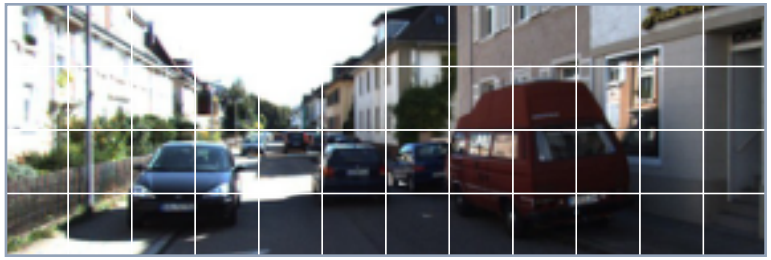


k identifie une position dans l'image originale.

La procédure conserve toutes les valeurs originales des blocs.

# Blocs visibles et masqués

Observation originale x



Blocs visibles V · masqués M

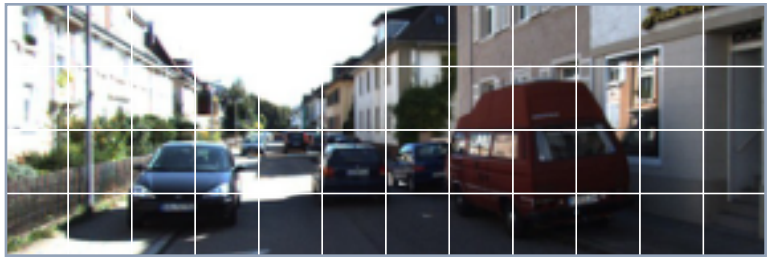


12 blocs visibles; 36 valeurs retirées de l'encodeur.

La procédure conserve toutes les valeurs originales des blocs.

# Blocs visibles et masqués

Observation originale x



Blocs visibles V · masqués M



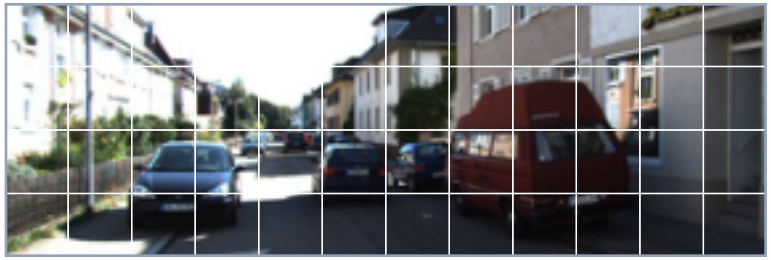



Jetons visibles + positions

L'encodeur MAE (masked auto-encoder) reçoit les jetons visibles et leurs positions originales.

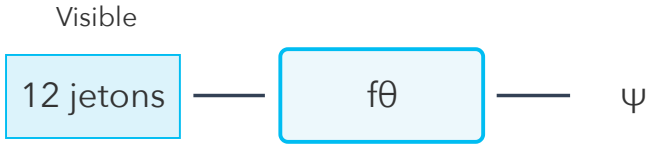
# Architecture de MAE

Observation originale



Entrée encodeur : blocs visibles seuls

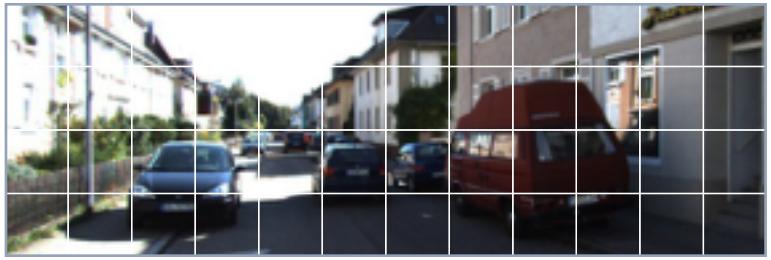





Encoder les blocs visibles seuls.

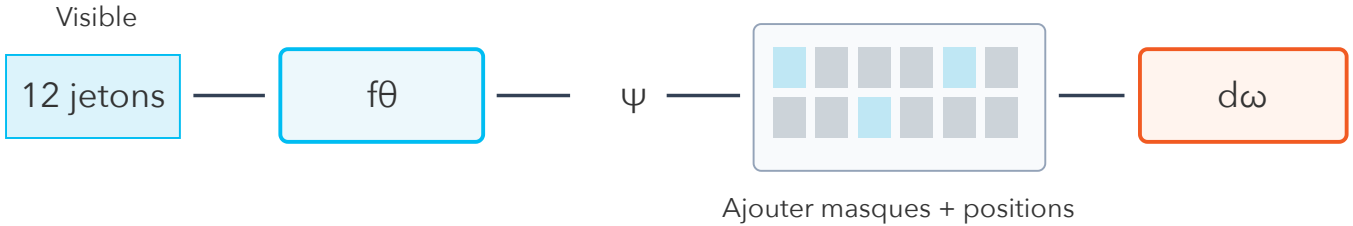
# Architecture de MAE

Observation originale



Entrée encodeur : blocs visibles seuls

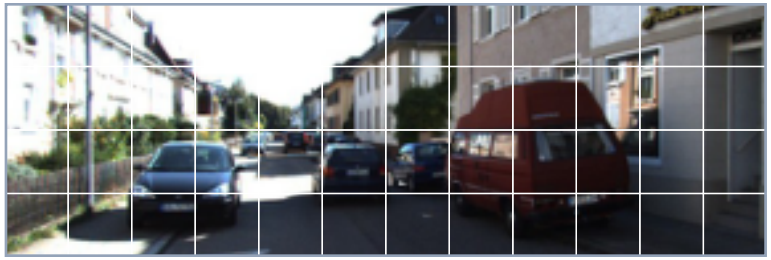





Restaurer les positions avec jetons visibles encodés et jetons de masque appris.

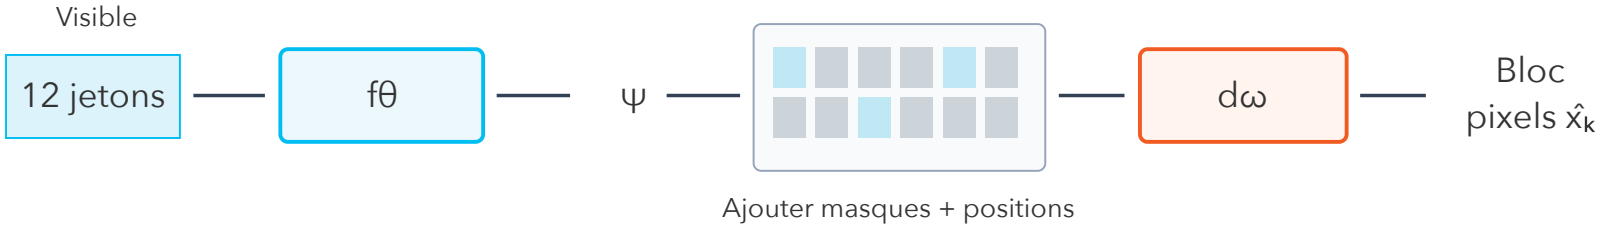
# Architecture de MAE

Observation originale



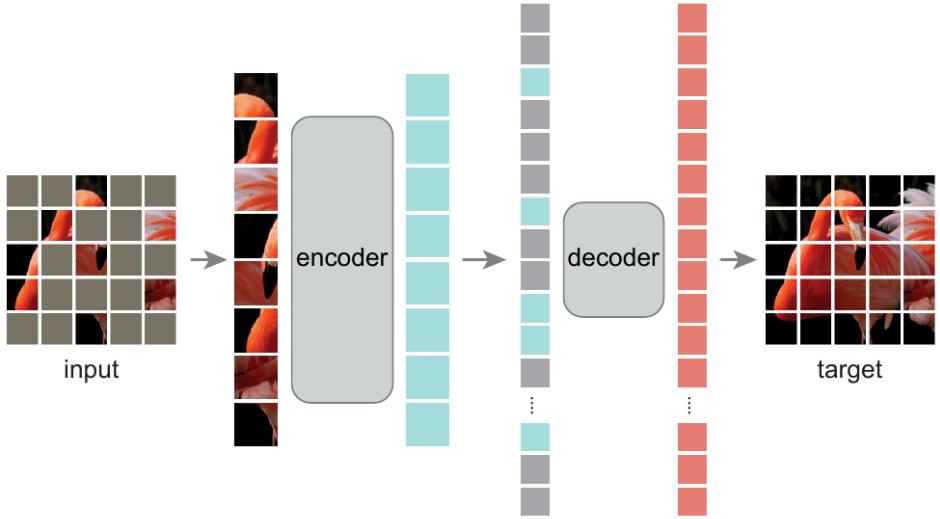
Entrée encodeur : blocs visibles seuls






Le décodeur prédit les pixels à toutes les positions de blocs.

# Architecture de MAE

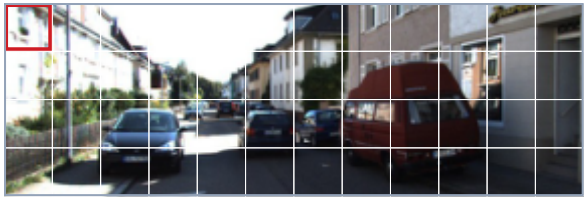



Les jetons de masque entrent dans le décodeur après encodage du visible.

He et al., MAE, CVPR 2022 · Fig. 1 · arXiv v3

# Perte de reconstruction aux positions masquées

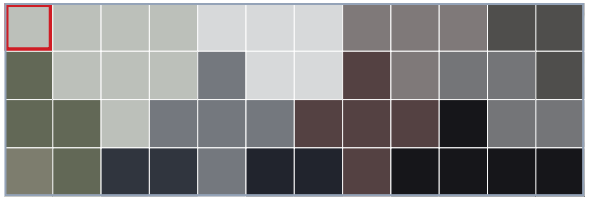
Pixels cibles originaux



Entrée encodeur visible



Prédiction de pixels



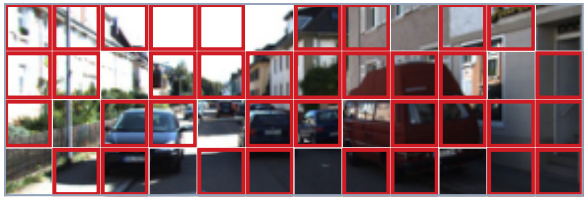
$$\|\hat{x}_k - x_k\|_2^2$$

Bloc masqué choisi k = 0: erreur quadratique = 96.68

$x_k$ est le vecteur RVB original du bloc k.

# Perte de reconstruction aux positions masquées

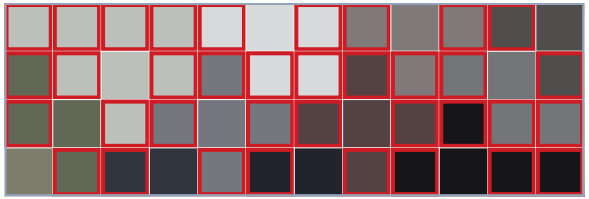
Pixels cibles originaux



Entrée encodeur visible



Prédiction de pixels



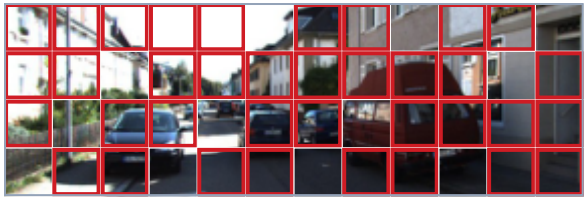
$$\mathcal{L}_{\text{pixel}} = \frac{1}{|\mathcal{M}|} \sum_{k \in \mathcal{M}} \|\widehat{x}_k - x_k\|_2^2$$

Moyenner sur 36 blocs masqués : Lpixel = 148.32

$x_k$ est le vecteur RVB original du bloc k.

# Perte de reconstruction aux positions masquées

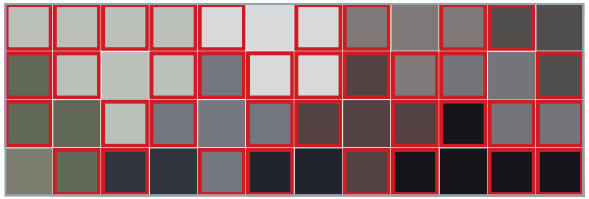
Pixels cibles originaux



Entrée encodeur visible



Prédiction de pixels



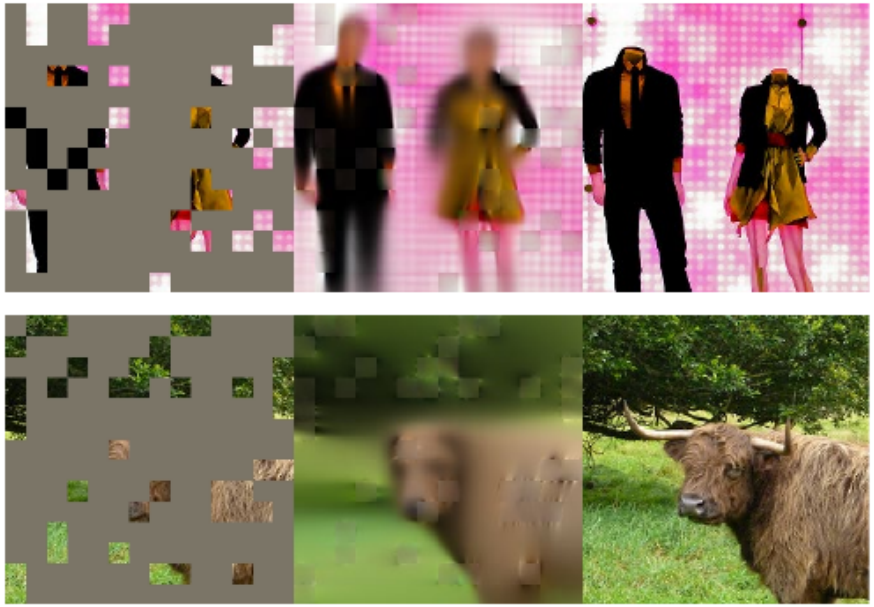
$$\mathcal{L}_{\text{pixel}} = \frac{1}{|\mathcal{M}|} \sum_{k \in \mathcal{M}} \|\widehat{x}_k - x_k\|_2^2$$

Moyenner sur 36 blocs masqués : Lpixel = 148.32

La perte de base agit sur les blocs masqués.

# Reconstruction plausible et ambiguïté

Entrée masquée Reconstruction MAE Image originale



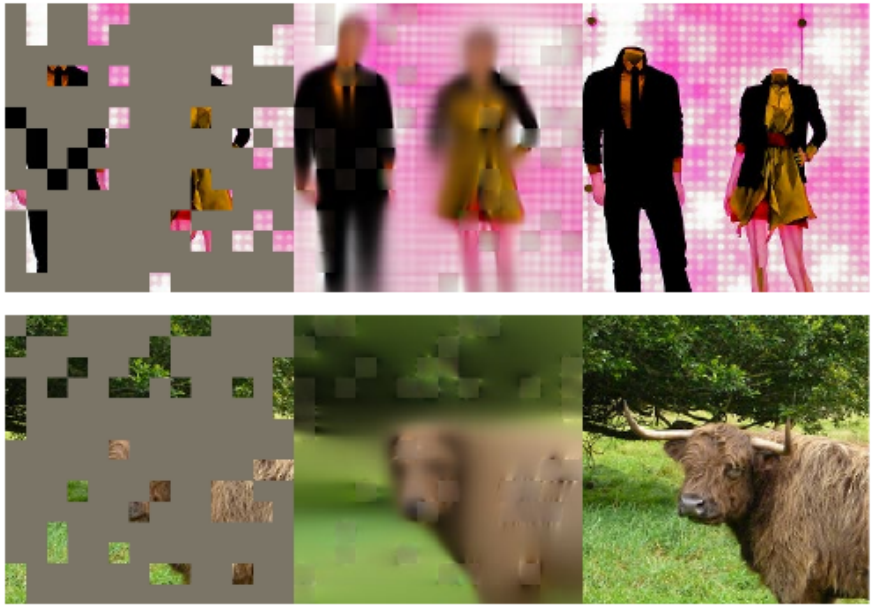
**Plusieurs complétions possibles**

Le contexte visible ne détermine pas chaque détail masqué.

He et al., MAE, CVPR 2022 · Fig. 3, deux exemples les plus à droite · arXiv v3 · Images de validation COCO; modèle préentraîné sur ImageNet

# Reconstruction plausible et ambiguïté

Entrée masquée Reconstruction MAE Image originale



**Plusieurs complétions possibles**

Le contexte visible ne détermine pas chaque détail masqué.

Les sorties diffèrent des originaux, avec une structure de scène plausible.

La plausibilité visuelle ne prouve ni compréhension sémantique ni précision robotique.

He et al., MAE, CVPR 2022 · Fig. 3, deux exemples les plus à droite · arXiv v3 · Images de validation COCO; modèle préentraîné sur ImageNet

# Que demande de conserver une cible de prédiction ?

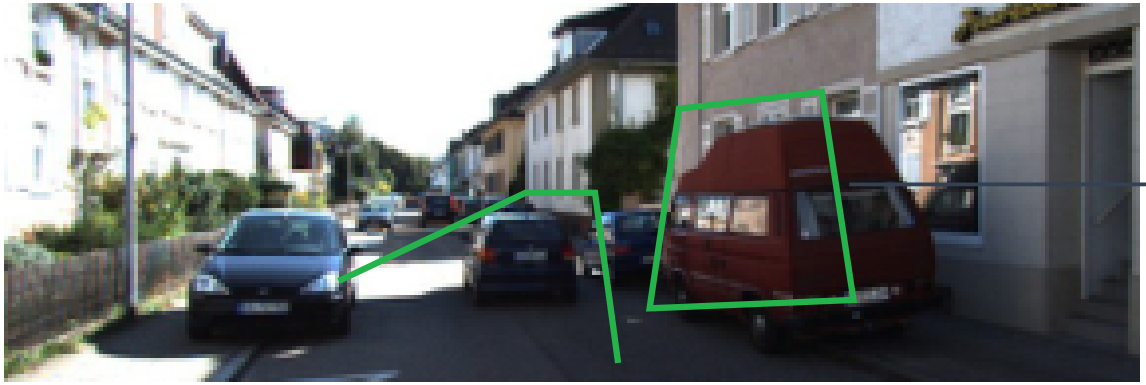



Les cibles de pixels demandent couleur, éclairage et texture.

La cible définit les erreurs de prédiction à réduire.

> Les caractéristiques utiles à apprendre dépendent de la tâche.

# Que demande de conserver une cible de prédiction ?

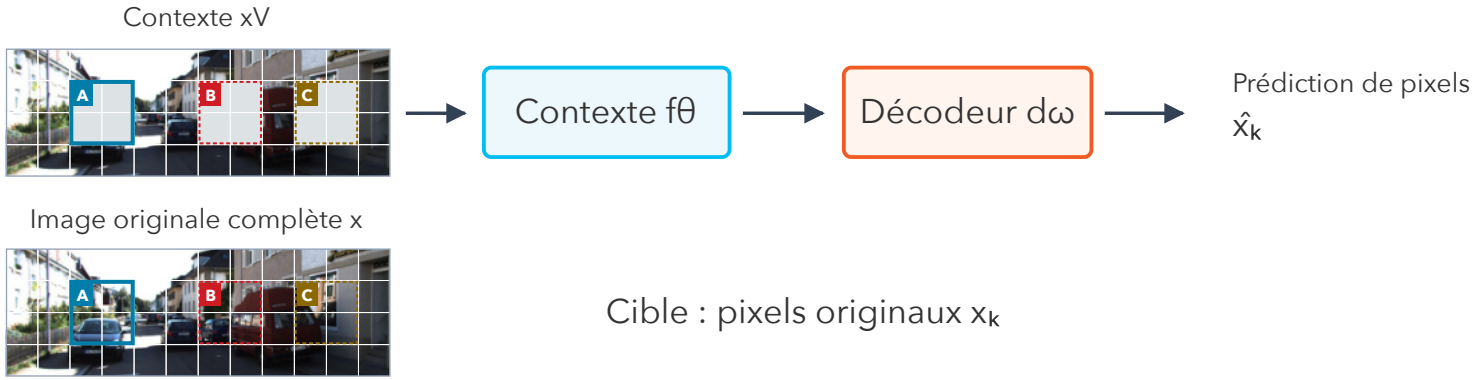



La tâche peut privilégier la structure des objets et de la route.

La cible définit les erreurs de prédiction à réduire.

> Les caractéristiques utiles à apprendre dépendent de la tâche.

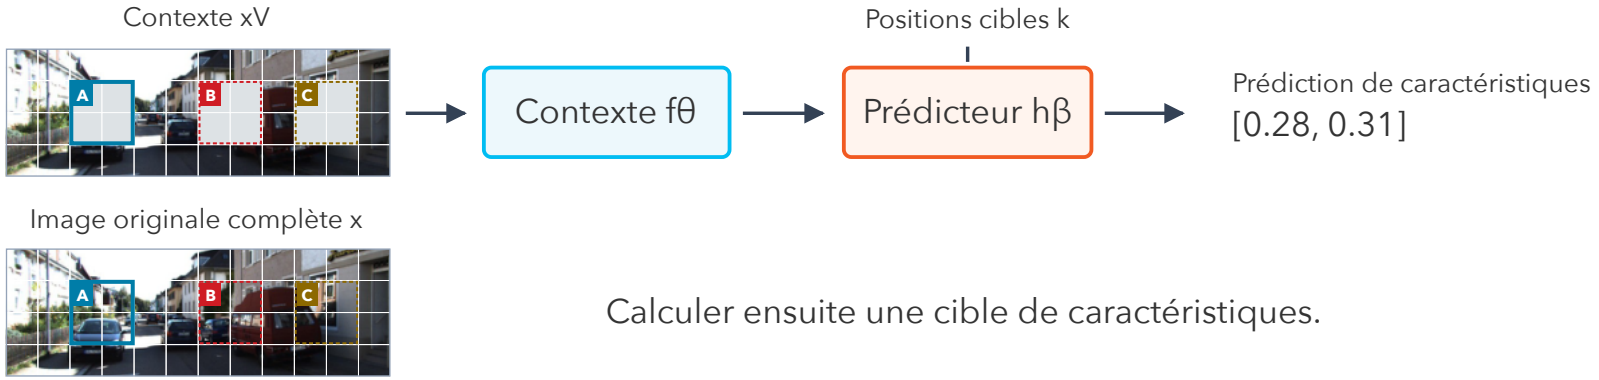
# JEPA: Prédire dans l'espace des caractéristiques




La reconstruction compare la sortie à l'image observée.

Changer le calcul de cible pour qu'elle soit dans l'espace intermédiaire des caractéristiques. Sans avoir à décoder dans l'espace de prédiction (ex: image). Permet d'apprendre des concepts plus abstraits. Entraînement à grande échelle plus efficace.

# JEPA: Prédire dans l'espace des caractéristiques

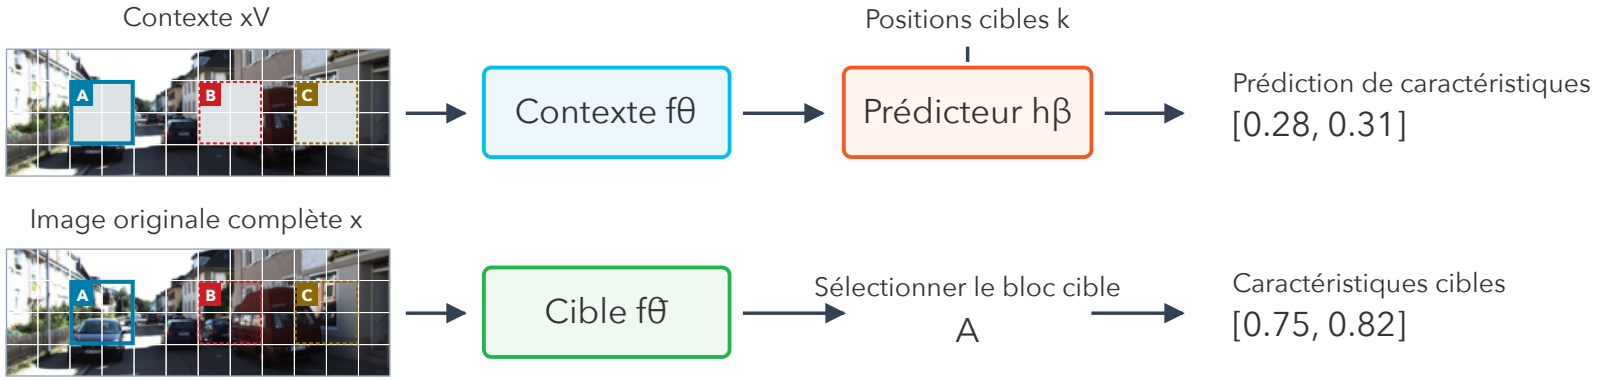



Calculer ensuite une cible de caractéristiques.

Le prédicteur produit des caractéristiques aux positions masquées demandées.

Changer le calcul de cible pour qu'elle soit dans l'espace intermédiaire des caractéristiques. Sans avoir à décoder dans l'espace de prédiction (ex: image). Permet d'apprendre des concepts plus abstraits. Entraînement à grande échelle plus efficace.

# JEPA: Prédire dans l'espace des caractéristiques

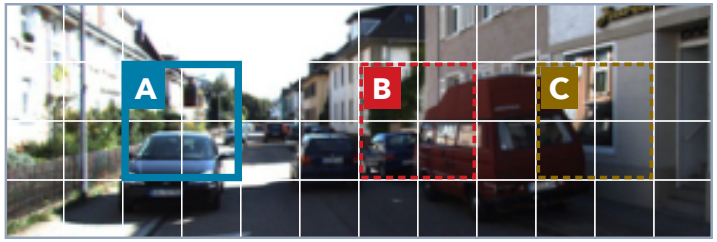



$$\psi_k^{\text{target}} = f_{\bar{\theta}}(x)_k$$

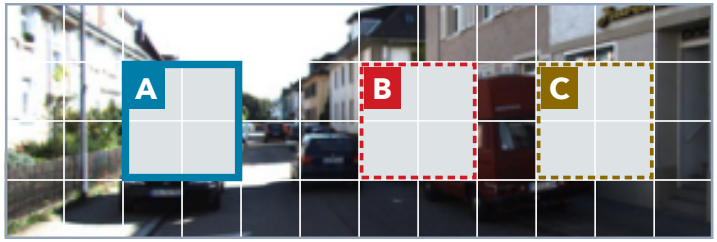
Changer le calcul de cible pour qu'elle soit dans l'espace intermédiaire des caractéristiques. Sans avoir à décoder dans l'espace de prédiction (ex: image). Permet d'apprendre des concepts plus abstraits. Entraînement à grande échelle plus efficace.

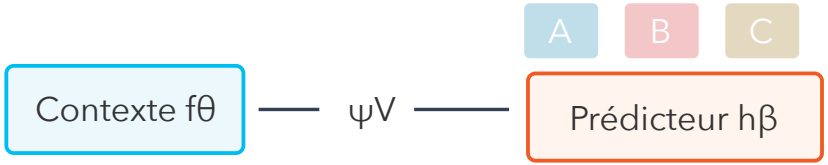
# JEPA: Contexte et positions cibles

Original · blocs spatiaux A, B, C




Contexte V · toutes les cibles retirées



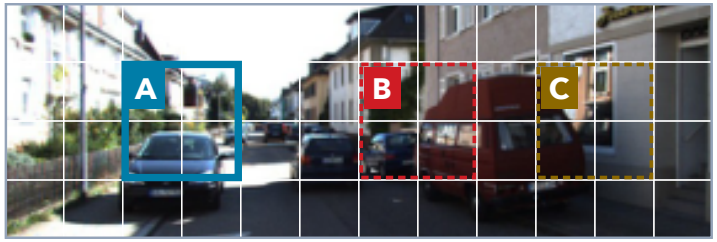




Le jeton indique où prédire, sans contenir de pixels masqués.

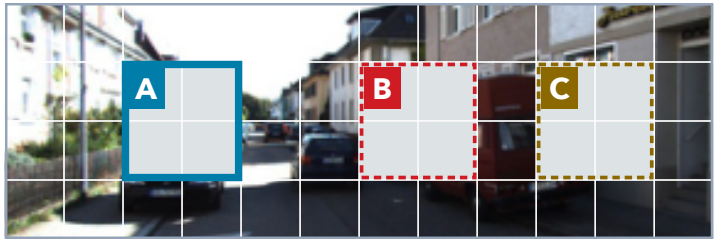
$$\widehat{\psi}_k = h_\beta(f_\theta(x_\mathcal{V}), k)$$

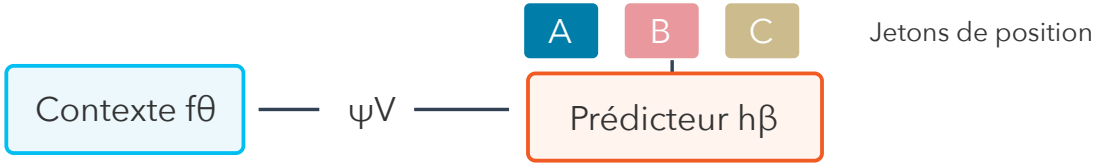
# JEPA: Contexte et positions cibles

Original · blocs spatiaux A, B, C




Contexte V · toutes les cibles retirées



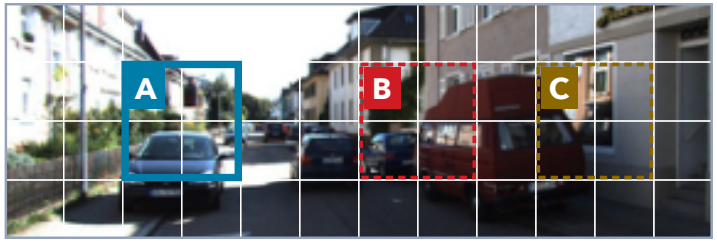




Le jeton indique où prédire, sans contenir de pixels masqués.

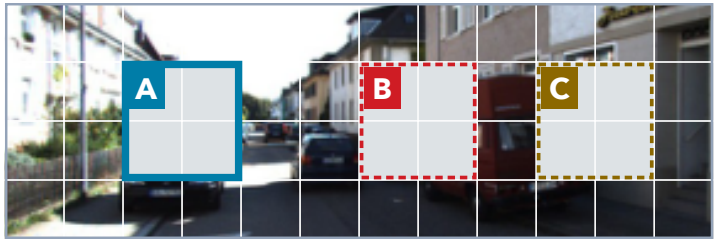
$$\widehat{\psi}_k = h_\beta(f_\theta(x_V), k)$$

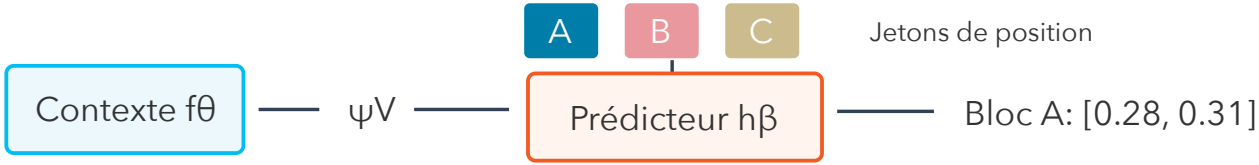
# JEPA: Contexte et positions cibles

Original · blocs spatiaux A, B, C




Contexte V · toutes les cibles retirées

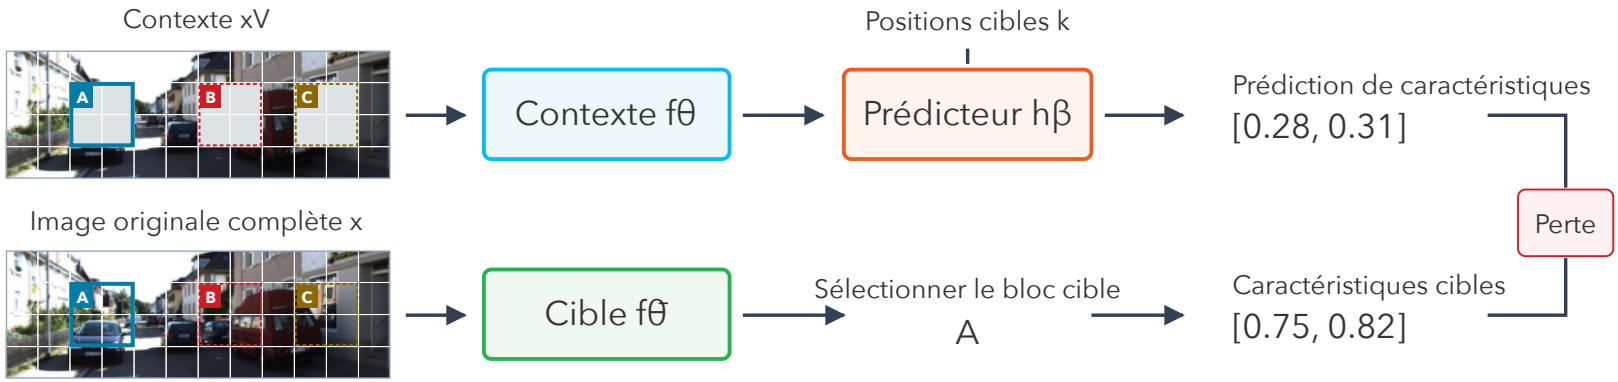



Le jeton indique où prédire, sans contenir de pixels masqués.

$$\widehat{\psi}_k = h_\beta(f_\theta(x_\mathcal{V}), k)$$

# JEPA: Perte de caractéristiques et mises à jour des cibles



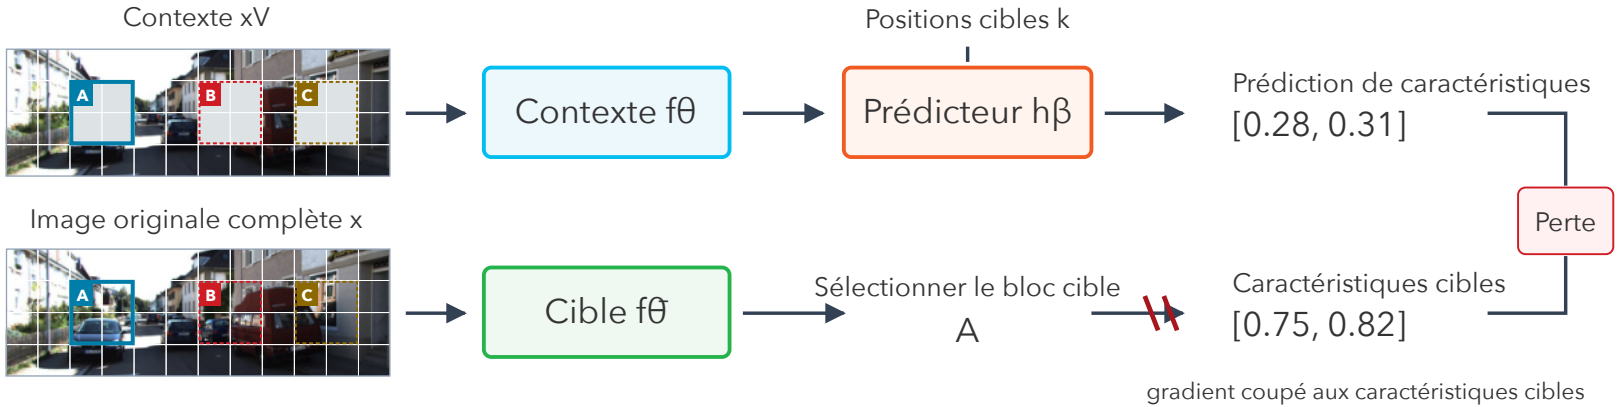

$$\mathcal{L}_{\text{feature}} = \frac{1}{|\mathcal{M}|} \sum_{k \in \mathcal{M}} \|\widehat{\boldsymbol{\psi}}_k - \boldsymbol{\psi}_k^{\text{target}}\|_2^2$$

Lfeature = 0.1978

θ = 0.800 · β = 0.700 · θ̄ = 1.000

Distance quadratique schématique, moyennée sur un bloc cible.

# JEPA: Perte de caractéristiques et mises à jour des cibles



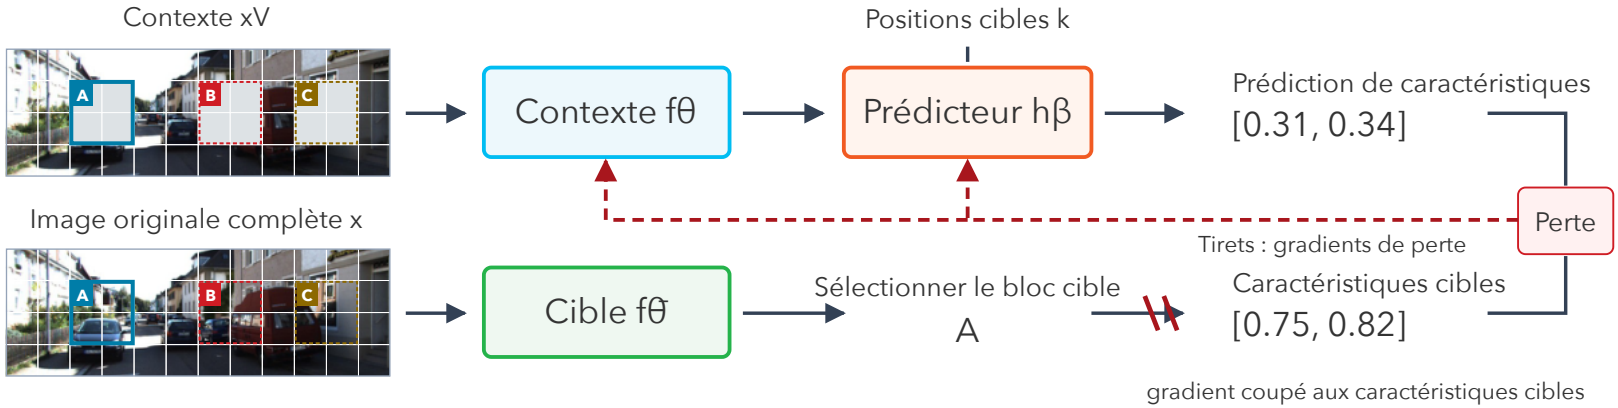

$$\psi_k^{\text{target}} = \text{sg}(f_{\bar{\theta}}(x)_k)$$

Lfeature = 0.1978

θ = 0.800 · β = 0.700 · θ̄ = 1.000

Traiter les caractéristiques cibles comme fixes pour différencier.

# JEPA: Perte de caractéristiques et mises à jour des cibles

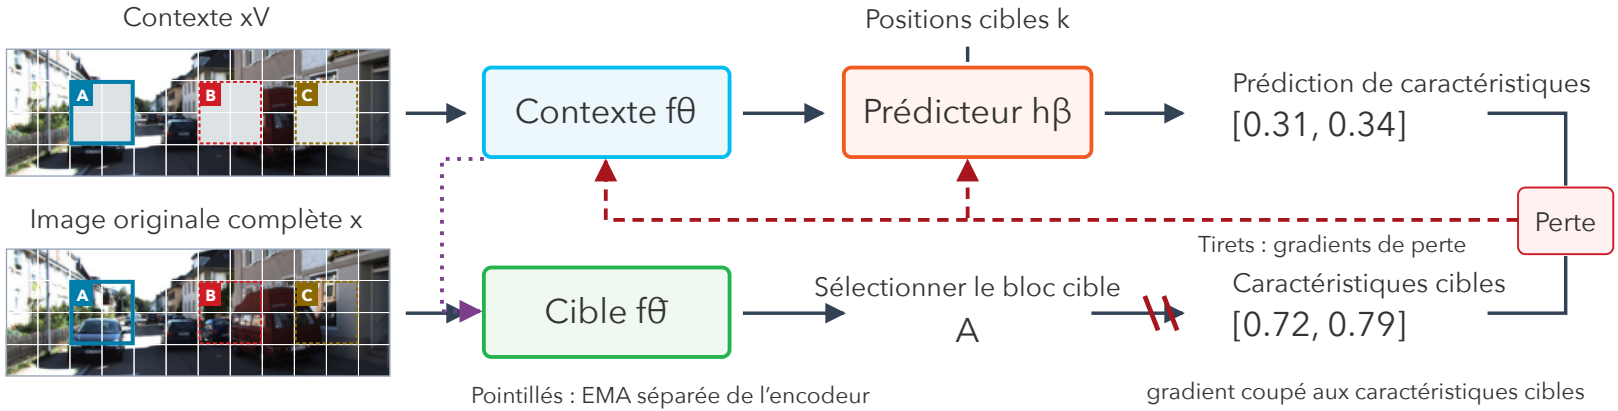



$$(\theta, \beta)_{n+1} = (\theta, \beta)_n - \eta \nabla_{(\theta,\beta)} \mathcal{L}_{\text{feature}}$$

Lfeature = 0.1731 θ = 0.833 · β = 0.738 · θ̄ = 1.000

Les gradients modifient l'encodeur de contexte et le prédicteur.

# JEPA: Perte de caractéristiques et mises à jour des cibles




$$\bar{\theta}_{n+1} = \mu\bar{\theta}_n + (1-\mu)\theta_{n+1}$$

Lfeature = 0.1515

θ = 0.833 · β = 0.738 · θ̄ = 0.967

L'EMA transfère les paramètres du contexte.

# Cibles de pixels et cibles de caractéristiques

## MAE · cible de pixels



fθ

dω

Masques + jetons de position

$\hat{x}_k$ ↔



Pixels observés $x_k$

# Cibles de pixels et cibles de caractéristiques

## MAE · cible de pixels



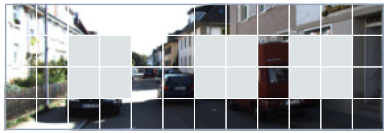
fθ — dω — $\hat{x}_k$ ↔



Masques + jetons de position

Pixels observés $x_k$

## I-JEPA · cible de caractéristiques



fθ — hβ — $\hat{\psi}_k$ ↔ $sg(f_{\bar{\theta}}(x)_k)$

Jetons de position cible

Cibles sur toutes les features de l'image

# Cibles de pixels et cibles de caractéristiques

## MAE · cible de pixels



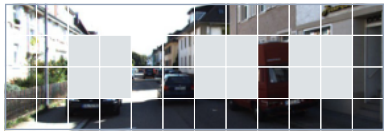
fθ — dω — $\hat{x}_k$ ↔



Masques + jetons de position

Pixels observés $x_k$

## I-JEPA · cible de caractéristiques



fθ — hβ — $\hat{\psi}_k$ ↔ $sg(f_{\bar{\theta}}(x)_k)$

Jetons de position cible

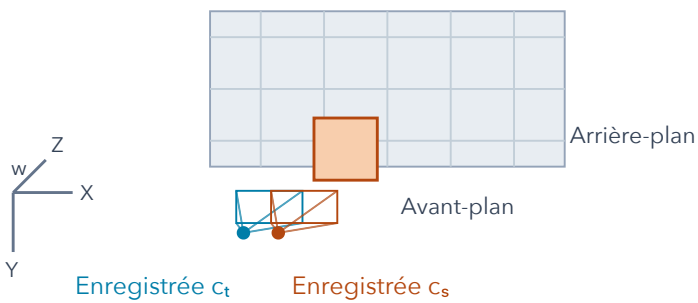
Cibles sur toutes les features de l'image

SECTION 05

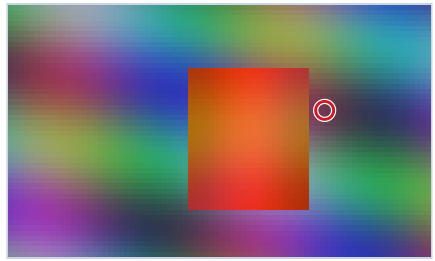
# Supervision géométrique

# Apprendre la profondeur à partir de plusieurs observations

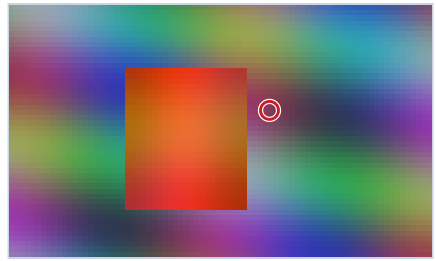
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Le marqueur source suit la projection calculée.

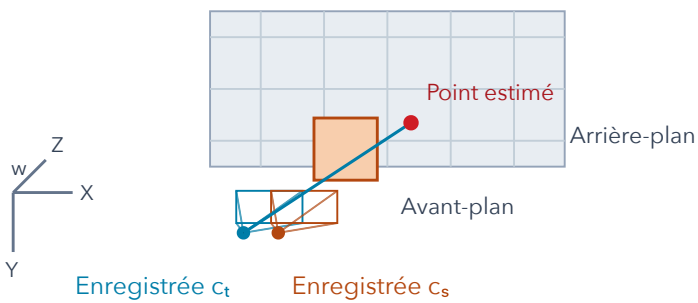
$\hat{D} = 3.50 \cdot \hat{p}$ dans $c_t$ : [1.06, -0.18, 3.50] · $u_s$ = [49.31, 20.00]

L'image enregistrée fournit la cible; profondeur et pose sont prédites.

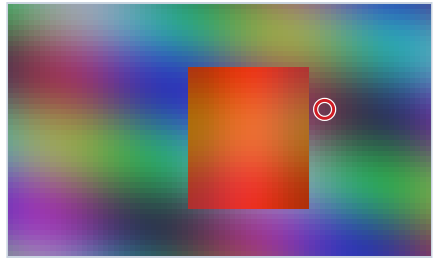
La structure de scène et le mouvement caméra peuvent fournir un signal d'apprentissage.

# Apprendre la profondeur à partir de plusieurs observations

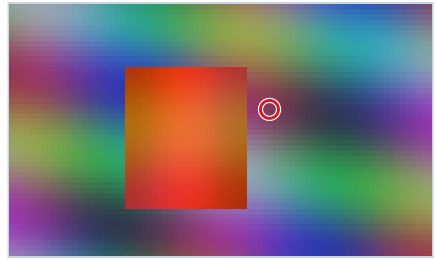
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Le marqueur source suit la projection calculée.

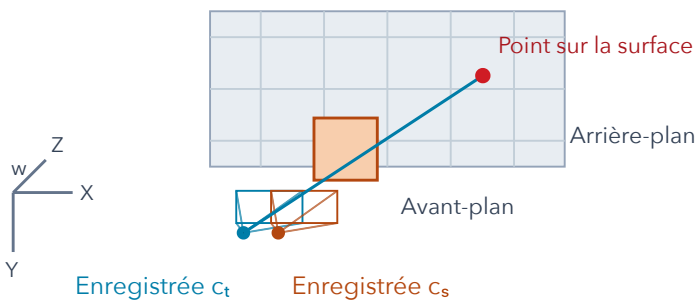
$\hat{D} = 3.50 \cdot \hat{p}$ dans $c_t$ : [1.06, -0.18, 3.50] · $u_s$ = [49.31, 20.00]

L'image enregistrée fournit la cible; profondeur et pose sont prédites.

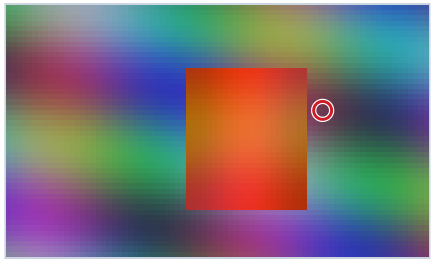
La structure de scène et le mouvement caméra peuvent fournir un signal d'apprentissage.

# Projection caméra et paramètres intrinsèques

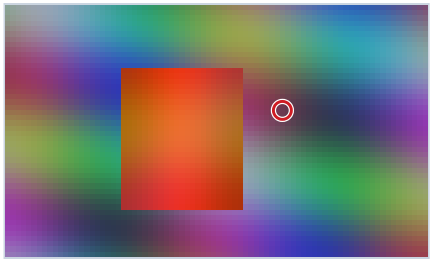
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Le marqueur source suit la projection calculée.

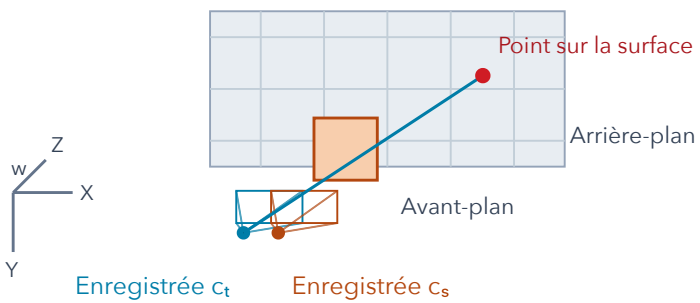
$$\mathbf{u} = \pi\left(K_t p^{c_t}\right)$$

fx = fy = 68 · cx = 39.5 · cy = 23.5 · X droite, Y bas, Z avant

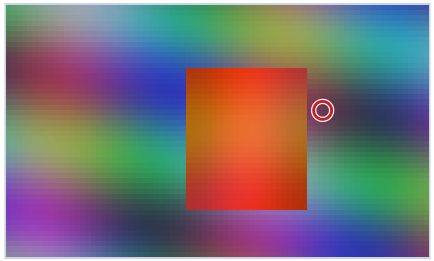
Coordonnées image : u vers la droite; v vers le bas.

# Projection caméra et paramètres intrinsèques

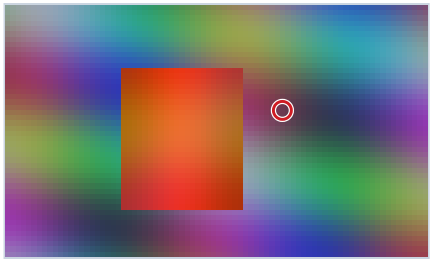
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Le marqueur source suit la projection calculée.

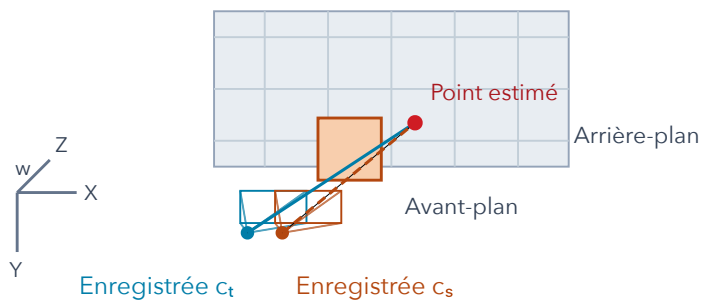
$$K_t = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

fx = fy = 68 · cx = 39.5 · cy = 23.5 · X droite, Y bas, Z avant

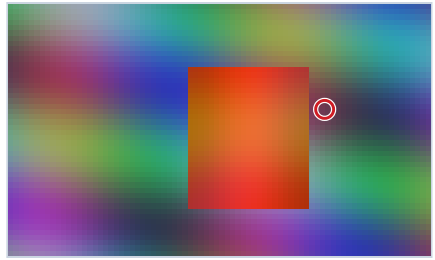
La profondeur est Z optique, distinct de la distance sur un rayon unitaire.

# Rétroprojeter un pixel cible

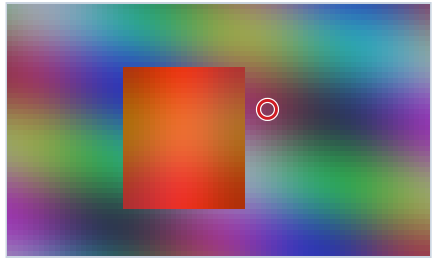
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Le marqueur source suit la projection calculée.

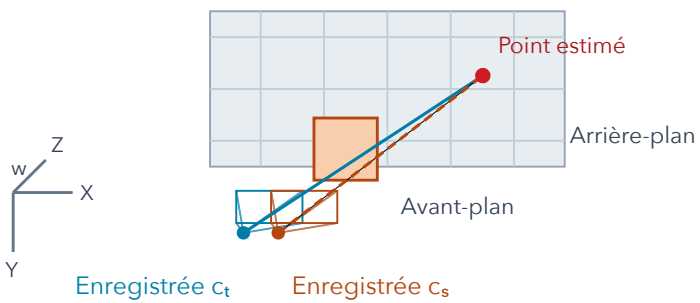
$$\hat{p}^{c_t} = \widehat{D}_t(\mathbf{u}) K_t^{-1} \tilde{\mathbf{u}}$$

$\hat{D}$ = 3.50 · $\hat{p}$ dans $c_t$ : [1.06, -0.18, 3.50] · $u_s$ = [49.31, 20.00]

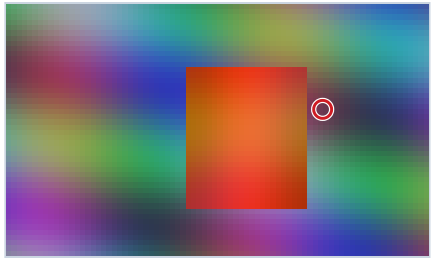
L'estimation de profondeur déplace le point sur un rayon cible fixe.

# Rétroprojeter un pixel cible

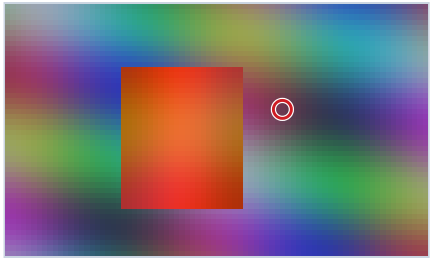
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Le marqueur source suit la projection calculée.

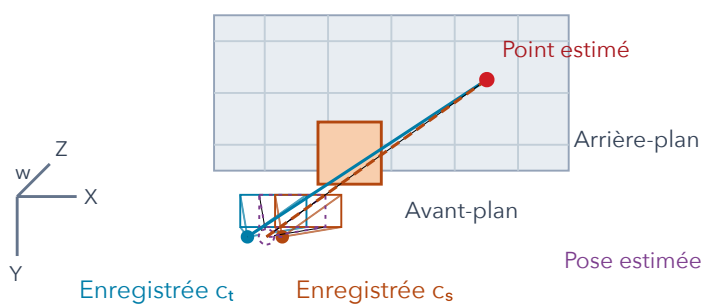
$$\hat{p}^{c_t} = \widehat{D}_t(\mathbf{u}) K_t^{-1} \tilde{\mathbf{u}}$$

$\hat{D}$ = 5.00 · $\hat{p}$ dans $c_t$ : [1.51, -0.26, 5.00] · $u_s$ = [52.52, 20.00]

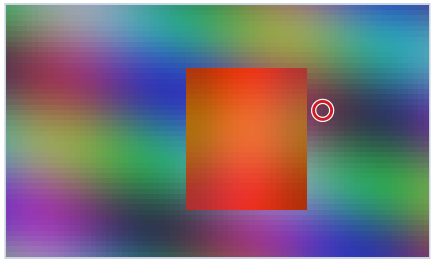
L'estimation de profondeur déplace le point sur un rayon cible fixe.

# Effet de la pose de la caméra

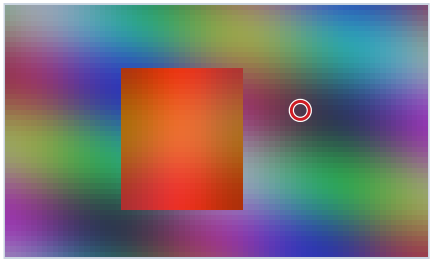
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Le marqueur source suit la projection calculée.

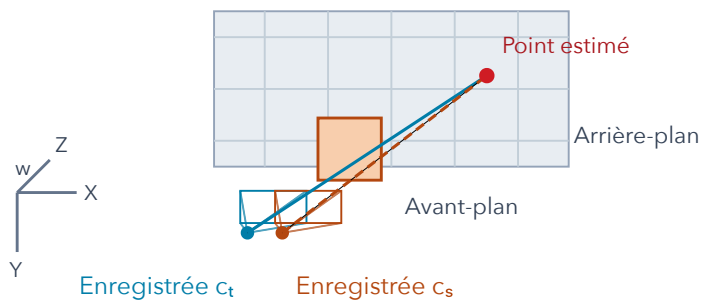
$$\hat{p}^{c_s} = \widehat{R}_{c_t}^{c_s} \hat{p}^{c_t} + \hat{t}_{c_t}^{c_s}$$

$\hat{p}$ dans $c_t$ : [1.51, -0.26, 5.00] · $\hat{p}$ dans $c_s$ : [1.21, -0.26, 5.00]

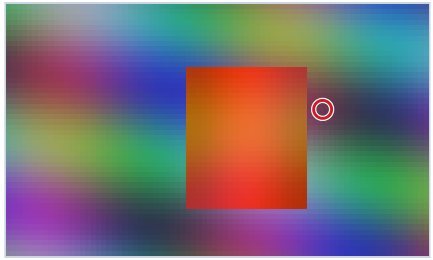
La pose estimée modifie les coordonnées et l'échantillonnage; les observations restent fixes.

# Effet de la pose de la caméra

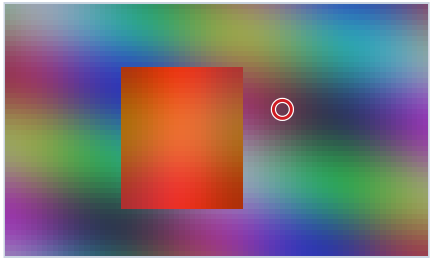
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Le marqueur source suit la projection calculée.

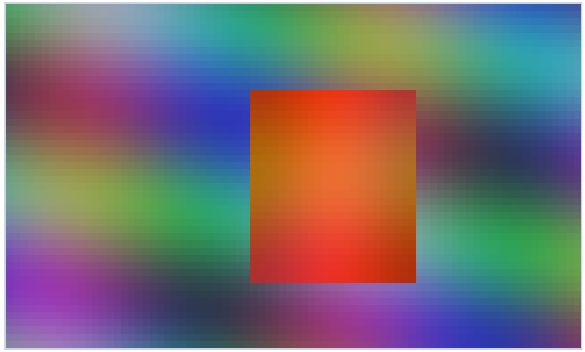
$$\hat{p}^{c_s} = \widehat{R}_{c_t}^{c_s} \hat{p}^{c_t} + \hat{t}_{c_t}^{c_s}$$

$\hat{p}$ dans $c_t$ : [1.51, -0.26, 5.00] · $\hat{p}$ dans $c_s$ : [0.96, -0.26, 5.00]

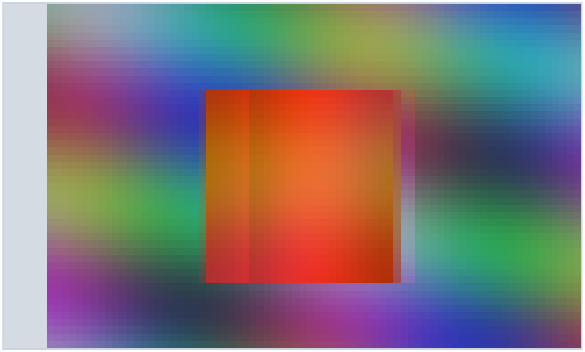
La pose estimée modifie les coordonnées et l'échantillonnage; les observations restent fixes.

# Perte de reconstruction photométrique

Cible enregistrée $I_t$



Cible reconstruite $\hat{I}_t$



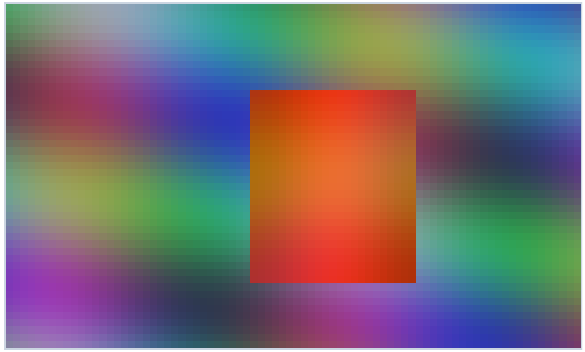
Prédire où échantillonner $I_s$ pour chaque pixel cible.

$$\mathcal{L}_{\text{photo}} = \frac{1}{|\Omega|} \sum_{\mathbf{u} \in \Omega} \| I_t(\mathbf{u}) - \hat{I}_t(\mathbf{u}) \|_1$$

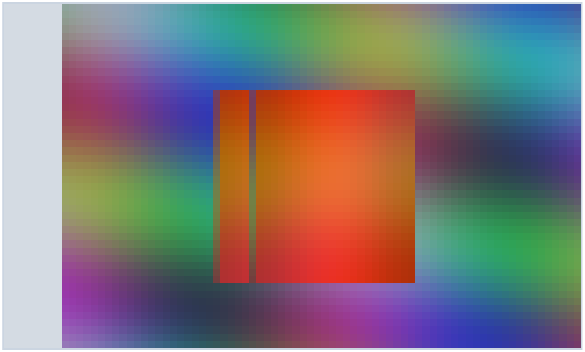
Moyenne RVB L1 = 0.1343 · 3552 / 3840 pixels dans Ω

# Perte de reconstruction photométrique

Cible enregistrée $I_t$



Cible reconstruite $\hat{I}_t$



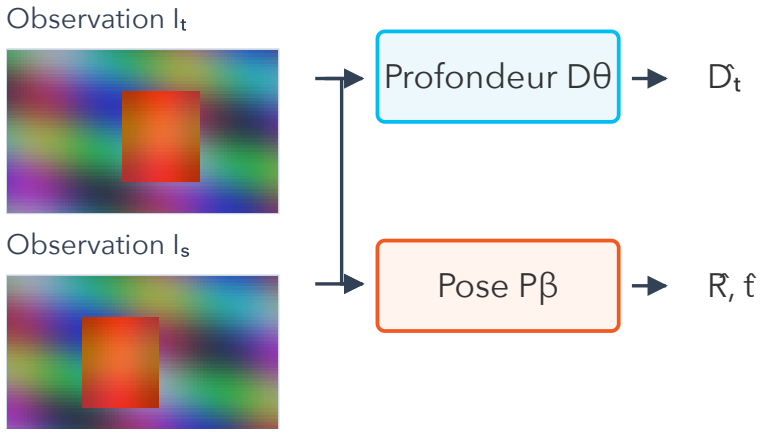
Erreur RVB L1 · clair = élevé



$$\mathcal{L}_{\text{photo}} = \frac{1}{|\Omega|} \sum_{\mathbf{u} \in \Omega} \| I_t(\mathbf{u}) - \hat{I}_t(\mathbf{u}) \|_1$$

Moyenne RVB L1 = 0.0448 · 3456 / 3840 pixels dans Ω

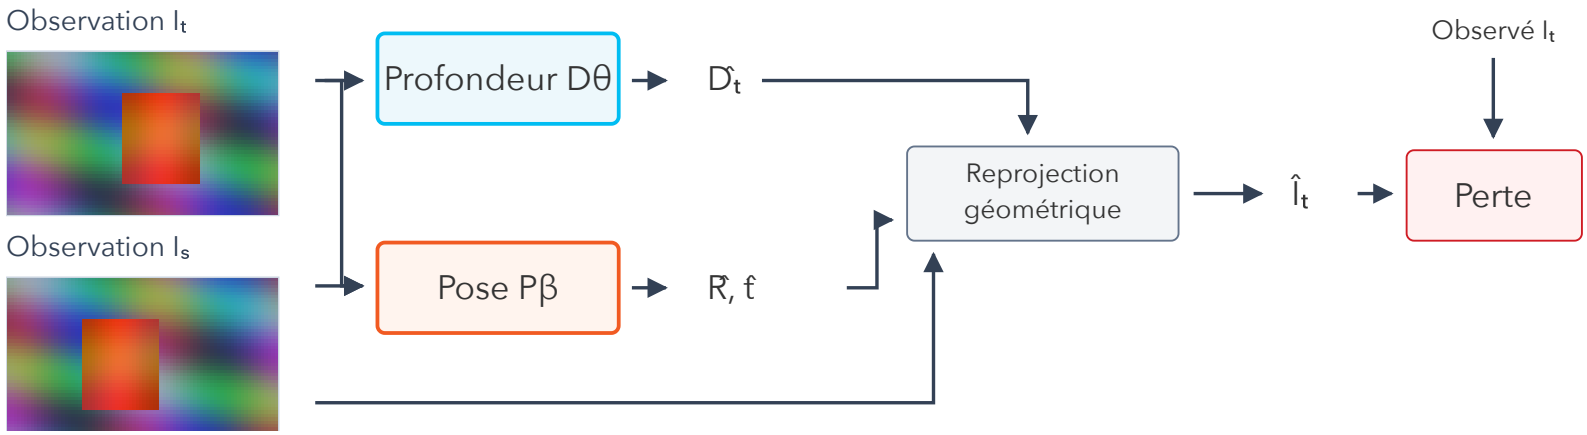
# Mettre à jour les réseaux de profondeur et de pose




$$\widehat{D}_t = D_\theta(I_t), \qquad \widehat{T}_{c_t}^{c_s} = P_\beta(I_t, I_s)$$

Profondeur et pose relative sont les grandeurs prédites.

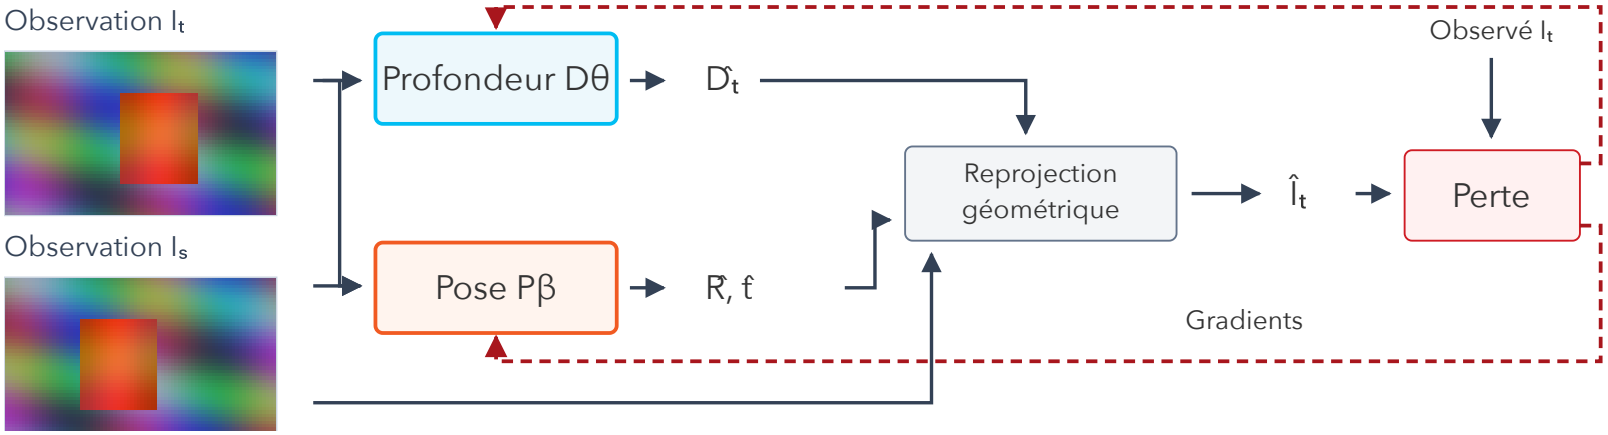
# Mettre à jour les réseaux de profondeur et de pose




$$\widehat{D}_t = D_\theta(I_t), \qquad \widehat{T}_{c_t}^{c_s} = P_\beta(I_t, I_s)$$

Profondeur et pose relative sont les grandeurs prédites.

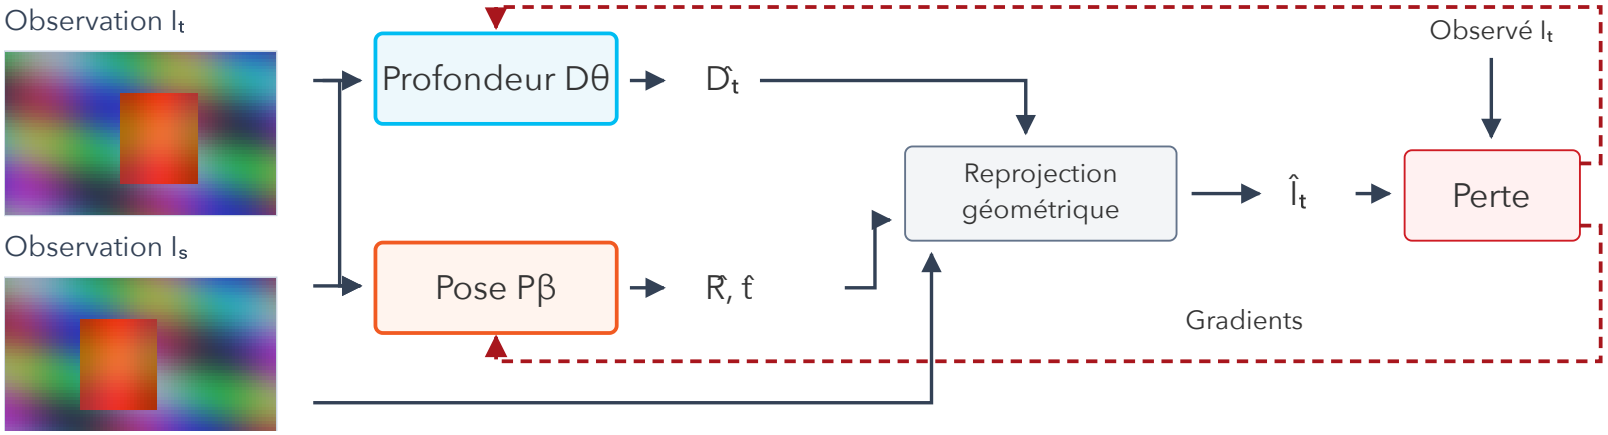
# Mettre à jour les réseaux de profondeur et de pose




$$\Theta_{n+1} = \Theta_n - \eta \nabla_\Theta \mathcal{L}_{\text{photo}}, \qquad \Theta = (\theta, \beta)$$

Modifier les réseaux, sans changer les images ni les poses physiques.

# Mettre à jour les réseaux de profondeur et de pose

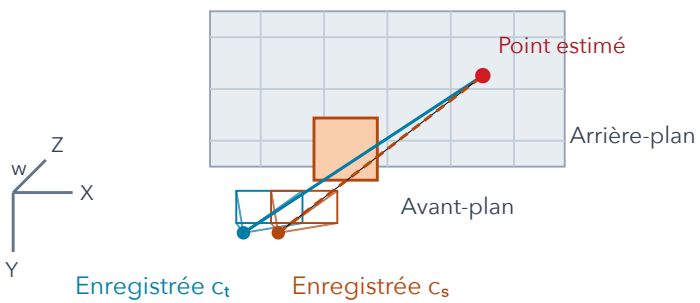



$$\Theta_{n+1} = \Theta_n - \eta \nabla_\Theta \mathcal{L}_{\text{photo}}, \qquad \Theta = (\theta, \beta)$$

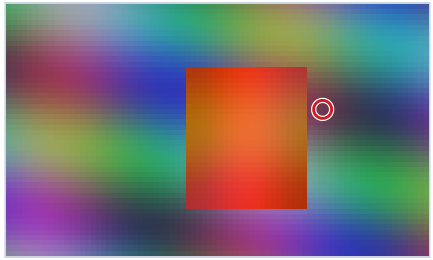
Mise à jour scalaire calculée : moins d'erreur ne fixe pas l'échelle métrique.

# Ambiguïté d'échelle monoculaire

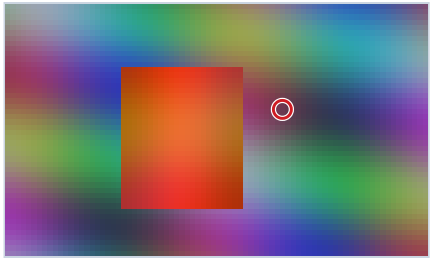
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Cible Échantillonné **RVB L1 = 0.0004**

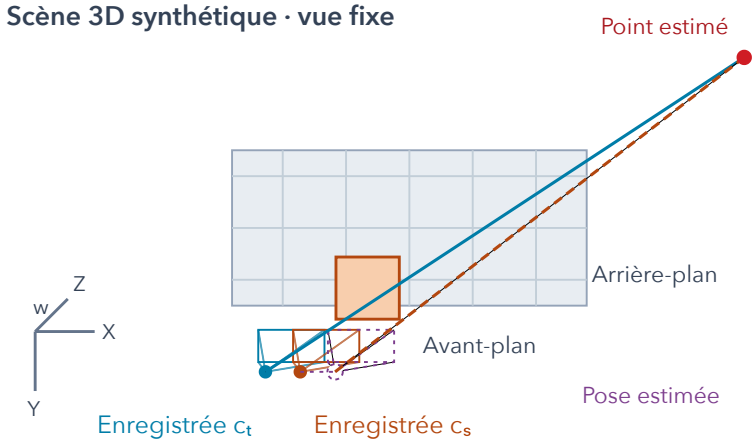
Le marqueur source suit la projection calculée.

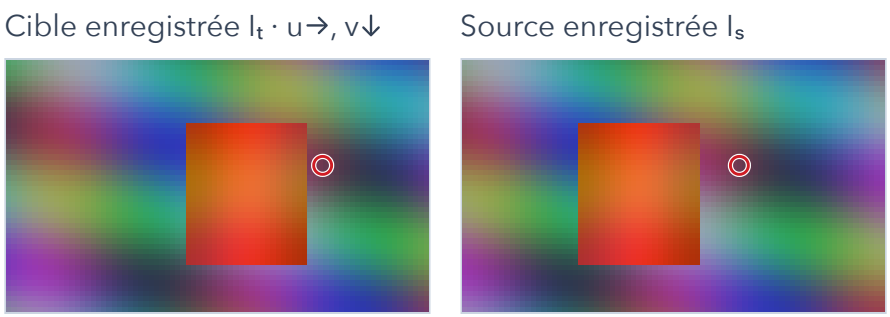
$$\pi(K_s\,\kappa\hat{p}^{c_s}) = \pi(K_s\hat{p}^{c_s}), \qquad \kappa > 0$$

$\hat{D}$ = 5.00 · $\hat{p}$ dans $c_t$ : [1.51, -0.26, 5.00] · $u_s$ = [52.52, 20.00]

Mettre profondeur et translation relative à l'échelle ensemble; les pixels restent fixes.

# Ambiguïté d'échelle monoculaire




Le marqueur source suit la projection calculée.

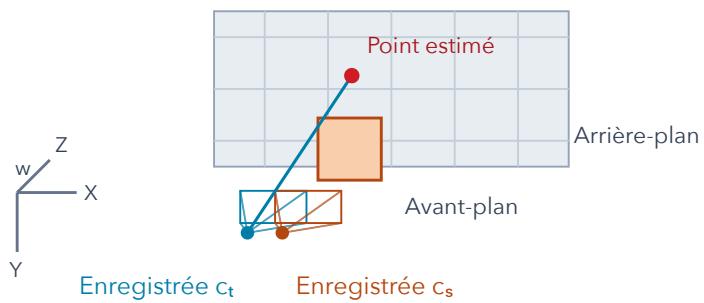
$$\pi\left(K_s\, \kappa \hat{p}^{c_s}\right) = \pi\left(K_s \hat{p}^{c_s}\right), \qquad \kappa > 0$$

$\hat{D}$ = 10.00 · $\hat{p}$ dans $c_t$ : [3.01, -0.51, 10.00] · $u_s$ = [52.52, 20.00]

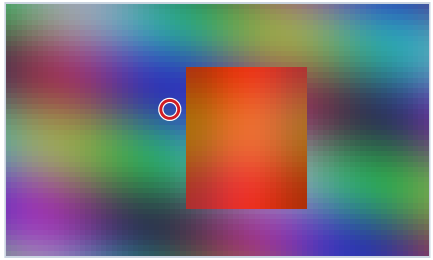
Mettre profondeur et translation relative à l'échelle ensemble; les pixels restent fixes.

# Limites liées aux occultations

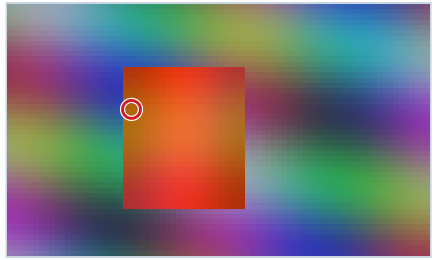
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Cible Échantillonné **RVB L1 = 1.2332**

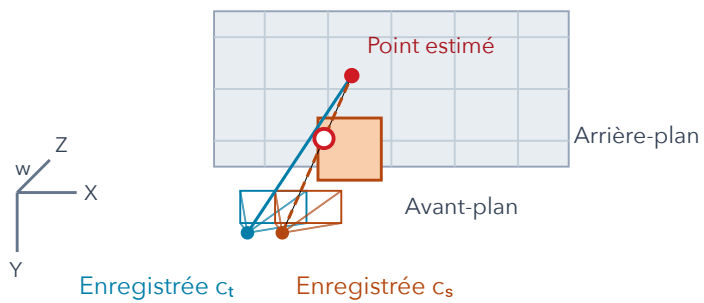
Le marqueur source suit la projection calculée.

$Z_s = 5.00 > 0$ · $u_s = [23.52, 20.00]$ · le rayon source atteint d'abord l'avant-plan

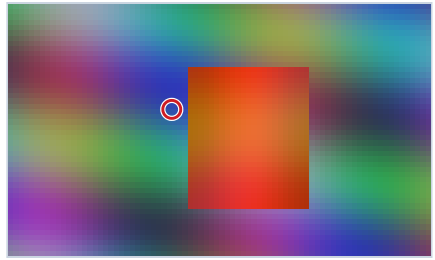
La caméra cible voit le fond.

# Limites liées aux occultations

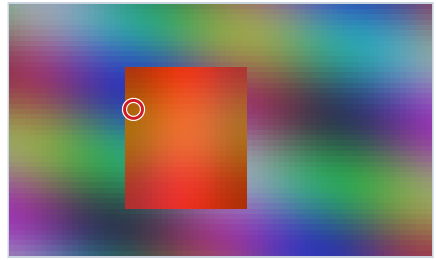
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Cible Échantillonné **RVB L1 = 1.2332**

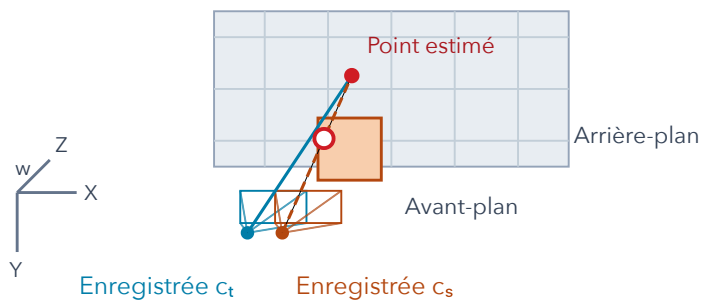
Le marqueur source suit la projection calculée.

$Z_s = 5.00 > 0$ · $u_s = [23.52, 20.00]$ · le rayon source atteint d'abord l'avant-plan

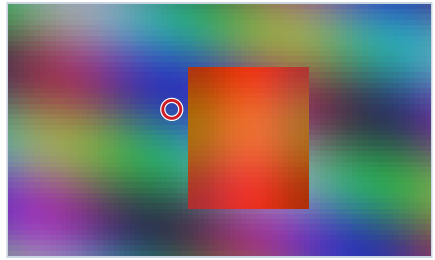
Une projection positive dans l'image peut encore être occultée.

# Limites liées aux occultations

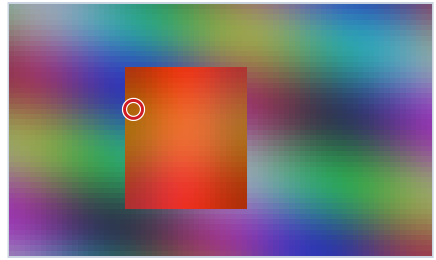
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Cible Échantillonné **RVB L1 = 1.2332**

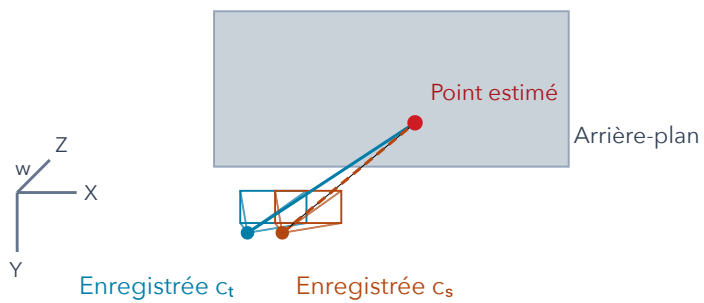
Le marqueur source suit la projection calculée.

$Z_s = 5.00 > 0$ · $u_s = [23.52, 20.00]$ · le rayon source atteint d'abord l'avant-plan

Une projection positive dans l'image peut encore être occultée.

# Limites liées à la texture et à la réflectance

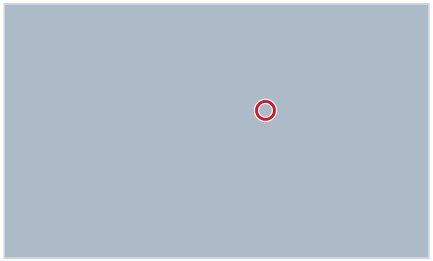
**Scène 3D synthétique · vue fixe**




Cible enregistrée $I_t$ · u→, v↓



Source enregistrée $I_s$



Cible Échantillonné **RVB L1 = 0.0000**

Le marqueur source suit la projection calculée.

$$I_t(\mathbf{u}) = \hat{I}_t(\mathbf{u}) \quad \text{pour plusieurs profondeurs}$$

$\hat{D}$ = 3.50 · $\hat{p}$ dans $c_t$ : [1.06, -0.18, 3.50] · $u_s$ = [49.31, 20.00]

Une apparence uniforme donne la même couleur à des projections différentes.

# Limites liées à la texture et à la réflectance




Godard et al., Monodepth2, ICCV 2019 · Fig. 8 · arXiv v4

**La cohérence d'apparence peut échouer**

En haut : zones déformées, réfléchissantes et saturées en couleur.

Exemples de l'article, avec étiquettes de méthodes et régions soulignées originales.

# Limites liées à la texture et à la réflectance




Godard et al., Monodepth2, ICCV 2019 · Fig. 8 · arXiv v4

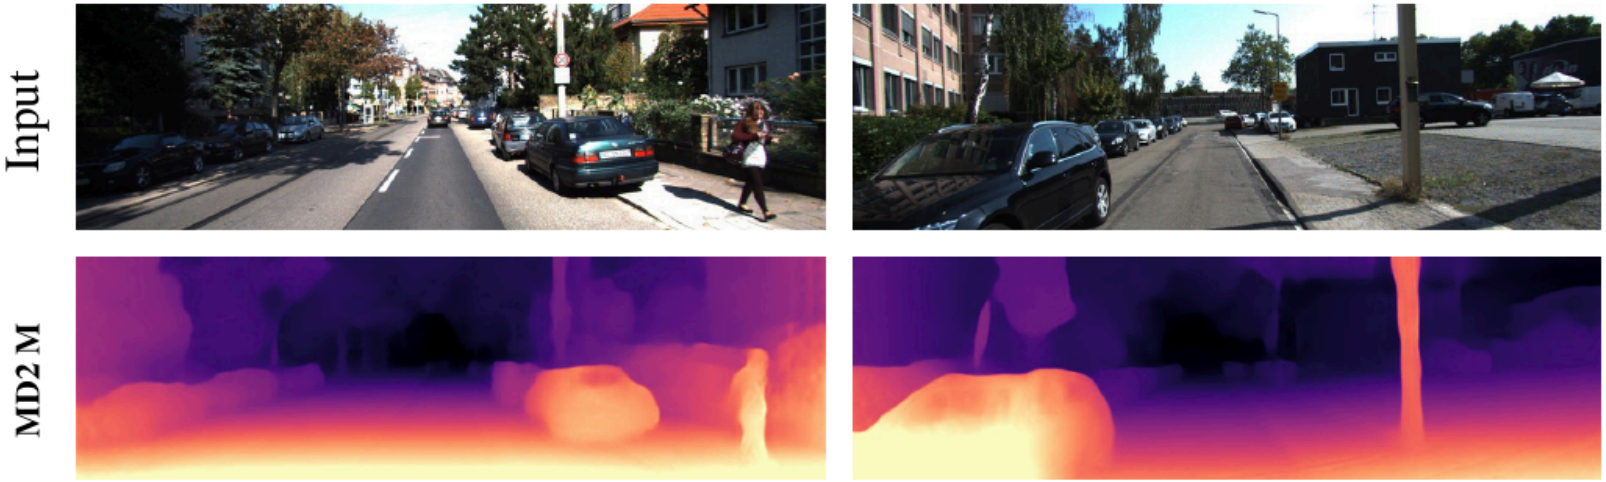
**La cohérence d'apparence peut échouer**

En haut : zones déformées, réfléchissantes et saturées en couleur.

En bas : frontières ambiguës et formes complexes peuvent aussi poser problème.

Exemples de l'article, avec étiquettes de méthodes et régions soulignées originales.

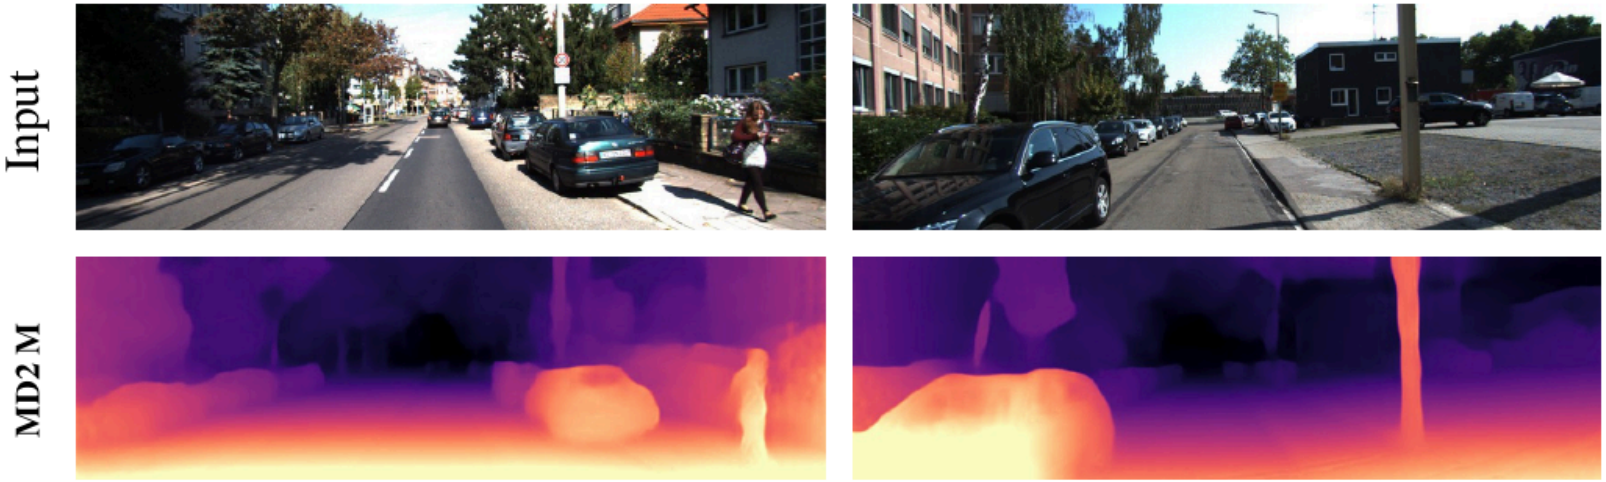
# Profondeur apprise sur des images réelles




Images caméra enregistrées en haut; profondeurs monoculaires Monodepth2 prédites en bas.

Godard et al., Monodepth2, ICCV 2019 · Fig. 7, deux premiers exemples, lignes Input et MD2 M · Partition Eigen de KITTI · arXiv v4

# Profondeur apprise sur des images réelles




Images caméra enregistrées en haut; profondeurs monoculaires Monodepth2 prédites en bas.

> Pour une profondeur métrique, il faut ajouter un fine-tuning par supervision contre des données 3D (ex: LiDAR).

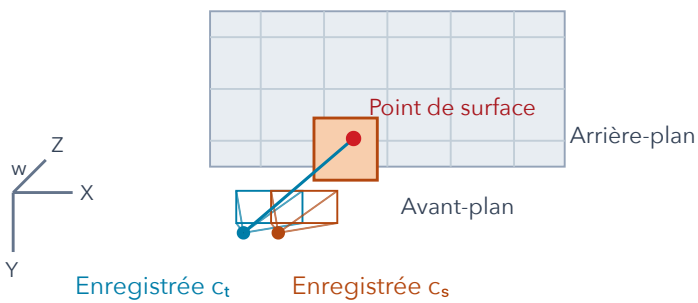
Godard et al., Monodepth2, ICCV 2019 · Fig. 7, deux premiers exemples, lignes Input et MD2 M · Partition Eigen de KITTI · arXiv v4

SECTION 06

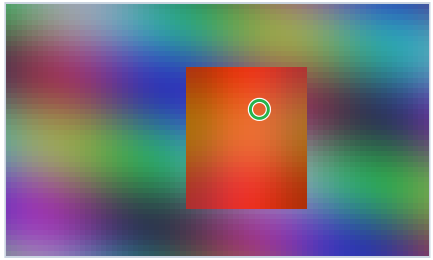
# Correspondances denses

# Correspondances de pixels construites par géométrie

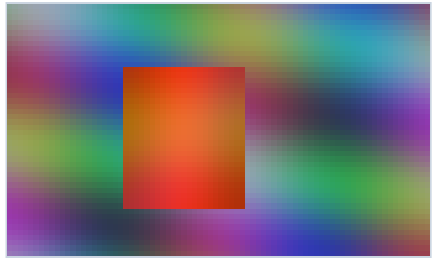
**Scène 3D synthétique · vue fixe**




Cible $I_t$



Source $I_s$

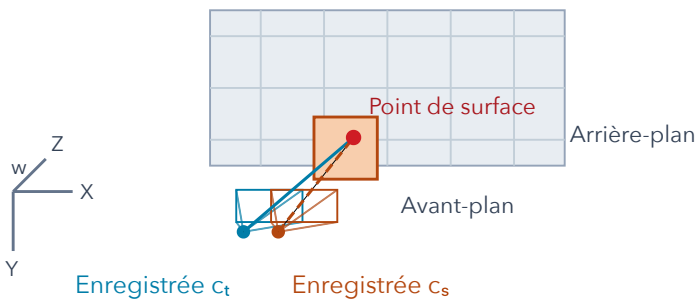


Vert : même point de surface

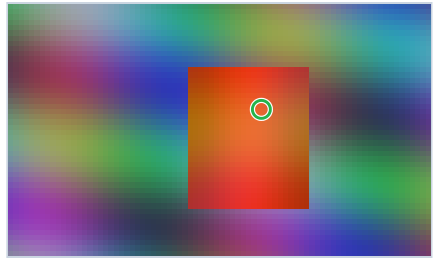
$$p^{c_t} = D_t(\mathbf{u}_t) K_t^{-1} \widetilde{\mathbf{u}}_t, \qquad \mathbf{u}_s = \pi(K_s(R_{c_t}^{c_s} p^{c_t} + t_{c_t}^{c_s}))$$

# Correspondances de pixels construites par géométrie

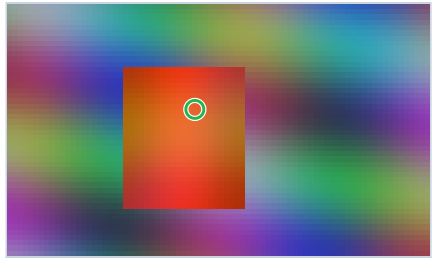
**Scène 3D synthétique · vue fixe**




Cible $I_t$



Source $I_s$

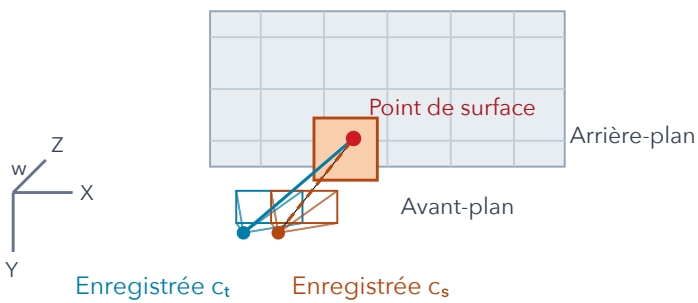


Vert : même point de surface

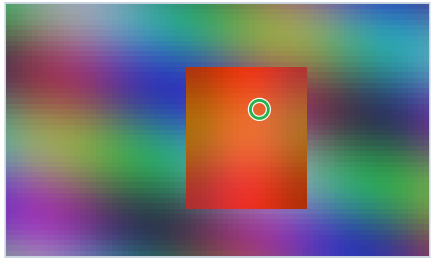
$$p^{c_t} = D_t(\mathbf{u}_t) K_t^{-1} \widetilde{\mathbf{u}}_t, \qquad \mathbf{u}_s = \pi(K_s(R_{c_t}^{c_s} p^{c_t} + t_{c_t}^{c_s}))$$

# Correspondances de pixels construites par géométrie

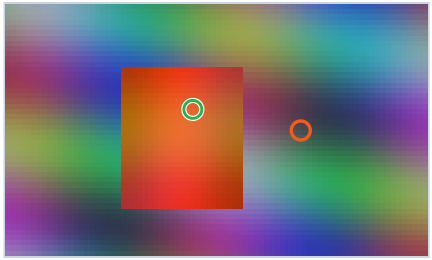
**Scène 3D synthétique · vue fixe**




Cible $I_t$



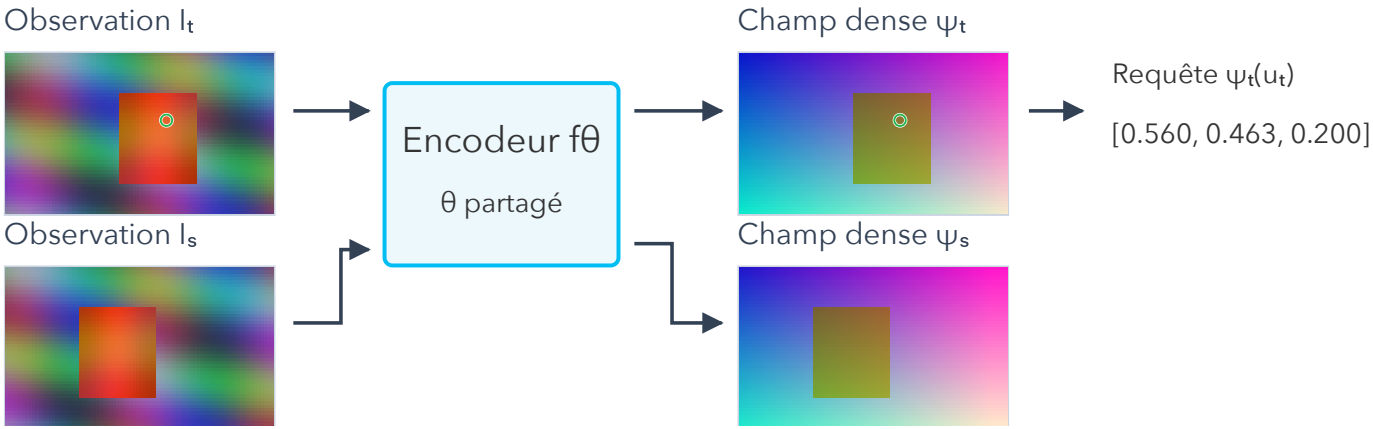
Source $I_s$



Vert : même point de surface · orange : autre point de surface

$$p^{c_t} = D_t(\mathbf{u}_t) K_t^{-1} \widetilde{\mathbf{u}}_t, \qquad \mathbf{u}_s = \pi(K_s(R_{c_t}^{c_s} p^{c_t} + t_{c_t}^{c_s}))$$

# Apprendre des descripteurs denses

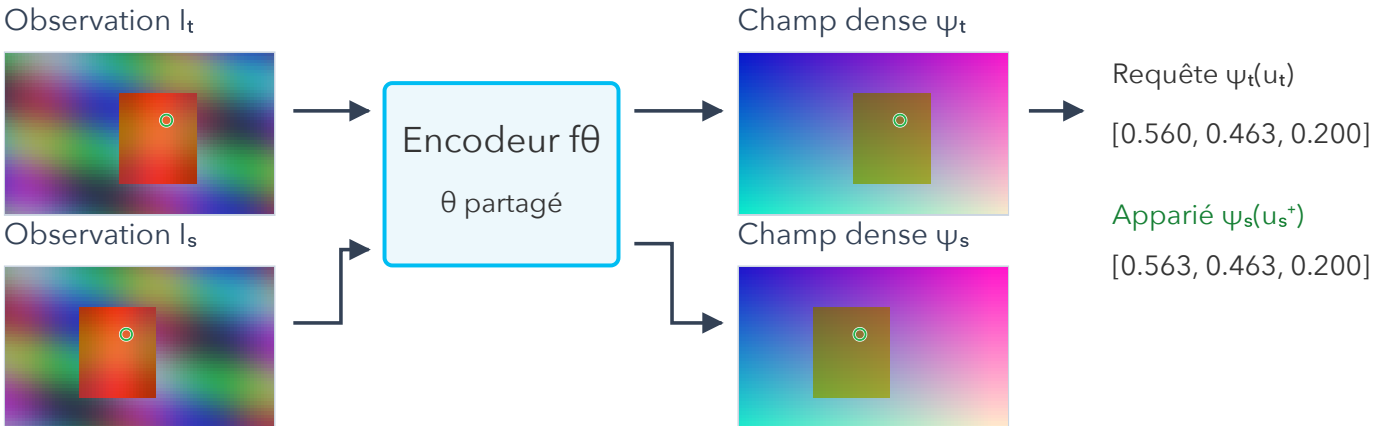



$$\boldsymbol{\psi}_t = f_\theta(I_t), \qquad \boldsymbol{\psi}_s = f_\theta(I_s)$$

Chaque position image possède un vecteur.

Les paires de pixels sélectionnent les vecteurs denses locaux.

# Apprendre des descripteurs denses

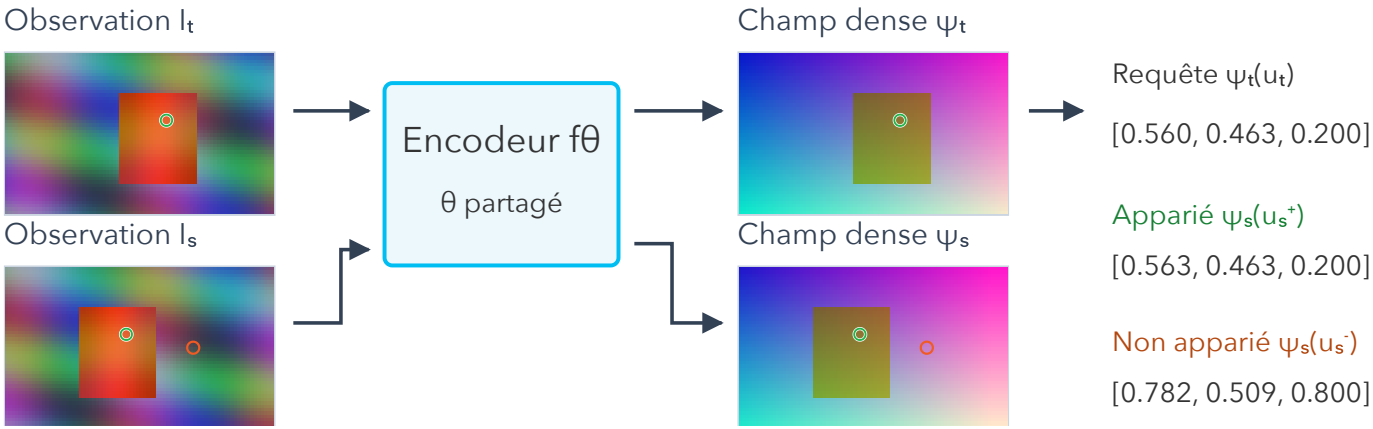



$$d_+ = \|\boldsymbol{\psi}_t(\mathbf{u}_t) - \boldsymbol{\psi}_s(\mathbf{u}_s^+)\|_2, \quad d_- = \|\boldsymbol{\psi}_t(\mathbf{u}_t) - \boldsymbol{\psi}_s(\mathbf{u}_s^-)\|_2$$

Distance correspondante $d_+ = 0.0033$

Les paires correspondantes rapprochent leurs vecteurs.

# Apprendre des descripteurs denses




$$d_+ = \|\boldsymbol{\psi}_t(\mathbf{u}_t) - \boldsymbol{\psi}_s(\mathbf{u}_s^+)\|_2, \quad d_- = \|\boldsymbol{\psi}_t(\mathbf{u}_t) - \boldsymbol{\psi}_s(\mathbf{u}_s^-)\|_2$$

Distance correspondante $d_+$ = 0.0033 — Distance non correspondante $d_-$ = 0.6414

Les non-correspondances imposent une séparation.

# Appariement de descripteur (recherche de matches)

Image requête $I_t$

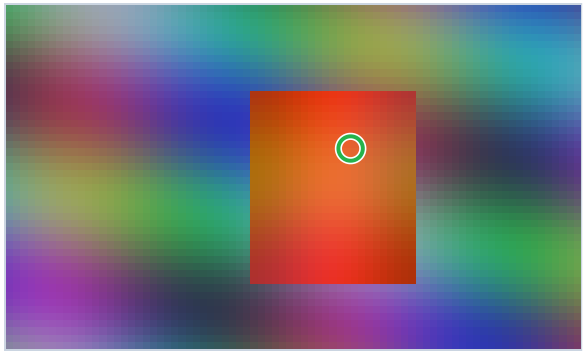
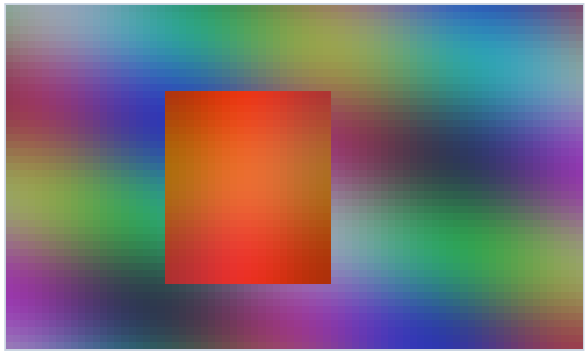


Image de recherche $I_s$



Choisir un descripteur requête $\psi_t(u_t)$ et champ candidat $\psi_s$.

$$\mathbf{u}_s^* = \arg\min_{\mathbf{u}_s} \|\boldsymbol{\psi}_t(\mathbf{u}_t) - \boldsymbol{\psi}_s(\mathbf{u}_s)\|_2$$

# Appariement de descripteur (recherche de matches)

Image requête $I_t$

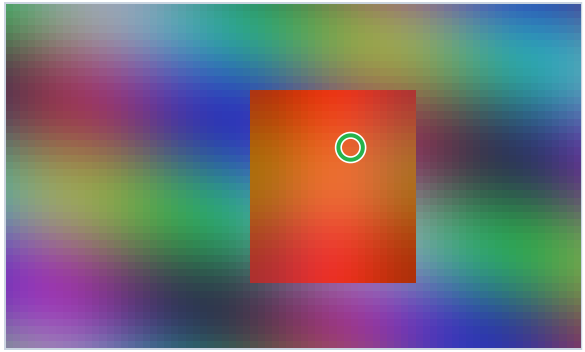
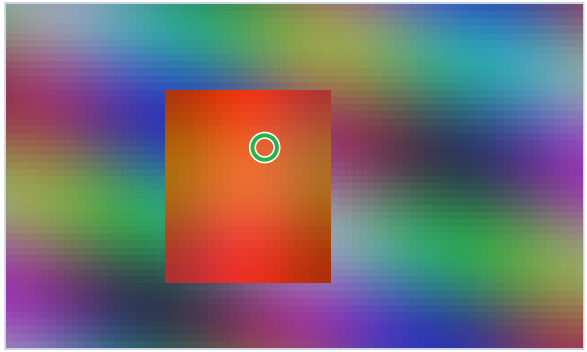
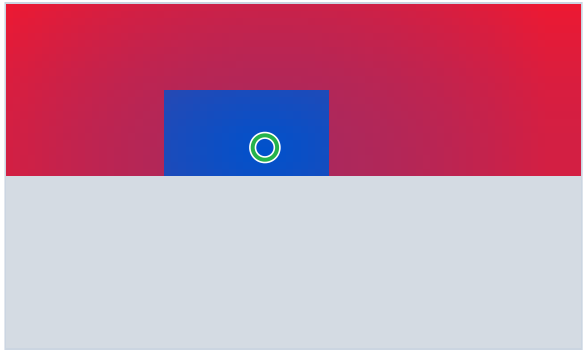


Image de recherche $I_s$



Distance · bleu : proche



$$\mathbf{u}_s^* = \arg\min_{\mathbf{u}_s} \|\boldsymbol{\psi}_t(\mathbf{u}_t) - \boldsymbol{\psi}_s(\mathbf{u}_s)\|_2$$

# Appariement de descripteur (recherche de matches)

Image requête $I_t$

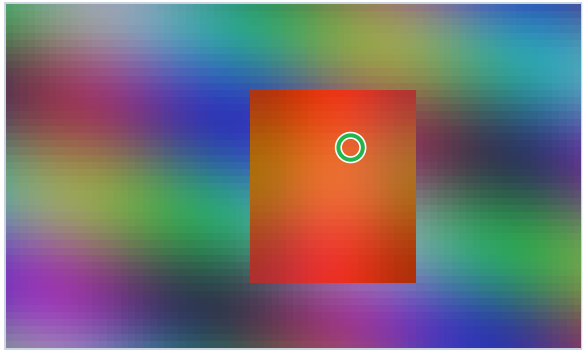
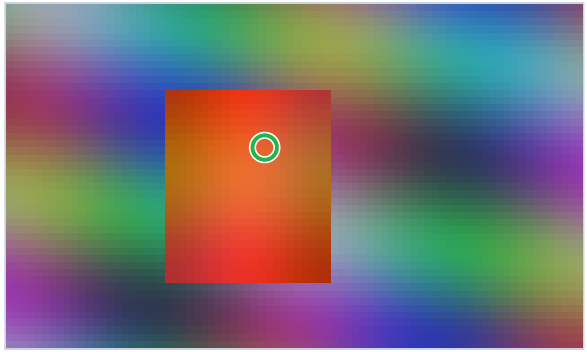
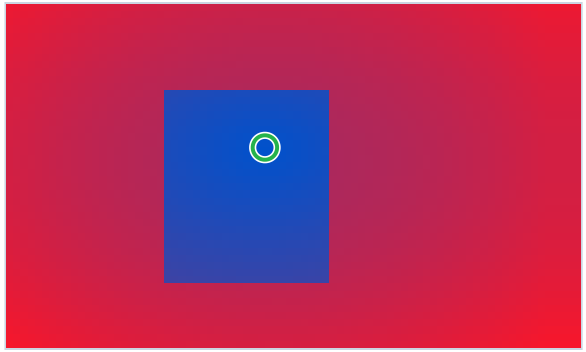


Image de recherche $I_s$



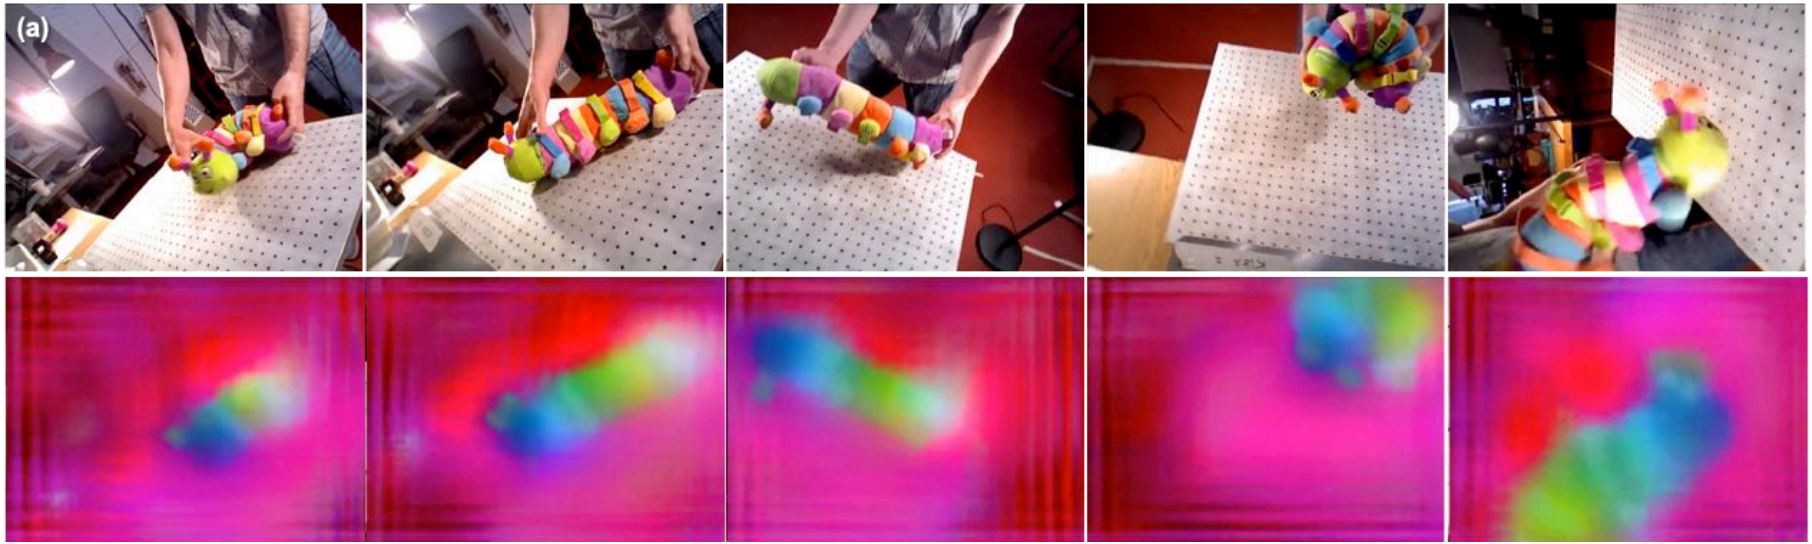
Distance · bleu : proche



$$\mathbf{u}_s^* = \arg\min_{\mathbf{u}_s} \|\boldsymbol{\psi}_t(\mathbf{u}_t) - \boldsymbol{\psi}_s(\mathbf{u}_s)\|_2$$

# Cohérence des descripteurs entre configurations

Observations RVB en haut · couleurs des descripteurs denses en bas

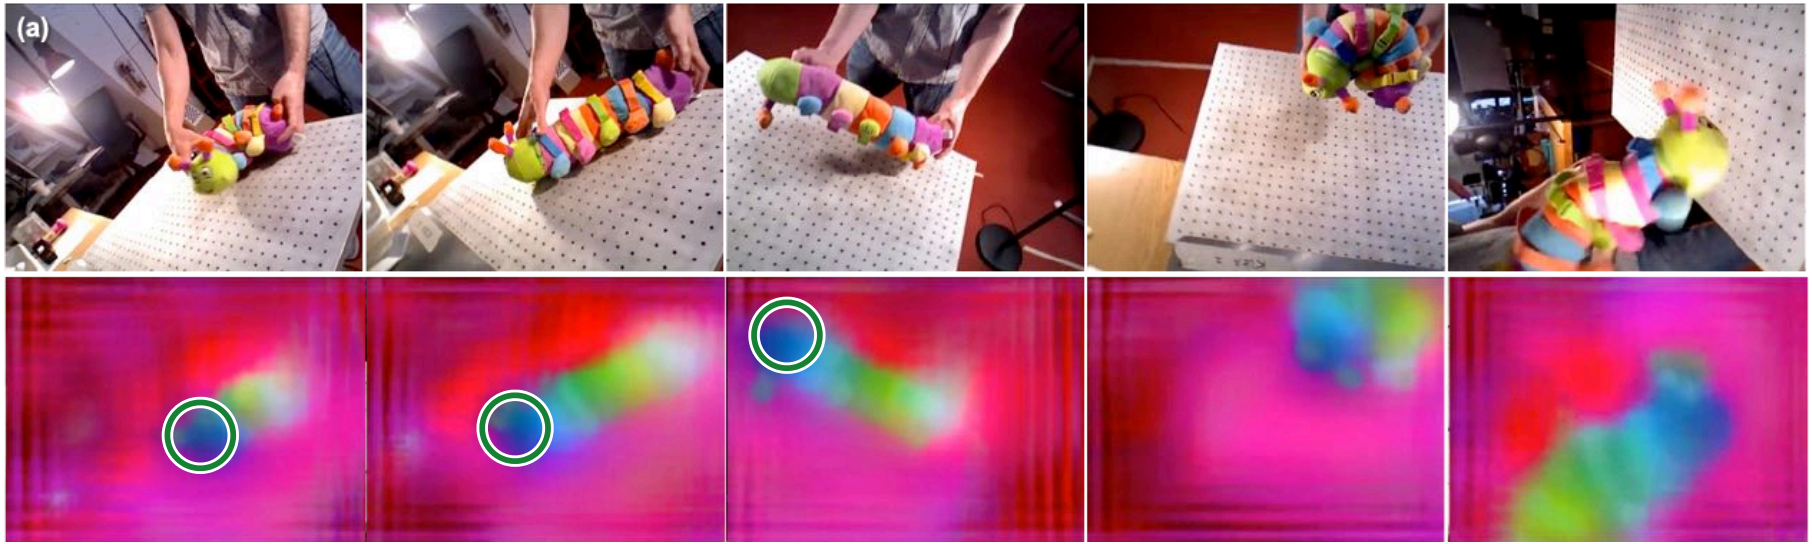



L'objet change de configuration; les régions correspondantes gardent des couleurs similaires.

Florence et al., Dense Object Nets, CoRL 2018 · Fig. 2(a), les cinq configurations · arXiv v2

# Cohérence des descripteurs entre configurations

Observations RVB en haut · couleurs des descripteurs denses en bas

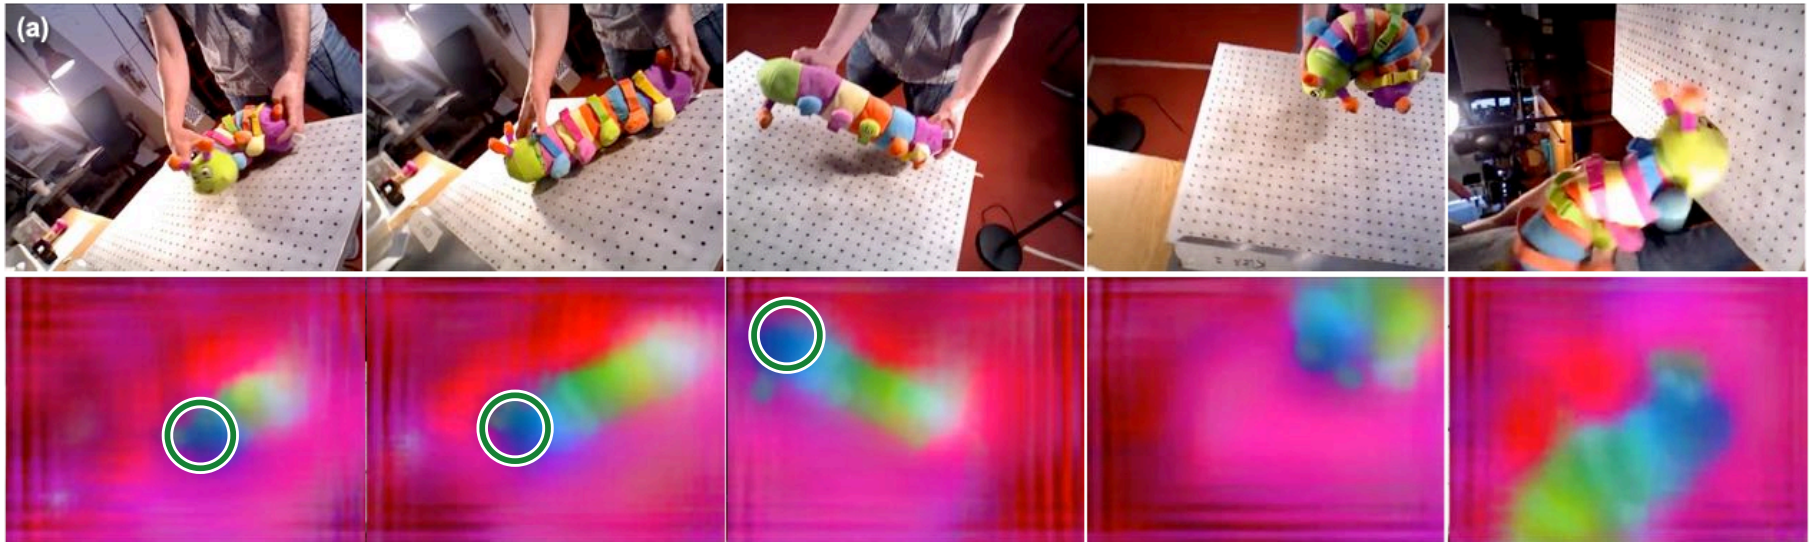



L'objet change de configuration; les régions correspondantes gardent des couleurs similaires.

Florence et al., Dense Object Nets, CoRL 2018 · Fig. 2(a), les cinq configurations · arXiv v2

# Cohérence des descripteurs entre configurations

Observations RVB en haut · couleurs des descripteurs denses en bas

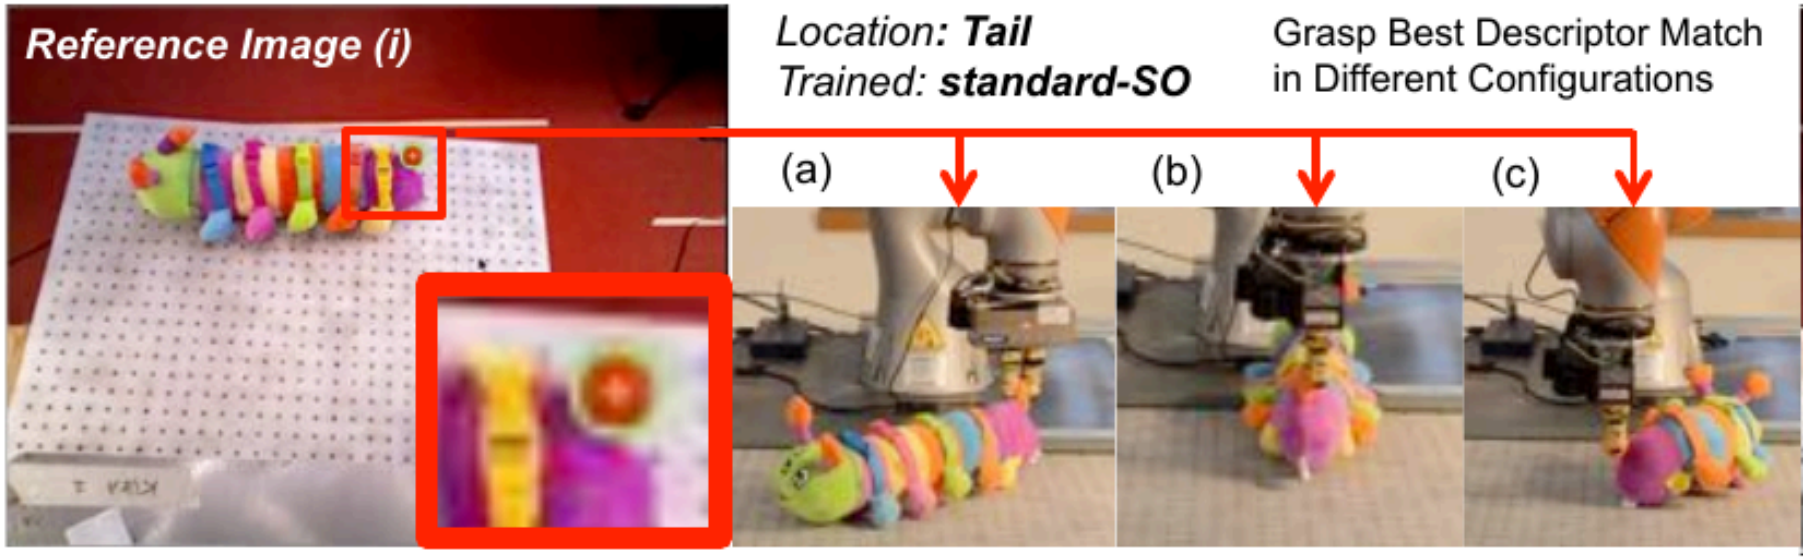



L'objet change de configuration; les régions correspondantes gardent des couleurs similaires.

> Les couleurs codent des descripteurs, sans étiquettes manuelles de parties sémantiques.

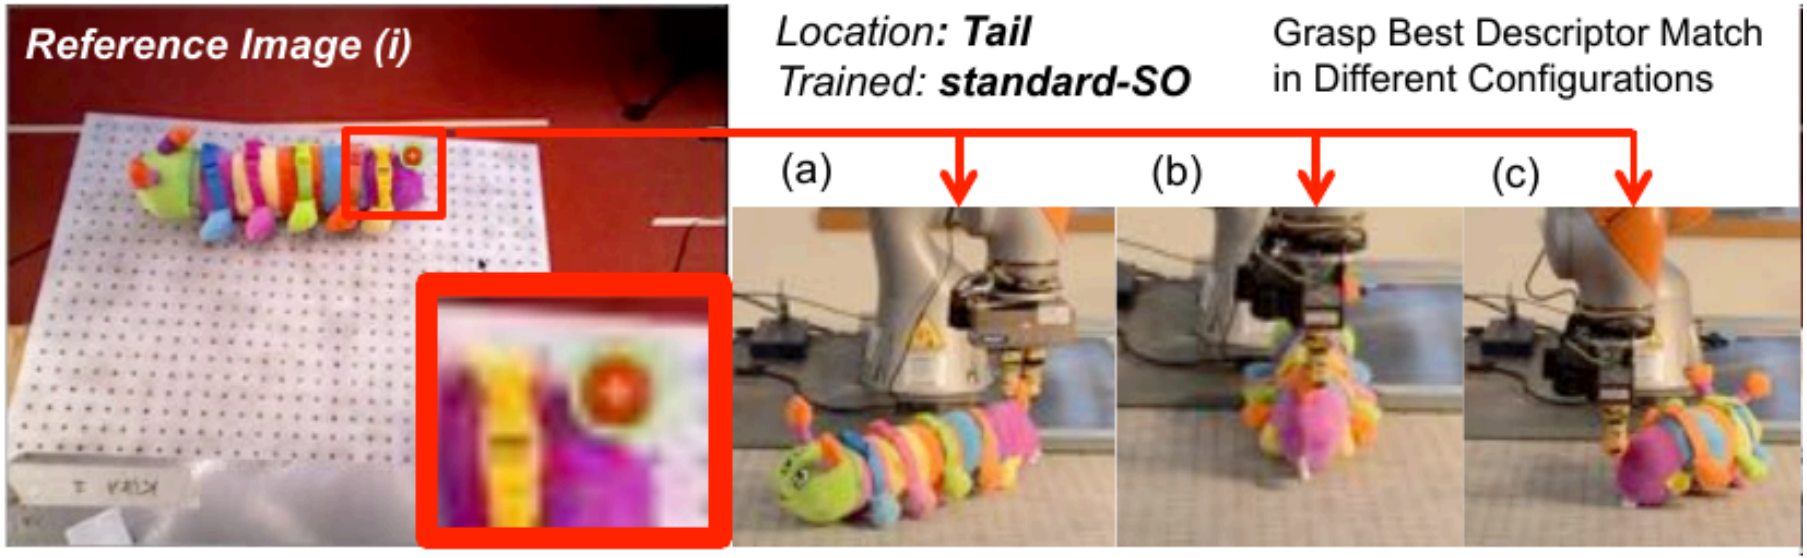
Florence et al., Dense Object Nets, CoRL 2018 · Fig. 2(a), les cinq configurations · arXiv v2

# Trouver un point de prise




Florence et al., Dense Object Nets, CoRL 2018 · Fig. 6(i), queue, standard-so · arXiv v2

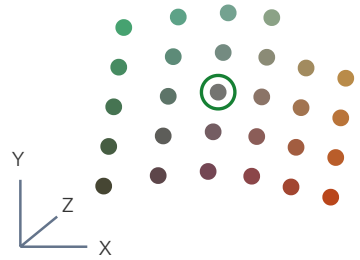
# Trouver un point de prise




Florence et al., Dense Object Nets, CoRL 2018 · Fig. 6(i), queue, standard-so · arXiv v2

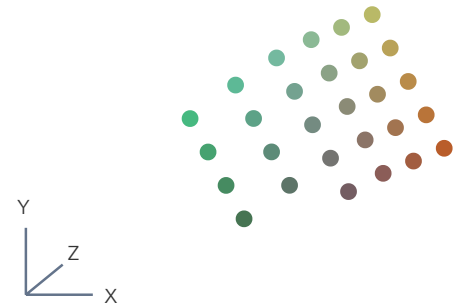
# Extension aux correspondances 3D

Nuage A · repère a




28 points

Nuage B · repère b

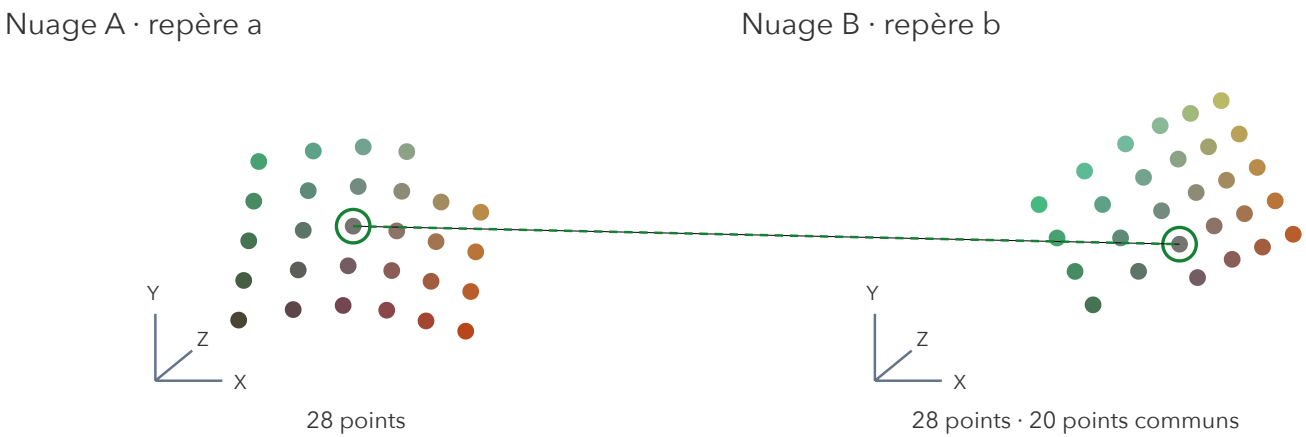



28 points · 20 points communs

Requête $p^a$ = [-0.18, -0.15, 0.49]

Les nuages superposés décrivent certaines surfaces physiques communes.

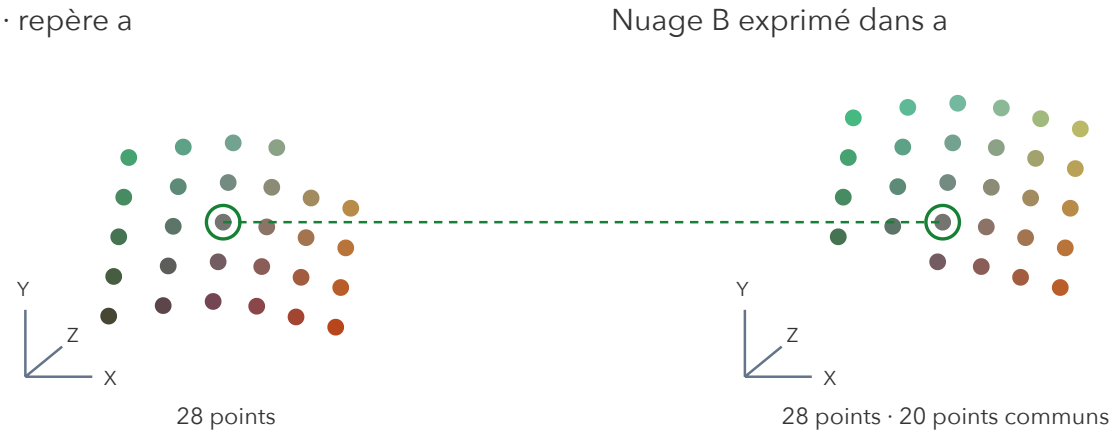
# Extension aux correspondances 3D




Requête $p^a$ = [-0.18, -0.15, 0.49] · apparié $p^b$ = [0.54, -0.48, 0.79]

L'appariement de descripteurs propose des correspondances de points.

# Extension aux correspondances 3D




$$p^a = R_b^a p^b + t_b^a$$

Requête $p^a$ = [-0.18, -0.15, 0.49] · apparié $p^b$ = [0.54, -0.48, 0.79]

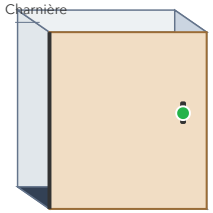
Des correspondances fiables et bien réparties peuvent contraindre un recalage rigide.

SECTION 07

# Apprendre les possibilités d’action par l’expérience

# Observation, action, résultat, cible

**Observation antérieure $x_t$**




t = 0 · avant l'action

**Action commandée $a_t$**

Saisir l'anse, tirer vers l'extérieur

Ouverture désirée : ≥ 30°

**Mesures capteurs ultérieures o**



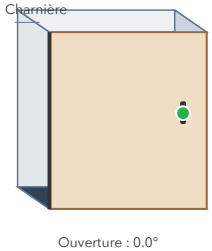

Contact détecté · ouverture 55°

$$y_t = \Gamma(x_t, a_t, o_{t:t+\Delta})$$

Le résultat désiré spécifie la tâche, sans fournir une étiquette mesurée.

# Observation, action, résultat, cible

**Observation antérieure $x_t$**



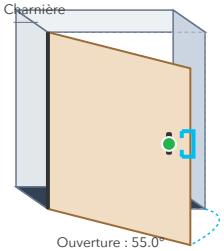

t = 0 · avant l'action

**Action commandée $a_t$**

Saisir l'anse, tirer vers l'extérieur

Ouverture désirée : ≥ 30°

**Mesures capteurs ultérieures o**



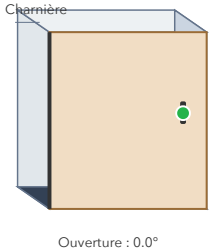

Contact détecté · ouverture 55°

$$y_t = \Gamma(x_t, a_t, o_{t:t+\Delta})$$

Les mesures après action fournissent une cible automatique.

# Observation, action, résultat, cible

**Observation antérieure $x_t$**



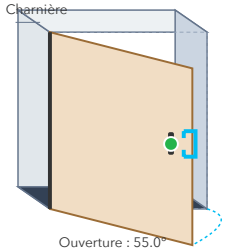

t = 0 · avant l'action

**Action commandée $a_t$**

Saisir l'anse, tirer vers l'extérieur

Ouverture désirée : ≥ 30°

**Mesures capteurs ultérieures o**




Contact détecté · ouverture 55°

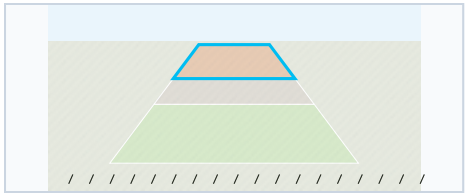
$$y_t = \Gamma(x_t, a_t, o_{t:t+\Delta})$$




Les gradients modifient θ et β; la cible mesurée reste fixe.

Prédiction illustrative 0.881 · cible mesurée 1 · perte binaire 0.1269

# La traversabilité dépend du robot



Zone sélectionnée : boue · même commande 1.00 m/s



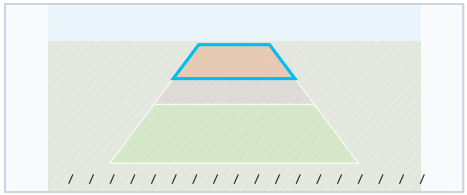
**Roues étroites / contrôleur A**



**Chenilles larges / contrôleur B**

La traversabilité dépend de plateforme, contrôle, action et règle de résultat.

# La traversabilité dépend du robot



Zone sélectionnée : boue · même commande 1.00 m/s



**Roues étroites / contrôleur A**

Mesuré 0.25 m/s

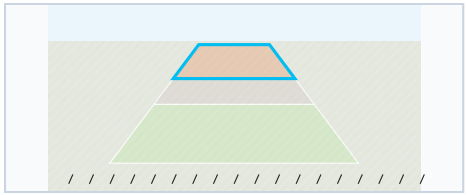


**Chenilles larges / contrôleur B**

Mesuré 0.65 m/s

La traversabilité dépend de plateforme, contrôle, action et règle de résultat.

# La traversabilité dépend du robot



Zone sélectionnée : boue · même commande 1.00 m/s



**Roues étroites / contrôleur A**

Mesuré 0.25 m/s

**Perte : 0.75**



**Chenilles larges / contrôleur B**

Mesuré 0.65 m/s

**Perte : 0.35**

La traversabilité dépend de plateforme, contrôle, action et règle de résultat.

# Mesurer les résultats de traversée

Sol parcouru · vue du dessus

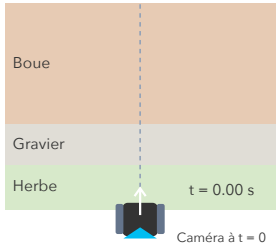



Image antérieure $I_0$ · t = 0

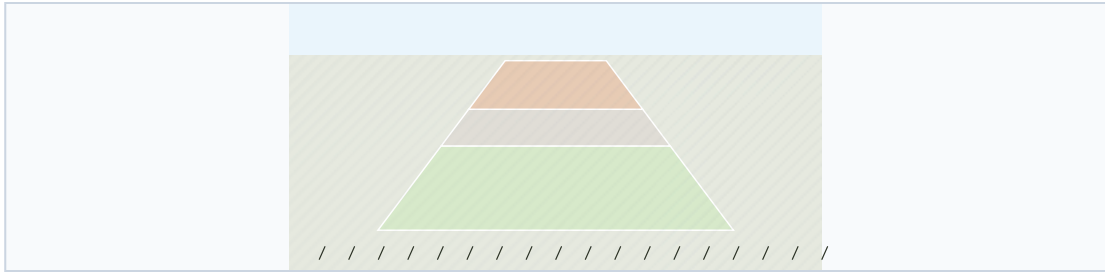


Image enregistrée → Pas encore de résultat

$$y = \Gamma(o) = \mathrm{clip}_{[0,1]}(1 - v_{\mathrm{meas}}/v_{\mathrm{cmd}})$$

Commande 1.00 m/s · mouvement futur non mesuré

Le parcours mesure le mouvement; l'indicateur choisi le transforme en coût.

# Mesurer les résultats de traversée

Sol parcouru · vue du dessus

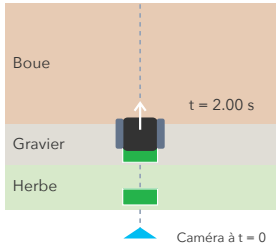



Image antérieure $I_0$ · t = 0

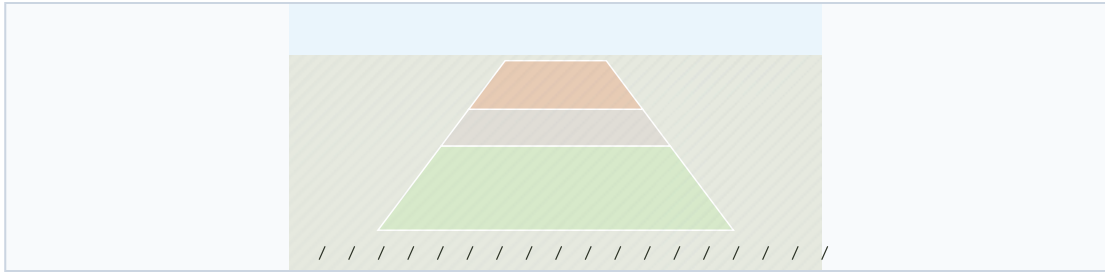


Image enregistrée → Résultat disponible

$$y = \Gamma(o) = \mathrm{clip}_{[0,1]}(1 - v_{\mathrm{meas}}/v_{\mathrm{cmd}})$$

Commande 1.00 m/s · mesure 0.80 m/s · perte y = 0.20

Le parcours mesure le mouvement; l'indicateur choisi le transforme en coût.

# Mesurer les résultats de traversée

Sol parcouru · vue du dessus

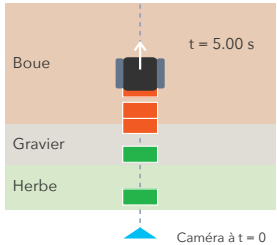



Image antérieure $I_0$ · t = 0

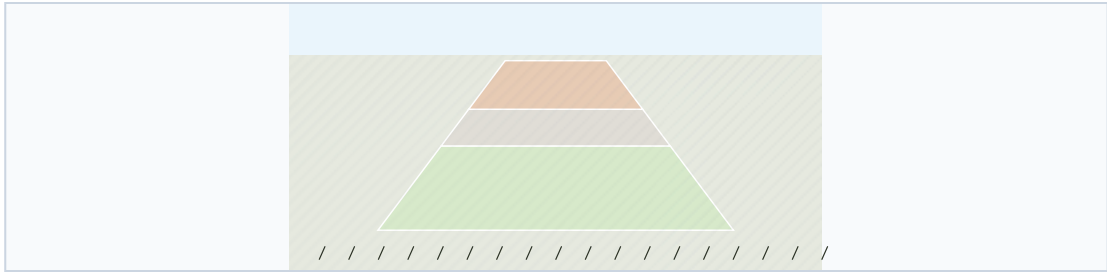


Image enregistrée → Résultat disponible

$$y = \Gamma(o) = \mathrm{clip}_{[0,1]}(1 - v_{\mathrm{meas}}/v_{\mathrm{cmd}})$$

Commande 1.00 m/s · mesure 0.60 m/s · perte y = 0.40

Le parcours mesure le mouvement; l'indicateur choisi le transforme en coût.

# Supervision différée

Sol parcouru · vue du dessus

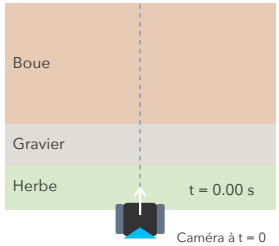



Image antérieure $I_0$ · $t = 0$

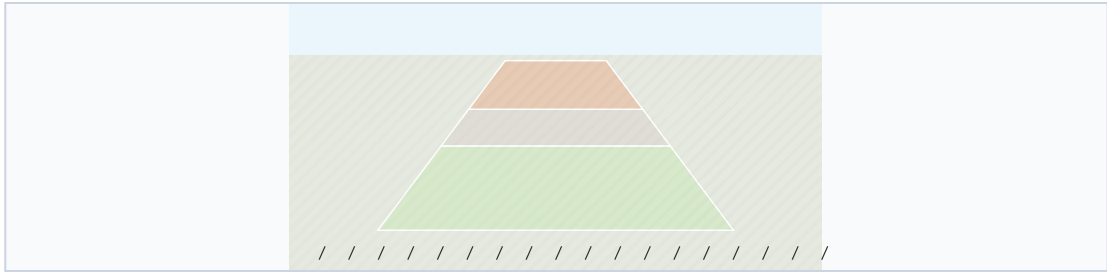


Image enregistrée → Pas encore de résultat

> Commande 1.00 m/s · mouvement futur non mesuré

L'image antérieure est fixe. La cible n'arrive qu'après traversée réelle.

# Supervision différée

Sol parcouru · vue du dessus

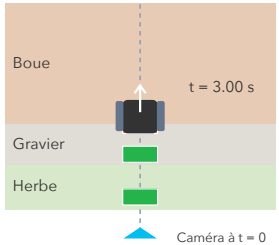



Image antérieure $I_0$ · t = 0

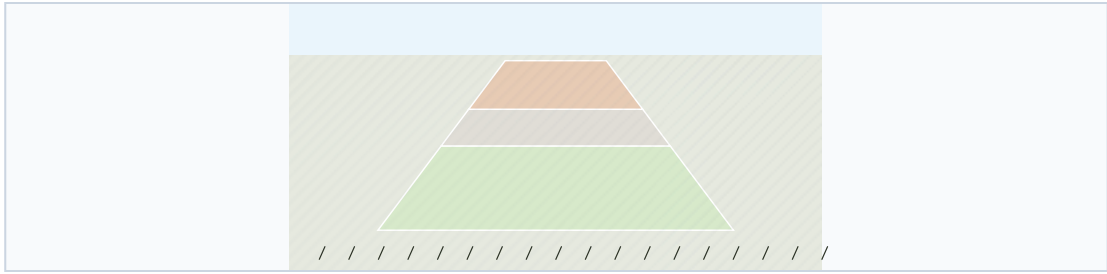


Image enregistrée → Résultat disponible

> Commande 1.00 m/s · mesure 0.35 m/s · perte y = 0.65

L'image antérieure est fixe. La cible n'arrive qu'après traversée réelle.

# Supervision différée

Sol parcouru · vue du dessus

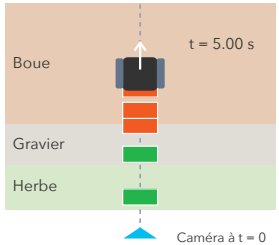



Image antérieure $I_0$ · t = 0

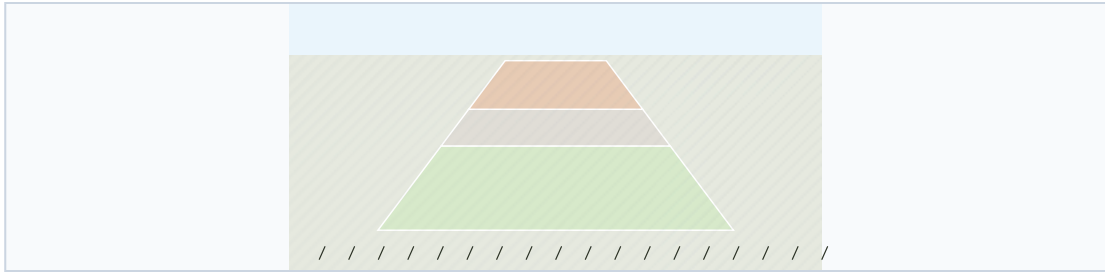


Image enregistrée → Résultat disponible

> Commande 1.00 m/s · mesure 0.60 m/s · perte y = 0.40

L'image antérieure est fixe. La cible n'arrive qu'après traversée réelle.

# Reprojeter l'expérience

Sol parcouru · vue du dessus

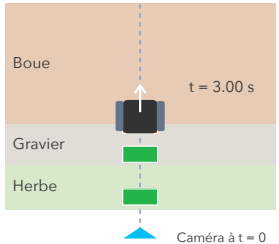
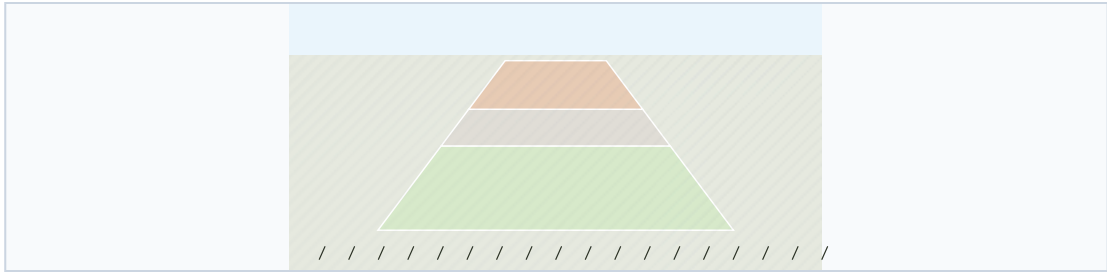



Image antérieure $I_0$ · $t = 0$



Coût faible observé  Coût élevé observé  Non visité

Commande 1.00 m/s · mesure 0.35 m/s · perte y = 0.65 · 0 cibles projetées · décalage temporel de pose 0.0 s

Reprojeter chaque empreinte avec la pose à l'instant de mesure.

# Reprojeter l'expérience

Sol parcouru · vue du dessus

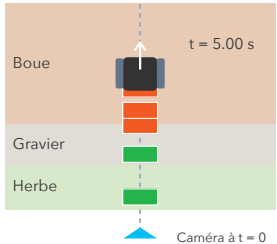
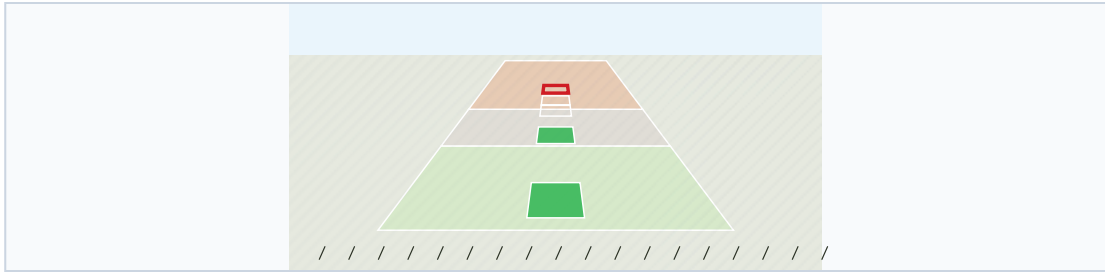



Image antérieure $I_0$ · $t = 0$



Coût faible observé  Coût élevé observé  Non visité

$$\mathbf{u}_0 = \pi\left(K_0\left(R_r^{c_0} p^r + t_r^{c_0}\right)\right)$$

Commande 1.00 m/s · mesure 0.60 m/s · perte y = 0.40 · 5 cibles projetées · décalage temporel de pose 0.0 s

Reprojeter chaque empreinte avec la pose à l'instant de mesure.

# Reprojeter l'expérience

Sol parcouru · vue du dessus

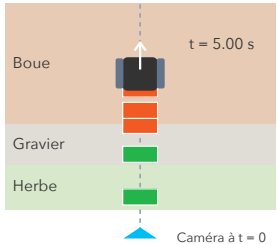
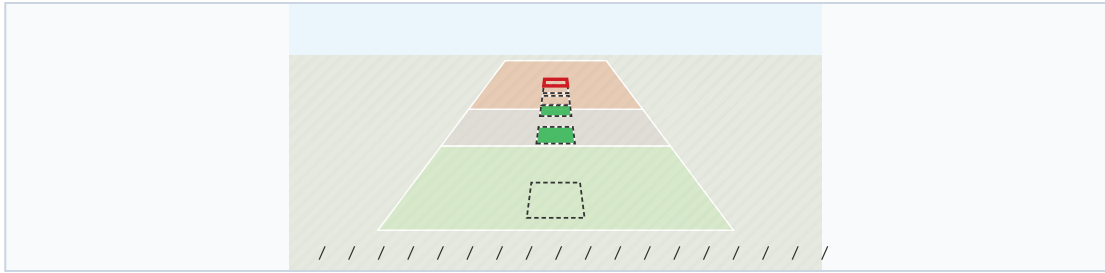



Image antérieure $I_0$ · t = 0



Coût faible observé · Coût élevé observé · Non visité

Contour en tirets : empreinte correcte

$$\mathbf{u}_0 = \pi\left(K_0\left(R_r^{c_0} p^r + t_r^{c_0}\right)\right)$$

Commande 1.00 m/s · mesure 0.60 m/s · perte y = 0.40 · 5 cibles projetées · décalage temporel de pose 1.0 s

Mauvais horodatage : mesure identique, région visuelle différente.

# Reprojeter l'expérience

Sol parcouru · vue du dessus

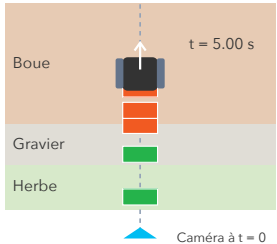
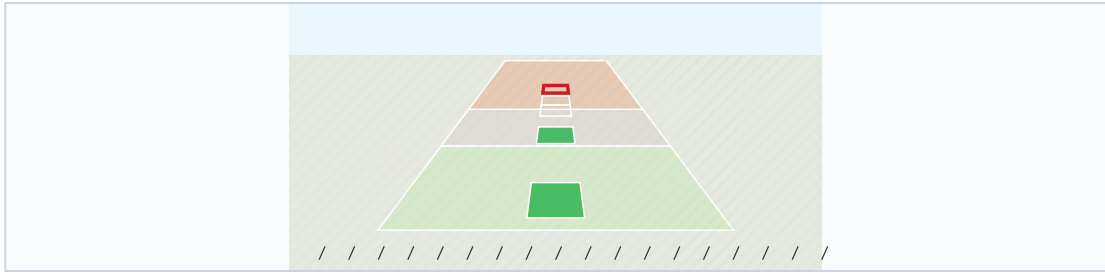



Image antérieure $I_0$ · $t = 0$



Coût faible observé · Coût élevé observé · Non visité

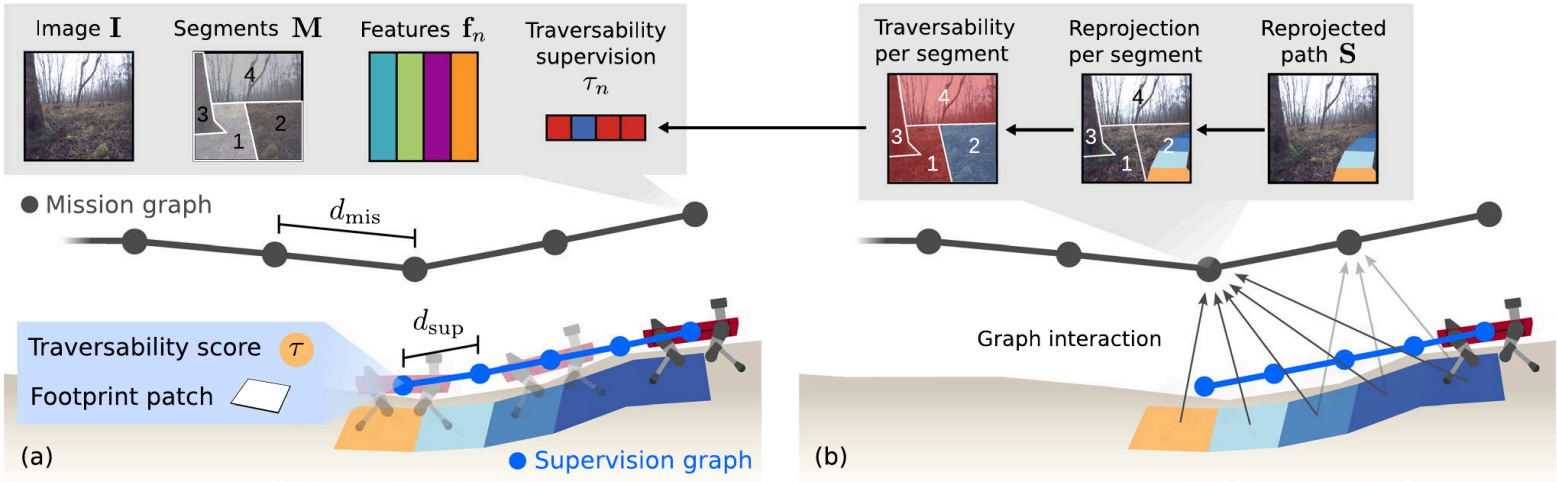
$$\mathbf{u}_0 = \pi\left(K_0\left(R_r^{c_0} p^r + t_r^{c_0}\right)\right)$$

Commande 1.00 m/s · mesure 0.60 m/s · perte y = 0.40 · 5 cibles projetées · décalage temporel de pose 0.0 s

Estimation locale jouet : 0.500 → cible mesurée 0.40 · erreur quadratique moyenne 0.0690

Restaurer la synchronisation avant d'utiliser ces cibles mesurées.

# Wild Visual Navigation



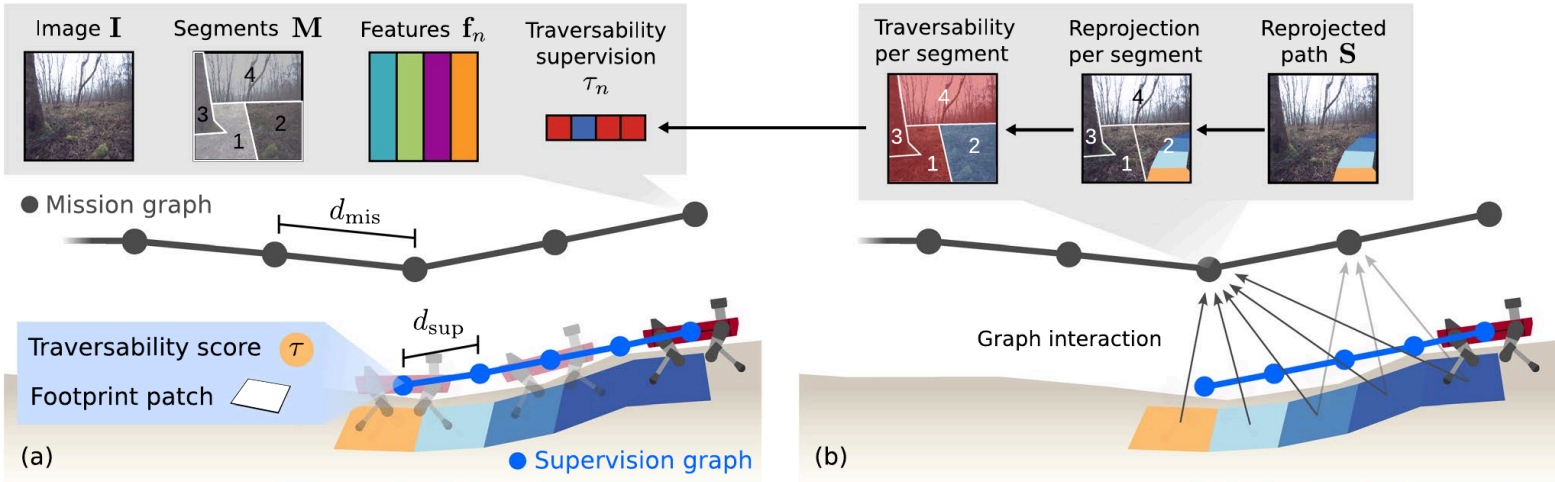

**Entrée visuelle**

Images RVB et caractéristiques visuelles préentraînées

Le mouvement expérimenté fournit des cibles d'estimation visuelle de traversabilité.

Mattamala et al., WVN, Autonomous Robots 2025 · Fig. 5(a,b), page 6 du PDF du journal

# Wild Visual Navigation




**Entrée visuelle**

Images RVB et caractéristiques visuelles préentraînées

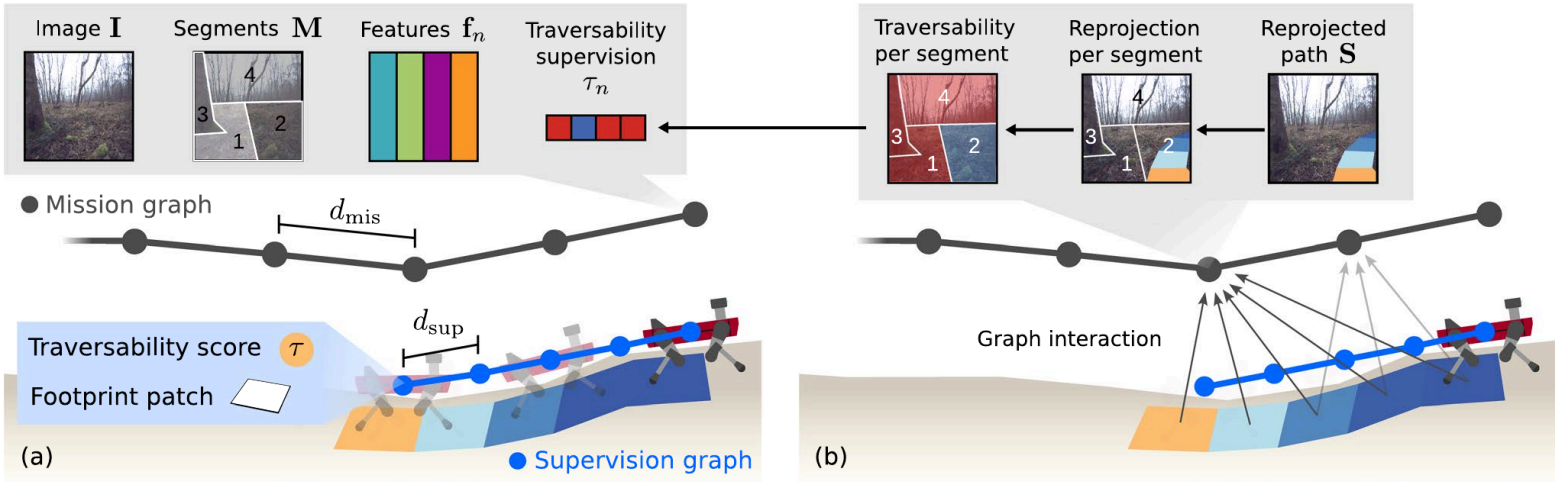
**Signal mesuré**

Vitesse plane commandée et estimée

Le mouvement expérimenté fournit des cibles d'estimation visuelle de traversabilité.

Mattamala et al., WVN, Autonomous Robots 2025 · Fig. 5(a,b), page 6 du PDF du journal

# Wild Visual Navigation




**Entrée visuelle**

Images RVB et caractéristiques visuelles préentraînées

**Signal mesuré**

Vitesse plane commandée et estimée

**Supervision accumulée**

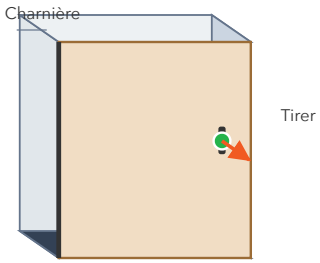
Scores d'empreintes reprojetés dans les images stockées

Le mouvement expérimenté fournit des cibles d'estimation visuelle de traversabilité.

Mattamala et al., WVN, Autonomous Robots 2025 · Fig. 5(a,b), page 6 du PDF du journal

# Possibilités d’action en manipulation

Observation initiale fixe $x_t$




**Tirer vers l’extérieur**

Direction initiale d’ouverture

**Le long de la porte fermée**

Faible moment d’ouverture

**Pousser vers l’intérieur**

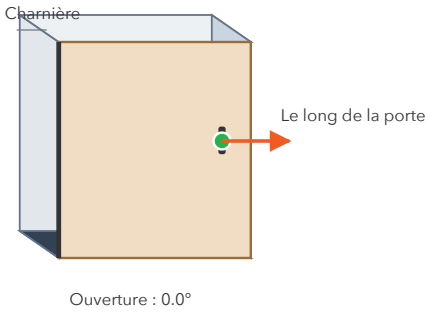
La butée bloque le mouvement

Rayon de contact 0.85 m · direction F = [0.00, -1.00, 0.00] · orientation de prise fixe

La même poignée produit des résultats différents selon la direction d’action.

# Possibilités d’action en manipulation

Observation initiale fixe $x_t$




**Tirer vers l’extérieur**

Direction initiale d’ouverture

**Le long de la porte fermée**

Faible moment d’ouverture

**Pousser vers l’intérieur**

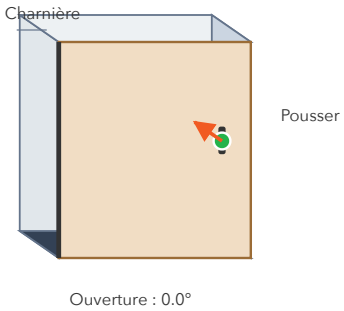
La butée bloque le mouvement

Rayon de contact 0.85 m · direction F = [1.00, 0.00, 0.00] · orientation de prise fixe

La même poignée produit des résultats différents selon la direction d’action.

# Possibilités d’action en manipulation

Observation initiale fixe $x_t$




**Tirer vers l’extérieur**

Direction initiale d’ouverture

**Le long de la porte fermée**

Faible moment d’ouverture

**Pousser vers l’intérieur**

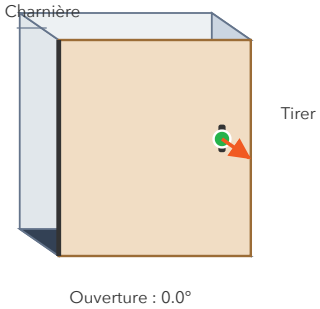
La butée bloque le mouvement

Rayon de contact 0.85 m · direction F = [0.00, 1.00, 0.00] · orientation de prise fixe

La même poignée produit des résultats différents selon la direction d’action.

# Prédire le résultat d'une action

Observation initiale fixe $x_t$




**Tirer vers l'extérieur**

Direction initiale d'ouverture

**Le long de la porte fermée**

Faible moment d'ouverture

**Pousser vers l'intérieur**

La butée bloque le mouvement

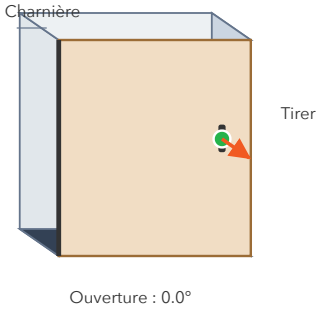
Rayon de contact 0.85 m · direction F = [0.00, -1.00, 0.00] · orientation de prise fixe

$$\hat{y}_t = h_\beta(f_\theta(x_t), a_t)$$

Prédire à partir de l'observation et de l'action proposée, avant de voir le résultat.

# Prédire le résultat d’une action

Observation initiale fixe $x_t$




**Tirer vers l’extérieur**

Direction initiale d’ouverture

**Le long de la porte fermée**

Faible moment d’ouverture

**Pousser vers l’intérieur**

La butée bloque le mouvement

Rayon de contact 0.85 m · direction F = [0.00, -1.00, 0.00] · orientation de prise fixe

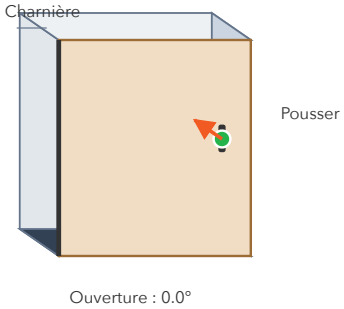
$$\hat{y}_t = h_\beta(f_\theta(x_t), a_t)$$

Succès d’ouverture prédit : 0.881

Prédire à partir de l’observation et de l’action proposée, avant de voir le résultat.

# Prédire le résultat d’une action

Observation initiale fixe $x_t$




**Tirer vers l’extérieur**

Direction initiale d’ouverture

**Le long de la porte fermée**

Faible moment d’ouverture

**Pousser vers l’intérieur**

La butée bloque le mouvement

Rayon de contact 0.85 m · direction F = [0.00, 1.00, 0.00] · orientation de prise fixe

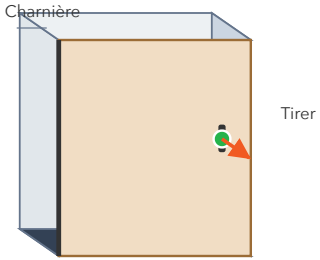
$$\hat{y}_t = h_\beta(f_\theta(x_t), a_t)$$

Succès d’ouverture prédit : 0.018

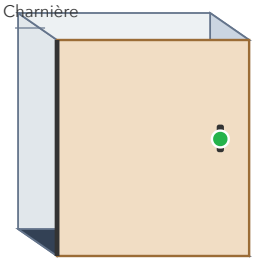
Prédire à partir de l’observation et de l’action proposée, avant de voir le résultat.

# Construire automatiquement une cible d’action

Observation initiale fixe $x_t$




Observation après action · action non exécutée

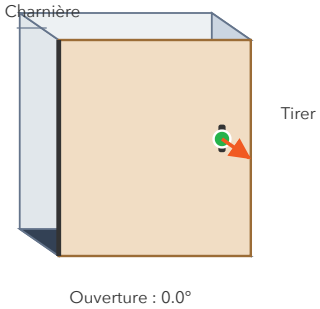



Rayon de contact 0.85 m · direction F = [0.00, -1.00, 0.00] · orientation de prise fixe

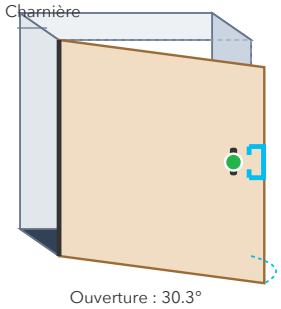
Objectif : ouvrir d’au moins 30°.

# Construire automatiquement une cible d’action

Observation initiale fixe $x_t$




Observation après action · action en cours



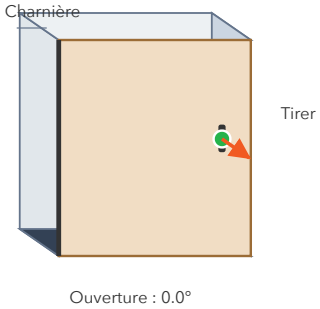

Rayon de contact 0.85 m · direction F = [0.00, -1.00, 0.00] · orientation de prise fixe

Succès d’ouverture prédit : 0.881 · Cible en attente de fin d’exécution

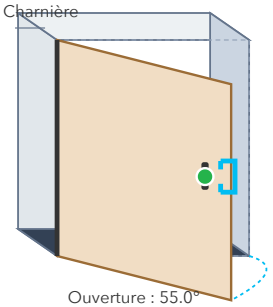
Objectif : ouvrir d’au moins 30°.

# Construire automatiquement une cible d'action

Observation initiale fixe $x_t$




Observation après action · action terminée




Rayon de contact 0.85 m · direction F = [0.00, -1.00, 0.00] · orientation de prise fixe

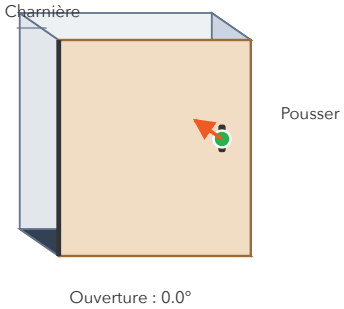
$$y_t = \Gamma(o) = \mathbf{1}[\text{ouverture mesurée} \geq 30^\circ]$$

Succès d'ouverture prédit : 0.881 · Ouverture mesurée 55.0° → cible automatique y = 1

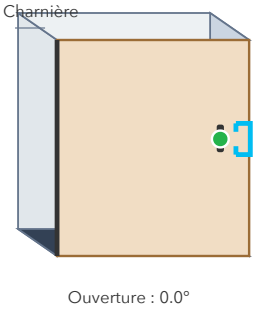
Objectif : ouvrir d'au moins 30°.

# Construire automatiquement une cible d'action

Observation initiale fixe $x_t$




Observation après action · action terminée




Rayon de contact 0.85 m · direction F = [0.00, 1.00, 0.00] · orientation de prise fixe

$$y_t = \Gamma(o) = \mathbf{1}[\text{ouverture mesurée} \geq 30^\circ]$$

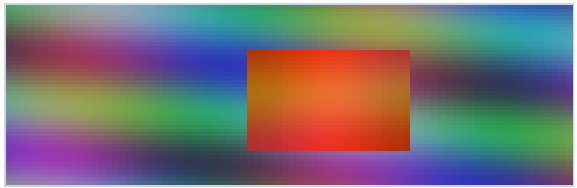
Succès d'ouverture prédit : 0.018 · Ouverture mesurée 0.0° → cible automatique y = 0

Objectif : ouvrir d'au moins 30°.

# En résumé: Le principe d'apprentissage

**Association géométrique**

Vue caméra enregistrée



Profondeur + poses + visibilité
→ pixels correspondants

Expérience de traversée



Commande + mouvement mesuré
→ cibles de coût local

Interaction avec le meuble




Résultat de tâche mesuré
→ cible de succès

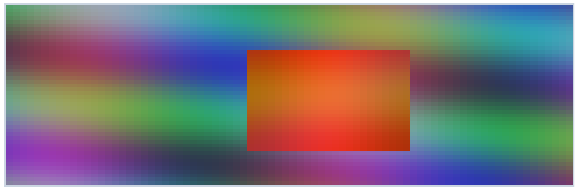
$$\hat{y}_t = h_\beta(f_\theta(x_t), a_t), \qquad y_t = \Gamma(x_t, a_t, o_{t:t+\Delta})$$

Identifier la source et le domaine de la cible, et ce que le modèle doit prédire.

# En résumé: Le principe d'apprentissage

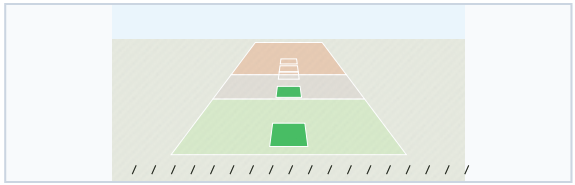
**Association géométrique**

Vue caméra enregistrée



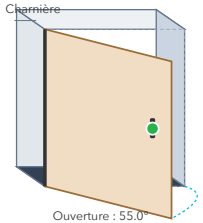
Profondeur + poses + visibilité
→ pixels correspondants

**Expérience de traversée**



Commande + mouvement mesuré
→ cibles de coût local

**Interaction avec le meuble**




Résultat de tâche mesuré
→ cible de succès

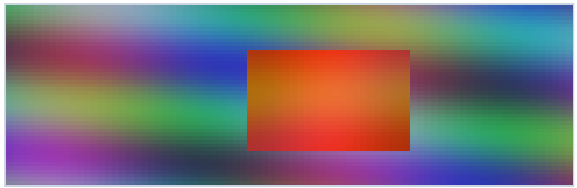
$$\hat{y}_t = h_\beta(f_\theta(x_t), a_t), \qquad y_t = \Gamma(x_t, a_t, o_{t:t+\Delta})$$

Identifier la source et le domaine de la cible, et ce que le modèle doit prédire.

# En résumé: Le principe d'apprentissage

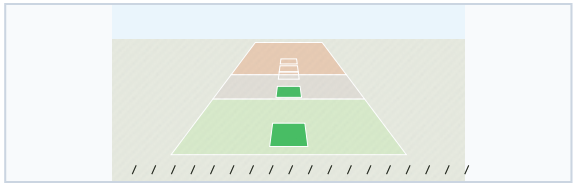
**Association géométrique**

Vue caméra enregistrée



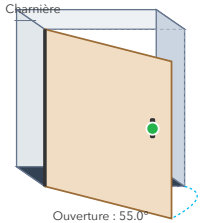
Profondeur + poses + visibilité
→ pixels correspondants

**Expérience de traversée**



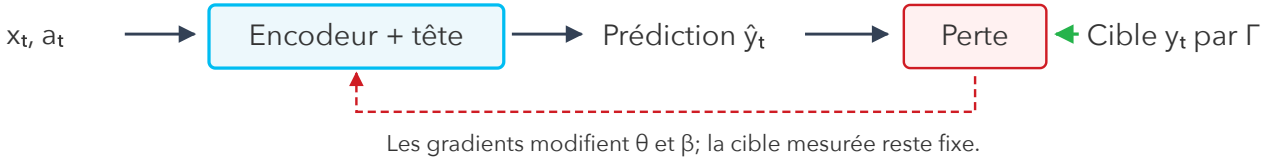
Commande + mouvement mesuré
→ cibles de coût local

**Interaction avec le meuble**




Résultat de tâche mesuré
→ cible de succès

$$\hat{y}_t = h_\beta(f_\theta(x_t), a_t), \qquad y_t = \Gamma(x_t, a_t, o_{t:t+\Delta})$$




Les gradients modifient θ et β; la cible mesurée reste fixe.

> Identifier la source et le domaine de la cible, et ce que le modèle doit prédire.

SECTION 08

# Adaption de modèles

# Pourquoi adapter les modèles en robotique ?

Un modèle entraîné dans un contexte peut perdre en performance lorsque ce contexte change.

### 🌍 Environnements variés

Intérieur, extérieur, sous-marin, aérien

**Ce qui change :** éclairage, visibilité, obstacles, perturbations

### 🎯 Tâches variées

Navigation, manipulation, inspection, exploration

**Ce qui change :** objectifs, précision, contraintes de sécurité

### 🤖 Robots variés

Robots à roues, quadrupèdes, bras, drones

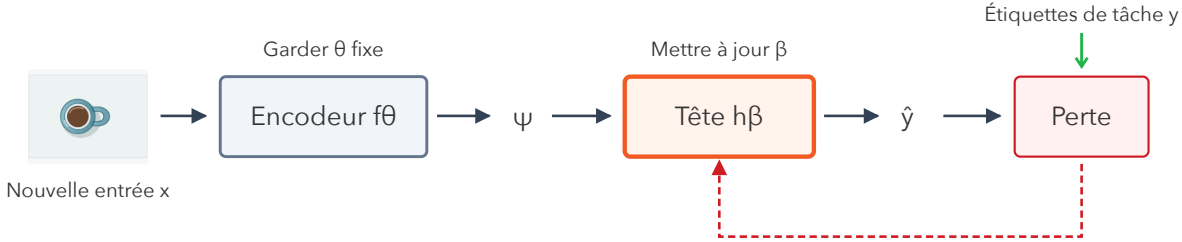
**Ce qui change :** capteurs, actionneurs, morphologie, dynamique

**Adapter les modèles pour transférer les acquis à de nouvelles conditions**

Maintenir les performances tout en limitant les données et le réentraînement nécessaires.

# Adaptation

## Geler l'encodeur · entraîner la tête




Sombre : prédiction · vert : cibles · tirets rouges : gradients

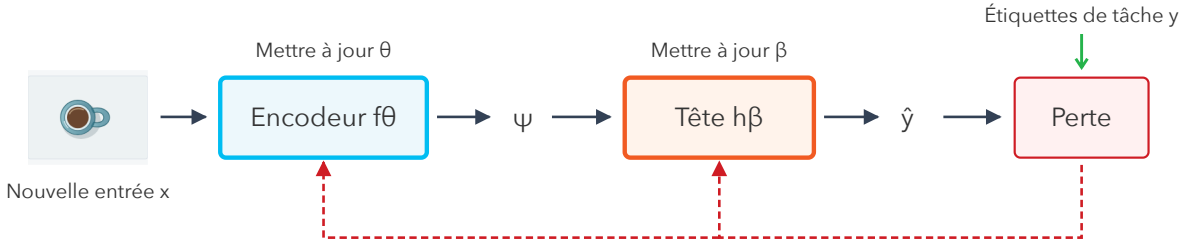
$$\theta = \text{fixe}, \quad \Theta = (\beta)$$

Une sonde linéaire exige hβ linéaire. Un encodeur gelé peut aussi alimenter une tête non linéaire.

Chen et al., SimCLR, ICML 2020 · Annexe B.8

# Adaptation

## Ajuster l'encodeur et la tête



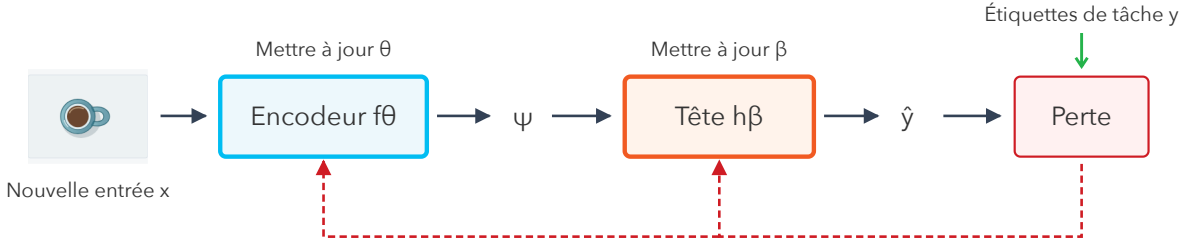

$$\Theta = (\theta, \beta), \quad \text{modifier encodeur et tête}$$

Une sonde linéaire exige hβ linéaire. Un encodeur gelé peut aussi alimenter une tête non linéaire.

Chen et al., SimCLR, ICML 2020 · Annexe B.8

# Adaptation

## Ajuster l'encodeur et la tête




$$\Theta = (\theta, \beta), \quad \text{modifier encodeur et tête}$$

**Caractéristiques gelées**

Évaluer l'information accessible à la tête choisie.

**fine tuning**

Adapter les caractéristiques et la tête à la tâche cible.

Une sonde linéaire exige hβ linéaire. Un encodeur gelé peut aussi alimenter une tête non linéaire.

Chen et al., SimCLR, ICML 2020 · Annexe B.8

# LoRA : adapter un modèle avec peu de paramètres

**Low-Rank Adaptation** – apprendre une correction de faible rang en gardant les poids d'origine gelés.

$$W_{\text{adapté}} = \underbrace{W_0}_{\text{poids gelés}} + \underbrace{\Delta W}_{BA\,:\,\text{correction apprise}}$$

### ⚙️ Adaptation légère

Seules deux petites matrices **A et B** sont entraînées.

**Moins de paramètres à optimiser** et de mémoire pour l'entraînement.

### 🔒 Modèle préservé

Les poids d'origine **restent inchangés** pendant l'adaptation.

Désactiver la correction permet de **retrouver le modèle initial**.

### 🔄 Adaptations modulaires

Un même modèle de base peut accueillir **plusieurs corrections**.

Charger l'adaptation correspondant au **domaine, à la tâche ou au robot**.

**Un modèle de base partagé + une petite correction propre à chaque contexte**

# LoRA: Low-Rank Adaptation




$$z = W_0 u + sB(Au), \qquad W_0 \in \mathbb{R}^{d\times k},\ A \in \mathbb{R}^{q\times k},\ B \in \mathbb{R}^{d\times q},\ s = \alpha/q$$

**A : k → q**

Mesurer q combinaisons apprises des coordonnées d'entrée.

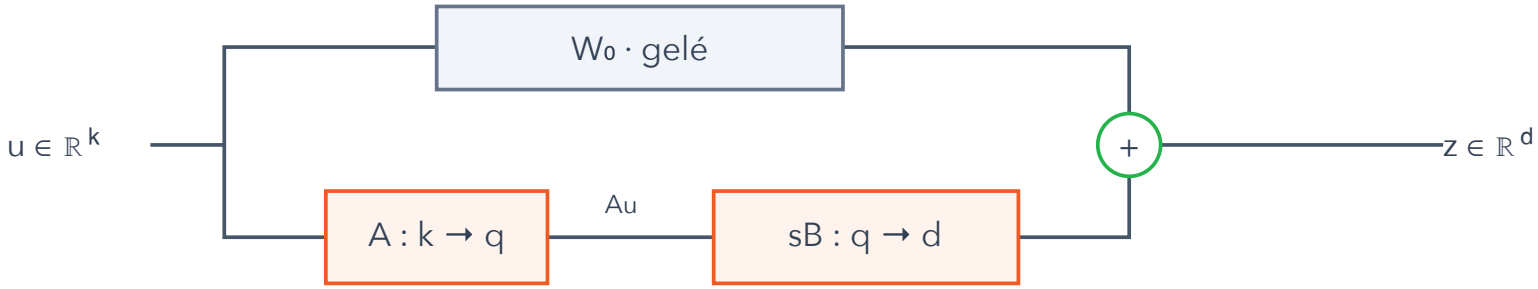
**B : q → d**

Utiliser ces q coefficients pour former une correction dans l'espace de sortie.

Les deux branches reçoivent le même u ; on additionne leurs sorties.

Hu et al. · LoRA · ICLR 2022 · §4

# LoRA: Low-Rank Adaptation




$$z = W_0 u + sB(Au), \qquad W_0 \in \mathbb{R}^{d\times k},\ A \in \mathbb{R}^{q\times k},\ B \in \mathbb{R}^{d\times q},\ s = \alpha/q$$

**A : k → q**

Mesurer q combinaisons apprises des coordonnées d'entrée.

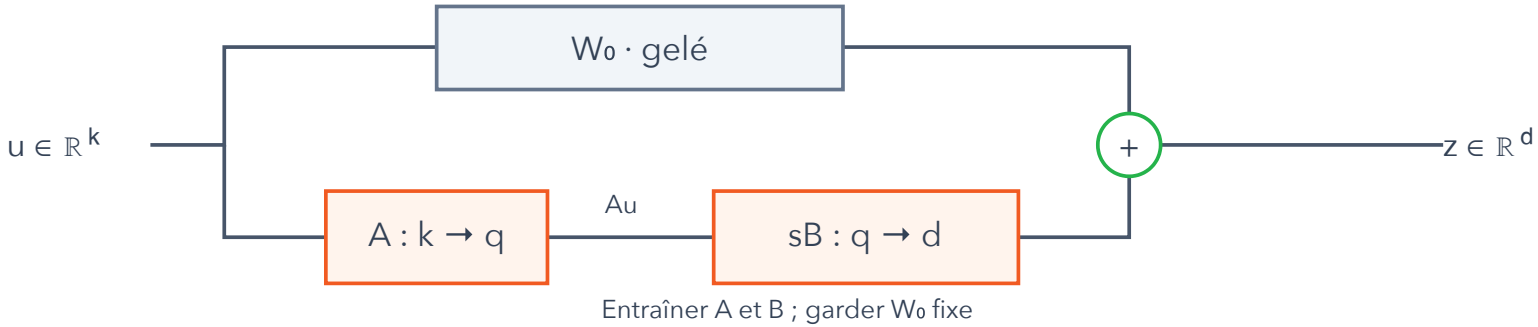
**B : q → d**

Utiliser ces q coefficients pour former une correction dans l'espace de sortie.

> Les deux branches reçoivent le même u ; on additionne leurs sorties.

Hu et al. · LoRA · ICLR 2022 · §4

# LoRA: Low-Rank Adaptation




$$z = W_0 u + sB(Au), \qquad W_0 \in \mathbb{R}^{d\times k},\ A \in \mathbb{R}^{q\times k},\ B \in \mathbb{R}^{d\times q},\ s = \alpha/q$$

**A : k → q**

Mesurer q combinaisons apprises des coordonnées d'entrée.

**B : q → d**

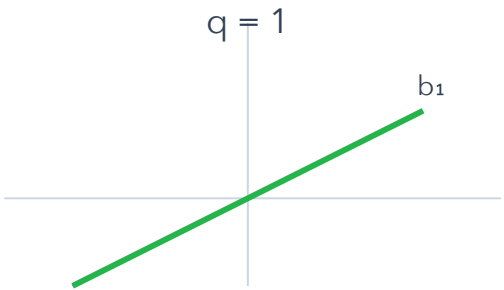
Utiliser ces q coefficients pour former une correction dans l'espace de sortie.

> Les deux branches reçoivent le même u ; on additionne leurs sorties.

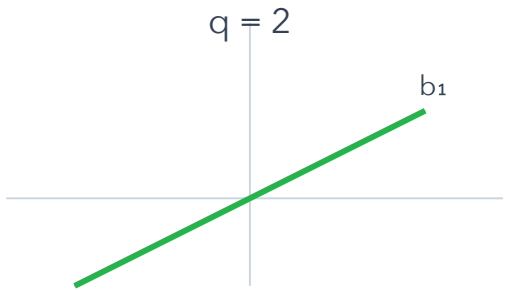
Hu et al. · LoRA · ICLR 2022 · §4

# Que contraint le « faible rang » ?

$$\Delta W = sBA = s\sum_{j=1}^{q} b_j a_j^\top, \qquad \Delta W u = s\sum_{j=1}^{q} b_j (a_j^\top u)$$




Une direction de correction




Jusqu'à deux directions indépendantes

## Lire une direction

Chaque ligne $a_j^\top$ extrait un scalaire de u.

## Écrire une direction

Chaque colonne $b_j$ fournit une direction de sortie.

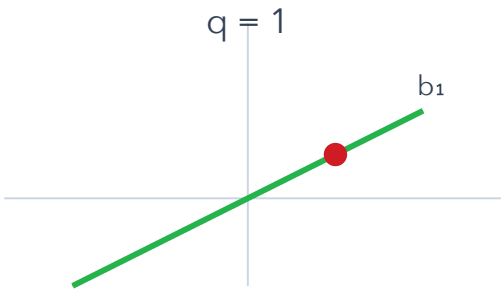
> rang(ΔW) ≤ q : toute correction appartient à span(b₁,…,bq). Ces directions sont elles-mêmes apprises.

La contrainte de rang porte sur ΔW. La matrice effective W₀ + ΔW peut rester de rang plein.

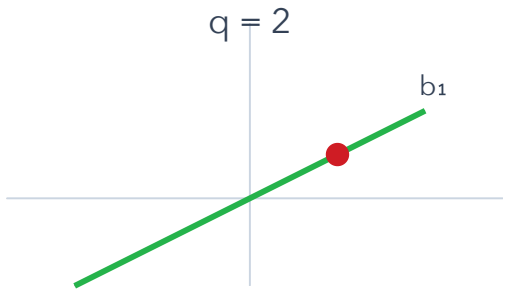
Hu et al. · LoRA · ICLR 2022 · §4

# Que contraint le « faible rang » ?

$$\Delta W = sBA = s\sum_{j=1}^{q} b_j a_j^\top, \qquad \Delta W u = s\sum_{j=1}^{q} b_j (a_j^\top u)$$




Une direction de correction




Jusqu'à deux directions indépendantes

## Lire une direction

Chaque ligne $a_j^\top$ extrait un scalaire de u.

## Écrire une direction

Chaque colonne $b_j$ fournit une direction de sortie.

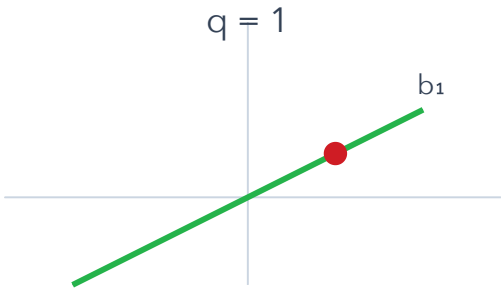
> rang(ΔW) ≤ q : toute correction appartient à span(b₁,…,bq). Ces directions sont elles-mêmes apprises.

La contrainte de rang porte sur ΔW. La matrice effective W₀ + ΔW peut rester de rang plein.

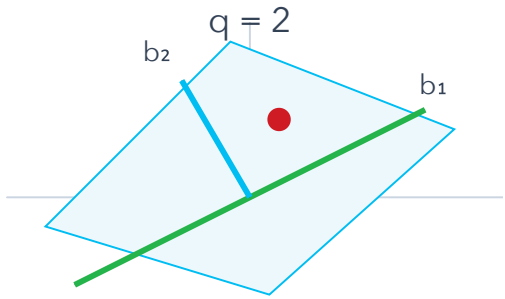
Hu et al. · LoRA · ICLR 2022 · §4

# Que contraint le « faible rang » ?

$$\Delta W = sBA = s\sum_{j=1}^{q} b_j a_j^\top, \qquad \Delta W u = s\sum_{j=1}^{q} b_j (a_j^\top u)$$




Une direction de correction




Jusqu'à deux directions indépendantes

## Lire une direction

Chaque ligne $a_j^\top$ extrait un scalaire de u.

## Écrire une direction

Chaque colonne $b_j$ fournit une direction de sortie.

> rang(ΔW) ≤ q : toute correction appartient à span(b₁,…,bq). Ces directions sont elles-mêmes apprises.

La contrainte de rang porte sur ΔW. La matrice effective W₀ + ΔW peut rester de rang plein.

Hu et al. · LoRA · ICLR 2022 · §4

# Combien de paramètres entraîne-t-on ?

**589 824**

Matrice entière 768 × 768

**12 288**

A + B avec q = 8

**48×**

Moins de paramètres entraînables

$$N_{\text{full}} = dk, \qquad N_{\text{LoRA}} = q(k+d), \qquad \frac{N_{\text{LoRA}}}{N_{\text{full}}} \approx 2.08\%$$

### q faible

Moins de stockage et d'états d'optimiseur ; corrections plus contraintes.

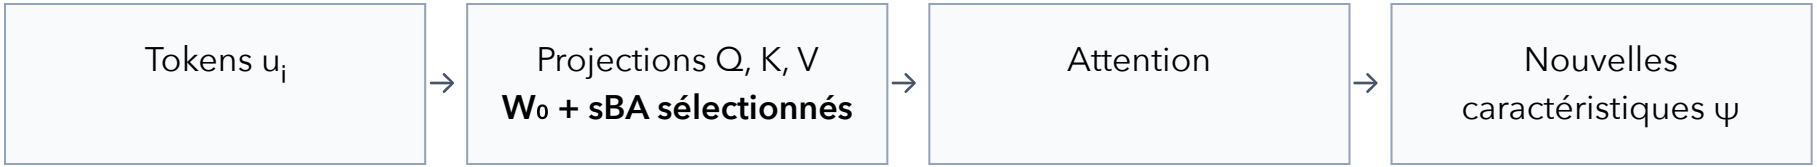
### q élevé

Plus de capacité et de coût

$W_0$ reste en mémoire. Les activations et la propagation des gradients dans l'encodeur ont encore un coût.

Hu et al. · LoRA · ICLR 2022 · §4

# Où LoRA agit-il dans un Transformer ?




$$Q_i = (W_{Q0} + sB_Q A_Q)u_i, \quad V_i = (W_{V0} + sB_V A_V)u_i, \quad K_i = W_{K0}u_i$$

## Changer Q

Modifier les tokens auxquels la représentation prête attention.

## Changer V

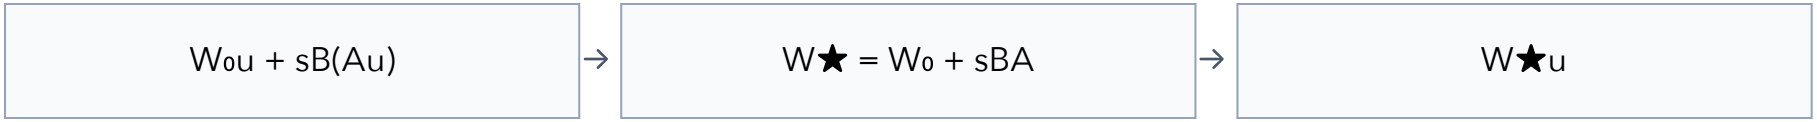
Modifier l'information portée par les tokens consultés.

L'article original étudie Q/V. Les matrices K, de sortie et des MLP sont aussi des cibles possibles.

Choisir couches, matrices, rang et échelle sur validation. Chaque matrice adaptée possède ses propres facteurs ; q désigne ici le rang.

Hu et al. · LoRA · ICLR 2022 · §4.2 · §7.1

# Au déploiement, intégrer la correction aux poids




## Avant intégration

Conserver une base et de petits adaptateurs par tâche ; changer d'adaptateur au besoin.

## Après intégration

Une multiplication matricielle ordinaire. Plus de branche LoRA pour cette tâche fixe.

$$(W_0 + sBA)u = W_0u + sB(Au)$$

On intègre une correction à ses propres poids de base. Combiner des modèles distincts ou plusieurs adaptateurs de tâches est un autre problème.

Hu et al. · LoRA · ICLR 2022 · §4

# Tête seule, LoRA ou ajustement complet ?

### Tête seule

Encodeur fixe. Entraînement peu coûteux ; cache possible si le prétraitement est fixe. Limité par la représentation disponible.

### LoRA + tête

Adapter les caractéristiques avec peu de paramètres. Rétropropager dans l'encodeur ; choisir rang et emplacements.

### Ajustement complet

Mises à jour plus libres. Plus de gradients et d'états d'optimiseur ; coût et risque de surapprentissage accrus.

Hu et al. · LoRA · ICLR 2022 · §4

# Tête seule, LoRA ou ajustement complet ?

### Tête seule

Encodeur fixe. Entraînement peu coûteux ; cache possible si le prétraitement est fixe. Limité par la représentation disponible.

### LoRA + tête

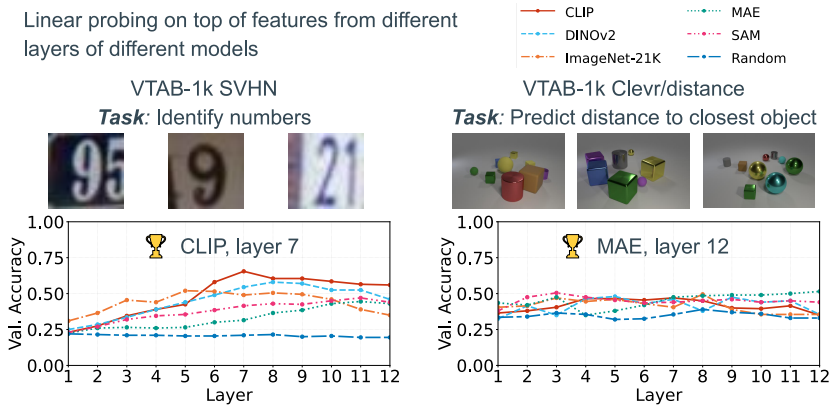
Adapter les caractéristiques avec peu de paramètres. Rétropropager dans l'encodeur ; choisir rang et emplacements.

### Ajustement complet

Mises à jour plus libres. Plus de gradients et d'états d'optimiseur ; coût et risque de surapprentissage accrus.

Hu et al. · LoRA · ICLR 2022 · §4

# Les caractéristiques utiles varient selon la couche




Chiffres : CLIP, couche 7

Distance : MAE, couche 12

## Un modèle gelé

Sa dernière couche n'est pas nécessairement la meilleure pour la nouvelle tâche.

## Plusieurs modèles gelés

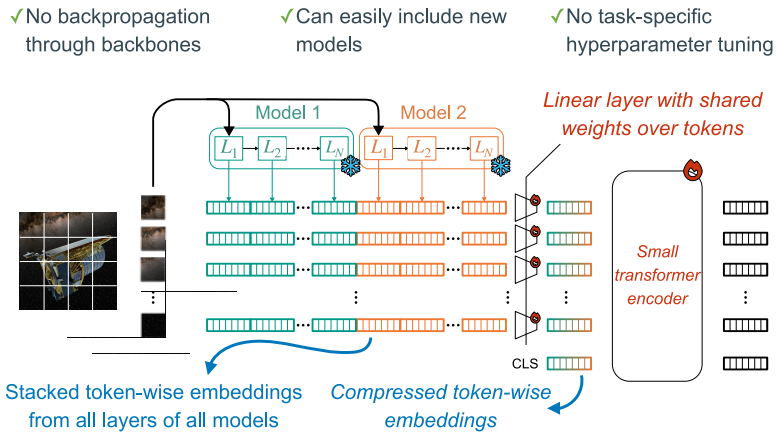
Des objectifs de préentraînement différents peuvent fournir des informations complémentaires.

> ComBo apprend à lire des caractéristiques intermédiaires d'un ou plusieurs encodeurs.

Figure originale du projet : précision de validation selon la couche. Le meilleur modèle et la meilleure couche diffèrent entre ces tâches.

Ramtoula et al. · ComBo · NeurIPS 2025 · page projet / project figure

# ComBo : combiner les caractéristiques de plusieurs encodeurs




Pour une tâche donnée (e.g. segmentation, traversabilité, etc), on entraîne un petit transformer qui combine les caractéristiques de plusieurs modèles à des couches différentes. Il en résulte un mélange de caractéristiques utiles spécifiques à la tâche.

> La fusion se fait dans l'espace des caractéristiques. Les encodeurs originaux restent distincts et gelés.

Ramtoula et al. · ComBo · NeurIPS 2025 · fig. 3 · §3

# Choisir où l'adaptation doit se faire

### Tête seule

Lire les caractéristiques finales gelées. Faible coût d'entraînement si elles suffisent déjà.

### LoRA

Changer les calculs internes d'un encodeur. Corrections compactes et branches linéaires intégrables.

### ComBo

Lire et combiner des caractéristiques intermédiaires de plusieurs modèles.

# Choisir où l'adaptation doit se faire

### Tête seule

Lire les caractéristiques finales gelées. Faible coût d'entraînement si elles suffisent déjà.

### LoRA

Changer les calculs internes d'un encodeur. Corrections compactes et branches linéaires intégrables.

### ComBo

Lire et combiner des caractéristiques intermédiaires de plusieurs modèles.

# Partitionner correctement les données robotiques

A · Apprentissage  V · Validation  E · Test / évaluation

Le temps avance →




Audit apprentissage/test · paires voisines : **18** · trajectoires communes : **6** · environnements communs : **3**

Des images voisines du même parcours traversent la frontière de test.

scikit-learn · évaluation groupée; regroupement robotique illustratif

# Partitionner correctement les données robotiques

A · Apprentissage  V · Validation  E · Test / évaluation

Le temps avance →




Audit apprentissage/test · paires voisines : **0** · trajectoires communes : **0** · environnements communs : **2**

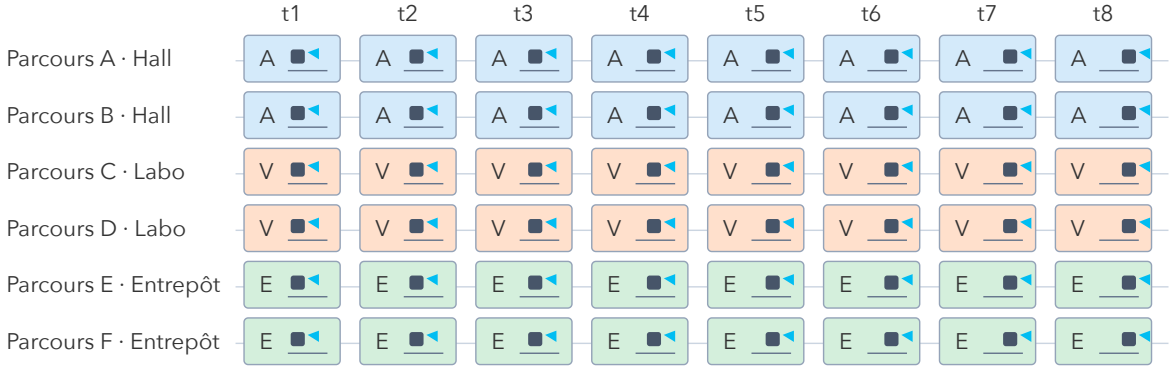
Parcours séparés, mais hall et laboratoire partagés entre apprentissage et test.

scikit-learn · évaluation groupée; regroupement robotique illustratif

# Partitionner correctement les données robotiques

A · Apprentissage  V · Validation  E · Test / évaluation

Le temps avance →




Audit apprentissage/test · paires voisines : **0** · trajectoires communes : **0** · environnements communs : **0**

Environnements séparés dans ces métadonnées; vérifier aussi les enregistrements.

Choisir la partition selon la généralisation : parcours, session, objet ou environnement.

scikit-learn · évaluation groupée; regroupement robotique illustratif

# Synthèse du cours

**Vues liées**

$\tilde{x}_1 \leftrightarrow \tilde{x}_2$

Transformation / temps

**Observations masquées**

$x_k \rightarrow$ cible $x_k$

Pixels retirés

**Self-Distillation**

$\mathrm{sg}(f_{\bar{\theta}}(x))$

Caractéristiques cibles

**Géométrie**

Profondeur + poses

Profondeur / paires visibles

**Mesures ultérieures**

$o \rightarrow \Gamma \rightarrow y$

Traversée / interaction

Sources de cibles alternatives, chacune avec sa règle et ses observations valides.




**Hypothèses du signal** Relations entre vues · représentation · visibilité · synchronisation · support de mesure

La cible automatique supervise; l'objectif façonne l'information conservée.

# Synthèse du cours

**Vues liées**

$\tilde{x}_1 \leftrightarrow \tilde{x}_2$

Transformation / temps

**Observations masquées**

$x_k \rightarrow$ cible $x_k$

Pixels retirés

**Self-Distillation**

$$\mathrm{sg}(f_{\bar{\theta}}(x))$$

Caractéristiques cibles

**Géométrie**

Profondeur + poses

Profondeur / paires visibles

**Mesures ultérieures**

$o \rightarrow \Gamma \rightarrow y$

Traversée / interaction

Sources de cibles alternatives, chacune avec sa règle et ses observations valides.



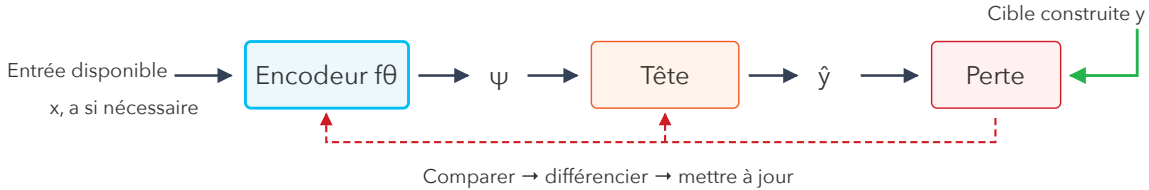

**Hypothèses du signal** Relations entre vues · représentation · visibilité · synchronisation · support de mesure

La cible automatique supervise; l'objectif façonne l'information conservée.

# Synthèse du cours

| Vues liées | Observations masquées | Self-Distillation | Géométrie | Mesures ultérieures |
|---|---|---|---|---|
| $\tilde{x}_1 \leftrightarrow \tilde{x}_2$ | $x_k \rightarrow$ cible $x_k$ | $\mathrm{sg}(f_{\bar{\theta}}(x))$ | Profondeur + poses | $o \rightarrow \Gamma \rightarrow y$ |
| Transformation / temps | Pixels retirés | Caractéristiques cibles | Profondeur / paires visibles | Traversée / interaction |

Sources de cibles alternatives, chacune avec sa règle et ses observations valides.




**Hypothèses du signal** Relations entre vues · représentation · visibilité · synchronisation · support de mesure

À retenir: Une même représentation peut être réutilisée pour plusieurs tâches.

SOURCES DU COURS

# Références

# Références : apprentissage de représentations


**SimCLR** A Simple Framework for Contrastive Learning of Visual Representations
T. Chen, S. Kornblith, M. Norouzi, G. Hinton. **ICML 2020.**

**DINO** Emerging Properties in Self-Supervised Vision Transformers
M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, A. Joulin. **ICCV 2021.**

**VICReg** VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning
A. Bardes, J. Ponce, Y. LeCun. **ICLR 2022.**

**MAE** Masked Autoencoders Are Scalable Vision Learners
K. He, X. Chen, S. Xie, Y. Li, P. Dollár, R. Girshick. **CVPR 2022.**

**I-JEPA** Self-Supervised Learning From Images With a Joint-Embedding Predictive Architecture
M. Assran, Q. Duval, I. Misra, P. Bojanowski, P. Vincent, M. Rabbat, Y. LeCun, N. Ballas. **CVPR 2023.**
Code officiel d'apprentissage: src/train.py


**Autres sources citées dans le cours**


**FixMatch** FixMatch: Simplifying Semi-Supervised Learning with Consistency and Confidence
K. Sohn, D. Berthelot, C.-L. Li, Z. Zhang, N. Carlini, E. D. Cubuk, A. Kurakin, H. Zhang, C. Raffel. **NeurIPS 2020.**

**NetVLAD** NetVLAD: CNN Architecture for Weakly Supervised Place Recognition
R. Arandjelović, P. Gronat, A. Torii, T. Pajdla, J. Sivic. **CVPR 2016.**

# Références : géométrie et correspondances

**Monodepth2**

Digging Into Self-Supervised Monocular Depth Estimation

C. Godard, O. Mac Aodha, M. Firman, G. Brostow. **ICCV 2019.**

Évaluateur officiel de profondeur: evaluate_depth.py · commit b017a81

**TCN**

Time-Contrastive Networks: Self-Supervised Learning from Video

P. Sermanet, C. Lynch, Y. Chebotar, J. Hsu, E. Jang, S. Schaal, S. Levine. **ICRA 2018.**

**Dense Object Nets**

Dense Object Nets: Learning Dense Visual Object Descriptors By and For Robotic Manipulation

P. R. Florence, L. Manuelli, R. Tedrake. **CoRL 2018.**

# Références : interaction et évaluation


**WVN**

Wild visual navigation: fast traversability learning via pre-trained models and online self-supervision

M. Mattamala, J. Frey, P. Libera, N. Chebrolu, G. Martius, C. Cadena, M. Hutter, M. Fallon.
**Autonomous Robots 49, article 19, 2025.**

**ActAIM**

Self-Supervised Learning of Action Affordances as Interaction Modes

L. Wang, N. Dvornik, R. Dubeau, M. Mittal, A. Garg. **ICRA 2023.**

**Source d'évaluation**

**Évaluation**

Cross-validation: evaluating estimator performance — grouped-data iterators

scikit-learn developers. **Documentation officielle · consultée le 7 octobre 2026.**

# Références : adaptation et fusion

**LoRA**

LoRA: Low-Rank Adaptation of Large Language Models

E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen. **ICLR 2022.**

**ComBo**

Fantastic Features and Where to Find Them: A Probing Method to combine Features from Multiple Foundation Models

B. Ramtoula, P.-Y. Lajoie, P. Newman, D. De Martini. **NeurIPS 2025.**

Projet et figures originales